

专题研讨:新质生产力赋能司法鉴定多场景应用

Special Topic Discussion: New Quality Productive Forces Empower Multi-Scenario Applications in Forensic Appraisal

人工智能合成语音与自然语音的对比研究

廖方菱¹, 陈蔓青¹, 陈胜湘¹, 郭宇航¹, 杨英仓¹, 牟帆²

(1. 贵州警察学院 刑事技术系, 贵州 贵阳 550005; 2. 贵阳市公安局刑侦支队, 贵州 贵阳 550000)

摘要: 目的 随着人工智能(artificial intelligence, AI)合成语音技术的快速发展,其在司法鉴定中的可检测性成为关键问题。通过听觉感知与声学量化双维度对比研究,系统分析AI合成语音与自然语音的差异特征,为司法实践中合成语音的识别、防范、检验和鉴定提供有效参考。方法 听觉检验采用李克特量表,对自然语音与合成语音的一致性进行评分;声学检验利用Praat语音分析软件提取基频、共振峰、音强、时长等特征参数,结合SPSS 27统计学分析软件进行成对样本 t 检验,量化自然语音与合成语音之间的差异性。结果 与自然语音相比,AI合成语音在听觉特征上表现为单音节完整性、儿化音特征、轻重音、语速、流畅度方面较差;声学检验中,基频与共振峰的统计学分析显示差异显著,而音强和时长的差异不显著。结论 司法鉴定中综合运用“人耳初筛”与声学量化双维度检验技术,可有效区分AI合成语音与自然语音,为相关合成语音的检验和鉴定提供技术支撑。

关键词: 人工智能;合成语音;自然语音;对比研究;司法鉴定

中图分类号: DF794.1 文献标志码: A doi: 10.3969/j.issn.1671-2072.2026.02.005

文章编号: 1671-2072-(2026)2-0038-08

Comparative Study of AI-Synthesized Speech and Natural Speech

LIAO Fangling¹, CHEN Manqing¹, CHEN Shengxiang¹, GUO Yuhan¹, YANG Yingcang¹, MU Fan²

(1. Department of Forensic Science and Technology, Guizhou Police College, Guiyang 550005, China;

2. Criminal Investigation Division, Guiyang Municipal Public Security Bureau, Guiyang 550000, China)

Abstract: **Objective** With the rapid development of artificial intelligence (AI)-synthesized speech technology, its detectability in forensic appraisal has become a key issue. This study systematically analyzes the differential features between AI-synthesized speech and natural speech through a two-dimensional comparative study of auditory perception and acoustic quantification, thereby providing an effective reference for the identification, prevention, inspection, and appraisal of synthesized speech in judicial practice. **Methods** In the auditory test, the Likert-type Scale was used to rate the consistency between natural speech and synthesized speech. Acoustic tests were conducted by extracting feature parameters such as fundamental frequency, formants, sound intensity, and duration using the Praat speech analysis software. Combined with SPSS 27 statistical analysis software, a paired-sample t -test was conducted to quantify the differences between natural speech and synthesized speech. **Results** Compared with natural speech, AI-synthesized speech exhibited poorer performance in terms of auditory features such as monosyllabic integrity, retroflex features, stress, speech rate, and fluency. Statistical analysis of the acoustic testing showed that there were significant differences in fundamental frequency and formants, while sound intensity and duration showed no significant differences. **Conclusion** The combined application of “human ear preliminary screening” and acoustic quantification two-dimensional testing techniques in forensic appraisal can effectively distinguish AI-synthesized speech from natural speech, providing technical support for the inspection and appraisal of AI-synthesized speech.

Keywords: artificial intelligence (AI); synthesized speech; natural speech; comparative study; forensic appraisal

收稿日期: 2025-04-24

基金项目: 2022年国家社会科学基金项目(22BYY083)。

作者简介: 廖方菱(2003—),女,主要从事刑事科学技术研究。E-mail: 2823172335@qq.com

通信作者: 杨英仓(1980—),女,教授,硕士,主要从事音频检验技术研究。E-mail: 864788442@qq.com

近年来,人工智能(artificial intelligence, AI)合成语音技术滥用引发的案件屡见不鲜。2019年,英国一家能源公司的首席执行官(chief executive officer, CEO)被不法分子合成的德国母公司CEO的声音电话诈骗,导致公司在一天内损失22万欧元^[1]。2024年,美国联邦通信委员会(Federal Communications Commission, FCC)在灵歌电信(Lingo Telecom)案中认定AI语音深度伪造自动拨号构成“欺诈性通信”,并依据《联邦通信法》对该企业处以100万美元罚款^[2]。国内类似案件同样频发,犯罪嫌疑人利用AI合成语音伪装身份,实施诈骗或虚假信息传播^[3-4]。2024年,全国首例“AI声音侵权案”宣判,原告获赔25万元^[5]。相关案件不仅造成直接经济损失,更严重威胁社会信任体系。在AI时代,声音权侵权的主要方式是利用AI技术合成语音,进而实施诈骗^[6]。虽然我国《民法典》在法律上明确了对声音权益的保护,但是如何鉴别语音的真伪成为一大难题。

以清华大学、北京大学、中国科学院计算所等为代表的国内高校及科研机构在深度学习框架的底层算法优化上取得显著成果, AI合成语音越来越接近自然语音。2021年,京东AI实验室发布了“京东流式语音合成技术”,能够实现更加自然流畅的语音合成效果,并具有较高的适应性和灵活性^[7]。百度Deep Voice 3全卷积语音合成系统,可以学习多个说话人的语音,且训练时间短、合成语音速度快^[8]。2024年,科大讯飞发布了基于其自主研发的深度学习框架和算法构建而成的星火语音大模型^[9]。DeepSeek开源和便于本地部署的特点,有效促进了科技强警^[10]。

任何技术的进步均伴随着“双刃剑”效应, AI合成语音的广泛应用在给人们带来便利的同时,也引发了一系列挑战。全国人大代表雷军在两会期间提出了加强“AI换脸拟声”治理的建议^[11]。精准区分AI合成语音与自然发音,确保信息的真实性与安全性,已成为音频检验技术领域的难点。ALBADAWY等^[12]通过双谱分析实验验证了多类分类的混淆矩阵,区分自然语音和合成语音,以及不同类型的合成语音。SINGH等^[13]研究出一种利用双频和倒谱分析来区分自然语音和AI合成语音的方法。WANG等^[14]提出构建一个检测器,通过监控语音合成系统中学习的神经元行为来识别合成语

音。江波翰等^[15]基于AI合成语音与人类语音的差异性,提出了参数鉴别的方法。王向阳等^[16]选取应用市场下载较多的11种语音合成软件进行研究,发现合成语音的过零率与基频一般小于正常语音,合成语音说话的节奏感偏弱,合成语音的声纹特征与正常语音存在较大差异。彭嘉俊等^[17]利用讯飞有声和阿里云智能云平台合成语音,研究表明,8 000 Hz频率以上合成语音因缺少噪声而呈空白状,正常语音因存在噪声而显示能量信息。王帅^[18]通过将微软TTS平台合成的18种语言的300个核心词的合成语音与自然语音进行对比,合成语音的整体音高均值相对偏低。冉启斌等^[19]的研究表明,合成语音在基音频率、振幅和噪音信号的周期性上具有更强的不规律性。陈子谦等^[20]使用讯飞有声语音合成软件合成语音,研究表明,合成语声和正常语声听觉相似度很高,但在儿化音特征上合成语声则和正常语声完全不同,过渡段形态特征和高次共振峰的频率值差异明显。张学海等^[21]通过收集两名AI虚拟主播及其各自原型的语音进行对比研究,合成语音在处理韵律问题上仍有待提高,听觉感知能发现缺乏情感和自然度、播报错误等问题,合成语音部分音节内的辅音-元音过渡段缺失,4 000 Hz以上的高频共振峰上差异明显。

尽管AI合成语音能够在一定程度上模仿人类的语言韵律和发音方式,但与自然语音相比,仍存在诸多可辨别的差异特征,有待深入研究。人体发音器官的生理差异,如声带的长短、厚薄,口腔、鼻腔的形状和共鸣特点,以及长期语言使用过程中形成的独特发音习惯,包括情感、语速、语调、连读、停顿等,共同造就了个体语音的稳定性和个体间的差异性,这些特征为识别说话者个体身份提供了重要依据。当前国内没有AI合成语音同一认定的技术标准, AI合成语音的稳定性、变异性、差异性和AI合成语音与自然语音的检验和鉴定,已成为司法鉴定领域亟待解决的关键问题。对AI合成语音与自然语音的对比分析,有助于推动相关技术标准与行业规范的制定,促进语音识别技术在刑事侦查、司法鉴定等领域的应用深化。同时,还能够增强对电信网络诈骗场景中AI合成语音的识别、预警与拦截能力,为公共安全治理智能化水平的系统性提升提供技术支撑。

1 实验设计

AI合成语音和自然语音的实验研究,主要聚焦于听觉感知和声学量化两个维度展开。听觉感知主要研究音强、音高、语速、轻重音、流畅度、变调特征、儿化音特征、发音标准度、清晰度和单音节完整性;声学量化主要研究基频、共振峰、音强和时长,这也是说话人识别研究的典型特征指标。

1.1 自然语音的录制

实验选取8名实验人员作为实验对象,4名男性和4名女性,年龄为20~22岁,身体健康、无生理疾病、无发音缺陷。8名实验人员均为贵州人,是在校大学生,其编号分别为:CSX(女)、LFL(女)、LGY(女)、LLY(女)、XHS(男)、SL(男)、LT(男)和FCC(男)。

录音对象在安静无噪声、无混响的录音室内,使用普通话进行录音。录音设备为爱国者录音笔(型号为R9977),录音文件均为“wav”格式,采样率为48 000 Hz,位深度为32位,双声道。录制内容为:“妈、麻、马、骂、衣、移、以、意、猫、毛、卯、帽、书、熟、暑、树。啊、喔、呃、一、乌、迂、摸、呢、了、日。马奶奶人很好,每年都让我、吴丽和李阿姨一起去买大米、鱼、零食和牛奶,拿来给蓝天幼儿园的小朋友们。先生,您好,我们来电联系您,是想问一下您有信用卡吗?最近您的公司收到不明来源的包裹。请告诉我,您的微信、银行卡账号是多少?还需要您对特定账号发出一次转账付款。犯罪分子常常虚构受害人亲属或朋友遭遇车祸,需要紧急处理交通事故为由,要求对方立即转账。今几个天儿真好,咱们公园儿走走,聊聊儿化音。瞧这小伙儿,精神儿倍儿棒,准能干大事儿。”每位实验对象重复念读3遍,本研究共得到24段自然语音。

1.2 AI合成语音的制作

实验选用GPT-SoVITS、讯飞星火、index-TTS、豆包和米可智能5种方式生成AI合成语音。8名实

验人员需要根据5种AI合成语音的操作提示录入自然语音,再由文本转语音的功能输出AI合成语音,每位实验人员每种合成语音各录3遍,本研究共得到120段AI合成语音。

1.3 软件分析

实验主要使用Praat语音分析软件、Adobe Audition音频编辑软件和SPSS 27统计学分析软件进行研究。

2 自然语音与AI合成语音的对比研究

2.1 听觉检验

2.1.1 检验方法

邀请10名具有相关声纹知识的听音人,分别对24段8名实验人员自然语音、120段5种AI合成语音的一致性进行打分测评。评分内容包括:音强、音高、语速、轻重音、流畅度、变调特征、儿化音特征、发音标准度、清晰度、单音节完整性10项指标。评分标准采用李克特量表(Likert-type Scale),按照李克特五级评分法进行打分^[22]。评分标准详见表1。

表1 听觉检验评分标准
Tab. 1 Scoring criteria for auditory testing

分数/分	自然语音与合成语音的相似度
1	完全不一致
2	多数部分不一致
3	不确定
4	多数部分一致
5	完全一致

2.1.2 检验结果

10名具有相关声纹知识的听音人分别对8名实验人员24段自然语音、120段5种AI合成语音进行听觉检验,再将表格按照合成语音的类型进行汇总(表2)。分值越低,说明合成语音与自然语音的差异越大。

表2 自然语音与5种AI合成语音对比的听觉检验结果
Tab. 2 Auditory test results of comparison between natural speech and five types of AI-synthesized speech

序号	评价指标	自然语音与5种AI合成语音的听觉对比分数/分					指标平均值/分
		GPT-SoVITS	讯飞星火	index-TTS	豆包	米可智能	
1	音强	3.84	3.41	4.28	3.28	3.91	3.74
2	音高	3.72	3.22	4.12	3.34	3.59	3.60
3	语速	3.50	3.41	3.79	3.31	3.47	3.50

续表 2

序号	评价指标	自然语音与 5 种 AI 合成语音的听觉对比分数/分					指标平均值/ 分
		GPT-SoVITS	讯飞星火	index-TTS	豆包	米可智能	
4	轻重音	3.47	3.50	3.76	3.38	3.31	3.48
5	流畅度	3.28	4.07	4.17	3.72	3.59	3.77
6	变调特征	3.22	3.54	4.13	3.25	3.56	3.54
7	儿化音特征	3.75	2.41	4.25	3.00	2.34	3.15
8	发音标准度	3.50	3.88	4.30	3.25	3.75	3.74
9	清晰度	3.41	3.80	4.37	3.31	3.69	3.72
10	单音节完整性	2.32	2.63	2.67	2.13	2.21	2.39

听觉检验结果显示,大部分得分小于4分,说明合成语音与自然语音存在可辨别的差异特征。5种AI合成语音在单音节完整性上均存在显著缺陷,这些差异为司法实践中识别AI合成语音提供了重要的听觉特征依据。5种AI合成语音均有漏字情况,例如自然语音为“啊、喔、呃”,合成语音为“啊、呃”。除index-TTS、讯飞星火外,其余合成语音会出现多字的情况,例如自然语音为“衣、移、以、意”,合成语音为“衣、移、以、意、意”。除index-TTS外,其余合成语音均存在错读的情况,例如自然语音为“猫、毛、卯、帽”,合成语音为“猫、毛、毛、帽”。豆包语音出现将“啊”错读成“呃”,米可智能出现将“卯”错读成“某”的情况。

index-TTS在语速(3.79分)和轻重音(3.76分)维度均为最高得分,但也低于4分,说明这5种AI合成语音在语速与轻重音方面与自然语音仍存在部分偏差。例如,实验人员LGY(女)的自然语音重读“告诉”,而5种AI合成语音中均没有体现。

在发音标准度方面。当自然语音存在前后鼻音(rén读成réng)、平翘舌音(sī读成shī)混淆时,GPT-SoVITS、讯飞星火、index-TTS和米可智能的合成语音均进行了校正。仅豆包合成语音没有对实验人员SL(男)的自然语音中的错误进行“纠正”。AI合成语音模型训练数据多为标准语音,算法以标准发音规则为基础进行构建,未充分融入多样化的发音特点。在汉语语音合成系统中,字音转换的任务就是在词典中检索当前词,配以对应的拼音,当输入序列中无相关发音信息时,很难在小样本条件下准确合成某一语音^[23]。

在流畅度方面。index-TTS(4.17分)和讯飞星火(4.07分)生成的语音虽接近自然语音,但仍存在一定的卡顿感,能感受到合成语音与自然语音在语

句衔接和断句上存在差异。一般而言:在语流中上声字在非上声前要变为半上,调值由214变为211;去声字在去声之前由全降变为半降,调值由51变为53;AI合成语音在语流表达中缺乏这些自然变化。GPT-SoVITS倾向于把每个字的调值发满,导致字与字之间缺乏流畅的衔接,从而在听感上产生一种字字分明、逐一蹦出的效果。

GPT-SoVITS的变调特征与自然语音相比有明显差异,实验人员LGY(女)的自然语音“妈、麻、马、骂”被读成“妈、麻、麻、麻、骂”,存在将三声、四声读成二声以及多读的问题,而自然语音不存在这些问题。实验人员LGY(女)的豆包合成语音将“妈、麻、马、骂”读成“妈、妈、妈、妈”,存在将二声、三声、四声读成一声的问题。豆包、讯飞星火、米可智能合成语音的儿化音还原效果较差,存在忽视儿化音或者直接读“儿”字的情况,这与陈子谦等^[20]的研究结果相似。

2.2 声学检验

2.2.1 基频检验

(1)数据提取。使用Praat语音分析软件,选取8名实验人员24段自然语音、120段5种AI合成语音中的“啊、喔、呃、一、乌、迂、摸、呢、了、日”,选定相对稳定部分进行标注,使用脚本批量提取实验语音10个音节的基频数据。

(2)数据分析。汇总8名实验人员10个音节的基频平均值,绘制自然语音与5种合成语音的基频走向对比图(图1)。由图1可知,自然语音与5种AI合成语音的10个音节的基频走向并不相同,GPT-SoVITS、index-TTS合成语音的基频有所降低,这与王向阳等^[16]的研究结果相似。讯飞星火、米可智能部分合成语音的基频有所升高,说明合成语音基频的变化规律并不明显。




图1 自然语音与5种AI合成语音的基频走向对比图
Fig. 1 Comparison of fundamental frequency (F0) between natural speech and five types of AI-synthesized speech

运用SPSS 27统计学数据处理软件对自然语音与5种AI合成语音的10个音节的基频数据进行成对样本 t 检验,显著性(P 值)小于0.05表示存在显

著性差异,结果详见表3。
按照相关方法^[24],分别统计表3中自然语音与5种AI合成语音各80个比较对中存在显著性差异的数量。由表3可知:GPT-SoVITS中具有显著性差异的 P 值共有68个,比例为85%;讯飞星火中具有显著性差异的 P 值共有71个,比例为89%;index-TTS中具有显著性差异的 P 值共有64个,比例为80%;豆包中具有显著性差异的 P 值共有60个,比例为75%;米可智能中具有显著性差异的 P 值共有63个,比例为79%。整体而言,表3中400个比较对中,自然语音与合成语音在基频上存在显著差异的比率为82%。

表3 自然语音与5种AI合成语音的基频成对样本 t 检验结果
Tab. 3 Paired-sample t -test results of fundamental frequency (F0) between natural speech and five types of AI-synthesized speech

实验人员	类别	P值									
		啊	喔	呃	一	乌	迂	模	呢	了	日
CSX(女)	自然语音-GPT-SoVITS	<0.01	0.02	<0.01	<0.01	<0.01	<0.01	0.48	<0.01	<0.01	0.03
	自然语音-讯飞星火	0.41	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.85
	自然语音-index-TTS	0.70	<0.01	<0.01	0.06	0.77	0.07	0.34	<0.01	<0.01	0.83
	自然语音-豆包	0.68	0.70	<0.01	0.11	<0.01	0.26	0.87	<0.01	<0.01	0.01
	自然语音-米可智能	0.01	0.45	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
LFL(女)	自然语音-GPT-SoVITS	0.01	<0.01	<0.01	<0.01	0.01	<0.01	<0.01	<0.01	<0.01	0.01
	自然语音-讯飞星火	0.13	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-index-TTS	<0.01	<0.01	<0.01	<0.01	<0.01	0.08	<0.01	<0.01	<0.01	<0.01
	自然语音-豆包	<0.01	0.03	0.21	0.85	<0.01	<0.01	<0.01	<0.01	0.16	<0.01
	自然语音-米可智能	0.06	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.27	0.67
LGY(女)	自然语音-GPT-SoVITS	<0.01	<0.01	<0.01	<0.01	0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-讯飞星火	<0.01	<0.01	<0.01	0.02	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-index-TTS	<0.01	<0.01	<0.01	0.07	<0.01	0.31	<0.01	<0.01	<0.01	0.49
	自然语音-豆包	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-米可智能	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
LLY(女)	自然语音-GPT-SoVITS	<0.01	<0.01	<0.01	<0.01	<0.01	0.95	<0.01	<0.01	<0.01	0.45
	自然语音-讯飞星火	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.04	<0.01	<0.01	<0.01
	自然语音-index-TTS	<0.01	0.27	<0.01	<0.01	<0.01	<0.01	0.67	<0.01	<0.01	0.04
	自然语音-豆包	<0.01	<0.01	0.9	0.05	0.96	<0.01	0.2	0.01	<0.01	0.90
	自然语音-米可智能	<0.01	<0.01	0.12	0.13	0.04	<0.01	0.08	0.08	<0.01	<0.01
XHS(男)	自然语音-GPT-SoVITS	<0.01	0.26	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-讯飞星火	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.04	<0.01	<0.01	<0.01
	自然语音-index-TTS	<0.01	<0.01	0.03	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.47
	自然语音-豆包	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.66	<0.01	<0.01
	自然语音-米可智能	0.59	0.14	0.64	0.02	<0.01	0.42	0.03	<0.01	0.02	0.45
SL(男)	自然语音-GPT-SoVITS	<0.01	0.92	0.62	<0.01	0.43	0.06	0.01	0.06	<0.01	<0.01
	自然语音-讯飞星火	<0.01	0.68	<0.01	<0.01	<0.01	<0.01	0.01	<0.01	<0.01	<0.01
	自然语音-index-TTS	<0.01	0.69	<0.01	<0.01	<0.01	<0.01	0.98	<0.01	<0.01	<0.01
	自然语音-豆包	<0.01	<0.01	<0.01	0.02	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-米可智能	<0.01	0.85	0.12	<0.01	<0.01	<0.01	<0.01	0.02	<0.01	0.36

续表 3

实验人员	类别	P值									
		啊	喔	呃	一	乌	迂	摸	呢	了	日
LT(男)	自然语音-GPT-SoVITS	0.17	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.02	0.05	0.91
	自然语音-讯飞星火	<0.01	<0.01	<0.01	0.90	0.41	0.09	0.03	0.16	<0.01	<0.01
	自然语音-index-TTS	<0.01	<0.01	<0.01	<0.01	0.70	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-豆包	<0.01	<0.01	0.94	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-米可智能	<0.01	<0.01	0.15	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
FCC(男)	自然语音-GPT-SoVITS	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-讯飞星火	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	0.15
	自然语音-index-TTS	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
	自然语音-豆包	<0.01	<0.01	<0.01	0.37	0.39	0.32	<0.01	0.67	0.26	<0.01
	自然语音-米可智能	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01	<0.01

2.2.2 共振峰检验

(1)数据提取。使用Praat 语音分析软件,选取8名实验人员24段自然语音、120段5种AI合成语音的“啊、喔、呃、一、乌、迂、摸、呢、了、日”10个音节,使用脚本提取前四条共振峰(F1、F2、F3、F4)数据。

(2)数据分析。整理8名实验人员24段自然语

音、120段5种AI合成语音的“啊、喔、呃、一、乌、迂、摸、呢、了、日”10个音节的前四条共振峰数据,取每个音节3次数据的平均值,将自然语音与5种AI合成语音两两对比并绘制成折线图,如图2所示。结果表明,自然语音与5种AI合成语音的共振峰均值相差较小。




图2 自然语音与5种AI合成语音共振峰数据对比图

Fig. 2 Comparison of formant data between natural speech and five types of AI-synthesized speech

共振峰平均值仅提取每个音节各次共振峰的平均数据,无法对共振峰的走向进行分析,不排除共振峰平均值相同但是走向截然相反的情况。整理8名实验人员24段自然语音、120段5种AI合成语音的10个音节的前四条共振峰数据,每个音节的每条共振峰各提取10个点位数据。运用SPSS 27统计学数据处理软件对自然语音与AI合成语音的前四条共振峰数据进行成对样本 t 检验。自然语音

与AI合成语音的前四条共振峰显著性差异结果见表4。因基频、共振峰、音强、时长数据整理的过程相似,为避免过于冗余,故后期共振峰、音强、时长部分省略了成对样本 t 检验的 P 值,只展示存在显著性差异的百分比。结果显示,自然语音和5种AI合成语音的共振峰F1、F2、F3和F4存在差异的比率分别为74%、72%、66%和66%。整体而言,共振峰的显著性差异为70%。

表4 自然语音与AI合成语音前四条共振峰显著性差异汇总表

Tab. 4 Summary of significant differences in the first four formants between natural speech and AI-synthesized speech

共振峰	自然语音与5种AI合成语音的共振峰显著性差异/%					平均值/%
	GPT-SoVITS	讯飞星火	index-TTS	豆包	米可智能	
F1	76	80	69	69	76	74
F2	68	74	74	68	75	72
F3	71	68	59	75	59	66
F4	60	73	53	70	74	66

2.2.3 音强检验

(1)数据提取。使用Praat语音分析软件,选取8名实验人员24段自然语音、120段5种AI合成语音的“啊、喔、呃、一、乌、迂、摸、呢、了、日”10个音节,使用脚本提取音强数据。

(2)数据分析。自然语音与5种AI合成语音的音强显著性差异结果见表5。结果表明,在音强数据分析中自然语音与AI合成语音的差异不显著,均未超过25.00%,平均值为8.75%。

表5 自然语音与AI合成语音音强显著性差异汇总表

Tab. 5 Summary of significant differences in sound intensity between natural speech and AI-synthesized speech

音强显著性差异结果	GPT-SoVITS	讯飞星火	index-TTS	豆包	米可智能	平均值/%
数值/%	2.50	25.00	3.75	10.00	2.50	8.75

2.2.4 时长检验

(1)数据提取。使用Praat语音分析软件,选取8名实验人员24段自然语音、120段5种AI合成语音中“啊、喔、呃、一、乌、迂、摸、呢、了、日”10个音节,使用脚本提取时长数据。

(2)数据分析。自然语音与AI合成语音的时长显著性差异结果见表6。结果表明,在时长数据分析中自然语音与AI合成语音的差异不显著,均未超过15%,平均值为6.25%。

表6 自然语音与AI合成语音时长显著性差异汇总表

Tab. 6 Summary of significant differences in duration between natural speech and AI-synthesized speech

时长显著性差异结果	GPT-SoVITS	讯飞星火	index-TTS	豆包	米可智能	平均值/%
数值/%	12.50	7.50	3.75	6.25	1.25	6.25

3 结果与讨论

3.1 结果

通过听觉感知与声学量化双维度对比,本研究系统分析了AI合成语音与自然语音的差异特征,为司法实践中合成语音的识别和检验提供参考。听觉检验结果表明,AI合成语音在单音节完

整性、儿化音特征、轻重音、语速、流畅度等方面与自然语音存在一定偏差。这些特征为司法鉴定中的“人耳初筛”提供了直接线索。声学检验结果表明,AI合成语音在基频和共振峰方面与自然语音存在统计学显著性差异,音强和时长的差异则不显著,为此类合成语音的司法鉴定提供一定的技术参考。

3.2 讨论

AI合成语音缺陷的技术根源可以从以下两个方面进行讨论:(1)人的语音受生理、心理与社会因素多层次交互作用,经过成千上亿次反复训练,形成了在语音共性基础上的个体差异性、变异性和稳定性。深度学习模型对人类发音器官及其运动轨迹模拟不足,尤其难以精确模拟由心理动态变化所导致的语音特征差异。(2)人类会根据语义动态调整语调,而AI模型多是依赖文本序列的局部特征预测韵律。汉语儿化音涉及韵母卷舌、鼻韵尾脱落等复杂音变(如本实验中的“今儿、天儿、园儿、伙儿、神儿、事儿”等),现有模型对语言规则的编码有限,很难覆盖所有变体。

人耳是最精密的听觉检验“设备”,听觉检验是声纹鉴定的重要内容^[25],但是截至目前国内没有一套标准的检验方法。将李克特五级评分法应用于听觉检验,不失为一种有效的解决策略。本研究结果为司法实践中AI合成语音检验提供了听觉-声学双维度鉴定依据,但样本量相对较小且研究对象群体单一,无法证明结果的普适性和跨群体的适用性,应加大实验对象研究样本量,并验证实验结果。针对AI合成语音带来的诸多挑战问题,后期可整合声学参数分析(增加基频、共振峰等)、语音动态特征建模(增加单音节完整性、儿化音特征等)及环境噪声检测技术,开发多模态智能检验系统,提升对合成语音的识别和检验能力。

当前,国内缺乏AI合成语音的同一性认定标准,亟需联合公安、司法及科研机构,制定覆盖声纹特征、稳定性检验及伪造溯源的标准化流程。同时,还应从源头限制合成语音的非法传播,构建“技术防御-司法鉴定-公众参与”的立体防控体系。

参考文献:

- [1] STUPP C. Fraudsters used AI to mimic CEO's voice in unusual cybercrime case[N]. The Wall Street Journal, 2019-08-30.
- [2] 张炎坤. AI语音合成技术在有声出版中的法律风险及其治理策略:域外经验与中国方案[J]. 出版科学, 2025, 33(3):27-38.
- [3] 马瑞萍. AI语音合成技术的应用和风险与声音权的保护研究[D]. 广州:暨南大学, 2021.
- [4] AI换声[J]. 方圆, 2025(1):8-9.
- [5] 北京互联网法院课题组. AI生成声音侵害声音权益的法律认定——以殷某某诉北京某智能科技公司等人人格权侵权案为例[J]. 法律适用, 2024(9):123-133.
- [6] 张天培, 苏滨. 以假乱真的AI诈骗, 如何防范?[N]. 人民日报, 2025-04-08(13).
- [7] 陈志业, 张智骞, 王兵, 等. AI语音合成技术的应用与展望[J]. 影视制作, 2023, 29(3):51-55.
- [8] 张小峰, 谢钧, 罗健欣, 等. 深度学习语音合成技术综述[J]. 计算机工程与应用, 2021, 57(9):50-59.
- [9] 科大讯飞发布首个全国算力平台成果“飞星一号”讯飞星火V_{3.5}[J]. 党史纵览, 2024(3):58.
- [10] 古嘉豪. 试论DeepSeek模型对基层公安民警工作效能的提升作用[J]. 公安教育, 2025(3):33-36.
- [11] 王俏. 全国人大代表雷军:加强“AI换脸拟声”治理 压实平台各方责任[N]. 人民法院报, 2025-03-05(5).
- [12] ALBADAWY E A, LYU S W, FARID H. Detecting AI-synthesized speech using bispectral analysis[EB/OL]. [2026-02-02]. <https://cse.buffalo.edu/~siweilyu/papers/cvprw19b.pdf>.
- [13] SINGH A K, SINGH P. Detection of AI-synthesized speech using cepstral & bispectral statistics[C]//Proceedings of the 2021 IEEE 4th International Conference on Multimedia Information Processing and Retrieval (MIPR). Washington, D.C., USA: IEEE Press, 2021:412-417.
- [14] WANG R, JUEFEI-XU F, HUANG Y H, et al. DeepSonar: Towards effective and robust detection of AI-synthesized fake voices[C]//Proceedings of the 28th ACM International Conference on Multimedia. Washington, D.C., USA: ACM Press, 2020:1207-1216.
- [15] 江波翰, 王新伟. 特征参数比对法在识别AI合成语音中的研究[J]. 信息与电脑(理论版), 2023, 35(24):174-177.
- [16] 王向阳, 孟利, 梁文静. 语音合成软件声纹特征的分析[J]. 警察技术, 2024(6):51-53.
- [17] 彭嘉俊, 陈海贤, 彭康盛, 等. 人工智能技术合成语音的鉴定特征研究[J]. 广东公安科技, 2024, 32(1):27-31.
- [18] 王帅. 合成语音与自然语音的音高差异——从18种语言核心词看合成语音的音高特点[J]. 天津外国语大学学报, 2024, 31(5):88-98.
- [19] 冉启斌, 黄玮. 合成语音与自然语音噪音的声学对比分析——以18种语言为例[J]. 天津外国语大学学报, 2024, 31(5):73-87.
- [20] 陈子谦, 王虹. 合成语音的语音同一认定研究[J]. 广东公安科技, 2021, 29(3):43-46.
- [21] 张学海, 杨璐铭. 合成语音的声纹鉴定分析——以两名AI虚拟主播语音为基础[J]. 中国司法鉴定, 2022(2):69-72.
- [22] LIKERT R. A technique for the measurement of attitudes[J]. Archives of Psychology, 1932, 22(140):55.
- [23] 牟科浩. 小样本及缺乏发音字典条件下的基于Taco-tron2的中国方言语音合成方法[D]. 北京:北京化工大学, 2023.
- [24] 张翠玲. 法庭语音技术研究[M]. 北京:中国社会科学出版社, 2009.
- [25] 杨英仓, 徐毓文, 欧荣安, 等. 听辨在声纹鉴定中的作用[J]. 刑事技术, 2012, 37(1):43-45.

(编辑:卢启萌;刘继娟)