

人工智能技术在文档解析中的应用综述

赵钰豪, 张仰森

(北京信息科技大学 计算机学院, 北京 100192)

摘要: 随着深度学习技术的发展, 尤其是基于Transformer的预训练模型的广泛应用, 文档解析逐步从传统规则方法演进为融合文本、视觉与布局信息的多模态系统。为了对后续研究提供理论参考与技术借鉴, 系统回顾了文档解析技术的演进脉络: 从早期基于规则的方法, 到基于深度学习的图像预处理、版面分析及信息抽取任务, 重点剖析了场景文本检测、表格理解等特定任务模型, 以及布局语言模型(layout language model, LayoutLM)系列通用预训练模型和基于大语言模型的最新探索。

关键词: 文档解析; 深度学习; 版面分析; 大语言模型

中图分类号: TP319

文献标志码: A

A review of applications of artificial intelligence technologies in document parsing

ZHAO Yuhao, ZHANG Yangsen

(College of Computer Science, Beijing Information Science & Technology University, Beijing 100192, China)

Abstract: With the advancement of deep learning technologies, particularly the widespread application of Transformer-based pre-trained models, document parsing has gradually evolved from traditional rule-based methods to multimodal systems integrating text, visual, and layout information. To provide theoretical reference and technical insights for subsequent research, the evolutionary trajectory of document parsing techniques was systematically reviewed, covering early-stage rule-based approaches, deep learning-based image preprocessing, layout analysis, and information extraction tasks. Specific task models such as scene text detection and table understanding, alongside general pre-trained models like the LayoutLM series and the latest explorations based on large language models, were further analyzed.

Keywords: document parsing; deep learning; layout analysis; large language models

0 引言

随着科技的迅猛发展, 人工智能技术不断突破传统边界, 其在文档结构解析与智能编辑等领域的应用也日益广泛, 尤其在格式结构校对、模板一致性检测等复杂场景中展现出极大的潜力和应用价值^[1]。

文档解析主要涉及对网页、数字文档以及扫描文档中的文本信息及其复杂排版结构进行识别、理解、分类、抽取和整合^[2-4]。由于文档在布局格式、语义结构等方面的高度异质化, 加之扫描图像质量不

一、模板结构复杂等现实问题, 文档解析任务面临诸多挑战^[5-6]。为了对后续研究提供理论参考与技术借鉴, 本文对国内外具有代表性的文档结构解析方法进行了系统梳理, 并对当前主流优化策略存在的问题与发展瓶颈进行了深入分析。

1 文档解析技术的发展

文档解析流程通常始于对原始文档图像的预处理, 旨在提升图像质量, 为后续内容分析和理解步骤奠定基础。研究者开发出一系列基于信号处理和图像分析的文档增强与校正技术。例如, Xue

等^[7]提出的基于傅里叶变换的文档复原方法在频域空间中提取图像的高频特征,可有效去除拍摄过程中产生的阴影等噪声干扰。在几何校正方面, Ma 等^[8]提出了一种融合强监督与弱监督的训练策略,利用自然场景下的文档图像来改善文档展平效果。这类预处理技术显著改善了后续文档识别、版面分析和内容理解等步骤的鲁棒性和准确性。

在核心的文档内容解析方法论上,技术发展经历了从规则方法到统计学习再到深度学习的演进过程。早期主要依赖基于人工经验总结的规则来分析和理解文档内容与结构。这类方法通常需要大量的人力来构建规则,而且所得到的规则扩展性较差^[9]。为了解决规则方法扩展性差的核心瓶颈,研究者逐渐转向基于统计学习的方法^[10]。进入统计学习阶段后,基于大量标注样本驱动模型逐渐占据主流。这些模型能够从数据中学习特征和模

式,泛化能力相比规则方法得到提升。

在深度学习框架下,文档解析技术通常使用可扩展标记语言(extensible markup language, XML)和便携式文档格式(portable document format, PDF)解析器等内容提取工具,结合光学字符识别(optical character recognition, OCR)技术对文本内容、版面信息和视觉图像进行结构化处理^[11],然后借助大规模预训练神经网络模型完成各类下游任务。尽管深度学习大幅提升了文档解析智能技术的准确度,但大规模预训练模型对输入文本长度存在固有限制,通常需要将长文档进行分段处理。这种处理方式往往无法充分捕捉文档整体的上下文与结构信息,从而影响理解精度与任务性能。因此,探索更加轻量化的模型架构、模型压缩与加速技术,已成为该领域的重要研究方向。文档解析技术各发展阶段的总结如表 1 所示。

表 1 文档解析技术的发展阶段
Table 1 Development stages of document parsing technologies

发展阶段	驱动方式	代表技术	优点	缺点	应用场景
规则方法	人工经验	词法分析、句法分析、语义分析	特定场景效果好,可解释性高,实现相对简单	人力成本高,泛化性、拓展性差,难以处理复杂布局和噪声	固定格式文档版面分析(如标准化表格)
统计学习	标注数据	支持向量机(support vector machine, SVM)、隐马尔可夫模型(hidden Markov model, HMM)	泛化性提升,减少人工规则成本	依赖高质量标注数据,特征工程较复杂,难以捕捉上下文信息	表单、票据等的信息提取,命名实体识别
深度学习	数据+预训练模型	布局语言模型(layout language model, LayoutLM)、快速区域卷积神经网络(faster region-based convolutional neural network, Faster R-CNN)	性能提升,处理复杂文档能力增强	依赖海量数据,计算成本高,模型可解释性差,存在输入长度限制	合同、科学文献等复杂文档结构理解,文档分类,表格检测与识别

2 主流文档解析任务

2.1 文档图像预处理

文档图像质量直接关系到后续版面分析和文本识别准确性,而图像质量又受到纸质文档自身形态、拍摄设备成像条件及角度等多种因素影响。早期研究主要围绕 2 类方法展开:一类是基于三维重建技术对文档进行几何校正,如 Brown 等^[12]提出了一个可行的 3D 数字化装置,用于将任意扭曲变形文档恢复到其原始平面形状,以改善后续文档分析;Meng 等^[13]利用页面表面和相机几何形状构建等距图像网格,以实现单张文档图像度量校正,以及通过基于凸包的图像重建来精确提取阴影图像,该方法在图像阴影校正和暗边去除方面表现出色^[14]。另一类则是基于二维图像处理的方法,如 Zhang 等^[15]尝试从单幅图像中估计文档形变并进行矫正。这些方法为后续更加

智能和自动化的图像校正研究打下了基础。

近年来,利用深度学习技术进行文档图像形变矫正已成为研究的主流方向。方法主要分为 2 大类:一类是基于预测密集形变场来进行校正,如 Das 等^[16]提出的 Dewarp Net 通过同时预测三维坐标图、形变场以及阴影图,能够实现更加精细的文档校正;而 Zhang 等^[17]则提出了一种名为 Marior 的文档去扭曲方法,用于解决自然场景中拍摄的文档图像存在的弯曲、褶皱和边缘干扰问题。该方法先进行边界消除、后对内容进行矫正。另一类则是通过预测稀疏控制点实现形变矫正。例如, Xie 等^[18]利用控制点和参考点之间的插值方法,将稀疏映射转化为后向映射,并将原始畸变文档图像重新映射到矫正后的图像上,可以矫正各种畸变类型的文档图像。

2.2 文档版面分析

文档版面分析总体上可分为物理版面分析和

逻辑版面分析。物理版面分析将文档视为一种特殊的目标检测任务,文档图像中的结构性元素,如标题、表格、图片等,均可被类比为需要识别与定位的目标。其中:基于目标检测的方法^[19-20]将页面分割任务建模为传统计算机视觉中的目标检测问题,在处理倾斜、弯曲等的文档区域时存在局限;基于实例分割的方法,如采用掩码区域卷积神经网络(Mask R-CNN)等实例分割框架,能够实现任意形状文档区域的像素级分割^[21-22]。基于图模型的分割方法则通过构建文档结构图的方式建模页面布局,例如,Riba等^[23]和高良才等^[24]在此方向做出了代表性的研究,展示了图结构对捕捉文档空间关系的优势。

逻辑版面分析更侧重于识别文本区域的语义类别,并确定各区域的阅读顺序。自上而下方法^[25-26]从整张表格图像出发,采用目标检测、语义分割或序列标注等方式识别行和列区域。此类方法依赖明确的行列结构,难以应对跨行跨列、空单元格较多等复杂表格。自下而上方法^[27]则从局部出发,先通过连通域分析、目标检测或OCR提取文本片段,再借助卷积网络、图神经网络或Transformer模型将属于同一单元格的片段合并,并判断它们之间的行列关系,结合视觉、语义和布局等多种特征

进行分类。随着近年来多个大规模、弱监督或自动标注的文档版面分析数据集如 TableBank^[28]、DocBank^[29]等相继发布,研究者得以在更贴近真实应用场景的数据上,对各类计算机视觉模型进行系统性评估与比较。基于这些数据集和方法论的进展,研究者提出了更先进的模型。例如,Li等^[30]提出的 MonkeyOCR 突破性地采用结构-识别-关系三元组范式,首先通过轻量化检测模型定位文档元素,再由多模态模型并行识别内容,最后通过关系网络重建逻辑顺序。该方法本质上属于自下而上的方法,但在流程设计和特征融合上进行了创新。在包含 390 万实例的 MonkeyDoc 数据集上进行评估时,MonkeyOCR 在中英文文档解析任务中的平均精度达到了显著提升,其性能优于该领域广泛使用的代表性基准模型 MinerU,平均精度提升了 5.1%。

主流的文档版面分析数据集如表 2 所示。表中, TEDS (tree edit distance similarity)、F1、BLEU-4 (bilingual evaluation understudy-4) 和 mAP (mean average precision) 是文档版面分析任务中常用的评价指标。其中, TEDS 主要用于评估表格结构还原精度, F1 和 mAP 适用于通用版面元素检测, BLEU-4 主要用于表格检测和内容提取。

表 2 主流文档版面分析数据集
Table 2 Mainstream document layout analysis datasets

数据集	语言	描述	标注类型	主要任务	基准模型性能	应用场景
TableBank ^[28]	中文、英文	基于 Word 和 Latex 文档的大型表格检测和识别数据集,通过弱监督方法创建,包含 41.7 万张高质量标注表格图像	表格区域边界框	表格检测	ResNeXt-152: Word 文档中 F1=0.916 6, Latex 文档中 F1=0.809 4	表格定位、代码转换
DocBank ^[29]	英文	通过弱监督构建的大规模多模态数据集,为文档版面分析提供了高可靠性基准	文本行、单词和字符的位置信息	文档布局分析	LayoutLM: F1=0.931 6; RoBERT: F1=0.889 1	OCR 增强、版面重建
PubTabNet ^[31]	英文	通过匹配 PubMed Central 开放获取子集 PMCOA 中科学文档的 XML 和 PDF 表示自动生成,是 ICDAR 2021 TaskB 表格识别任务使用的数据集	表格图像及其对应的结构化 HTML 表示	表格识别	EDD(encoder-decoder-decoder): TEDS=88.3%	金融分析、科学研究、统计学等领域的图像表格识别
TNCR ^[32]	英文	从公开免费网站收集,涵盖扫描文档图像(如 PDF 扫描件、摄影图像),包含不同光照、分辨率及背景噪声场景	表格区域+类型(线框/无框)	表格检测与分类	Cascade Mask R-CNN+ ResNeXt-101: F1=84.4%	档案数字化
TabLeX ^[33]	英文	包含从科学文档生成的表格图像的大规模基准数据集。该数据集有 2 个子集,分别用于表格结构提取和表格内容提取	单元格结构+内容	表格结构与内容联合提取	ResNet-101+Transformer: BLEU-4=81.35%	科学知识提取
IIIT-AR-13K ^[34]	多语言	用于商业文档中图形对象检测的数据集,来自不同公司、跨越多年度、使用多种语言编制的年度报告。包含 1.3 万张标注页面图像	图形对象边界框(表格、图表、段落等)	图形对象检测	Faster R-CNN: 鲁棒性不足,加入 DynamicHead 后 mAP 提升 11.18%	商业文档理解

3 针对特定任务的深度学习模型

3.1 基于深度学习的场景文本检测

相较于通用目标,场景中的文本通常表现出多方向分布、极端的纵横比以及多样化的形态特征。Zhang等^[35]提出了深度关系推理图(deep relational reasoning graph, DRRG),该方法通过回归方式直接获取文本单元及其关联对,并利用图神经网络建模各文本单元之间的关系,提升检测的结构合理性。针对传统四边形框难以贴合复杂文本轮廓的问题,Wang等^[36]提出了轮廓网络(ContourNet),该方法通过对文本边界在水平和垂直方向上进行解耦预测,显式刻画文本区域的多边形边界。为更有效地适配形态各异的场景文本,Liu等^[37]设计了自适应贝塞尔曲线网络(adaptive Bezier curve network, ABCNet),引入贝塞尔曲线进行文本轮廓拟合。为了进一步贴合高度不规则的文本形状,Zhu等^[38]提出了傅里叶轮廓嵌入网络(Fourier contour embedding network, FCENet),通过傅里叶曲线建模文本边界,有效增强了模型对复杂轮廓的适应能力。张庭瑞等^[39]提出一种基于多分支特征融合的自然场景文本检测算法,增强对小文本定位的准确性。为提升文本检测的效率并降低模型的整体复杂度,宋建辉等^[40]引入了轻量化的MobileNet V3作为局部特征提取模块,在有效减少参数量的同时保持了模型的表达能力。

3.2 基于深度学习的表格理解

表格的结构复杂、形式多样,因此表格理解被视为文档分析领域最具挑战性的子任务之一。表格理解通常包含2个核心阶段:表格检测与表格识别。其中,表格检测负责定位文档中的表格区域;表格识别则进一步解析表格内部结构。

在表格检测任务中,算法经历了从基于锚框(anchor-based)到无锚框(anchor-free)的发展^[41-42]。基于锚框的算法中:R-CNN算法首先生成候选区域,再用CNN提取特征进行分类与回归,精度高但速度慢;特征金字塔网络(feature pyramid network, FPN)通过自顶向下路径融合深层语义和浅层细节特征,显著提升小目标检测能力(如表格中的细线或小单元格);YOLO(you only look once)系列模型将检测视为单次网格回归问题,通过在

全局图像上直接预测边界框与类别标签,实现了极快的检测速度,但其早期版本存在小目标检测精度较低的问题;视网膜网络(RetinaNet)引入焦点损失函数(Focal Loss)解决正负样本不平衡问题,在保持速度优势的同时达到两阶段模型精度,尤其适合密集表格结构的检测。无锚框算法中:特征选择性无锚框(feature selective anchor-free, FSAF)算法动态学习多尺度特征的重要性权重,如FPN不同层级,优化目标表示,提升复杂表格的定位鲁棒性。

在表格识别任务中,传统基于规则的表格识别方法的识别效果在很大程度上依赖于人工经验和主观规则^[43-44]。随着人工智能技术特别是深度学习技术的发展,基于深度学习的表格识别技术也应运而生。主流算法主要包括:①基于语义分割的方法:表格检测与结构识别的深度学习方法(deep learning for detection and structure recognition of tables, DeepDeSRT)用双分支网络同步检测单元格并预测行列位置;TableNet^[45]也是此类方法的典型代表,其核心思想是通过图像分割的方式实现对表格结构的整体推理;级联表格检测网络(CascadeTabNet)^[46]在语义分割基础上引入了启发式规则,专门针对无边框表格的识别难点进行优化。②基于双向割并的方法:分割与合并(split and merge, SPLERGE)模型基于几何线检测重建拓扑,擅长识别残缺表格。③基于图神经网络融合的方法:TIES(trim elect sign)利用Transformer建模单元格序列关系,解决大跨度合并;基于图神经网络的金融表格提取(graph-based financial table extraction, GFTE)方法通过集成图像特征、位置特征和文本特征进行精确的边缘预测。④端到端的方法:TableMASTER融合多尺度特征并行解码内容与结构,高效处理大表格^[47]。⑤预训练增强的方法^[48]:表格解析(table parsing, TaPas)模型是较早将预训练机制应用于表格识别任务的代表性模型^[49],能够有效地捕捉表格中的语义与结构信息,在多个下游任务中展现出远超传统方法的性能表现,但其调参比较困难,且网络组装的灵活性较差^[50-51]。

表3对主流表格识别方法的优缺点和典型适用场景进行了对比。

表 3 主流表格识别方法对比
Table 3 Comparison of mainstream table recognition methods

技术类别	代表算法	核心优势	主要局限	典型适用场景
语义分割	DeepDeSRT, TableNet, CascadeTabNet	像素级结构解析, 擅长识别合并单元格	需要大量的标注数据, 计算慢	医疗、金融等领域的复杂表格
双向割并	SPLERGE	不依赖显式表格线, 抗图像扭曲/残缺能力强	容易受图像质量、噪声等干扰	手绘表格、扫描文档
融合图神经网络	TIES, GFTE	解决跨页结构	训练复杂(需关系标注), 推理延迟高	扭曲文档、跨页大表格
端到端	TableMASTER	内容与结构联合输出, 效率高	需海量标注数据, 超长表格易出错	Excel/HTML 结构化导出
预训练增强	TaPas	精度高	部署成本高, 速度慢	追求精度的研究项目

4 支持多种下游任务的通用预训练模型

4.1 基于布局感知预训练模型的方法

以上针对特定任务的深度学习方法通常都需要依赖有标记的数据,而文档中除了包含文本信息外,还蕴含大量视觉线索,如字体大小、斜体、加粗等样式特征,这些元素都有特定的语义含义^[52]。文档常常包含 3 种模态信息:文本、布局和视觉信息,因此如何达到跨模态对齐是一个值得研究的方向。为了充分利用文档所包含的信息,Xu 等^[53]提出了支持多种下游任务的通用预训练模型 LayoutLM,该模型是在标准 Transformer^[54]架构基础上添加了布局嵌入(layout embedding)层和图像嵌入(image embedding)层。其基本原理是通过 OCR 技术获取文本在文档中的位置信息,将对应坐标进行转换后,分别计算其在 x (水平位置)、 y (垂直位置)、 w (宽度)、 h (高度)这 4 个 Embedding 子层的特征表示,然后求和,以生成文本的综合布局嵌入表示。在视觉处理方面,模型将每个文本的边界框视为 Faster R-CNN 中的候选区域,提取相应的局部图像特征,再通过线性变换与文本特征对齐。这种设计实现了文本语义、空间布局和视觉特征的三维融合,为文档智能理解提供了全面的多模态表征能力。后续提出的 LayoutLMv2^[55]在 LayoutLM 的基础上引入了空间感知自注意力机制,进一步增强了视觉特征的融合能力。再后来的 LayoutXLM^[56]通过 53 种语言的预训练实现了对更多语言的支持。而 LayoutLMv3^[57]不再依赖复杂的 CNN 或 Faster R-CNN 网络来表征图像,而是直接利用文档图像的图像块进行表征,从而大幅减少了模型参数并避免了复杂的文档预处理,提升了整体效率。EPHOIE (examination paper head dataset for OCR and information extraction)是中文考试文档视觉信息抽

取数据集,包含页眉、题号、分数等实体。LayoutLMv3 在 EPHOIE 上的表现显著优于其他模型,以 99.21% 的平均 F1 值刷新了 SOTA (state-of-the-art)记录。

4.2 基于大模型的方法

近年来,以 ChatGPT(chat generative pre-trained Transformer)为代表的大语言模型展现出出色的泛化能力,然而这类模型缺乏直接解析文档图像中文本、布局和视觉信息的多模态理解能力。为了突破这一限制,部分研究致力于通过多模态预训练与任务微调的方法,增强语言模型对多模态数据的理解能力。通过引入文档图像中的视觉信息和布局坐标,模型能够更全面地建模图文之间的语义关联,从而提升其在文档理解等任务中的表现^[58-60]。文档大语言模型(document large language model, DocLLM)^[61]在现有大语言模型的架构基础上,引入了解耦注意力机制以有效建模文档中的布局结构信息。LayoutLLM^[62]借鉴了传统文档预训练模型的设计理念,以提升其在文档理解任务中的表现。该方法利用文档图像、文本信息以及布局坐标,通过文档预训练模型提取多模态特征,并将其对齐至统一的输入表示空间。对于参数规模较大的模型,训练所需的计算资源急剧增加,限制了其在如 GPT 等闭源商用大模型中的实际应用可行性。王文瑾等^[63]提出通过引入空格符与换行符,对文档图像中的文本进行格式化重构,从而在纯文本环境中近似模拟文本间的空间相对位置关系,构建具有布局感知能力的文本输入。在此基础上,针对不同下游任务设计相应的指令模板,以指令形式引导大语言模型生成符合任务需求的输出结果。

5 未来挑战

人工智能文档解析技术正迎来前所未有的发

展机遇,其演进将呈现多维度的深化趋势。该领域的核心挑战在于如何有效整合文本内容、布局结构和视觉信息这3种关键模态。当前研究重点正转向开发更精细的跨模态对齐机制,特别是针对大语言模型在图像处理方面的局限性,研究者致力于构建性能更优、资源消耗更低的多模态架构体系。

在技术实现层面,数据效率的提升尤为关键。通过创新性的数据增强策略和自监督学习范式,新一代系统将显著提升在数据稀缺场景下的适应能力。然而,该领域仍面临若干关键挑战:跨页信息的连贯建模、训练数据的质量优化、多任务间的协同机制构建,以及在极端数据条件下的模型泛化能力提升。

值得关注的是,人机协同将成为技术落地的重要突破口。通过融合专家知识规则与深度学习模型,构建具有可解释性的交互系统,不仅能提升处理结果的可靠性,更能促进技术在法律文书分析、医疗报告处理等专业场景的深度应用。可视化分析工具和决策追溯机制的完善,将进一步增强用户对智能文档处理系统的信任度。

6 结束语

本文系统梳理了人工智能技术在文档解析领域的技术演进与应用实践,展现了从早期基于规则的方法到当前融合多模态信息的智能化系统的完整发展脉络。随着以Transformer架构为核心的预训练模型兴起,文档解析技术已突破传统OCR的文本识别局限,逐步形成了整合文本语义、视觉特征与空间布局的综合性技术体系。特别是LayoutLM系列模型通过创新的跨模态对齐机制,在发票识别、表格重建等实际场景中展现出显著优势;而大语言模型与文档图像的结合,则为构建更通用的文档智能系统提供了新的可能性。这些技术进步不仅提升了金融票据处理、法律文书分析等专业场景的自动化水平,也为教育评估、医疗报告等垂直领域的数字化转型提供了技术支撑。当前技术发展已证明,深度融合文本内容理解与视觉空间感知的多模态方法,是解决文档结构异质性问题的有效路径。随着计算效率优化和模型轻量化技术的持续发展,人工智能必将为文档处理领域带来更智能、更高效的解决方案。

参考文献:

[1] 金皓月,李艳.国内人工智能写作的研究现状分析及启示

[J].现代远程教育,2023(2):19-29.

JIN H Y, LI Y. Analysis and enlightenment of the current research status of artificial intelligence (AI) writing in China [J]. Modern Distance Education, 2023(2):19-29. (in Chinese)

[2] 张帆.权威与角色:智媒时代的新闻职业话语研究[J].湖北大学学报(哲学社会科学版),2021,48(4):140-147.

ZHANG F. Authority and role switching: study of professional journalism discourse in smart media age [J]. Journal of Hubei University (Philosophy and Social Sciences), 2021, 48(4):140-147. (in Chinese)

[3] 左阔,李宁,田英爱,等.流式文档排版效果自动化测试方法[J].计算机工程与应用,2021,57(2):273-278.

ZUO K, LI N, TIAN Y A, et al. Automatic testing method for typesetting effect of reflowable document [J]. Computer Engineering and Applications, 2021, 57(2):273-278. (in Chinese)

[4] 纳利军.基于Open XML的毕业论文格式修订系统的设计与实现[J].电脑知识与技术,2022,18(9):41-43.

NA L J. Design and implementation of a thesis format revision system based on Open XML [J]. Computer Knowledge and Technology, 2022, 18(9):41-43. (in Chinese)

[5] 李雪晴,王石,王朱君,等.自然语言生成综述[J].计算机应用,2021,41(5):1227-1235.

LI X Q, WANG S, WANG Z J, et al. Summarization of natural language generation [J]. Journal of Computer Applications, 2021, 41(5):1227-1235. (in Chinese)

[6] 刘泽刚.论算法认知偏差对人工智能法律规制的负面影响及其矫正[J].政治与法律,2022(11):50-65.

LIU Z G. On the negative impacts of cognitive biases of algorithm on the legal regulation of artificial intelligence and its correction [J]. Political Science and Law, 2022(11):50-65. (in Chinese)

[7] XUE C H, TIAN Z C, ZHAN F N, et al. Fourier document restoration for robust document dewarping and recognition [C]// 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos, CA, USA: IEEE Computer Society, 2022:4563-4572.

[8] MA K, DAS S, SHU Z X, et al. Learning from documents in the wild to improve document unwarping [C]//ACM SIGGRAPH 2022 Conference Proceedings. New York, USA: Association for Computing Machinery, 2022:1-9.

[9] 刘成林,金连文,白翔,等.文档智能分析与识别前沿:回顾与展望[J].中国图象图形学报,2023,28(8):2223-2252.

LIU C L, JIN L W, BAI X, et al. Frontiers of intelligent document analysis and recognition: review and prospects [J]. Journal of Image and Graphics, 2023, 28(8):2223-2252. (in Chinese)

[10] CHOW C K. An optimum character recognition system using decision functions [J]. IRE Transactions on Electronic Computers, 1957, EC-6(4):247-254.

[11] 刘崇宇,陈晓雪,罗灿杰,等.自然场景文本检测与识别的深度学习方法[J].中国图象图形学报,2021,26(6):1330-

- 1367.
- LIU C Y, CHEN X X, LUO C J, et al. Deep learning methods for scene text detection and recognition [J]. *Journal of Image and Graphics*, 2021, 26(6): 1330–1367. (in Chinese)
- [12] BROWN M S, SEALES W B. Document restoration using 3D shape: a general deskewing algorithm for arbitrarily warped documents [C]//*Proceedings of the 8th IEEE International Conference on Computer Vision*. New York, USA: IEEE, 2001: 367–374.
- [13] MENG G F, PAN C H, XIANG S M, et al. Metric rectification of curved document images [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012, 34(4): 707–722.
- [14] MENG G F, XIANG S M, ZHENG N N, et al. Nonparametric illumination correction for scanned document images via convex hulls [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2013, 35(7): 1730–1743.
- [15] ZHANG L, ZHANG Y, TAN C. An improved physically-based method for geometric restoration of distorted document images [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2008, 30(4): 728–734.
- [16] DAS S, MA K, SHU Z X, et al. DewarpNet: single-image document unwarping with stacked 3D and 2D regression networks [C]//*Proceedings of 2019 IEEE/CVF International Conference on Computer Vision*. New York, USA: IEEE, 2019: 131–140.
- [17] ZHANG J X, LUO C J, JIN L W, et al. Marior: margin removal and iterative content rectification for document dewarping in the wild [C]//*Proceedings of the 30th ACM International Conference on Multimedia*. New York, USA: Association for Computing Machinery, 2022: 2805–2815.
- [18] XIE G W, YIN F, ZHANG X Y, et al. Document dewarping with control points [C]//*Document Analysis and Recognition-ICDAR 2021*. Berlin, Germany: Springer-Verlag Berlin, 2021, 12821: 466–480.
- [19] GAO L C, YI X H, JIANG Z R, et al. ICDAR2017 competition on page object detection [C]//*2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*. Los Alamitos, CA, USA: IEEE Computer Society, 2017: 1417–1422.
- [20] ZHONG X, TANG J B, JIMENO YEPES A. PubLayNet: largest dataset ever for document layout analysis [C]//*2019 International Conference on Document Analysis and Recognition (ICDAR)*. Los Alamitos, CA, USA: IEEE Computer Society, 2019: 1015–1022.
- [21] RENTON G, SOULLARD Y, CHATELAIN C, et al. Fully convolutional network with dilated convolutions for handwritten text line segmentation [J]. *International Journal on Document Analysis and Recognition*, 2018, 21(3): 177–186.
- [22] LI X H, YIN F, XUE T, et al. Instance aware document image segmentation using label pyramid networks and deep watershed transformation [C]//*2019 International Conference on Document Analysis and Recognition (ICDAR)* Los Alamitos, CA, USA: IEEE Computer Society, 2019: 514–519.
- [23] RIBA P, DUTTA A, GOLDMANN L, et al. Table detection in invoice documents by graph neural networks [C]//*Proceedings of the 15th International Conference on Document Analysis and Recognition*. Los Alamitos, CA, USA: IEEE Computer Society, 2019: 122–127.
- [24] 高良才, 李一博, 都林, 等. 表格识别技术研究进展 [J]. *中国图象图形学报*, 2022, 27(6): 1898–1917.
- GAO L C, LI Y B, DU L, et al. A survey on table recognition technology [J]. *Journal of Image and Graphics*, 2022, 27(6): 1898–1917. (in Chinese)
- [25] SIDDIQUI S A, FATEH I A, RIZVI S T R, et al. DeepTabStR: deep learning based table structure recognition [C]//*Proceedings of the 15th International Conference on Document Analysis and Recognition*. Los Alamitos, CA, USA: IEEE Computer Society, 2019: 1403–1409.
- [26] LI Y B, HUANG Y L, ZHU Z Y, et al. Rethinking table structure recognition using sequence labeling methods [C]//*Proceedings of the 16th International Conference on Document Analysis and Recognition*. Berlin, Germany: Springer-Verlag Berlin, 2021: 541–553.
- [27] LI X H, YIN F, DAI H S, et al. Table structure recognition and form parsing by end-to-end object detection and relation parsing [J]. *Pattern Recognition*, 2022, 132: 108946.
- [28] LI M H, CUI L, HUANG S H, et al. TableBank: table benchmark for image-based table detection and recognition [C]//*Proceedings of the 12th Language Resources and Evaluation Conference*. Paris, France: European Language Resources Association, 2020: 1918–1925.
- [29] LI M H, XU Y H, CUI L, et al. DocBank: a benchmark dataset for document layout analysis [EB/OL]. (2020-11-11) [2025-06-28]. <https://doi.org/10.48550/arXiv.2006.01038>.
- [30] LI Z, LIU Y L, LIU Q, et al. MonkeyOCR: document parsing with a structure-recognition-relation triplet paradigm [EB/OL]. (2025-06-05) [2025-07-15]. <https://doi.org/10.48550/arXiv.2506.05218>.
- [31] ZHONG X, SHAFIEIBAVANI E, JIMENO Y A. Image-based table recognition: data, model, and evaluation [C]//*Computer Vision-ECCV 2020*. Cham, Switzerland: Springer International Publishing AG, 2020, 12366: 564–580.
- [32] ABDALLAH A, BERENDEYEV A, NURADIN I, et al. TNCR: table net detection and classification dataset [J]. *Neurocomputing*, 2022, 473: 79–97.
- [33] DESAI H, KAYAL P, SINGH M. TabLeX: a benchmark dataset for structure and content information extraction from scientific tables [C]//*Document Analysis and Recognition-ICDAR 2021*. Berlin, Germany: Springer-Verlag Berlin, 2021, 12822: 554–569.
- [34] MONDAL A, LIPPS P, JAWAHAR C V. IIIT-AR-13K: a new dataset for graphical object detection in documents [C]//*Document Analysis Systems*. Berlin, Germany: Springer-Verlag

- Berlin, 2020, 12116: 216–230.
- [35] ZHANG S X, ZHU X B, HOU J B, et al. Deep relational reasoning graph network for arbitrary shape text detection [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Los Alamitos, CA, USA: IEEE Computer Society, 2020: 9696–9705.
- [36] WANG Y X, XIE H T, ZHA Z J, et al. ContourNet: taking a further step toward accurate arbitrary-shaped scene text detection [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Los Alamitos, CA, USA: IEEE Computer Society, 2020: 11750–11759.
- [37] LIU Y L, SHEN C H, JIN L W, et al. ABCNet v2: adaptive Bezier-curve network for real-time end-to-end text spotting [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(11): 8048–8064.
- [38] ZHU Y Q, CHEN J Y, LIANG L Y, et al. Fourier contour embedding for arbitrary-shaped text detection [C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Fourier contour embedding for arbitrary-shaped text detection, 2021: 3122–3130.
- [39] 张庭瑞, 方承志, 徐国钦, 等. 基于多分支特征融合的自然场景文本检测算法 [J]. 计算机技术与发展, 2024, 34(2): 142–147.
- ZHANG T R, FANG C Z, XU G Q, et al. Natural scene text detection algorithm based on multi-branch feature fusion [J]. Computer Technology and Development, 2024, 34(2): 142–147. (in Chinese)
- [40] 宋建辉, 佟悦, 刘晓阳, 等. 改进特征提取模块的场景文本检测方法 [J]. 通信与信息技术, 2024: 96–100.
- SONG J H, TONG Y, LIU X Y, et al. Improve feature extraction module scene text detection method [J]. Communication & Information Technology, 2024(1): 96–100. (in Chinese)
- [41] TIAN Z, SHEN C H, CHEN H, et al. FCOS: a simple and strong anchor-free object detector [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(4): 1922–1933.
- [42] KONG T, SUN F C, LIU H P, et al. FoveaBox: beyond anchor-based object detection [J]. IEEE Transactions on Image Processing, 2020, 29: 7389–7398.
- [43] 雷寰宇. 基于图像的表格识别问题研究 [J]. 科技视界, 2021(13): 32–34.
- LEI H Y. Research on image-based table recognition [J]. Science & Technology Vision, 2021(13): 32–34. (in Chinese)
- [44] 秦振海, 谭守标, 徐超. 基于Web的表格信息抽取研究 [J]. 计算机技术与发展, 2010, 20(2): 217–220.
- QIN Z H, TAN S B, XU C. Study on tables information extraction based on web [J]. Computer Technology and Development, 2010, 20(2): 217–220. (in Chinese)
- [45] PALIWAL S, RAHUL R, SHARMA M, et al. TableNet: deep learning model for end-to-end table detection and tabular data extraction from scanned document images [EB/OL]. (2020-01-06) [2025-06-28]. <https://doi.org/10.48550/arXiv.2001.01469>, 2020: 01469.
- [46] PRASAD D, GADPAL A, KAPADNI K, et al. CascadeTabNet: an approach for end to end table detection and structure recognition from image-based documents [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Los Alamitos, CA, USA: IEEE Computer Society, 2020: 2439–2447.
- [47] RAMAN N, SHAH S, VELOSO M. Synthetic document generator for annotation-free layout recognition [J]. Pattern Recognition, 2022, 128: 108660.
- [48] 田翠华, 张一平, 胡志钢, 等. PDF文档表格信息的识别与提取 [J]. 厦门理工学院学报, 2020, 28(3): 70–76.
- TIAN C H, ZHANG Y P, HU Z G, et al. Recognition and extraction of table information from PDF documents [J]. Journal of Xiamen University of Technology, 2020, 28(3): 70–76. (in Chinese)
- [49] HERZIG J, NOWAK P K, MÜLLER T, et al. TaPas: weakly supervised table parsing via pre-training [EB/OL]. (2020-04-21) [2025-06-28]. <https://doi.org/10.48550/arXiv.2004.02349>.
- [50] 梁天恺, 苏新铎, 黄宇恒, 等. 智能化表格识别技术综述 [J]. 计算机工程与应用, 2023, 59(12): 62–76.
- LIANG T K, SU X D, HUANG Y H, et al. Survey on intelligent table recognition [J]. Computer Engineering and Applications, 2023, 59(12): 62–76. (in Chinese)
- [51] SCHREIBER S, AGNE S, WOLF I, et al. DeepDeSRT: deep learning for detection and structure recognition of tables in document images [C]//2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR). New York, USA: IEEE, 2017: 1162–1167.
- [52] 袁鸿雁. 基于本体的Web表格信息抽取技术的研究 [J]. 青岛大学学报(自然科学版), 2010, 23(2): 47–51.
- YUAN H Y. Study on information extraction technique with web tables based on ontology [J]. Journal of Qingdao University (Natural Science Edition), 2010, 23(2): 47–51. (in Chinese)
- [53] XU Y H, LI M H, CUI L, et al. LayoutLM: pre-training of text and layout for document image understanding [C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, USA: Association for Computing Machinery, 2020: 1192–1200.
- [54] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. La Jolla, CA, USA: Neural Information Processing Systems (NIPS), 2017, 30: 6000–6010.
- [55] XU Y, XU Y H, LÜ T C, et al. LayoutLMv2: multi-modal pre-training for visually-rich document understanding [C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Stroudsburg, PA, USA: Association for Computational Linguistics, 2021: 2579–2591.
- [56] XU Y H, LÜ T C, CUI L, et al. LayoutXLM: multimodal pre-training for multilingual visually-rich document understanding

- [EB/OL]. (2021-09-09) [2025-06-28]. <https://doi.org/10.48550/arXiv.2104.08836>.
- [57] HUANG Y P, LÜ T C, CUI L, et al. LayoutLMv3: pre-training for document AI with unified text and image masking [C]// Proceedings of the 30th ACM international conference on multimedia. New York, USA: Association for Computing Machinery, 2022:4083-4091.
- [58] YE Q H, XU H Y, XU G H, et al. Mplug-owl: modularization empowers large language models with multimodality [EB/OL]. (2024-03-29) [2025-06-28]. <https://doi.org/10.48550/arXiv.2304.14178>.
- [59] YE J B, HU A W, XU H Y, et al. Ureader: universal OCR-free visually-situated language understanding with multimodal large language model [EB/OL]. (2023-10-08) [2025-06-28]. <https://doi.org/10.48550/arXiv.2310.05126>.
- [60] ZHANG Y Z, ZHANG R R, GU J X, et al. Llavar: enhanced visual instruction tuning for text-rich image understanding [EB/OL]. (2024-02-02) [2025-06-28]. <https://doi.org/10.48550/arXiv.2306.17107>.
- [61] WANG D S, RAMAN N, SIBUE M, et al. DocLLM: a layout-aware generative language model for multimodal document understanding [EB/OL]. (2023-12-31) [2025-06-28]. <https://doi.org/10.48550/arXiv.2401.00908>.
- [62] LUO C W, SHEN Y F, ZHU Z Q, et al. LayoutLLM: layout instruction tuning with large language models for document understanding [C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos, CA, USA: IEEE Computer Society, 2024:15630-15640.
- [63] 王文瑾,李昀昊,张寅. 大语言模型文档图像智能问答指令设计与微调方法实证研究[J]. 数字图书馆论坛, 2025, 21(1): 11-21.
- WANG W J, LI Y H, ZHANG Y. Empirical research on instruction design and fine-tuning methods for large language models in document image intelligent question answering [J]. Digital Library Forum, 2025, 21(1): 11-21. (in Chinese)