



基于 LLM 与 Transformer 机制的网络安全 防御技术与应用研究

杨伟青, 周 游, 张婉澂, 陈 阳

(中国铁路上海局集团有限公司 信息技术所, 上海 200071)

摘 要: 针对现有技术存在的网络攻击类别检测性能差、网络安全防御性能低等问题, 开展基于大语言模型 (LLM, Large Language Model) 与 Transformer 机制的网络安全防御技术与应用研究。引入 LLM 与 Transformer 机制构建网络安全防御模型, 采用 LLM 对构建模型训练数据进行采集与预处理; 基于 Transformer 机制建立训练数据与网络攻击类别的映射关系, 完成构建模型的预训练; 以损失函数为依据, 微调处理构建模型参数; 根据构建模型预训练结果与构建模型参数微调结果, 确定网络攻击类别, 实现对网络攻击类别的有效检测与防御。实验结果表明, 该技术的网络攻击类别检测效果优于对比技术, F1 分数最大值可达 0.9。

关键词: Transformer 机制; 网络安全防御; 训练语料采集与预处理; 大语言模型 (LLM); 网络攻击检测

中图分类号: U29 : U285.41 : TP393 **文献标识码:** A **DOI:** 10.3969/j.issn.1005-8451.2025.10.07

Network security defense technology and application based on LLM and Transformer mechanism

YANG Weiqing, ZHOU You, ZHANG Wancheng, CHEN Yang

(Institute of Information Technology, China Railway Shanghai Group Co. Ltd., Shanghai 200071, China)

Abstract: This paper focused on the problems of poor network attack category detection performance and low network security defense performance in existing technologies, and conducted research on network security defense technology and applications based on Large Language Model (LLM) and Transformer mechanism. It introduced LLM and Transformer mechanisms to construct a network security defense model, used LLM to collect and preprocess the training data of the constructed model, established a mapping relationship between training data and network attack categories based on the Transformer mechanism, and completed the pre-training of the model construction. Based on the loss function, the paper fine tune the parameters of the constructed model, and based on the pre-training results of the constructed model and the fine tuning results of the parameters, the paper determined the network attack category to implement effective detection and defense of the network attack category. The experimental results show that the network attack category detection effect of this technology is superior to the comparative technology, and the maximum F1 score can reach 0.9.

Keywords: transformer mechanism; network security defense; training corpus collection and pretreatment; Large Language Model (LLM); network attack detection

数字时代的攻击者通过融合人工智能 (AI, Artificial Intelligence) 生成技术、供应链污染、零日漏洞、社会工程学等, 形成跨平台、多阶段的复合式攻击路径, 瓦解传统安全防护的“边界防御”理念, 为网络安全带来了巨大的威胁与挑战^[1]。现有技术多因应用模型或算法的自身缺陷, 无法获得较好

的网络安全防御效果。因此, 众多研究人员在该领域进行了针对性的研究。文献 [2] 集成威胁检测、分析与自动响应功能, 采用机器学习和深度学习构建多层次智能防御框架, 通过实时流量分析、异常行为建模及动态策略调整, 实现对 DDoS 攻击、恶意代码传播等威胁的精准识别与快速处置。该技术依赖海量历史数据训练模型, 本体构建依赖专家知识, 若领域知识库不完备, 可导致策略推荐偏差; 文献 [3]

收稿日期: 2025-06-30

作者简介: 杨伟青, 工程师; 周 游, 助理工程师。

针对网络入侵检测中数据不完备、特征冗余问题,提出基于邻域量化容差条件熵的增量式特征选择算法,该算法通过计算特征在邻域内的条件熵增量,动态评估特征对分类的贡献度,实现特征子集的在线更新,在设计算法实际应用过程中,条件熵可能忽略特征间的间接依赖关系,导致关键特征被错误剔除,进而影响网络入侵检测精度;文献[4]基于工业互联网架构,提出“安全大脑+全面防护”技术路线,通过统一管理平台实现设备级、网络级、应用级安全策略联动,降低矿山企业安全体系建设成本,但矿山生产环境复杂,可导致监测数据失真,影响威胁研判准确性;文献[5]分析联邦学习(Federated Learning)在数据收集、训练、推理阶段的安全威胁,提出基于CIA三元组的防御框架。针对投毒攻击、对抗样本攻击等,归纳鲁棒性提升方法和隐私性增强技术,但FL架构过于依赖参数服务器,容易遭受单点故障或恶意服务器攻击,进而影响防御性能;文献[6]针对资源受限场景,提出基于攻击图与知识推理的防御策略智能规划方法,通过本体建模融合领域知识,结合有限理性博弈模型生成动态防御策略,但本体构建依赖专家知识,若领域知识库不完备,可能导致策略推荐偏差。

基于上述研究,本文开展基于大语言模型(LLM, Large Language Model)与Transformer机制的网络安全防护技术(简称:本文网络安全防御技术)与应用研究,构建高效的网络安全防御模型(简称:本文模型),以提升网络攻击类别的检测性能和防御能力,解决现有网络安全防御技术的不足。

1 本文网络安全防御技术

1.1 网络安全防御模型构建

LLM是以深度学习为核心的自然语言处理模型,能够对海量数据进行预训练,从而挖掘并学习数据的内部规律或者关联关系,为Transformer提供更丰富的上下文信息;Transformer机制能够通过自注意力机制对数据的长距离依赖关系进行精准捕捉,使得构建模型能够识别出隐藏在复杂数据中的攻击信息,而不仅是依赖局部信息^[7]。综上,本文引入

LLM与Transformer机制,构建网络安全防御模型,其架构如图1所示。




图1 网络安全防御模型架构

1.2 数据采集与预处理

训练数据的体量与丰富程度是决定网络安全防御模型性能的关键因素之一。本文利用LLM采集终端设备数据、安全文档数据、网络设备数据、安全建议数据、威胁情报数据、漏洞数据、代码脚本数据与通用语料数据作为模型训练原始数据,并对其进行预处理^[8],具体数据如表1所示。

将采集到的原始数据记为 $\{x_i, i=1, 2, \dots, n\}$, n 代表训练原始数据的总体量^[9]。由于原始数据量纲、数值范围等均不一致,故对其进行标准化处理,公式为

$$y_i = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)} \quad (1)$$

式(1)中, y_i 为标准化处理后的训练数据; $\min(x_i)$ 与 $\max(x_i)$ 为原始数据 x_i 的最小值与最大值。

1.3 预训练阶段

采用Transformer机制中的编码器结构捕获训练数据与网络攻击类别间的长距离依赖关系,以此为基础,建立训练数据与网络攻击类别的映射关系^[10],公式为

$$\begin{cases} P(z=c|\mathbf{Y};\theta) = \text{Softmax}(\mathbf{W}_c \cdot \mathbf{h}_L + \mathbf{b}_c) \\ \mathbf{h}_L = \sum_{i=1}^n \text{Softmax}\left(\frac{y_i \cdot \mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \end{cases} \quad (2)$$

式(2)中, $P(z=c|\mathbf{Y};\theta)$ 为给定输入训练数据集 $\mathbf{Y}$ 和构建模型参数集合 θ ,构建模型预测输入属于攻击类别 c 的概率; $\text{Softmax}(\cdot)$ 为归一化函数,确保输出概率之和为1; $\mathbf{W}_c$ 与 $\mathbf{b}_c$ 为分类头的权重矩阵和偏置向量,用于将训练数据映射到网络攻击类别空间; $\mathbf{h}_L$ 为Transformer编码器最后一层的输出结果; $\mathbf{Q}$ 、

表1 训练原始数据示意

数据类型	数据种类	数据信息
终端设备数据	终端IOA&IOC	IOA类日志、杀毒类日志等
	Windows	服务信息、账号信息、API信息等
	Linux	系统调用信息、驱动信息等
安全文档数据	ATT&CK	攻击链应用实例信息、技战术手法描述信息等
	引擎解决方案	引擎开发逻辑信息、文档信息等
	安全百科	安全名词解释信息、博客信息等
网络设备数据	NDR	攻击利用信息、邮件攻击信息等
	防火墙	网站攻击信息、漏洞攻击信息等
安全建议数据	误报反馈	误报数据
	安全事件处置建议	安全事件处置信息、事件分析文档等
	攻击链溯源报告	溯源分析报告、真实入侵路径等
威胁情报数据	PDNS信息	域名DNS历史记录查询
	IP、域名情报	IOC情报信息、APT信息等
	域名注册信息	whois信息、域名服务商信息等
漏洞数据	CVE漏洞信息	公开漏洞信息
	互联网漏洞情报	POC情报信息、漏洞博客等
代码脚本数据	恶意脚本	恶意shell脚本、Webshell脚本等
	开源代码	开源代码片段
	带有漏洞的脚本片段	带有漏洞业务片段、带有问题代码片段等
通用语料数据	开源威胁情报库	中文语料、英文语料等

K 与 V 为查询矩阵、键矩阵与值矩阵； d_k 为键维度。

1.4 参数微调阶段

针对网络安全防御的需求，通过对抗样本生成对少数类网络攻击样本进行增强处理，以此来缓解网络攻击类别不平衡的问题^[11]，公式为

$$y_{new} = y_i + \zeta \cdot \text{sign}[\nabla_Y \cdot J(\theta, y_i, y_j)] \tag{3}$$

式（3）中， y_{new} 为生成的对抗样本； ζ 为扰动强度； ∇_Y 为辅助常数，其取值范围为[0,1]； $J(\theta, y_i, y_j)$ 为当前网络攻击类别样本的损失函数值。

将生成的对抗样本 y_{new} 整合到训练数据集合中，对构建模型参数集合 θ 进行微调处理，以损失函数为依据^[12]，公式为

$$L_{loss} = - \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log_2 \hat{y}_{i,c} \tag{4}$$

式（4）中， L_{loss} 为网络攻击类别检测对应的交叉熵损失函数，主要用于衡量模型预测与真实标签之间的差异； N 为训练样本总数； C 为网络攻击类别总数； $y_{i,c}$ 为第 i 个样本的真实标签（如果属于类别 c ，则为1，否则为0）； $\hat{y}_{i,c}$ 为模型输出的第 i 个样本的类别标签。

当损失函数 L_{loss} 达到最小值时，构建的模型参数（Transformer编码器的参数和分类头的参数）达

到最佳，记为 θ^* ，将其输入至模型中，即可有效提升构建模型的网络攻击类别检测性能与网络安全防御性能^[13]。

1.5 网络安全防御阶段

根据模型预训练结果与参数微调结果，确定网络攻击类别检测结果^[14]，公式为

$$\hat{c} = \arg \max \left[P \left(z = c \mid \hat{y}; \theta^* \right) \right] \tag{5}$$

式（5）中， $\hat{c}$ 代表模型输出的网络攻击类别检测结果^[15]； $P(z = c \mid \hat{y}; \theta^*)$ 代表模型预测输入 $\hat{y}$ 属于类别 c 的概率。

以式（5）输出的网络攻击类别检测结果为基础，对网络攻击进行针对性处理，从而实现准确、高效的网络安全防御。

2 网络安全防御技术应用性能测试

测试网络安全防御技术应用性能，选取文献[2]中基于人工智能的网络安全防御技术和文献[6]中基于有限理性的网络安全防御技术作为对比技术1和对比技术2，与本文技术进行对比。

2.1 实验数据集构建

从某企业内网监控系统的区域网络数据库中随

机抽取网络攻击相关数据，以此为基础，构建实验数据集，如表 2 所示。

表2 实验数据集示意

数据集	训练集 (S)	测试集 (Y)
数据总和	8 000/MB	2 000/MB
终端设备数据	1 245/MB	254/MB
安全文档数据	1 024/MB	210/MB
网络设备数据	987/MB	198/MB
安全建议数据	895/MB	157/MB
威胁情报数据	1 202/MB	301/MB
漏洞数据	1 014/MB	303/MB
代码脚本数据	816/MB	216/MB
通用语料数据	817/MB	361/MB
信噪比	45.46/dB	43.21/dB
网络攻击类别	SQL注入攻击、XSS注入攻击、Java代码攻击、PHP代码攻击、Java反序列化攻击、Webshell上传攻击等。	

2.2 参数选取

以表 2 实验数据集数据为基础，对本文模型进行训练，以此来确定本文模型参数的最佳取值。本文模型训练迭代曲线如图 2 所示。




图2 基于 LLM 与 Transformer 机制的网络安全防御模型训练迭代曲线

如图 2 所示，当迭代次数为 15 次时，本文模型损失函数值达到最小值 4。此时，本文模型参数取值达到最优化，具体包括：Transformer 层数为 8 层；Transformer 隐藏层维度为 256；注意力头数为 10；前馈网络维度为 4×256；学习率为 1e⁻⁴；批量大小为 256；训练轮数为 40 轮；正则化参数为 0.2。

2.3 网络攻击类别检测结果分析

将 SQL（Structured Query Language）注入攻击、XSS（Cross-Site Scripting Attack）注入攻击、Java 代码攻击、PHP（Hypertext Preprocessor）代码攻击、

Java 反序列化攻击与 Webshell 上传攻击等网络攻击类别编码为 1~6，在测试集中提取相应的训练数据，进行对比检测实验，检测结果如图 3 所示。




图3 网络攻击类别检测结果示意

如图 3 所示，本文技术应用后获得的网络攻击类别检测结果与实验样本网络攻击类别标注编码保持一致，而对比技术 1 与对比技术 2 应用后获得的网络攻击类别检测结果与实验样本网络攻击类别标注编码存在着一定的偏差。这主要是因为本文模型在构建过程中引入了 LLM 与 Transformer 机制，通过两者的协同作用显著提升了网络攻击类别识别能力和分类精度。

2.4 网络安全防御性能分析

应用本文技术、对比技术 1 和对比技术 2 进行网络安全防御实验，以 F1 分数作为评价指标，F1 分数是综合衡量分类模型性能的指标，为精确率（Precision）和召回率（Recall）的调和平均数（Harmonic Mean），其核心作用是量化模型在误报（False Positive）与漏报（False Negative）之间的平衡能力，尤其适用于攻击样本稀疏（如 0.1% 攻击流量）的高风险场景。精确率（Precision）模型判定为攻击的样本中真实攻击的比例；召回率（Recall）真实攻击中被模型成功捕捉的比例，计算公式为

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall}) \tag{6}$$

网络安全防御性能对比如图 4 所示。

由图 4 可知，本文模型（黄色曲线）的 F1 分数最大值达到了 0.9，对比技术 1 模型（蓝色曲线）最大值达到了 0.6，对比技术 2 模型（绿色曲线）最大




图4 F1 分数对比示意

值达到了 0.5，本文模型（黄色曲线）的 F1 分数显著高于对比技术模型 1（蓝色曲线）与对比技术 2 模型（绿色曲线）。这主要是因为本文技术协同应用了 LLM 与 Transformer 机制，并将 LLM 预训练的网络攻击相关数据与 Transformer 建立的训练数据与网络攻击类别映射关系进行了有效地融合，使得所提技术能够同时兼顾训练数据与结构化特征，从而为网络攻击类别检测性能的提升提供一定的助力。

与此同时，Transformer 的并行化计算特性能够大幅度提升模型技术的处理速度，进而提升其网络安全防御响应速度。虽然图中未直接显示本文模型的预训练阶段、参数微调阶段与网络安全防御阶段等具体实施过程，但从其良好且稳定的性能表现可推断，本文技术通过这些阶段的实施实现了快速适应特定网络攻击场景，有效减少了对标注数据的依赖并提升了泛化能力，从而在实验样本范围内展现出了优于对比技术的性能表现。综上所述，本文技术在 LLM 与 Transformer 机制的引入与应用背景下，实现了网络安全防御性能的显著提升，即提高了 F1 分数。

3 结束语

本文针对网络攻击种类和数量激增导致安全威胁加剧的问题，研究了基于 LLM 与 Transformer 机制的网络安全防护技术。通过 LLM 智能采集与预处理训练数据，并利用 Transformer 构建攻击类别映射模型，完成预训练和参数微调。实验结果显示，该方法在攻击检测中 F1 分数最高可达 0.9，显著提升了防御精度和性能，有效实现了主动识别与防护，为

实际网络安全应用提供了可靠支撑。下一步，为验证技术泛化能力，计划在工业控制、云平台等异构网络环境中部署轻量级 Transformer 检测模块，测试模型对 0day 漏洞和跨协议攻击的泛化能力。

参考文献

- [1] 张凤霞. 地铁信号系统信息安全防护技术研究 [J]. 都市轨道交通, 2023, 36 (1): 168-173.
- [2] 徐建龙. 基于人工智能的广播电视网络安全防御系统研究 [J]. 电视技术, 2024, 48 (11): 201-203.
- [3] 骆公志, 侯若娴. 基于邻域量化容差条件熵增量式更新的网络入侵检测方法 [J]. 数据采集与处理, 2024, 39 (1): 181-192.
- [4] 张冬阳. 基于工业互联网的矿山企业网络与信息安全纵深防御体系研究与构建 [J]. 中国煤炭, 2024, 50 (8): 142-151.
- [5] 高莹, 陈晓峰, 张一余, 等. 联邦学习系统攻击与防御技术研究综述 [J]. 计算机学报, 2023, 46 (9): 1781-1805.
- [6] 刘盈泽, 郭渊博, 方晨, 等. 基于有限理性的网络防御策略智能规划方法 [J]. 通信学报, 2023, 44 (5): 52-63.
- [7] 蒋宁, 范纯龙, 张睿航, 等. 基于模型的零信任网络安全架构 [J]. 小型微型计算机系统, 2023, 44 (8): 1819-1826.
- [8] 吴娜, 沈思, 王东波. 基于开源 LLMs 的中文学术文本标题生成研究——以人文社科领域为例 [J]. 情报科学, 2024, 42 (7): 137-145.
- [9] 李婷婷, 王琪, 王嘉康, 等. SWARM-LLM: 基于大语言模型的无人集群任务规划系统 [J]. 计算机科学, 2025, 52 (1): 72-79.
- [10] 顾兆军, 孙浩然. 基于时间自动机的工控系统网络安全研究 [J]. 计算机仿真, 2023, 40 (1): 326-332.
- [11] 张霄智, 方巍, 王溟西. 基于 Swin-Transformer 和时空融合注意力机制的 ENSO 预测 [J]. 海洋学报, 2024, 46 (12): 111-121.
- [12] 牟雨萌, 刘亮, 张磊, 等. 基于 Transformer 和 CNN 的恶意代码分类方法 [J]. 四川大学学报 (自然科学版), 2024, 61 (4): 042004.
- [13] 胡航, 刘鹏程, 张玉臣, 等. 基于博弈论组合赋权的网络防御系统风险评价研究 [J]. 现代防御技术, 2025, 53 (1): 88-96.
- [14] 钱锦, 徐汉麟, 李昂, 等. 多重攻击下自安全网络的防御策略设计 [J]. 控制工程, 2024, 31 (12): 2312-2320.
- [15] 孙帅, 张蕾, 胡春卉, 等. 多视角下的网络空间安全模型与体系化发展 [J]. 中国工程科学, 2023, 25 (6): 116-125.

责任编辑 李依诺