

分类号_____

学校代码 10487

学号 M201970018

密级_____

硕士学位论文

(学术型☐ 专业型☒)

基于 TF-IDF 和机器学习的文本向量化 与分类研究

学位申请人： 石慧

学 科 专 业： 应用统计

指 导 教 师： 梅正阳教授

答 辩 日 期： 2022 年 05 月 14 日

**A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Professional Master Degree**

**Research on Text Vectorization and Classification based
on TF-IDF and Machine Learning**

Candidate : SHI Hui
Major : Applied Statistics
Supervisor : Prof. MEI Zhengyang

Huazhong University of Science and Technology
Wuhan 430074, P. R. China
May, 2022

摘要

随着互联网技术的飞速发展和社交媒体的爆炸式增长，数据量与信息量暴增。随着各种信息铺天盖地的到来，数据飞速更新。对于用户来说，想要准确地获得对于自己有价值的信息越来越难。因此自动化的文本分类与挖掘的技术应运而生，也随着时代的发展变得越来越重要。

由于文本分类技术的飞速发展，数据挖掘、机器学习不断被运用到文本分类中。本文选取清华大学 NLP 实验室的 THUCNews 数据集的子集 Cnews，共 10 个类别，训练集与测试集的比例为 5:1，共 6 万条样本。首先，在预处理方面，利用 jieba 分词工具，并进行去表情符号和特殊字符等处理，然后利用 TF-IDF 词向量化模型来提取文本的特征向量。考虑到量纲的影响以及词频与文本的相关度可能不一定是线性的增长关系，分别提出标准化 TF-IDF 和 $1+\log(\text{TF})_IDF$ 的词向量方式，对 TF-IDF 中的 TF 计算方式进行了改进。

本文通过逻辑回归、支持向量机、朴素贝叶斯和梯度提升等机器学习分类算法，首先验证了标准化 TF-IDF 和 $1+\log(\text{TF})_IDF$ 的词向量方式相比于传统 TF-IDF 词向量方式来说在分类效果上的提升，并利用准确率、召回率、F 值等指标对分类模型进行了评价和分析。然后与传统的 Word2vec 的词向量模型进行对比，进一步验证了本文提出的标准化 TF-IDF 和 $1+\log(\text{TF})_IDF$ 的词向量方式在短文本词向量特征提取方面的优势。最后利用 Voting 融合分类模型，验证了模型融合在一定程度上可以提升分类器的分类效果。

关键词：文本分类；词向量化；机器学习；TF-IDF；Word2vec

Abstract

With the quick development of internet technology and the highly explosive growth of social media, various types of information, text, pictures, audio, video are constantly being generated, and the amount of data and information soars. With the arrival of all kinds of information and the rapid update of dataset, it is more and more difficult for users to accurately obtain valuable information for themselves. Therefore, the technology of automatic text classification and mining came, and it has been more and more significant with the development of the times.

Because of the quick development of text classification technology, data mining and machine learning have been continuously applied to text classification. This paper selects the subset Cnews of the THUCNews dataset of the NLP laboratory of Tsinghua University, with a total of 10 categories, the ratio of training set to test set is 5:1, and it contains 60,000 samples.

Firstly, the dataset is preprocessed, including jieba word segmentation, removal of emotions, removal of special characters, etc. Then, the TF-IDF word vector model extracts the feature vectors of words. According to the characteristics of short texts, considering the influence of dimension and the non-linear growth relationship between word frequency and text importance, standardized TF-IDF and $1+\log(\text{TF})_IDF$ are proposed respectively. The word vector method of $1+\log(\text{TF})_IDF$ improves the TF calculation method in TF-IDF.

This thesis uses NB, SVM, LR, GBM and other classification algorithms to verify that the word vector method of standardized TF-IDF and $1+\log(\text{TF})_IDF$ is better than the traditional TF-IDF word vector method in classification. The effect is improved, and the classification model is evaluated and analyzed from the aspects of accuracy, recall, F value, etc. At the same time, compared with the traditional word2vec, it further verifies the advantages of the standardized TF-IDF and $1+\log(\text{TF})_IDF$ word vector methods. Finally, the voting fusion classification model is used to verify that the model fusion can improve the classification effect of the classifier to a certain extent.

Key words: Text classification, Word vectorization, Machine learning, TF-IDF, Word2vec

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	1
1.3 本文主要研究内容.....	3
1.4 论文的组织安排.....	3
2 文本分类技术相关理论与基础概述	5
2.1 文本预处理.....	5
2.2 词向量与文本表示.....	6
2.3 文本分类算法.....	8
2.4 文本分类算法的在新闻分类中的应用	13
2.5 算法性能评价指标.....	14
2.6 本章小结.....	14
3 模型的构建与数据的分析	15
3.1 词向量的表示.....	15
3.2 分类模型的构造.....	17
3.3 数据集介绍与预处理.....	18
3.4 TF-IDF 模型实验结果	21
3.5 本章小结.....	26
4 实验结果与对比分析	27
4.1 改进 TF-IDF 模型的介绍与实验	27
4.2 分类模型的对比与分析.....	30
4.3 分类模型的融合.....	36
4.4 本章小结.....	39
5 总结与展望.....	40
5.1 工作总结.....	40
5.2 论文创新点.....	41
5.3 工作展望.....	41
参考文献.....	43

1 绪论

本章首先介绍了文本分类的研究背景和意义，然后就文本分类的国内外研究现状进行了总结和阐述，进而引进了本文的主要研究内容和工作。最后对论文的组织架构进行了分章节的概括。

1.1 研究背景和意义

由于计算机与互联网的飞速发展，数据量与信息量暴增。随着各种信息铺天盖地的到来，数据飞速更新。对于用户来说，想要准确的获得对于自己有价值的信息越来越难。曾经大多采用手动分类或者人工标注的方式来对文本进行分类，但是从时间和人力方面来说，耗费的成本越来越高。因此自动化的文本分类与挖掘的技术应运而生，也随着时代的发展变得越来越重要^[1]。

通过文本分类技术快速自动化地处理海量数据，比人工处理更加的高效智能。运用这项技术可以用来分析消费者的情感倾向，商家能借此更好地挖掘用户的需求。同时通过命名体识别等技术，可以快速的识别文本中的专有名词，便于医学和化学等领域快速的进行专有名词的识别，从而实现降本提效的效果。

在机器学习时代，文本分类主要依赖于支持向量机、朴素贝叶斯、KNN、逻辑回归、XGboost 等算法。现由于自动化的文本分类技术能够快速的对海量数据进行分类和有价值信息的提取，用途在生活中十分广阔，可以用于解决众多的实际和商业问题，并为其提供大量技术支持，因此有很重要的研究意义^[2]。

新闻信息是一种十分重要的社会信息资源，目前人们对于新闻时事的需求日益增大。新闻信息的分类有利于快速的推荐新闻、挖掘新闻的重要信息、抽取新闻中的语义信息等。因此借助文本分类算法来实现高效新闻分类有重要意义。

1.2 国内外研究现状

在自然语言处理研究的领域，文本分类是一项非常基本的任务，其具有重要的实际意义，并且在应用方面有很多突出的案例。文本分类的主要目的是对文本资源

进行归类 and 整理, 另一方面也可以解决信息量过大等问题^[3]。由于信息和数据的大量增长, 文本分类技术也快速发展。在 20 世纪 50 年代开始, H. P. Luhn 提出了词频概念, 文本分类的研究开始^[4]。

20 世纪 50 年代, 常用词频、互信息法、卡方值等来作为特征提取的方法。随后出现 TF-IDF 算法, 通过计算词频和逆向文档频率来提取特征。但由于 TF-IDF 算法的单一性, 未考虑到语义信息或者类别差异, 因此出现了多种对于 TF-IDF 算法的改进技术。2019 年 5 月, 王根生等人提出了基于改进词频和 Word2vec 的 CNN 文本分类模型, 通过 Word2vec 与词频特征算法相结合提取文本向量特征^[5]。

20 世纪 60 年代, Chomsky 首次用代数和集合把自然的语言描述成计算机可以识别的语言。由于文本和语言是复杂的非结构化数据, 还包含上下文信息、语义结构、词频以及词语的特殊含义等复杂的内容, 早期的文本分类十分的繁琐, 并且很耗时耗力^[6]。

到上世纪 90 年代, 开始兴起了基于机器学习、数据挖掘和统计学习理论的文本分类方法^[7]。通过算法去自动化的挖掘文本中的规则, 提取特征, 训练有效的文本分类模型^[8]。1995 年, Vapnik 提出了传统机器学习算法中的 SVM 模型^[8]。随后, 李荣陆利用最大熵原理提出了一种新的文本分类算法^[9]。张群等人考虑了数据的稀疏性问题, 提出了将 W2V 与主题模型相结合的文本分类技术^[10]。

随着谷歌学术等学术搜索引擎的推出, 研究人员正在使用它们来大规模访问学术资料并且无需支付任何费用。现有的基于关键字和规则的搜索系统, 存在推荐具有高引用频率的研究文献而不是推荐上下文相似文档的风险。Jo Jeongje 等人提出提出了一种使用 LDA 和 BERT 的基于语义的半监督推荐系统。由于采用了半监督的方法, 可以将上下文和分类信息嵌入研究文献, 也可以捕获研究文献的全局主题信息。此外, 还实现了文献信息提取器系统的开发, 该系统包括模型的分类网络和使用 BERT 自注意力结构实现的可解释关键字提取器系统。该模型可以帮助用户快速准确地从数据库中找到信息和与上下文匹配的数据^[11]。

在计算机视觉领域, 深度学习取得了不错的应用结果, 于是也被研究者运用到了自然语言处理领域。比较常见的有 RNN, CNN 等, 国内不少学者不断尝试改进文

本分类的各种算法。陈巧红等人将 CNN 和 RNN 模型相融合，提取高阶文本特征，并引入注意力机制^[12]。目前的研究中，也有多数学者采用 LSTM 算法解决自然语言处理问题。鞠婷等人将 BERT 词向量化模型和双向 LSTM 分类算法用于舆情评论的分析与研究，效果优于很多主流倾向分析模型^[13]。

1.3 本文主要研究内容

为解决新闻标题内容短小、时效性强、主题不明确、内容增长迅速带来的问题，本文通过梳理新闻文本分类与词向量化技术的相关文献，探究适合新闻文本分类的算法，建立本文的数学模型。

在数据预处理阶段，本文选取的是 THUCNews 的子集。THUCNews 是清华 NLP 组提供的数据集，包含 74 万篇新闻文档。实验选取的是该数据集其中的十个类别，每个类别都包含有 5 千条样本，一共包含有 5 万条新闻样本。首先，对该数据集进行预处理，包括 jieba 分词、去表情符和复杂字符、单词长度与句子长度的统计以及高频词的统计。然后，用 TF-IDF 词向量化算法对每个类别的关键词进行特征权重提取，来达到向量化的目的。

在词向量化过程中，首先采用了 TF-IDF 算法、改进的 TF-IDF 算法和传统的 Word2vec 模型将文本转化为计算机可识别的向量矩阵，并进行模型参数优化。然后将 Word2vec 词向量化模型提取的词语向量代入分词后的文本矩阵，运用平均化词向量的方式对高维词向量进行降维。最后，将向量矩阵嵌入分类器中进行分类。

在实证分析方面，分别对比三种不同 TF-IDF 词向量方式（包括传统的 TF-IDF 词向量方式和两种改进的 TF-IDF 词向量方式）和 Word2vec 的词向量方式所提取的词向量的分类结果。分别选择逻辑回归、朴素贝叶斯、支持向量机、GBDT 以及 Voting 模型融合技术对词向量进行分类，观察并分析分类评价指标，探究效果最好的分类模型。

1.4 论文的组织安排

本文的核心内容是分别通过 TF-IDF 词频算法、Word2vec 算法对文本进行向量

化处理。根据新闻标题这类文本的结构特点，对 TF-IDF 算法进行改进，主要是对 TF (Term Frequency, 即词频) 进行对数处理与标准化处理，其中取对数是为了降低线性相关性，标准化处理是消除量纲影响。然后将处理好的向量化矩阵嵌入到分类器中进行分类，分别包含了逻辑回归、支持向量机、朴素贝叶斯、GBDT 与模型融合等分类技术。在模型训练过程中分别对词向量化模型与分类模型进行参数调优，最后对分类结果进行评价与分析。实验利用 PyCharm 编程软件与 Anaconda 环境，利用 python 语言进行实验代码编写。总的来说，本文的总体框架和构思如下：

第一章是绪论：该部分对本文的主要研究与工作的内容以及背景和意义等进行了总结，并概况了文章的大体框架与整体布局。

第二章是文本分类技术相关理论与基础：该部分首先介绍了文本分类的预处理过程。然后对文本向量化的技术与理论进行了概述，并依次介绍了分类器的模型与理论，包括逻辑回归分类器、朴素贝叶斯分类器、支持向量机分类器、GB 分类器以及 Voting 模型融合算法等技术和常用的分类器效果评价指标。最后是对该部分的总结。

第三章是分类器的构造与数据预处理：该部分介绍了本文的实验流程和分类器的构造，并且对本文所选用的数据集进行了预处理与数据分析，最后是对该部分的总结。

第四章实验与结果分析：根据第二章与第三章所介绍的理论模型与分类技术，利用 Python 语言进行编程，对本文所选用的新闻数据集进行词向量化与分类，并对实验结果进行评价与分析，最后再对不同模型与方法的结果进行横向对比与总结。

第五章总结与展望：该部分是对全文的进一步思考和对整体的总结。从本文的背景与理论、词向量化的技术、分类器的构造以及分类效果等方面依次进行了总结。并且对本文存在的不足和可以优化的地方进行了思考和概述，明确了今后需要完善和继续学习的地方。

2 文本分类技术相关理论与基础概述

本章介绍了文本分类技术的一些相关理论和数学模型。主要包括文本预处理的流程，词向量和文本表示的方法，以及文本分类算法的主要原理，并总结了分类算法评价指标的定义和计算公式。最后对文本分类在新闻领域的应用进行了简要概述。

2.1 文本预处理

文本预处理主要包括去停用词、文本分词和去特殊字符等部分。文本预处理是为了将文本划分成多个用来表述文本信息的词汇，并且去除掉对于分类没有作用的符号或者单个停用词。

2.1.1 文本分词

分词是进行文本分类任务进行之前的第一步，文本分词是将连续的句子按照一定的文本规则，划分成多个词汇集合的一个过程。中文文本是由很多词汇和一些连接词组成，无法像英文句子那样直接进行单词分割，分词的过程会复杂很多^[14]。

本文采用 python 语言自带的 jieba 分词库进行新闻文本的分词处理。jieba 分词利用语料库中已有的对照词典来获取句子的 DAG 图（即有向无环图）。按照选取的分词模式，搜寻最优与最短路径从而来完成对句子的分词工作。由于中文表达方式本身存在了一些问题，于是给中文分词带来了这些问题：

(1) 歧义问题：是指中文语义可能存在多种语义，那么这时一个文本可能存在多种分词的方式。由于存在歧义问题，那么计算机无法得到最适合的处理方式。因此，语义的歧义带来的分词问题无法避免^[15]。

(2) 新词识别问题：是指在分词识别过程中，出现一些新奇的词语或者在分词词典中未出现过的词语，比如人名、地名、网络用语等。同时这些新词更新快、时效性强^[16]，因此词典不能完全收录，存在新词的识别问题。

2.1.2 去停用词

由于文本信息中往往包含很多停用词，于是会增加计算的成本。因此，往往会

对文本进行去停用词处理。

通常情况下,停用词大致可分为两类,即功能词和词汇词等。功能词主要有“的”、“了”、“啦”、“哎呀”和“哟”等。词汇词主要有“想要”、“认为”等。这些词存在很广泛,但是对于文本的分类识别来说,一般不能带来有用的信息。由于大部分停用词在文本分类工作中会增加工作量、降低分类效率,而且这些停用词的存在大部分对于分类来说没有什么作用,因此去除这些停用词有利用提高分类工作的效率。

2.2 词向量与文本表示

2.2.1 词向量由来

对于自然语言处理领域来说,文本信息作为非结构化的字符,需要转化为计算机可以识别的结构化字符信息。由于独热编码的表示方法不能用来表示包含语义信息的文本数据,而且当数据量比较大的时候,会给计算带来很大的负担。因此有学者提出了利用数学向量来表示词语、文本的方式^[17]。

词向量的概念自 1986 年被 Hinton^[18]提出以后,在研究领域就产生了很多种词向量模型,例如 CBOW、Skip-Gram、TF-IDF 和 N-Gram 等。在训练词向量模型的过程中,模型会产生词向量,因此就展开了对词向量的研究。本文主要介绍 Word2vec 词向量模型和 TF-IDF 词向量模型。

2.2.2 Word2vec 词向量模型

Word2vec 是基于神经网络的语言学习模型,是用来训练生成文本词向量的一种模型^[17]。它是谷歌在 2013 年左右提出的自然语言处理领域的模型,作用就是将词汇进行向量化。通过数学向量就可以挖掘词语之间的联系和相关度,并进行定量化与模型化的分析。

由于模型框架和预测内容的差别,Word2vec 词向量模型主要包括 CBOW 和 Skip-Gram 模型。CBOW 模型是利用某个特征词的内容来预测这个特征词的上下文,而 Skip-Gram 模型是利用某个待预测词的上下文来预测该词,和 CBOW 恰好相反。训

练完成之后，每个词可以被映射成一个向量，这个词就被表示成了这个向量，并且可以用来计算词语之间的相关性。

CBOW 模型通过上下文预测给定词，CBOW 的数学表示如(2.1)所示：

$$P(W_t | \tau(W_{t-k}, W_{t-k+1}, \dots, W_{t+k-1}, W_{t+i})). \quad (2.1)$$

Skip-Gram 则是通过当前词预测其上下文，Skip-gram 的数学表示如(2.2)所示：

$$P(\tau(W_{t-k}, W_{t-k+1}, \dots, W_{t+k-1}, W_{t+i}) | W_t). \quad (2.2)$$

2.2.3 TF-IDF 模型

TF-IDF 是由词频（Term Frequency，缩写为 TF）和逆向文档频率（Inverse Document Frequency，缩写为 IDF）两部分组成，通过这种方法可以用来评价特征词在一个文件库中的某个文件的重要程度^[18]。词频计算如下面公式(2.3) 所示：

$$TF_{i,j} = \frac{n_{i,j}}{\sum_{k=1}^k n_{k,j}}. \quad (2.3)$$

$TF_{i,j}$ 代表词语 w_i 在文档 d_j 中出现频率， $n_{i,j}$ 为 w_i 在文档 d_j 中的出现次数，分母为文档 d_j 中全部的特征词出现的频数的一个求和式， k 为文档 d_j 中不同词语的个数。模型的另一部分 IDF 的计算如公式(2.4)所示：

$$IDF_i = \log\left(\frac{n_d}{df(d, w_i) + 1}\right), \quad (2.4)$$

其中 IDF_i 代表特征词 w_i 在文档 d_j 中的反向文档频率， n_d 为文本库中所有文档数， $df(d, w_i)$ 为文档库中包含特征词 w_i 的文档数，加 1 是为了防止出现次数为 0。

TF 的思想表示的是：如果某个特征词在某个文档中出现的次数比较多时，那么这个特征词能作为该文档的关键词，并且它和包含这个关键词的文本的相关程度很大，可以用来作为分类的特征词汇。IDF 的思想表示的是：如果只有很少的文本包含了某个特征词，那么这个关键词可以用来作为分类特征词，更有利于区分不同类别的文本。一般情况下，会把 TF 和 IDF 结合起来一起用，计算 TF-IDF 值^[19]，从而达到文本向量化的目的。

2.2.4 基于新闻文本特点改进的 TF-IDF 词向量

由于 TF 仅仅从词语频率方面考虑了文本所包含的信息，其忽略了文本结构信息，比如文本的长度、文本的量纲等。经典的 TF 计算方式并没有考虑文本的长度以及文本分词后包含的词语个数带来的不同量纲化的问题。

比如文本 A 有 15 个单词，文本 B 只有 5 个单词，假如“建设”这个词汇在这两个文档中都同样出现过 3 次，那么这里出现的 3 次在文档 A 和文档 B 中不能是起到同等大小的重要作用，明显对于文档 B 来说，“建设”这个词汇更加重要。其实，这种关系几乎很难说明是呈现线性的。

本文考虑两种对 TF 的改进方式：

一是进行“标准化”，即对传统的 TF 进行标准化处理，可以在一定程度上消除文本长度的不同带来的量纲上的影响。

二是考虑到 TF 的原始计算方式在原始定义中没有最大的上限阈值。虽然，一般情况下认为如果一个文档多次包含某个关键词，那么一般来说，这个关键词可能和这个文档的相关度比较高，但这种关系几乎很难说明二者之间一定是呈现线性的。通过对 TF 取对数，利用数学函数中的对数函数的特点来避免 TF 的线性增长趋势。

2.3 文本分类算法

文本分类作为一项很基础且很重要的自然语言处理任务，从字面意思理解就是对语料库中的文本或者文档库中的文本进行分类。简单地说，可以认为它包括情感分析、新闻分类、舆情分析、评论研究等方面的工作。

随着人工智能领域的兴起与火爆发展，越来越多的机器学习与数据挖掘算法被应用到文本分类的过程中，接下来主要介绍一下几种常用机器学习分类算法的原理。

2.3.1 朴素贝叶斯算法

朴素贝叶斯算法 (Naive Bayes, 简称 NB) 来源于统计学领域，它基于经典的贝叶斯定理。贝叶斯定理最重要的一点是要满足条件特征独立的假设^[20]。贝叶斯定理的数学公式如下(2.5)所示：

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}. \quad (2.5)$$

朴素贝叶斯分类器是较为简单、直观并且非常有效的一种分类器。该算法具有很多的优点，比如效率快、可以处理存在缺失的数据、分类结果很容易被理解^[21]。那么缺点主要是，该算法对应的条件独立假设在很多现实条件中无法满足。利用统计学中满足独立条件的联合概率公式可以得到公式(2.6)：

$$P(X|C_i) = \prod_{k=1}^n P(x_k|C_i). \quad (2.6)$$

由于朴素贝叶斯算法具有比较平稳的分类效率，收敛的比較快。而且算法的思想简单，能够用到多分类问题中，它并不会对缺失的数据很敏感。

2.3.2 支持向量机算法

支持向量机是一种有监督的分类学习方法，其分类的核心工作就是找到能将数据尽可能分离的超平面。由于能将数据分离的超平面有很多，那么支持向量机是需要找到一个最优化的超平面，使得这个超平面能把不同类别的样本进行分类，并且它到样本数据的最小的那个间距是最大化的。也就是说，离被分类的数据的距离长度越远越好^[22]。下图 2.1 为支持向量机模型的图示：




图 2.1 支持向量机图示^[23]

如图 2.1 所示，对于二分类数据，用来分类的超平面可由下列线性方程(2.7)表示：

$$w^T x + b = 0, \quad (2.7)$$

式(2.7)中的 w 表示超平面的系数，在数学意义上也称为平面的法向量。 b 表示超平面的截距， $\frac{b}{\|w\|}$ 为该超平面到原点的距离。在图 2.1 中， $w^T x + b = 1$ 与 $w^T x + b = -1$ 为两条穿过离超平面最近的点线，两者之间具有相同的法向量，相互平行，这两条线的距离即 $\frac{2}{\|w\|}$ 为分类间隔。支持向量机对于样本量小的数据集分类具有十分突出的优势，但是对于非线性可分的数据，分类效果可能会稍为弱一些^[24]。

为了使得离超平面最近的点与超平面的距离达到最大化，那么就演变成一个优化问题，如式(2.8)：

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2, \\ \text{st} \quad & y_i(w^T x_i + b) \geq 1, \forall i. \end{aligned} \quad (2.8)$$

这一类优化问题主要是针对线性可分的问题，也称为硬间隔支持向量机算法。那么对于非线性可分问题，需要引入一个软间隔，其对应的算法也成为软间隔支持向量机算法^[25]，如式(2.9)所示：

$$\begin{aligned} \min_{w,b,\zeta} \quad & \frac{1}{2} w^T w + C \sum_{i=1}^n \zeta_i, \\ \text{st} \quad & y_i(w^T x_i + b) \geq 1 - \zeta_i, \forall i, \zeta_i \geq 0. \end{aligned} \quad (2.9)$$

在式(2.9)中， ζ_i 为惩罚项，如果分离的误差越大，惩罚项的数值越大。 C 为正则化系数，用来表示惩罚的强度大小。即 C 越大，惩罚强度越大，对应的分离误差也越大^[26]。

该算法的优点主要是：分类原理比较简单，性能较优，分类效果一般比较好，并且可以解决一些非线性化的分类任务。缺点主要：是对于多分类问题和大样本存在一定的困难，并且对于缺失数据比较敏感。

2.3.3 逻辑回归算法

逻辑回归算法（Logistic Regression，简称 LR）是一种计算效率较快、泛化能力

较强、适用性较强的一种机器学习算法^[27]。

逻辑回归可以用来预测在多种不同输入变量作用下，因变量发生的可能性大小。其也可以对于发生与不发生的事件进行信度分析，即可以用来做二分类也可以用来做多分类。逻辑回归可以看作是一种概率化的估计方式，类似于线性回归，通过 sigmoid 函数的映射，模型输出的因变量的数值范围在 0-1 之间。结合设置的阈值，大于该阈值的类一般被归为 1 类或者正类，小于该阈值的类一般被归为 0 类或者负类^[28]。

对于二分类问题，逻辑回归函数的概率分布表达式如式(2.10)和式(2.11)所示：

$$P(Y=1)_{x,w} = \frac{e^{wx+b}}{1+e^{wx+b}} = \frac{1}{1+e^{-(wx+b)}}, \quad (2.10)$$

$$P(Y=0)_{x,w} = \frac{1}{1+e^{wx+b}}, \quad (2.11)$$

其中 w 为自变量的权重系数， b 为偏置常数， P 为输出的概率结果，也可以称为类别的可信度或者发生概率， x 为输入的自变量。逻辑回归的函数表达式即(2.12)：

$$f(x) = \frac{1}{1+e^{-w^T x}}. \quad (2.12)$$

式(2.12)中的 $f(x)$ 为逻辑回归的函数，对于具体的应用，需要对 $f(x)$ 进行阈值设定，且阈值的大小需要根据实际情况而定。一般认为，函数值大于设定阈值的类别会被分为正类，函数值小于阈值的类别会被分为负类。当阈值为 0.5 时，逻辑回归的函数图像如图 2.2 所示：




图 2.2 阈值为 0.5 的逻辑回归函数图像^[28]

通过逻辑回归模型的构建，利用给定的数据，设置好迭代次数与模型参数，通过训练得到最优的回归系数，完成分类任务。该分类方法同样可以拓展到多分类任务当中去。

逻辑回归算法的优点主要是：实用性比较广，效率相对较好，也可以用于多分类问题。同时，该算法不需要假定分布。缺点主要是：比较容易造成训练数据的不平衡性，从而导致分类器的偏向性^[29]。

2.3.4 梯度提升算法

梯度提升（Gradient Boosting）算法是一种有监督的学习算法，简称为 GB 算法。GB 算法的每一次的训练过程中，按照损失函数相对于参数梯度的相反方向去寻找损失函数的最小值。并且，梯度的方向是损失函数斜率最大、上升的速度最快的方向^[30]。该算法的梯度函数表达式如下式(2.13)所示：

$$\nabla S(\theta, y) = \lim_{\varepsilon \rightarrow 0} \arg \max S(\theta + d, y), \quad (2.13)$$

式(2.13)中： $\nabla S(\theta, y)$ 表示损失函数的上升或者下降对应的梯度大小； d 为训练过程中对应参数的变化量大小。

梯度提升算法的优点主要是：基本可以用于所有的回归问题，包含线性回归与非线性回归。其泛化能力较强，精度比较高，对于连续型和非连续型数据都可以处理。该算法的缺点主要是：其内部的基分类器存在了一定的依赖关系，所以可能难以进行并行式训练，训练效率在有些情况中可能会比较低。

2.3.5 Voting 融合原理

Voting 是一种基于投票来进行模型融合的方法^[31]，分为软投票（soft voting）和硬投票（hard voting）。Voting 是一种比较快速的模型融合方法，直接根据已有模型的预测结果进行投票即可。

对于硬投票方式，它直接根据已有分类器的结果，利用少数分类结果服从多数分类结果的原则，从而进行最终预测结果的确定。例如，现有的分类器 SVM、朴素贝叶斯、逻辑回归对于某个样本的预测结果分类是正、正、负类，那么该样本经过 Voting 融合的预测结果为正类，即少数服从多数。

对于软投票方式，采用加权融合的方法。它是结合多个不同分类器，并且为各分类器设定相应的权值，然后利用二值函数乘以其权重进行汇总，采用平均预测概率的方式来预测分类标签，最终得到分类结果^[32]。假设共有 K 个分类器，那么加权融合的结果即为式(2.14)：

$$C = w_1 C_1 + w_2 C_2 + w_3 C_3 + \dots + w_k C_k. \quad (2.14)$$

2.4 文本分类算法在新闻分类中的应用

新闻文本作为重要的信息资源，其数量级别很大，更新换代的速度非常快，时效性也非常强。对于新闻文本的自动化分类，有利于降低人工成本、快速挖掘新闻信息、实现新闻有序化^[33]。

随着互联网技术、人工智能以及时代的快速发展，涌现出的互联网上的新闻与文字包含的信息量和数据变得越来越多。因此，信息传递在很多方面都起着十分积极的作用^[34]。于是，对网络新闻加以分类，同时满足用户的个性化需求的分类技术变得越来越重要^[35]。

从文本分类、数据挖掘的角度来说，新闻文本具有以下这些特征：

- (1) 新闻文本的增长速度日益加快，基本趋于指数型增长。杂乱的新闻日益增多，但是新闻网民的数量也日增不减，有新闻消费需求的群体不断的壮大。
- (2) 新闻文本结构性强，在分类方面具有可实施性。新闻信息的语言一般简明扼要，结构清晰，陈述性强，存在一定的固定模板。同时，根据已有经验，新闻文本的文本长度不长，六要素清晰。因此根据新闻文本的这些独有特征，对于模型的特征提取和分类带来了一些优势，也有利于模型的训练与学习。

目前文本分类算法在新闻文本的应用方面主要有：新闻内容的个性化推荐、新闻网站的分类与导航、话题引流等。利用新闻的个性化推荐，可以满足不同用户对于新闻内容的需求，提高用户的留存。利用新闻网站的导航功能，可以快速的贴合用户的需求，增加页面的简洁度，减少杂乱信息的堆积等。这些应用之间的联系也十分密切，可以作为一个金字塔的形式呈现。

2.5 算法性能评价指标

在模型构建和训练工作结束后，需要设定一些指标来评价算法性能和分类准确性，主要运用准确率（precision）、召回率（recall）、F 统计量的值来对模型效果进行评价^[36]。

准确率：即在分类结束后，对于已知类别的数据集，训练得到的分类器对其正确分类的样本数量占总样本数量的比例，反映的是算法的整体性能。

召回率：即在分类结束后，对于已知类别的数据集，训练得到的分类器对其正确分类的样本数量占属于该类别实际样本总数的比例，这是区别于准确率的地方。

F 值：即准确率和召回率的调和平均值，用来衡量分类问题的精确度。

对于典型的二分类问题，一般运用混淆矩阵，来计算准确率、召回率这些指标。由该混淆矩阵可以引出如下准确率 P、召回率 R、F 值等等评估指标，如式(2.15)：

$$P = \frac{TP}{TP + FP}, R = \frac{TP}{TP + FN}, F = \frac{2TP}{2TP + FP + FN}. \quad (2.15)$$

2.6 本章小结

本章针对文本分类算法的理论以及相关基础进行了介绍，主要包括文本的预处理过程、文本的向量化训练算法即 Word2vec 与 TF-IDF 算法、常用的机器学习文本分类算法模型与原理等，并且依次总结了分类算法的优缺点。同时对文本分类算法在新闻领域的应用进行了概述与总结，最后是对分类效果的评价指标进行了介绍。

本章对于文本分类流程与理论进行了综述，依次介绍了相关的方法与模型以及背后的原理，为下一章节的分类实验打下了坚实的基础。

3 模型的构建与数据的分析

本章主要介绍模型的构造和对数据的预处理以及统计分析。首先介绍了词向量的表示模型，即传统的 TF-IDF 词向量化模型。其次，结合新闻文本的特点对传统的 TF-IDF 模型进行了改进，介绍了改进方式的具体计算方式。然后，介绍了分类模型的构造，分类过程主要是将词向量模型提取的特征向量嵌入分类模型中进行模型的训练。其次，基于本文的数据集的特点进行了预处理和统计分析。预处理主要包括 jieba 分词、去表情符、去特殊字、去停用词等。最后，对传统 TF-IDF 词向量模型进行了实证分析与算法评价。

3.1 词向量的表示

本节首先介绍了传统 TF-IDF 词向量模型的算法原理，分别介绍了 TF 与 IDF 的计算方式以及背后的原理。然后基于新闻文本的特点对传统 TF-IDF 中 TF 的计算方式进行了改进，主要为了在一定程度上消除量纲的影响和避免线性增长的趋势。

3.1.1 基于 TF-IDF 的词向量

TF-IDF 经常用来衡量一个文档库中某个词对于包含该词的文本的重要程度，是一种很常见的文本特征提取方法，而且提取效果比较好。TF (Term Frequency) 表示特征词在文本中出现的频率^[36]。TF 的计算公式如式(3.1)所示：

$$TF_{d,t} = \frac{m}{M}, \quad (3.1)$$

式(3.1)中，分子表示某个词语 t 在文档 d 中出现的频数大，分母为文档 d 所包含的词汇总数量。

如果某个词在某个文档中出现的次数比较多。那么表明这个特征词能够更全面的描述文档所代表的信息，更适合用作当分类的特征词。如果只有 TF，那么对于一些文本来说，如果文本中有太多对于文本信息无关的介词、停用词等，那么会对于分类产生很大的干扰。

IDF 是逆向文档频率，如果包含某个特征词的文档比较多的话，那么该特征词的

分类重要性比较弱。如果包含某个特征词的文档比较少的话，那么说明该特征词的分类重要性比较高。可以降低某些不太重要的特征词的权重，并且可以提升某些重要特征词的权重。IDF 公式如式(3.2)所示：

$$IDF_{d,t} = \log\left(\frac{N}{n_t} + 0.01\right), \quad (3.2)$$

式(3.2)中， N 为语料库中的包含的文本总数， n_t 表示包含特征词 t 的文本数量^[37]，式(3.2)中加上 0.01 主要为了防止 $\log$ 函数结果为 0。那么 TF-IDF 的值即为式(3.3)：

$$TF-IDF = TF * IDF = \frac{m}{M} * \log\left(\frac{N}{n_t} + 0.01\right). \quad (3.3)$$

总的来说，TF-IDF 算法是一种类似于词袋模型的算法，文本在分词后可以用 TF-IDF 计算的词语的特征权重值并进行向量化表示。

3.1.2 基于新闻文本特点改进的 TF-IDF 词向量

由于 TF 仅仅从词频方面考虑了文本所包含的信息，忽略了文本结构信息，上下文的联系等问题。经典的计算并没有考虑文本的长度以及文本分词后包含的词语个数带来的量纲化的问题。

比如文本 A 有 15 个单词，文本 B 只有 5 个单词，假如“建设”这个词汇在这两个文档中都同样出现过 3 次，那么这里出现的 3 次在文档 A 和文档 B 中不能是起到同等大小的重要作用。明显对于文档 B 来说，“建设”这个词汇更加重要。其实，这种关系几乎很难说明是呈现线性的。

本文考虑两种对 TF 的改进方式：

一是进行“标准化”，即对传统的 TF 进行标准化处理，可以在一定程度上消除文本长度的不同带来的量纲上的影响。

二是考虑到 TF 的原始计算方式在原始定义中没有最大的上限阈值。虽然，一般情况下认为如果一个文档多次包含某个关键词，那么一般来说，这个关键词可能和这个文档的相关度比较高，但这种关系几乎很难说明二者之间一定是呈现线性的。通过对 TF 取对数，利用数学函数中的对数函数的特点来避免 TF 的线性增长趋势。对于改进方式一，对 TF 进行标准化，改进后的 TF 简称 STF (Standard TF)，计算

方式如式(3.4):

$$STF(i) = \frac{\max(TF) - TF(i)}{\max(TF) - \min(TF)}, \quad (3.4)$$

式(3.4)中的 TF 计算方式即式(3.1), $\max(TF)$ 即对应文本中所有词汇中最大的 TF 值, $\min(TF)$ 即对应文本中所有词汇中最小的 TF 值。

对于改进方式二, 对 TF 取对数, 改进后的 TF 简称 $\log(TF)$, 计算方式如式(3.5):

$$\log(TF) = 1 + \lg(TF), \quad (3.5)$$

式(3.5)中的 TF 计算方式即式(3.1), $\lg(TF)$ 即对 TF 值取以 10 为底的对数, 加 1 是为了防止 $\lg(TF)$ 的值为 0。

3.2 分类模型的构造

分类器的构造过程如下: 首先利用打上已知标签的训练集进行有规则的训练得到一个最优化的分类器, 然后对其他未分类的样本进行分类处理并输出分类结果。

对于文本分类来说, 训练样本的结构是否清晰, 是否存在可提取的特征, 是否有噪音或者异常值, 分类类别的差别是否鲜明可分都会影响分类结果。所以对于不同的样本集, 分类的计算方法与分类模型是不固定的^[38]。

本文首先利用 jieba 分词对文本进行分词处理, 其次是去表情符或特殊字符, 将这些与分类无关的符号去除。然后利用 TF-IDF 算法计算词向量, 得到词向量矩阵, 将词向量矩阵嵌入分类器中进行分类模型的训练。一般流程大致如下图 3.1 所示:




图 3.1 分类流程图示

3.3 数据集介绍与预处理

本节首先对数据集 THUCNews 的来源和类别等信息进行了介绍，并选择 THUCNews 的子集作为本文的实验数据集。然后是数据集预处理部分，预处理主要包括对文本的统计分析、jieba 分词以及去表情符、特殊字符和停用词等。

3.3.1 数据集介绍

THUCNews 是清华自然语言处理组提供的，总共包含了七十四万篇新闻文本集，共 14 个类别。本文采用了 THUCNews 新闻文本分类数据集的一个子集 Cnews，该数据集使用了其中的 10 个类别，每个类别共 5000 条，总共 50000 条新闻数据。Cnews 数据集部分示例如下表 3-1：

表 3-1 Cnews 数据集部分示例

类别	内容
体育	马晓旭受伤让国奥警惕，无奈大雨青睐殷家军记者傅亚雨沈阳报道...
科技	102 亿光年发现最遥远星系(图)新浪科技讯...
娱乐	阮经天新片盗版影响票房新浪娱乐讯 昨日(25 日)，台湾人气偶像阮经天(小天)与赵又...

Cnews 共财经，体育，家居，房产，科技，时尚，教育，游戏，娱乐，时政 10 个类别，每个类别的样本量均为 5000。表 3-1 为数据集的部分示例，第一列为数据集类别，第二列为新闻内容，训练集共 5 万条，测试集共 1 万条。

3.3.2 数据集预处理

本文训练集和测试集的比例为 5:1，分别为 5 万条训练集和 1 万条测试集样本。本节是对数据集文本进行的预处理工作，包括 jieba 分词、去除表情符号、去除停用词和特殊字符。

jieba 分词是根据已有的词典按照一定的规则对句子进行分词，对于不在词典中的词语采用新词发现的方式进行识别。本文的数据集经过 jieba 分词后的结果如表 3-2

所示：

表 3-2 去表情符、去停用词后的分词样例

类别	分词结果
体育	[马晓旭, 意外, 受伤, 让, 国奥, 警惕, 无奈, 大雨, 格外, 青睐]
体育	[商瑞华, 首战, 心切, 要, 攻克]

首先读入数据，统计样本数，划分训练集和测试集（分别为 5 万和 1 万条样本，共 10 个类别）。然后对文本进行 jieba 分词，对分词后的文本进行去表情字符（只保留中英文和数字）和停用词（“的”、“了”、“啊”、“哟”等）和复杂字符的去除（如《》、|、^、#、http:/、@等）。最后再对词频和句子进行一些数据分析和统计，预处理工作流程图如图 3.2 所示：




图 3.2 预处理工作流程

利用 python 语言自带的 pandas 库读入 txt 文本数据，然后对文本数据集进行训练集和测试集的划分，训练集与测试集共 10 个类别。在样本数量方面，训练集和测试集的比例为 5:1，共 6 万条文本数据。首先，对新闻文本的进行一些频数统计和长度与字数的描述性统计分析，得到文本数据集的数据分布情况与特征等。然后，利用 jieba 分词库对文本进行分词。由于分词后的文本包含了很多复杂字符和停用字，

于是对文本中的复杂字符和特殊字符进行过滤（如《》、|、^、#、网址链接、@等）。利用停用词表对“的”、“了”、“啊”、“哟”等这些停用词进行过滤，避免这些词和符号的存在会影响文本的向量化和分类。图 3.3 是对数据集的新闻文本长度统计的分布图：




图 3.3 新闻文本长度统计直方图

表 3-3 训练集数据特征统计

统计量	数值	统计量	数值
count	50000	std	930
Mean	913	25%	350
min	8	50%	688
75%	1154	max	27467

通过对训练集的新闻文本长度进行统计和分析，新闻文本长度集中在 0-5000 这个范围内。文本长度最短的长度是 8 个字符，文本长度最短的长度是 27467 个字符，平均长度值为 913 个字符，共 50000 个样本。通过上述统计可以得出以下结论：

(1) 每个新闻包含的字数平均为 913 个，还有一些新闻字符较长，可能需要截断。

(2) 训练集和测试集类别个数分布均匀，共 10 个类别，每个类别占比相同，训练集和测试集比例为 5:1。

由于文本长度较长，本文截取了包括新闻标题在内的最多 30 个字符，对截取后的短文本进行文本分类实验。然后对分词后的文本进行了词语个数统计，得到每个文本单词的个数分布如图 3.4 所示，可以得出以下结论：

(1) 截断后再进行分词的文本所包含的单词数最少的仅有 2 个单词，包含单词数最多的文本有 21 个单词。

(2) 大部分文本所含的单词数集中在 12-15 个左右。




图 3.4 分词后文本单词个数统计直方图

3.4 TF-IDF 模型实验结果

本节利用 TF-IDF 模型对数据集进行关键词权重提取和词向量化，并且将词向量

化结果嵌入逻辑回归模型中进行分类实验。同时根据关键词的权重大小调整 TF-IDF 算法中最大词频的阈值^[39]，找到了 TF-IDF 词向量化模型的最优参数，最后对算法结果进行了分析与评价。

TF-IDF 训练及关键词抽取其部分权重提取结果下表 3-4 至 3-6 所示，提取的是前 $n=5$ 个关键词：

表 3-4 体育类 TF-IDF 权重计算结果

体育	TF-IDF 权重
体育讯	0.775
新浪	0.620
火箭	0.096
热火	0.093
湖人	0.081

表 3-5 娱乐类 TF-IDF 权重计算结果

娱乐	TF-IDF 权重
新浪	0.460
娱乐	0.440
组图	0.074
电影	0.066
新片	0.056

表 3-6 房产类 TF-IDF 权重计算结果

房产	TF-IDF 权重
楼市	0.071
北京	0.067
记者	0.063
房价	0.051
本报讯	0.050

表 3-7 教育类 TF-IDF 权重计算结果

教育	TF-IDF 权重
留学	0.250
组图	0.139
美国	0.090
留学生	0.080
移民	0.073

如表 3-4、表 3-5、表 3-6、表 3-7 所示，体育类的 TF-IDF 算法计算结果的前五个关键词为体育讯、新浪、火箭、热火、湖人。娱乐类的 TF-IDF 算法计算结果的前五个关键词为新浪、娱乐、组图、电影、新片。房产类的 TF-IDF 算法计算结果的前五个关键词为组图、家居、风格、客厅、空间。

将 TF-IDF 词向量化后的提取的特征矩阵嵌入逻辑回归模型中，得到的在各类别中和在整体数据集中的分类结果所表 3-8 与 3-9 所示：

表 3-8 基于 TF-IDF 词向量化的逻辑回归类别分类结果

类别	precision	recall	F 值
体育	99.32%	94.16%	96.67%
娱乐	96.58%	87.44%	91.78%
家居	80.30%	88.78%	84.33%
房产	78.94%	89.44%	83.86%
教育	88.73%	86.42%	87.56%
时尚	86.91%	88.94%	87.91%
时政	82.11%	89.96%	85.86%
游戏	89.36%	94.26%	91.75%
科技	94.77%	79.08%	86.22%
财经	92.61%	85.74%	89.04%

表 3-9 基于 TF-IDF 词向量化的逻辑回归整体分类结果

指标计算类别	precision	recall	F 值
平均值	88.96%	88.42%	88.50%
加权平均	88.96%	88.42%	88.50%

分类结果由 Pycharm 输出，基于 python 编程语言，Anaconda 编程环境。结果如

表 3-8 与表 3-9 所示，从表 3-8 和表 3-9 以及输出结果可以得到以下结论：

(1) 整体的分类准确率为 88.42%，精确率为 88.96%、召回率为 88.42%、F 值为 88.50%。

(2) 由于每个类别的样本量相同，因此如表 3-10 所示，整体的分类指标的平均值与加权平均值是相同的。

(3) 在房产、家居、时政等类别上的分类评价指标表现弱于其他类别的，其中房产的精准率为 78.94%，家居的精准率为 80.30%，时政的准确率为 82.11%。而分类效果最好的类别是体育，三个指标的表现都很好，其中精确率达到 99.32%、召回率达到 94.16%、F 值达到 96.67%。




图 3.5 基于 TF-IDF 词向量化的逻辑回归分类混淆矩阵

图 3.5 为基于 TF-IDF 词向量化的逻辑回归分类混淆矩阵，其中对角线上的红框里的数据为正确分类的样本数^[40]。从图 3.5 可以得到以下结论：

- (1) 每个类别被正确分类的样本数（即对角线上的数据）都有 4000 以上。
- (2) 体育的正确分类样本数最多，有 4781 个。其次是游戏，正确分类样本数有 4685。

TF-IDF 模型的主要参数设置如下表 3-10 所示：

表 3-10 TF-IDF 模型的参数设置

参数	值
binary	False
token_pattern	r"(?u)\b\w+\b"
max_df	0.78

其中，binary 为布尔值，设置为 False。如果为 True，则所有非 0 词特征都被置为 1，由于这里是多分类（10 个类别），因此 binary 被设置为 False。token_pattern 为正则化方式，标点符号完全被忽略，始终被视为一个标记分隔符。max_df 为最大词频，当词语的频率大于 max_df 时，将不会被计入 TF-IDF 模型中进行特征向量提取^[41]。这里首先选择 max_df=0.78，原因是 TF-IDF 提取的关键词的最大词频为 0.78，对应的词语为体育。

通过 TF-IDF 关键词提取的词频发现，大部分关键词的词频都低于 0.1，因此本文通过该表 TF-IDF 模型的 max_df 值来调整实验结果，实验结果如图 3.6 所示：




图 3.6 max_df 在[0,0.1]范围内对应的分类结果准确率

如图 3.6 所示, 当 max_df 在 0-0.1 这个范围内, 准确率曲线的最高点在 $\text{max_df}=0.06$ 时, 其对应的准确率达到 91.06%, 输出的召回率、F 值分别为 90.72%、90.76%, 相比 $\text{max_df}=0.78$ 时有所提升。因此, 最后得到的 TF-IDF 模型的最优模型参数如表 3-11 所示:

表 3-11 TF-IDF 模型的最终参数设置

参数	值
binary	False
token_pattern	<code>r"(?u)\b\w+\b"</code>
max_df	0.06

3.5 本章小结

本章介绍了 TF-IDF 的词向量化方法, 利用 TF-IDF 模型来提取文本的词向量特征。同时结合新闻文本的特点对 TF-IDF 中的 TF 计算方式进行改进, 分别考虑到文本长度的不同量纲和特征词的 TF 值对文档的重要程度不一定是线性关系, 提出分别对 TF 的计算方式进行标准化与取对数。标准化可以消除量纲的影响, 取对数可以在一定程度降低 TF 对词频重要度的线性增长趋势。其次是介绍了本文所选用的数据集, 即清华大学 NLP 实验室的 THUCnews 数据集对应的子集 Cnews, 共 10 个类别, 并对数据集 Cnews 进行了预处理和数据分析。预处理包括 jieba 分词、去表情符和特殊字符等, 数据分析主要是对文本长度和词汇数量进行了一定的描述性统计并得出一些结论。

然后是对 TF-IDF 词向量模型进行了实证分析, 采用逻辑回归分类器, 将 TF-IDF 提取的词向量嵌入逻辑回归分类器中。TF-IDF 模型的最大词频参数采用的是 TF-IDF 提取的最大关键词词频作为阈值(即 0.78), 得到的准确率为 88.96%、召回率为 88.42%、F 值为 88.50%。当考虑到关键词的词频时, 调整了 TF-IDF 模型的最大词频阈值, 当最大词频阈值(即 max_df)为 0.06 时, 实验效果达到最优, 相比于 $\text{max_df}=0.78$ 时, 准确率、召回率、F 值分别提升了 2.10%、2.30%、2.26%。

4 实验结果与对比分析

本章首先对改进的 TF-IDF 进行介绍和实证分析，对比了三种 TF-IDF 词向量化模型的分类结果。然后将三种 TF-IDF 词向量化模型与 Word2vec 的分类结果进行对比和算法评价，进一步验证了改进的 TF-IDF 词向量化模型在新闻短文本分类上的优势。最后利用 Voting 融合原理验证了模型融合在一定程度上比单个分类器效果更好。

4.1 改进 TF-IDF 模型的介绍与实验

本节首先对改进的 TF-IDF 进行了介绍，包括改进原理和计算方式的介绍。然后对改进 TF-IDF 模型进行了实验，并且与传统 TF-IDF 模型进行了对比，进一步验证了改进 TF-IDF 词向量模型在特征提取上的优势。

4.1.1 改进 TF-IDF 模型的介绍

由于本文预处理后的文本，最长有 21 个单词，最短的只有 2 个单词。经典的计算并没有考虑文本的长度以及文本分词后包含的词语个数带来的量纲方面的影响^[42]，本节将对改进 TF-IDF 模型进行详细的介绍。

本文考虑两种对 TF 的改进方式，一是进行“标准化”，即对传统 TF 的值进行标准化处理。标准化方式如下式(4.1)所示：

$$STF(i) = \frac{\max(TF) - TF(i)}{\max(TF) - \min(TF)}, \quad (4.1)$$

式(4.1)中， $\max(TF)$ 即对应文本中所有词汇中最大的 TF 值， $\min(TF)$ 即对应文本中所有词汇中最小的 TF 值。

二是考虑到传统的 TF 值在传统的定义中没有任何的上限值。举个例子，如果文本库中的一个文档包含某一个关键词很多次，那么相对来说，可以认为该关键词和这个文档之间存在了某种意义上的相关性，但这样的相关性很难说是线性的。那么，本文通过对 TF 取对数，通过对数函数来避免 TF 的线性增长。计算方式如下式(4.2)所示， $\lg$ 即以 10 为底的对数，加 1 是为了防止 $\lg(TF)$ 的值为 0：

$$\log(TF) = 1 + \lg(TF). \quad (4.2)$$

分别采用标准化 TF-IDF、 $1+\text{Log}(\text{TF})_IDF$ 、传统 TF-IDF 的方式提取词向量特征，嵌入逻辑回归分类器中，得到的实验的结果如下文所示。实验是在 Windows10 环境中进行，使用 PyCharm2021 编程工具与 Anaconda 环境，调用 python 自带的 sklearn、numpy、pandas、Matplotlib、gensim、jieba 等库^[43]。

4.1.2 改进 TF-IDF 模型的实验结果

本节首先对改进的 TF-IDF 词向量模型（即标准化 TF-IDF 和 $1+\text{Log}(\text{TF})_IDF$ ）进行了分类实验，也就是将改进的 TF-IDF 词向量模型训练得到的词向量矩阵嵌入逻辑回归分类器中进行分类^[44]。然后与传统的 TF-IDF 词向量模型的逻辑回归分类实验结果进行了对比和算法评价。

本实验的数据集为清华大学 NLP 实验室的开源数据集 THUCNews 的子集 Cnews。在样本数量方面，训练集：测试集是 5:1，分别为 50000 与 10000 条样本，共 10 个类别。截断后的每段文本的长度大概在 10-20 之间，首先采用 python 自带的 jieba 库进行分词，进行去表情字符（只保留中英文和数字^[45]）、去停用词（“的”、“了”、“啊”、“哟”等）和去复杂字符的去除（如《》、|、^、#、http:/、@等）。一般的工作流程大致如下图 4.1 所示：




图 4.1 改进 TF-IDF 模型的实验分析流程

首先是标准化 TF-IDF 的逻辑回归分类实验，实验结果如表 4-1 所示：

表 4-1 标准化 TF-IDF 的逻辑回归分类实验结果

类别	precision	recall	F 值
体育	99.84%	99.42%	99.63%
娱乐	98.54%	98.54%	98.54%
家居	96.45%	97.92%	97.18%
房产	95.98%	96.86%	96.42%
数育	97.21%	96.96%	97.09%
时尚	98.33%	97.72%	98.02%
时政	95.08%	97.42%	96.24%
游戏	98.56%	98.44%	98.50%
科技	97.77%	95.60%	96.67%
财经	97.33%	96.10%	96.71%

然后是 $1+\text{Log}(\text{TF})_IDF$ 的逻辑回归分类实验，实验结果如表 4-2 所示：

表 4-2 $1+\text{Log}(\text{TF})_IDF$ 的逻辑回归分类实验结果

类别	precision	recall	F 值
体育	99.84%	99.46%	99.63%
娱乐	98.54%	98.54%	98.54%
家居	96.45%	97.92%	97.18%
房产	95.98%	96.86%	96.42%
数育	97.21%	96.96%	97.09%
时尚	98.33%	97.72%	98.02%
时政	95.08%	97.42%	96.24%
游戏	98.56%	98.44%	98.50%
科技	97.77%	95.60%	96.67%
财经	97.33%	96.10%	96.71%

最后是三种不同 TF-IDF 方式的逻辑回归分类实验结果对比：

表 4-3 三种不同 TF-IDF 方式的逻辑回归分类实验结果

模型	precision	recall	F 值
传统 TF-IDF	91.06%	90.72%	90.76%
标准化 TF-IDF	97.51%	97.50%	97.50%
$1+\text{Log}(\text{TF})_IDF$	97.52%	97.51%	97.51%

在分类算法的评估中，由于 precision 和 recall 之间有相互的影响关系，而 F 值是二者的调和平均^[46]，可以通过 F 值的大小来衡量总和的分类结果。

从表 4-1 至表 4-3 可以得到以下结论：

(1) 标准化 TF-IDF 和 $1+\text{Log}(\text{TF})_IDF$ 词向量模型的逻辑回归分类效果较好，每个类别的分类精准率、召回率、F 值都在 95%以上。

(2) 标准化 TF-IDF 和 $1+\text{Log}(\text{TF})\text{-IDF}$ 词向量模型分类效果相比于传统 TF-IDF 词向量模型来说, 分类效果更好, 准确率提升了大概 7%。

三种不同 TF-IDF 方式的 python 核心代码和具体实现代码如下:

```
57 def feature_select(dataset):
58     doc_frequency = defaultdict(int)
59     for file in dataset:
60         for word in file:
61             doc_frequency[word] += 1
62     word_tf = {} # 存储每个词的tf值
63     for i in doc_frequency:
64         word_tf[i] = doc_frequency[i] / sum(doc_frequency.values()) #传统TF计算方式
65         word_log_tf[i] = log(doc_frequency[i] / sum(doc_frequency.values())) #对TF取Log
66         word_stf[i] = (max(doc_frequency.values())-doc_frequency[i])/(max(doc_frequency.values())-min(doc_frequency.values())) #对TF标
67     doc_num = len(dataset)
68     word_idf = {} # 存储每个词的idf值
69     word_doc = defaultdict(int) # 存储包含该词的文档数
70     for word in doc_frequency:
71         for file in dataset:
72             if word in file:
73                 word_doc[word] += 1
74     for word in doc_frequency:
75         word_idf[word] = math.log(doc_num / (word_doc[word] + 1))
76     for word in doc_frequency:
77         word_tf_idf[word] = word_tf[word] * word_idf[word]
78     dp = [[] for i in range(50000)]
79     for line in range(len(dataset)):
80         for word in range(len(dataset[line])):
81             word = word_tf_idf.get(dataset[line][word])
82             dp[line].append(word)
83     return dp
```

图 4.2 改进 TF-IDF 具体实现的 python 核心代码

图 4.2 为改进 TF-IDF 的具体实现过程的 python 核心代码, 包含了 TF 的计算过程, 改进 TF 的计算过程, 和 IDF 的计算过程。最后将计算得到的改进 TF 值与 IDF 值做乘积, 实现最终的改进 TF-IDF 值的计算。

4.2 分类模型的对比与分析

为了检验分类模型的效果, 找到适合分类的算法模型, 进行了以下的实验设计: 将不同词向量模型与 TF-IDF、标准化 TF-IDF、 $1+\log(\text{TF})\text{-IDF}$ 进行对比, 这里采用与以上三种方法进行对比的词向量模型是 Word2vec 词向量化模型。同时, 引入不同分类算法进行对比, 主要有支持向量机、朴素贝叶斯、梯度提升算法、逻辑回归等。

在 Cnews 数据集中, 训练集: 测试集为 5:1。首先对文本进行 jieba 分词、去表情符和复杂字符、去停用词等处理。然后分别采用 Word2vec 和三种不同的 TF-IDF 方法进行词向量矩阵的提取, 将词向量矩阵嵌入分类模型中进行训练。最后利用算

法评价分析指标对模型进行评价与结果的分析。

4.2.1 不同 TF-IDF 在不同分类模型中的实验结果

本节利用三种 TF-IDF 提取文本词向量（即传统 TF-IDF、标准化 TF-IDF、 $1+\text{Log}(\text{TF})_IDF$ ），这里采用最大词频阈值^[47]（即 max_df ）为 0.06 对词语进行过滤（上文已验证当 $\text{max_df}=0.06$ 时，分类效果达到最优），即对词频大于 0.06 的词语进行过滤。然后利用逻辑回归、支持向量机和朴素贝叶斯等算法进行分类实验。

首先是逻辑回归分类算法的实验结果：

表 4-4 三种不同 TF-IDF 在逻辑回归模型中的分类实验结果

词向量模型	precision	recall	F 值
传统 TF-IDF	91.06%	90.72%	90.76%
标准化 TF-IDF	97.51%	97.50%	97.50%
$1+\text{Log}(\text{TF})_IDF$	97.52%	97.51%	97.51%

表 4-4 中，用准确率、召回率和 F 值这三个指标来对算法进行评价和分析。三者的值越大，实验效果越好。具体计算过程可以参考 2.5 节中的计算公式。

由上表 4-4 可以得到以下结论：

- (1) $1+\text{Log}(\text{TF})_IDF$ 训练的词向量在逻辑回归模型中分类效果最优，标准化 TF-IDF 训练得到的词向量在分类效果上略低 $1+\text{Log}(\text{TF})_IDF$ 。
- (2) 传统的 TF-IDF 训练的词向量在逻辑回归模型中的分类效果弱于标准化 TF-IDF、 $1+\text{Log}(\text{TF})_IDF$ 。

接下来是在支持向量机分类器中的实验结果。通过模型的训练，当支持向量机模型中的核函数参数选用 rbf 函数，间隔选择软间隔时，分类效果达到最优。

表 4-5 三种不同 TF-IDF 在支持向量机模型中的分类实验结果

词向量模型	precision	recall	F 值
传统 TF-IDF	99.76%	99.76%	99.76%
标准化 TF-IDF	99.82%	99.81%	99.81%
$1+\text{Log}(\text{TF})_IDF$	99.83%	99.83%	99.83%

从表 4-5 可以看出，首先，在支持向量机模型中，三种 TF-IDF 的分类准确率都在 99% 以上，其中 $1+\text{Log}(\text{TF})_IDF$ 效果最好，其次是标准化 TF-IDF。然后，两种改

进后的 TF-IDF 的实验效果都略优于传统 TF-IDF。

其中支持向量机模型的参数如下表 4-6:

表 4-6 支持向量机模型的参数设置

参数	值
degree	3
kernel	'rbf'
gamma	'auto'
C	1

表 4-6 中, degree 默认为 3。惩罚参数 C, 当 C=1 时, 选择软间隔, 这种情况适合多分类的情况。Kernel 即核函数^[48], 这里选择 rbf 核函数。gamma 为核函数的对应参数, 选择 auto, 表示设置为默认值。

最后是在朴素贝叶斯模型中的分类结果, 朴素贝叶斯模型原理简单, 分类直观易懂, 结果如下表 4-7 所示:

表 4-7 三种不同 TF-IDF 在朴素贝叶斯模型中的分类实验结果

词向量模型	precision	recall	F 值
传统 TF-IDF	95.07%	94.97%	94.98%
标准化 TF-IDF	96.87%	96.84%	96.84%
1+Log(TF) IDF	96.88%	96.85%	96.88%

从表 4-7 可以看出: 首先, 在朴素贝叶斯模型中 1+Log(TF)_IDF 训练得到的词向量的分类效果最好, 其次是标准化 TF-IDF。然后, 两种改进后的 TF-IDF 的实验效果都优于传统 TF-IDF。




图 4.3 三种不同 TF-IDF 在不同分类模型中的分类效果

根据图 4.3 可以得到以下结论：

- (1) 在词向量化方式上，三种不同 TF-IDF 方法的效果有所差异，其中， $1+\log(\text{TF})_{\text{IDF}}$ >标准化 TF-IDF>传统 TF-IDF。
- (2) 在分类模型中，支持向量机的效果最优，其次是逻辑回归，最后是朴素贝叶斯。
- (3) 对于不同词向量方式和不同分类模型来说，分类实验的准确率均在 90%以上，最高的可以达到 99.83%，最低的也有 91.06%，说明分类实验的效果较好。

4.2.2 Word2vec 在不同分类模型中的实验结果

本节利用传统 Word2vec 提取文本词向量，探究 Word2vec 提取的词向量在不同分类模型中的分类效果，并且进行对比和分析。通过采用 Word2vec 的两种不同模型（即 CBOW 和 Skip-Gram）来训练词向量，利用支持向量机、朴素贝叶斯、梯度提升算法、逻辑回归进行分类。结合本文的数据集特点，Word2vec 的模型参数设置如下：

表 4-8 Word2vec 词向量模型的主要参数设置

参数	值
sg	1
window	3
min_count	1
workers	5

表 4-8 中，sg=1 是表示选用 Skip-Gram 算法进行特征提取，由于 Skip-Gram 算法对低频词敏感^[49]，同时大部分该文本库中的大部分词频都比较低，这里考虑采用 Skip-Gram 模型。window 表示句子中当前词汇距离目标特征词的最大步数^[50]，默认为 3。min_count 是最小词频数，由于很多词语出现频数仅 1 次，故选 min_count=1。workers 是线程数，选择 5 表示多线程，可以提高计算效率，否则只能使用单核。

下面是 Word2vec 提取“体育”的词向量结果，词向量共 100 维(函数默认为 size=100)：

$$\begin{bmatrix} -0.60641176 & -0.26776057 & 0.14847001 & 0.06141708 & -0.5401925 & 0.3197649 \\ 0.3399646 & 0.19315265 & \dots & \dots & \dots & \dots \end{bmatrix}$$

通过 Word2vec 提取的词向量矩阵，每个文本包含了 $n \times 100$ 维的高维向量。通过对高维向量（维度为 $n \times 100$ ， n 为词汇个数）取平均值来获取文本的低维向量（维度为 1×100 ），因此每个文本被表示为 1 个 100 维的向量。

首先对比 Word2vec 中 Skip-Gram 和 CBOW 两种不同模型的词向量化分类效果。利用 jieba 分词后，进行去表情符和特殊字符的处理，分别采用 Skip-Gram 和 CBOW 两种不同方式来提取文本的词向量，将两种不同方式提取的词向量嵌入逻辑回归分类器中进行效果的对比：

表 4-9 两种不同 Word2vec 模型在 LR 中的分类实验结果

词向量模型	precision	recall	F 值
Skip-gram	86.77%	86.72%	86.73%
CBOW	83.28%	83.25%	83.24%

从表 4-9 可以看出：Skip-Gram 相比于 CBOW 来说，在准确率、召回率、F 值上的效果都有更优的表现。其实，有这样的结果并不意外，因为 Skip-Gram 算法相比于 CBOW 来说，其对低频词敏感，而本文的数据集共五万，词汇量在十万级别以上，而大部分词汇出现次数仅为个位数，词频都比较低，因此 Skip-Gram 算法相比于 CBOW 来说，更适合存在大量低频率词语的文本数据集。

通过 Word2vec 的 Skip-Gram 算法，提取词向量，得到高维词向量矩阵（维度为 $n \times 100$ ， n 为词汇个数）。通过对高维向量取平均值来获取文本的低维向量（维度为 1×100 ），从而得到每个文本的向量，于是，每个文本被表示为 1 个 100，训练时长大概在 320s 左右。将文本向量分别嵌入逻辑回归、支持向量机、朴素贝叶斯分类模型中进行分类。

三种分算法类模型的分类效果对比如下表 4-10 所示：

表 4-10 Word2vec 词向量模型在不同分类模型中的分类实验结果

分类模型	precision	recall	F 值
逻辑回归	86.77%	86.72%	86.73%
支持向量机	88.41%	88.25%	88.27%
朴素贝叶斯	74.09%	74.06%	74.07%

利用 Word2vec 的 Skip-Gram 词向量模型得到的词向量矩阵，分别在逻辑回归、支持向量机、朴素贝叶斯上的分类效果如表 4-10 所示。

从表 4-10 可以得到以下结论：支持向量机分类器的效果最好，准确率在 88%左右，效果由于朴素贝叶斯和逻辑回归。朴素贝叶斯的分类效果不是很理想，准确率低于 80%。由于朴素贝叶斯分类器的实验效果不太理想，通过引入 GB 算法（即梯度提升算法），来进行进一步的分类实验。

GB 算法的主要思想是通过迭代生成 M 个弱分类器，然后将弱分类器的结果相加，第 M+1 个模型是基于前 M 个弱分类器的效果生成的，即常见的残差学习。通过残差学习的方式，不断更新模型，来优化或者最小化损失函数，能有效的运用到分类场景中。GB 模型的参数设置如下表 4-11 所示：

表 4-11 GB 模型的主要参数设置

参数	值
learning_rate	0.1
max_depth	7
max_features	'sqrt'
subsample	0.8

Skip-Gram 提取的词向量在 GB 模型中的各类别分类效果如下表 4-12 所示：

表 4-12 Skip-Gram 词向量模型在 GB 模型中的分类实验结果

类别	precision	recall	F 值
体育	99.86%	99.96%	99.91%
娱乐	97.85%	98.44%	98.15%
家居	97.32%	96.64%	96.98%
房产	92.66%	94.90%	93.77%
数育	96.74%	97.18%	96.96%
时尚	98.10%	97.86%	97.98%
时政	96.34%	97.36%	96.85%
游戏	97.03%	98.10%	97.56%
科技	97.50%	96.10%	96.80%
财经	96.63%	93.38%	94.98%

表 4-13 基于 Skip-Gram 词向量化的 GB 模型整体分类结果

指标计算类别	precision	recall	F 值
平均值	97.00%	96.99%	96.99%
加权平均	97.00%	96.99%	96.99%

从表 4-12 和表 4-13 可以得到以下结论：

(1) 利用 Skip-Gram 提取的词向量在 GB 模型中的分类效果不仅在各类别上的表现很好，而且在整体上也可以高达 97% 的准确率。

(2) GB 模型分类效果优于 NB 模型，基于 Skip-Gram 词向量化矩阵在 GB 模型上的分类效果较好，准确率可以高达 97%。

4.2.3 TF-IDF 与 Word2vec 的分类效果对比

由于上文分别对三种 TF-IDF 词向量模型和 Word2vec 词向量模型的在不同分类器中的分类效果做了实证分析，因此在本节对上述实验结果进行了汇总与对比分析。

表 4-14 TF-IDF 与 Word2vec 在不同模型中的分类实验结果

词向量模型	NB 准确率	SVM 准确率	LR 准确率
传统 TF-IDF	95.07%	99.76%	91.06%
标准化 TF-IDF	96.87%	99.82%	97.51%
1+log(TF)_IDF	96.88%	99.83%	97.52%
Word2vec	74.09%	88.41%	86.77%

从表 4-14 可以得到以下结论：

(1) 在各种分类器中，从词向量模型的角度来说，1+log(TF)_IDF 效果最优，其次是标准化 TF-IDF 和传统 TF-IDF，三种不同的 TF-IDF 的词向量方法在分类器中的实验效果都由于 Word2vec。说明了 TF-IDF 词向量化在特征提取方面有不错的效果。

(2) 改进的 TF-IDF 即 1+log(TF)_IDF 和标准化 TF-IDF 相比于传统的 TF-IDF 方法，针对长度较短的新闻文本数据集来说，有一定的提升，准确率大概提升了 1.81% 左右。

4.3 分类模型的融合

由于上文探究了朴素贝叶斯、支持向量机、逻辑回归和梯度提升算法等分类算法的实验效果，本节考虑使用 Voting 融合的方式，探究模型融合的分类效果。通过将多个单分类模型进行模型融合，对比 Voting 融合与单个分类模型分类效果并进行算法的评价，具体工作流程如下：




图 4.4 Voting 模型融合实验流程图

Voting 是一种通过投票的来进行模型融合的方式，有软投票和硬投票两种方式。Voting 是一种比较快速的模型融合方法，直接根据已有模型的预测结果进行投票即可。本文利用 Voting 融合，将三种不同的分类器进行融合，对分类的实验效果进行进一步探究：

对于改进的 TF-IDF 算法（即 $1+\log(\text{TF})_{\text{IDF}}$ ），本文将朴素贝叶斯、支持向量机、逻辑回归三种分类器进行融合，这里采用软投票的方式。实验结果如下：

```
<class 'sklearn.linear_model._logistic.LogisticRegression'> 0.9752
<class 'sklearn.svm._classes.SVC'> 0.9976
<class 'sklearn.naive_bayes.MultinomialNB'> 0.94974
<class 'sklearn.ensemble._voting.VotingClassifier'> 0.9968
```

图 4.5 $1+\log(\text{TF})_{\text{IDF}}$ 的 Voting 融合结果

从图 4.5 可以得到以下结论：

(1) 融合之前，逻辑回归的准确率为 97.52%，支持向量机的准确率为 99.76%，朴素贝叶斯的准确率为 94.97%。

(2) 融合之后，Voting 投票融合实验的分类准确率有 99.68%。对于 $1+\log(\text{TF})_{\text{IDF}}$

来说, Voting 融合的实验效果明显优于单个的逻辑回归分类器和朴素贝叶斯分类器。

对于 Word2vec 来说, 本文将梯度提升、支持向量机、逻辑回归三种分类器进行融合, 这里同样采用软投票的方式。实验结果如下:

```
<class 'sklearn.linear_model._logistic.LogisticRegression'> 0.8674  
<class 'sklearn.svm._classes.SVC'> 0.88048  
<class 'sklearn.ensemble._gb.GradientBoostingClassifier'> 0.97058  
<class 'sklearn.ensemble._voting.VotingClassifier'> 0.91418
```

图 4.6 Word2vec 的 Voting 融合结果

从图 4.6 可以得到以下结论:

(1) 融合之前, 逻辑回归的准确率为 86.74%, 支持向量机的准确率为 88.05%, 梯度提升的准确率为 97.06%。

(2) 融合之后, Voting 的融合实验准确率达到 91.41%。对于 Word2vec 来说, Voting 融合的实验效果明显优于单个的逻辑回归分类器和支持向量机分类器。

综上, 对所有的实验结果进行汇总, 得到表 4-15, 从表 4-15 可以直观看出所有不同实验模型的实验效果:

表 4-15 TF-IDF 与 Word2vec 在不同模型中的分类准确率汇总

词向量模型	NB	SVM	LR	GB	Voting
传统 TF-IDF	95.07%	99.76%	91.06%	-	92.34%
标准化 TF-IDF	96.87%	99.82%	97.51%	-	99.65%
1+log(TF)_IDF	96.88%	99.83%	97.52%	-	99.68%
Word2vec	-	88.41%	86.77%	97.06%	91.41%

从表 4-15 可以得到以下结论:

(1) 对于不同的分类器来说, 1+log(TF)_IDF 和标准化的 TF-IDF 词向量方法的分类效果都优于传统的 TF-IDF 和 Word2vec。

(2) 对于三种不同的 TF-IDF 算法来说, 在 SVM 中的分类效果达到最优, 准确率在 99%左右;对于 Word2vec 来说, 在 GB 中的分类效果达到最优, 准确率达到 97.06%。

(3) 通过 Voting 融合, 验证了融合模型相比于单个的逻辑回归、朴素贝叶斯等模型来说, 在实验效果方面有一定的提升。对于 1+log(TF)_IDF 来说, Voting 相比于逻辑回归来说, 准确率提升了 2.16%。相比于 NB 来说, 准确率提升了 2.8%。对于 Word2vec 来说, Voting 相比于支持向量机来说, 准确率提升了 3%。相比于逻辑回归

来说,准确率提升了 4.64%。因此,验证了 Voting 融合相比于某些单个的分类器来说,效果有一定的提升。

4.4 本章小结

本章针对 Cnews 数据集进行了分词、停用词过滤等文本预处理过程;分别用三种不同的 TF-IDF 计算方法对文本进行向量化处理。通过模型的训练,从准确率、召回率、F 值等指标的计综合比较三种不同的 TF-IDF 词向量化在分类器中的分类性能。在词向量化方式方面,利用改进的 TF-IDF 词向量化方式与 Word2vec、传统的 TF-IDF 模型进行对比,验证了改进的 TF-IDF 词向量化算法在新闻短文本上的特征提取的优势。最后通过 Voting 融合的方式,进一步验证了 Voting 融合实验的效果在一定程度上优于某些单个分类器的效果。

5 总结与展望

本章是对全文的总结和思考，从本文的背景与理论、词向量化的技术、分类器的构造等方面依次进行了总结。并且对本文存在的不足和可以优化的地方进行了思考和概述，明确了今后需要完善和继续学习的地方。

5.1 工作总结

随着互联网技术的飞速发展和社交媒体的爆炸式增长，各类新闻文本信息不断涌现。其次，文本信息在互联网上出现时，具有刷新速度快、文本量大、时效性强的特点。因此，如何快速有效地对文本信息进行分类和组织变得非常重要，文本分类技术应运而生。

新闻的发展越来越快，承载的形式也从传统的纸质媒体发展到现在的网络媒体。新闻的种类也在不断增加，从过去的文字、图片等单一形式发展到视频、音频等多种形式。因此新闻分类不能再局限于传统的文本分类和人工区分，而是专注于图像识别、语音识别和自然语言处理等技术。新闻文本分类主要应用在新闻网站的分类引导、热点话题追踪、特定类别新闻过滤和筛选等方面，而新闻的特点也适合运用自动化技术和数据挖掘等技术来进行分类。综合本文，主要完成了以下工作：

(1) 首先，梳理文本分类与词向量化技术的相关文献，总结国内外研究现状。通过文献的研读和资料的收集，总结各类机器学习分类算法的优缺点，并结合新闻短文本的特点选择合适的词向量模型。文本主要选择 TF-IDF 词向量方法来提取新闻文本的词向量。

(2) 改进 TF-IDF 模型的计算方式。结合新闻标题短文本的特点，考虑到不同长度的文本量纲的不同，以及词频与文本之间的相关性不一定是线性增长关系，分别提取标准化 TF-IDF 模型和 $1+\log(\text{TF})_IDF$ 模型，在一定程度上消除量纲的影响和降低线性的增长趋势。并且分别利用朴素贝叶斯、支持向量机、逻辑回归等分类器，从准确率、召回率、F 值等方面验证了提出的标准化 TF-IDF 模型和 $1+\log(\text{TF})_IDF$ 模型相对于传统的 TF-IDF 的效果提升。

(3) 对比传统 Word2vec 词向量模型,验证了本文采用的三种不同 TF-IDF 模型的词向量方式对于新闻短文本来说,在词向量特征提取方面的优势。同时对各类分类器的算法进行了综合评价与分析,最后利用 Voting 融合原理验证了 Voting 融合的方式相比于某些单个分类器来说,效果有所提升。

5.2 论文创新点

(1) 改进 TF-IDF 模型的计算方式。结合新闻标题短文本的特点,考虑到不同长度的文本量纲的不同,以及词频与文本之间的相关性不一定是线性增长关系。分别利用标准化 TF-IDF 模型和 $1+\log(\text{TF})_IDF$ 模型,即对 TF 的计算方式进行标准化和取对数,分别在一定程度上消除量纲的影响和降低线性的增长趋势。

(2) 数据集的选择和数据清洗。通过选择清华 NLP 实验室的 THUCnews 的子集 Cnews,来进行实证分析,共 10 个类别。在数据清洗方面,利用 jieba 分词和去表情符与特殊字符的方式。同时,为了提高效率,对原始的长文本进行了截断处理,截断后的文本长度均小于 30。

(3) 分类器的融合与分类效果验证。通过 Voting 软投票与硬投票的方式,分别把多种单一的分类器进行融合。逐一与单个分类器的效果进行了对比与分析,验证了 Voting 模型融合的方式在一定程度上比单个分类器的实验效果的提升。

5.3 工作展望

虽然本文能够基于新闻短文本的内容特质对其进行有效的分类识别,但是在一定程度上也存在一些不足和缺点。在模型的选取和数据的处理、以及编程方面还存在着一些欠缺。

(1) 本文选用的是 THUCNews 数据的子集进行实验,但是新闻的种类并不一定主要是 THUCNews 数据的子集中的这 10 个类别,对于某些类别的识别可能不一定有优势。今后可以考虑进一步探究一些较为复杂文本的识别方法。

(2) 本文所选用的三种 TF-IDF 词向量方式,主要从文本长度、词频等方面来提取词向量特征。但是,对于 IDF 的计算方式来说,IDF 主要缺乏对特征词在类之间

分布状况的考虑，即特征词在不同类中分布的方差、密度等。可以考虑增加类频方差，优化 IDF 的计算方式。

(3) 本文的分类模型虽然能够较好的识别 THUCNews 数据的子集，但是目前有很多深度学习的方式可以运用到文本分类，今后可以考虑进一步探究深度学习的方式在文本分类上的运用。

(4) 本文所选用三种 TF-IDF 词向量方式，虽然从词频、文本长度、量纲化等方面对词向量进行了提取，但是可能在一定程度上缺乏对上下文语义信息、语言环境、语句之间的联系的考虑。目前也有一些深度学习模型可以对上下文、语义语境方面提取词向量，今后可以考虑进一步探究这种考虑语境和上下文信息的词向量模型的应用。

在今后的学习中，还需要不断地加强知识结构的更新和 python 的编程水平，加强实际的动手能力和工程能力。

参考文献

- [1] 张航. 基于朴素贝叶斯的中文文本分类及 Python 实现[硕士学位论文]. 山东: 山东师范大学, 2018
- [2] 谌志群, 鞠婷. 基于 BERT 和双向 LSTM 的微博评论倾向性分析研究. 情报理论与实践, 2020, 43(08): 173-177
- [3] 汪焱, 刘柏嵩. 文本分类研究综述. 数据通信, 2019, 20(03): 37-47
- [4] 常春. 基于词频信息确定叙词表概念属性. 图书情报, 2013, 57(16): 11-14
- [5] 王根生, 黄学坚. 基于 Word2vec 和改进型 TF-IDF 的卷积神经网络文本分类模型. 小型微型计算机系统, 2019, 40(05): 1120-1126
- [6] Borah Samarjeet, Pradhan Ratika. An Experiment on Parameter Selection for Landslide Susceptibility Mapping using TF-IDF. Journal of Physics: Conference Series, 2020, 1712(1): 123-145
- [7] 宋冠仪. 基于 BERT 的多任务文本分析研究[硕士学位论文]. 山东: 山东大学, 2021
- [8] Wei Chun, Shi Liang. Using TF-IDF to hide sensitive itemsets. Applied Intelligence, 2013, 38(4): 145-178
- [9] 张群, 王红军, 王伦文. 词向量与 LDA 相融合的短文本分类方法. 现代图书情报技术, 2016, 23(12): 27-35
- [10] 陈巧红, 王磊, 孙麒. 基于混合神经网络的中文短文本分类模型. 浙江理工大学学报(自然科学版), 2019, 41(04): 509-516
- [11] 石凤贵. 基于 jieba 中文分词的中文文本语料预处理模块实现. 电脑知识与技术, 2020, 16(14): 248-251
- [12] 王甜甜. 互联网新闻分类中特征选择和特征提取方法研究[硕士学位论文]. 安徽: 中国科学技术大学, 2016
- [13] 严红. 词向量发展综述. 现代计算机(专业版), 2019, 10(08): 50-52
- [14] 程盼, 徐弼军. 基于 Word2vec 和 logistic 回归的中文专利文本分类研究. 浙江科技学院学报, 2021, 33(06): 454-460

- [15] 周源, 刘怀兰, 杜朋朋. 基于改进 TF-IDF 特征提取的文本分类模型研究. 情报科学, 2017, 35(05): 111-118
- [16] 马文, 陈庚, 李昕洁. 基于朴素贝叶斯算法的中文评论分类. 计算机应用, 2021, 41(S2): 31-35
- [17] 周晓兰, 戴香平, 陈洪龙. 基于朴素贝叶斯模型的评论文本情感分析. 科学技术创新, 2021, 10(33): 88-90
- [18] 冯彦明. 基于支持向量机和集成学习的大象流模型研究[硕士学位论文]. 广西: 桂林电子科技大学, 2021
- [19] 于敏. 基于机器学习的文本分类方法研究[硕士学位论文]. 江苏: 江南大学, 2021
- [20] 李秀秀, 陈海山. 基于机器学习的新闻文本分类研究. 电脑编程技巧与维护, 2021, 14(12): 132-135
- [21] 王爽. 基于机器学习的自动文本分类方法研究[硕士学位论文]. 四川: 电子科技大学, 2020
- [22] 赵延平, 王芳, 夏杨. 基于支持向量机的短文本分类方法. 计算机与现代化, 2022, 34(02): 92-96
- [23] Qin Jiahua, Zhou Zhuo. A Big Data Text Coverless Information Hiding Based on Topic Distribution and TF-IDF. International Journal of Digital Crime and Forensics (IJDCF), 2021, 13(4): 2-5
- [24] 王正存, 肖中俊, 严志国. 逻辑回归分类识别优化研究. 齐鲁工业大学学报, 2019, 33(05): 47-51
- [25] 金国鹏. 基于 Voting 融合算法的上证综指涨跌预测方案策划[硕士学位论文]. 上海: 上海师范大学, 2019
- [26] 赵乐, 麦范金, 张兴旺. 多特征融合的 Voting-SRM 情感分类研究. 小型微型计算机系统, 2019, 40(11): 2269-2273
- [27] 薛春香, 张玉芳. 面向新闻领域的中文文本分类研究综述. 图书情报工作, 2013, 57(14): 134-139
- [28] 王彬, 司杨涛, 付军涛. 基于改进的 TF-IDF 和贝叶斯算法的新闻分类. 科技

- 风, 2020, 40(31): 9-10
- [29] 周旻晏. 基于事件研究法的互联网热点新闻对股价影响研究[硕士学位论文]. 南京: 南京大学, 2015
- [30] Mariem Bounabi, Karim Elmoutaouakil, Khalid Satori. A new neutrosophic TF-IDF term weighting for text mining tasks: text classification use case. *International Journal of Web Information Systems*, 2021, 17(3): 23-45
- [31] Numik Gopalan. Key Term Extraction using a Sentence based Weighted TF-IDF Algorithm. *Journal of Education and Management Engineering(JEME)*, 2019, 9(4): 346-378
- [32] 唐晓波, 刘江南. 基于 BERT 和 TF-IDF 的问答社区问句自动标引研究——以金投网问答社区为例. *情报科学*, 2021, 39(03): 3-10
- [33] Kandhro Ali, Juman Zafar, Lashari Ali. Classification of Sindhi Headline News Documents based on TF-IDF Text Analysis Scheme. *Indian Journal of Science and Technology*, 2019, 12(33): 134-145
- [34] 王垚, 贾宝龙, 杜依宁. 基于词向量的多维度正则化 SVM 社交网络抑郁倾向检测方法. *计算机应用与软件*, 2022, 39(03): 116-120
- [35] Geoffrey Hinton. Learning Distributed Representations of Concepts. *Eighth Conference of the Cognitive Science Society*, 1989, 15(6): 23-45
- [36] Yang Hulin, Zhu An. Analysis of Telecommunication Fraud Cases Based on TF-IDF Algorithm. *IOP Conference Series: Earth and Environmental Science*, 2021, 742(1): 23-78
- [37] Xiao Shuwei, Tong Weiqin. Prediction of User Consumption Behavior Data Based on the Combined Model of TF-IDF and Logistic Regression. *Journal of Physics: Conference Series*, 2021, 1757(1): 123-135
- [38] Mohamed Chiny, Marouane Chihab. LSTM, VADER and TF-IDF based Hybrid Sentiment Analysis Model. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 2021, 12(7): 1-23
- [39] Wen Xiaoyang. Topological Data Analysis In Text Classification Based On Word Embedding And TF-IDF. *Journal of physics: Conference series*, 2020, 1634(1): 23-45

- [40] Mohammed Manal, Omar Nazlia. Question classification based on Bloom's taxonomy cognitive domain using modified TF-IDF and word2vec. PloS one, 2020, 15(3): 1-20
- [41] You Yu. Research on Text Representation Method Based on Improved TF-IDF. Journal of Physics: Conference Series, 2020, 1486(7): 356-567
- [42] Saihanqiqige. Application Research of English Scoring Based on TF-IDF Clustering Algorithm. IOP Conference Series: Materials Science and Engineering, 2020, 750(23): 168-176
- [43] Zhou Zhuo, Qin Jiaohua. News Text Topic Clustering Optimized Method Based on TF-IDF Algorithm on Spark. CMC: Computers, Materials & Continua, 2020, 62(1): 135-138
- [44] Lee Sangin, Oh Miae. A comparison of TF and TF-IDF analysis for trends of blockchain in health and welfare. Journal of the Korean Data And Information Science Society, 2019, 30(5): 123-145
- [45] Rahim Khan, Sajid Naeem. Extractive based Text Summarization Using K-Means and TF-IDF. International Journal of Information Engineering and Electronic Business(IJIEEB), 2019, 11(3): 23-45