

# 基于检索增强生成的私有化AI问答系统研究

包晓明

(国能(绥中)发电有限责任公司, 辽宁 葫芦岛 125222)

**摘要:**为了准确、自动处理大量用户问题并提供个性化建议和解答,设计采用基于检索增强生成的方式构建私有化AI问答系统。该系统利用数据层的Neo4j数据库和MySQL数据库存储企业私有资源信息、问答语料及知识库信息。逻辑处理层基于ChatGPT4.0交互式训练,获取用户问答请求实体,运用语义依存树连接用户问答请求实体与数据库内实体,由检索器检索特定字段。自动整合字段生成私有化AI问题答案,并发送至应用层,通过可视化操作界面呈现给用户。实验表明,该系统并行检索能力强,能准确理解用户私有化AI问题意图,答案可通过表格和图形呈现,归一化折损累积增益值稳定在0.85以上,检索精度高。

**关键词:** 检索增强生成;私有化;AI问答系统;意图理解器;大语言模型

中图分类号: TP391.1

文献标识码: A

文章编号: 1674-6236(2026)08-0120-05

DOI: 10.14022/j.issn1674-6236.2026.08.025

## Research on private AI question answering system based on retrieval enhancement generation

BAO Xiaoming

(CHN Energy(Suizhong)Power Generation Co.,Ltd., Huludao 125222, China)

**Abstract:** In order to deal with a large number of user questions accurately and automatically and provide personalized suggestions and answers, this paper designs a privatization AI question answering system based on retrieval enhancement generation. The system uses the Neo4j database and MySQL database in the data layer to store enterprise private resource information, question and answer corpus and knowledge base information. Based on ChatGPT4.0 interactive training, the logic processing layer obtains the user's question-and-answer request entity, uses semantic dependency tree to connect the user's question-and-answer request entity with the entity in the database, and the retriever retrieves the specific field. Automatically integrate fields to generate answers to privatization AI questions, and send them to the application layer, and present them to users through the visual operation interface. Experiments show that the system has strong parallel retrieval ability and can accurately understand the user's intention to privatize AI. The answers can be presented in tables and graphs, and the normalized cumulative gain value is stable above 0.85, with high retrieval accuracy.

**Keywords:** retrieval enhancement generation; privatization; AI question answering system; intention interpreter; Large Language Model(LLM)

人工智能技术的飞速发展促使AI问答系统成为人机交互的关键接口,其应用已广泛渗透至日常生活的各个领域,从智能家居助手到企业级智能客

服,展现出巨大的应用潜力<sup>[1]</sup>。然而,当前主流的AI问答系统大多构建于公有云平台上,数据处理与模型训练等核心环节暴露于公共网络环境,引发了数据隐私泄露的风险,还可能因网络延迟等因素对用

收稿日期:2025-03-17 稿件编号:202503145

作者简介:包晓明(1983—),男,蒙古族,辽宁彰武人,硕士研究生,工程师。研究方向:火电厂数字化转型。

用户体验造成负面影响。在此背景下,私有化 AI 问答系统的研究显得尤为关键。私有化部署策略意味着将 AI 问答系统的组件迁移至企业内部或专属数据中心<sup>[2-3]</sup>,从而确保对数据流的全面控制,有效保障用户数据的隐私与安全。

目前很多学者设计私有化 AI 问答系统,如丁志坤等人<sup>[4]</sup>在 BIM 正向设计问答系统中提出私有化部署策略,将 AI 问答系统的组件迁移至企业内部或专属数据中心,实现 AI 问答。但私有化部署方式会限制系统的可扩展性和灵活性,导致该系统应用范围较小。张鹤译等人<sup>[5]</sup>设计融合知识图谱的问答系统,在该系统中通过大语言模型捕获海量文本数据中的语义信息,并构建语义信息知识图谱,再使用相似度检索方式获得 AI 问答内容。但该系统构建知识图谱需要大量准确的结构化数据,受数据多源异构影响,生成的 AI 问答内容不够准确。冯雨溪等人<sup>[6]</sup>设计图神经网络的问答系统,该系统使用图神经网络提取用户检索内容特征,结合图注意力算法对用户检索内容进行推理后,从数据库内抽取对应内容返回给用户,实现系统 AI 问答。图注意力算法在图神经网络中起着关键作用,用于捕捉节点之间的关系和重要性。如果算法实现不当,可能会导致节点之间的关系被错误地表示或忽略,从而影响推理结果的准确性。

检索增强生成是一种结合了信息检索与文本生成技术的先进方法。它通过在生成文本的过程中引入外部信息检索机制<sup>[7]</sup>,有效地融合了广泛的知识 and 数据资源。这种方法能够提升文本生成的准确性和丰富性,使得生成的文本更加符合用户需求,同时避免了生成内容的空洞和重复。检索增强生成在多个领域展现出巨大潜力,如智能写作助手、对话系统、内容创作等,为提升人工智能系统的创造性和实用性提供了有力支持。通过不断优化检索算法和生成模型,检索增强生成技术有望在未来实现更加智能化、个性化的文本生成。

# 1 私有化 AI 问答系统

## 1.1 系统架构设计

以 Open AI 公布的 ChatGPT4.0 版本作为私有化 AI 问答系统的基础框架,设计私有化 AI 问答系统架构,如图 1 所示。

私有化 AI 问答系统架构由数据层、逻辑处理层和应用层组成,其中数据层使用 Neo4j 数据库和




图1 私有化 AI 问答系统架构

MySQL 数据库存储企业私有资源信息、问答语料和知识库信息,逻辑处理层连接数据层内 Neo4j 数据库和 MySQL 数据库后,在 ChatGPT4.0 交互式训练基础上,使用 Agent-Chain 意图理解器对用户问答请求意图进行理解,获得用户问答请求实体后,使用 LSTM 网络模型对用户问答意图实体进行增强处理,然后使用语义依存树对增强后的用户问答请求实体与数据库内实体进行连接,再使用检索器从数据库内检索特定字段后生成检索问答结果,然后将该检索问答结果输入到应用层内,该层以 B/S 架构为基础,在该基础上使用 Tableau 和 QlikView 对用户问答结果进行编辑,其中包括条形图、饼图、散点图、文本、表格等,然后通过可视化操作界面呈现给用户。

## 1.2 基于 LangChain 的 Agent-Chain 意图理解器构建

LangChain 是 AI 开发的基础框架,其为 AI 开发提供不同功能组件和工具,并可将大语言模型与外部数据库进行结合。在 AI 开发框架 LangChain 上,构建 Agent-Chain 意图理解器,通过该意图理解器理解用户问答需求,获得用户问题实体。Agent 是一个重要的组件<sup>[8]</sup>,进一步串联工具(Tools),将大语言模型和本地或云服务结合。Agent-Chain 意图理解器结构如图 2 所示。

## 1.3 基于检索增强生成的私有化 AI 问答结果生成方法

ChatGPT 属于一种大型语言模型,以 ChatGPT 为基础,通过检索增强生成方式生成私有化 AI 问答结果。基于 ChatGPT 的私有化 AI 问答流程如图 3 所示。




图2 Agent-Chain意图理解器结构




图3 基于ChatGPT的私有化AI问答流程

用户通过系统检索界面输入私有化AI问答问题后,系统使用ChatGPT API接口连接数据层数据库和Open AI,然后对Agent-Chain意图理解器输出的用户意图实体进行增强处理后,将增强后的用户意图实体与数据层数据库内实体进行连接,对数据库内特定字段进行检索,最后生成私有化AI问答结果。

### 1.3.1 基于LSTM与CRF算法用户意图实体增强

使用长短期记忆神经网络(Long Short-Term Memory, LSTM)对上文得到的用户问答意图实体进行增强处理,将用户问答意图实体输入到LSTM模型内,可从用户问答意图实体中捕捉token之间的距离来优化用户问答意图实体的特征表达能力。用户问答意图实体输入到LSTM网络模型的输入门,其负责提取用户问答意图实体的特征,其输出的用户问答意图实体特征 $G_t$ 表达式为:

$$G_t = f(X_t \mathbf{h}_{xi} + u_{t-1} \mathbf{h}_{hi} + c) \quad (1)$$

式中, $f(\cdot)$ 表示激活函数; $X_t$ 表示 $t$ 时刻用户问答意图实体参数; $u_{t-1}$ 表示上一时刻用户问答实体

的隐藏状态参数; $\mathbf{h}_{xi}$ 和 $\mathbf{h}_{hi}$ 表示输入门权重矩阵; $c$ 为偏置数值。

LSTM网络模型使用遗忘门对用户问答意图实体特征进行遗忘处理,其表达式如下:

$$F_t = f(\mathbf{h}_{xf} G_t + c) \quad (2)$$

式中, $\mathbf{h}_{xf}$ 表示遗忘门的权重矩阵。

用户问答意图实体特征遗忘处理后,通过LSTM网络模型的门控单元选择用户问答意图实体特征<sup>[9-10]</sup>,然后通过输出门输出增强后的用户问答意图实体 $E_t$ ,其表达式如下:

$$E_t = f(\mathbf{h}_{xo} M_t + c) \quad (3)$$

式中, $\mathbf{h}_{xo}$ 为输出门权重矩阵; $M_t$ 为经过门控单元选择后的用户问答意图实体特征参数。

经过上述过程,使用LSTM网络模型输出增强后的用户问答实体意图特征,为后续实体连接提供基础。

### 1.3.2 基于语义依存树的实体连接

语义依存树是一种用于分析句子内部语义关系的方法。在此使用语义依存树对增强后的用户意图实体和数据库内实体进行连接,其详细实现过程如下:

步骤一:假设 $\Phi_1$ 和 $\Phi_2$ 分别表示增强后的用户意图实体树和数据库内数据实体树,对这两个语义依存树进行向量化处理,其表达式如下:

$$\begin{cases} q(\Phi_1) = (q_1(\Phi_1), q_2(\Phi_1), \dots, q_n(\Phi_1)) \\ q(\Phi_2) = (q_1(\Phi_2), q_2(\Phi_2), \dots, q_m(\Phi_2)) \end{cases} \quad (4)$$

式中, $q(\Phi_1)$ 、 $q(\Phi_2)$ 分别表示语义依存树 $\Phi_1$ 和 $\Phi_2$ 的量化结果; $q_i(\Phi_1)$ 表示语义依存树 $\Phi_1$ 的子树在该树内出现的次数, $i \in n$ ;  $q_j(\Phi_2)$ 表示语义依存树 $\Phi_2$ 的子树在该树内出现的次数。

步骤二:在增强后的用户意图实体树和数据库内数据实体树向量化基础上<sup>[11-12]</sup>,计算语义依存树 $\Phi_1$ 和 $\Phi_2$ 的余弦值,将该余弦值作为二者的相似度<sup>[13]</sup>,计算公式如下:

$$Y(\Phi_1, \Phi_2) = \sum_{k=1}^{n+m} q_k(\Phi_k)^2 \quad (5)$$

式中, $Y(\Phi_1, \Phi_2)$ 表示语义依存树 $\Phi_1$ 和 $\Phi_2$ 的相似度,当该相似数值超过0.75时,可将这两个语义依存树内对应的实体进行连接,得到连接后的用户问答实体 $B$ 。

### 1.3.3 检索器构建

在式(5)的基础上对增强后的用户意图实体树

和数据库内数据实体进行连接后,使用SQL查询模型作为检索器,对连接后的用户意图实体和数据库数据实体进行检索,搜索与以上实体相似度较高的特定字段,则检索器表达式如下:

$$\gamma_z = \arg \max \text{Sim}(B \| S_1, S_2, \dots, S_k) \quad (6)$$

式中,  $\gamma_z$  表示检索到的与用户意图实体和数据库数据实体相似度较高的用户问题  $z$  相关上下文集合;  $\|$  表示拼接操作;  $\text{Sim}(\cdot)$  为相似度函数;  $S_1, S_2, \dots, S_k$  表示  $k$  个与用户问答实体  $B$  相似度较高的特定字段序列参数。

通过式(6)得到连接后的用户意图实体和数据库数据实体相似度较高的特定字段后,依据上下文关系,对  $\gamma_z$  进行降序排列处理<sup>[14]</sup>,降序后的特定字段由  $\tilde{\gamma}_z$  表示。

### 1.3.4 检索问答生成

获得降序后的用户意图实体和数据库数据实体相似度较高的特定字段  $\tilde{\gamma}_z$  后,使用 Open AI 内的大语言模型自动整合特定字段<sup>[15-16]</sup>,并生成私有化 AI 问答结果,其表达式如下:

$$A = \arg \max \prod_{i=1}^k P(\gamma_z \| (\eta_1, \eta_2)) \quad (7)$$

式中,  $A$  表示生成的最终私有化 AI 问答结果;  $P(\cdot)$  为大语言模型整合函数;  $\eta_1$ 、 $\eta_2$  分别表示标点符号和中文功能词参数。

通过式(7)得到私有化 AI 问答结果,将其传输到应用层,应用层通过可视化操作界面呈现给用户。

## 2 性能测试与分析

以某电子商务公司作为实验对象,该电子商务公司主要从事 B2C 电子商务平台的研发、运营、销售及服务等业务。该公司下设若干个部门,不同部门业务之间存在关联,但信息交流存在一定阻碍,形成信息孤岛现象。在此使用该文系统为该电子商务公司提供私有化 AI 问答服务,旨在打破该公司不同部门之间的信息孤岛,促进和推动公司内部信息交流,为公司制定运营、销售等策略提供信息服务。

系统执行私有化 AI 问答检索增强生成过程的稳定性是衡量其执行能力的指标之一。Karp-Flatt 量度是用来衡量并行程序性能的指标,在此使用 Karp-Flatt 量度作为衡量该文系统执行能力指标,测试在并行 AI 问答数量不同的情况下,该文系统 Karp-Flatt 量度数值如图 4 所示。




图4 Karp-Flatt量度数值

根据图4可知,所研究系统展现出较低的 Karp-Flatt 量度数值,这一数值与并行 AI 问答的数量呈正比关系。值得注意的是,随着并行 AI 问答数量的增加, Karp-Flatt 量度数值的上升幅度相对有限,这表明系统具有出色的并行化运算能力。较小的 Karp-Flatt 量度数值进一步印证了这一点,说明该系统在处理用户私有化 AI 问答的检索、增强和生成时,能够高效地利用并行计算能力,从而提供优质的服务。

在系统内对用户私有化 AI 问答过程中用户意图进行检索是生成私有化 AI 问题答案的基础。在此以归一化折损累积增益作为衡量该文系统检索能力的指标,测试在用户意图实体复杂度不同情况下,3个检索目标在检索过程中的归一化折损累积增益数值,分析该文系统的检索能力。在测试过程中设置归一化折损累积增益阈值为0.85,测试结果如图5所示。




图5 系统检索归一化折损累积增益数值

根据图5可知,在检索3个私有化 AI 问题答案的过程中,随着用户意图实体复杂度的增加,不同检索目标的归一化折损累积增益虽略有下降,但降幅并不显著。重要的是,这3个检索目标的归一化折损累积增益值均稳定保持在0.85以上,这一高水平的结果有力地证明了该文方法在检索私有化 AI 问

题答案时的高精度,同时从侧面反映出文中所设计的系统能够高效且准确地实现私有化AI问答功能,具备良好的应用前景。

### 3 结 论

在探索基于检索增强生成的私有化AI问答系统的研究进程中,认识到这一领域对于提升信息处理效率与个性化服务体验的关键作用。通过整合检索技术与生成式AI的优势,实现了对海量数据的快速索引与精准提取,并利用生成模型创造出符合用户需求的个性化回答。私有化部署确保了数据的安全性与隐私保护,提供了更为可靠的服务环境。该研究在理论与实践层面均取得显著进展,为AI问答系统的发展提供了新思路与方法,也为未来智能化服务的创新奠定了坚实基础。然而,面对日益复杂多变的信息需求与隐私保护挑战,仍需不断深化技术研究,优化算法模型,以持续提升系统的智能化水平与用户体验。

#### 参考文献:

- [1] 张佳豪,黄勃,王晨明,等.一种融合文本与知识图谱的问答系统模型[J].重庆大学学报,2024,47(8): 55-64.
- [2] 杨喆,许甜,靳哲,等.基于知识图谱的羊群疾病问答系统的构建与实现[J].华中农业大学学报, 2023,42(3):63-70.
- [3] 李帅驰,杨志豪,王鑫雷,等.基于特征增强的开放域知识库问答系统[J].计算机工程与应用,2022, 58(17):206-212.
- [4] 丁志坤,李金泽,刘明辉.基于大语言模型的BIM正向设计问答系统研究[J].土木工程与管理学报, 2024,41(1):1-7,12.
- [5] 张鹤译,王鑫,韩立帆,等.大语言模型融合知识图谱的问答系统研究[J].计算机科学与探索,2023, 17(10):2377-2388.
- [6] 冯雨溪,张燮弛,黄正结,等.基于图神经网络的问答系统[J].计算机工程与设计,2024,45(5):1351-1358.
- [7] 范国栋,陈世展,肖建茂,等.面向App评论响应的语义检索和生成框架[J].计算机学报,2022,45(12):2528-2543.
- [8] 陈章辉,熊贲.基于解耦-检索-生成的图像风格化描述生成模型[J].计算机科学,2022,49(6):180-186.
- [9] 聂为之,王岩,杨嵩,等.基于循环生成对抗网络的跨媒体信息检索算法[J].计算机学报,2022,45(7): 1529-1538.
- [10] 秦春秀,吕树月,王玉龙,等.智能检索中基于生成式模型和伪相关反馈的查询扩展方法[J].图书情报工作,2024,68(15):117-127.
- [11] 汤丽君,关东海,汪子璇,等.融合CNN和二进制生成对抗网络的多元时间序列检索[J].小型微型计算机系统,2023,44(2):281-287.
- [12] 曾立英,王亭亭,刘耀,等.基于对抗学习的查新检索式自动生成[J].郑州大学学报(理学版),2024,56(6):70-76.
- [13] 张松鸣,王帅博,陈钰枫,等.一种基于级联架构与多模型融合的知识型对话系统[J].中文信息学报, 2024,38(7):95-105.
- [14] 刘佳楠,范晶晶,赵建光,等.基于二重语义相关性图卷积网络的跨模态检索方法[J].计算机应用研究,2024,41(4):1239-1246.
- [15] 王雪菽,刘世俭,王玉吉.AI智能问答系统在档案咨询服务中的应用与研究[J].陕西档案,2023(2): 18-20.
- [16] 艾洲.基于大模型和区块链的电力知识问答系统设计 with 实现[J].电力大数据,2024,27(1):87-96.

欢迎订阅 2026 年度《电子设计工程》(半月刊)

国内邮发代号:52-142

国际发行代号:M2996

订价:15.00 元/期 360.00 元/年