



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目：基于深度学习的跨语言语音合成技术综述
作者：周祉彤，周若华，郭子夜，赵明园
网络首发日期：2026-01-14
引用格式：周祉彤，周若华，郭子夜，赵明园. 基于深度学习的跨语言语音合成技术综述[J/OL]. 计算机科学. <https://link.cnki.net/urlid/50.1075.tp.20260114.0852.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于深度学习的跨语言语音合成技术综述

周祉彤, 周若华*, 郭子夜, 赵明园

北京建筑大学 智能科学与技术学院, 北京 102616

摘要: 随着语音合成技术的持续进步, 跨语言语音合成技术也取得了显著的进展。尽管近年进展显著, 现有研究在跨语言的发音与韵律一致性、说话人音色保持以及统一可比的评价协议等方面仍存在待提升空间。本文系统梳理了跨语言语音合成领域的最新研究进展, 内容涵盖经典模型架构、跨语言关键技术、数据集以及评价体系等方面。首先, 概述了当前跨语言语音合成的主要类型与存在的不足; 随后, 深入分析了跨语言语音合成中模型架构、低资源语言合成、特征解耦、零样本学习、对抗性学习、情感迁移以及大规模预训练模型等核心技术。此外, 本文还归纳总结跨语言语音合成数据集及其特性, 并系统归纳、比较主观和客观评价指标。最后, 对跨语言语音合成技术的未来发展趋势进行了前瞻性探讨。

关键词: 跨语言语音合成; 深度学习; 生成式神经网络; 多语言特征映射

中图分类号: TP391.4; TN912.33

A Review on Deep Learning-based Cross-lingual Speech Synthesis Technology

Zhou Zhitong, Zhou Ruohua*, Guo Ziyue and Zhao Mingyuan

School of Intelligent Science and Technology, Beijing University of Civil Engineering and Architecture, Beijing 102616, China

Abstract: With the continuous advancement of speech synthesis technology, cross-lingual text-to-speech has made significant progress. Despite notable progress, current studies still face gaps in cross-lingual consistency in pronunciation and prosody, speaker timbre preservation, and unified, comparable evaluation. This paper provides a comprehensive review of recent developments in the field, covering model architectures, key cross-lingual techniques, datasets, and evaluation metrics. We first introduce the main types and limitations of Cross-lingual TTS. Then, we analyze universal architectures, low-resource synthesis, feature disentanglement, zero-shot learning, adversarial training, emotional transfer, and large-scale pre-trained models. Commonly used datasets and evaluation methods are also summarized and compared. Finally, future directions for cross-lingual TTS are discussed.

Key words: Cross-lingual Speech Synthesis; Deep Learning; Generative neural networks; Multilingual feature mapping

语音合成技术 (Speech Synthesis), 即文本转语音 (Text-to-Speech, TTS), 是指将书面文本自动转换为自然、流畅、可理解的语音的技术。作为语音处理领域的核心方向之一, 语音合成技术已广泛应用于智能语音助手、辅助技术、有声内容生成、语言学习等多个场景。随着深度学习的快速发展, 语音合成系统在语音自然度、个性表达、情感呈现等方面取得了显著提升。

近年来, 在全球化与跨区域服务快速发展的背景下, 多

语言语音交互对实时性、稳定可懂度与跨语言一致的表达提出了迫切需求。跨语言语音合成 (Cross-lingual Speech Synthesis) 成为研究的前沿方向之一, 旨在实现模型在多种语言语音合成之间的知识迁移与泛化, 尤其是在目标语言数据稀缺或零样本的情况下, 生成自然、语者一致的目标语言语音。这一任务对语音合成系统的语言建模能力、说话人保持能力和多语言表示学习能力提出了更高要求^[1]。跨语言语音合成不仅有助于提升低资源语言的可达性与技术普惠性,

基金项目: 国家自然科学基金 (批准号: 11590774); 国家自然科学基金 (批准号: 62371032)

This work was supported by the National Natural Science Foundation of China (Grant No.11590774) and the National Natural Science Foundation of China (Grant No.62371032).

通信作者: 周若华 (zhou ruohua@bucea.edu.cn)

也为构建多语种、个性化、情感化的人机语音交互系统奠定了基础。然而，现有技术在高资源与低资源语言之间仍存在显著性能差异，具体表现为发音准确性、韵律自然度与说话人音色保持等指标在低资源语种上明显退化，难以满足大规模应用的一致性要求。

根据支持的语言数量和语言间的交互方式，TTS 技术可分为单语言、多语言和跨语言三类。单语言系统专注于将一种语言的文本转换为对应的语音，训练所需语料一般来源于同一语种的单说话人或说话人语音数据。多语言系统能够支持多语种的语音合成，但通常是独立训练多个模型，或在统一模型中通过语言标签区分语种，模型参数共享度低，语言间知识迁移能力有限^[2]。跨语言语音合成则致力于在保持说话人音色的基础上合成其使用其他语言的语音，即实现跨语言的语音迁移^[3]。

随着全球化进程不断加快，跨语言沟通的需求日益增长，跨语言语音合成作为打破语言障碍的关键技术，其研究价值不断凸显。传统的单语种 TTS 模型虽然在高资源语言上表现优异，但在实际应用中暴露出诸多局限^[4]。例如，它们通常严重依赖大规模同语种高质量标注语料，在低资源语言中难以实现高质量合成；此外，传统 TTS 模型的迁移能力较弱，无法直接适用于多语言环境，且缺乏在新语言上的快速适配能力^[5]；面对多说话人、多音色或情感迁移等复杂任务时，传统方法亦表现出较大的性能瓶颈^[6]。这些问题在当前多语种智能语音系统、语言教育和个性化语音交互等应用背景下愈发突出，进一步凸显了跨语言语音合成研究的重要意义。跨语言语音合成通过引入语音转换（VC）技术，结合共享的模型架构或语言无关的声学表示，使得单模型能够支持多语言合成任务，显著提升了合成质量与系统的语言泛化能力^[7]。

当前，深度学习技术的迅猛发展为跨语言语音合成领域

提供了强大的技术驱动力。基于此，研究人员深入探索了低资源语言语音合成、语音特征解耦、零样本学习、生成对抗网络（Generative Adversarial Networks, GAN）学习、预训练大模型等前沿方法，推动跨语言语音合成性能迈向新的高度。然而，该领域仍面临诸如语言间音系、韵律、语调差异显著、音色与语言内容难以解耦、模型难以灵活适配多说话人多情感等挑战^[8]。

近年来，关于“跨语言/多语言 TTS”专题的系统性综述虽逐渐显现，却仍然稀缺。例如，综述^[9]把 few-shot、zero-shot 与多语言 TTS 纳入统一框架，梳理了当前多语音克隆技术路线及评价方式，但其视角偏向语音克隆总体，不专注于 TTS 模型的表征、跨语言建模或模块对齐等技术细节系统化分析。另一篇关于多语言文本转换与语音生成的工作流综述探讨了多语言处理环境下从文本到语音生成的整体流程与挑战，涉及发音差异、语音生成系统设计等，但同样未对跨语言 TTS 的模型机制和任务谱系做深入刻画^[10]。因此，尽管已有工作触及跨语言/多语言语音合成的某些方面，仍未见一篇以跨语言因素为主线、系统覆盖表征、对齐、控制、生成与评测全链的综述。本文即致力于填补这一空白。本文旨在概述跨语言语音合成的关键技术和发展现状，综合现有方法对跨语言语音合成技术进行更细致的总结。以往的语音合成综述并未聚焦于跨语言方向，本文填补了国内语音合成综述在跨语言问题处理上的空白。本文结构如下：第1章剖析跨语言语音合成模型核心架构；第2章对基于深度学习的跨语言语音合成技术进行分类和介绍，涵盖低资源语言合成、特征解耦、零样本学习、对抗学习、情感迁移和预训练大模型等前沿方法；第3章梳理多语种语音合成数据集与主客观评价体系；第4章总结研究现状并展望未来发展趋势。

表 1 单语言、多语言、跨语言语音合成的联系与区别

Table 1 The Connections and Differences among Monolingual, Multilingual, and Cross-lingual Speech Synthesis

对比维度	单语言	多语言	跨语言
目标	高质量合成目标语言的语音	在多语言之间保持语音质量和一致性	迁移参考说话人的音色到目标语言，实现语音跨语言迁移
输入	单一语言文本	多语言文本	一种语言的文本+另一语言的音色参考音频
输出	相应语言的语音输出	对应语言的语音输出	保留参考音色的目标语言语音输出
语言适应能力	仅适用于特定语言	适用于已训练的多语言，扩展新语言需额外训练	强调迁移能力，可将说话人适配到未说过的语言
代表模型	Tacotron 2 ^[11] , FastSpeech ^[12] , Glow-TTS ^[13]	MUSA ^[14] , Deep Voice 3 ^[15]	Meta-TTS ^[16] Polyglot TTS ^[17] , maskgct ^[18]

1. 跨语言合成模型核心架构

跨语言语音合成模型通常有两类输入与一类输出。文本输入提供待合成语音的内容，参考语音输入提供待合成语音的音色，其中参考语音和输入文本为不同语种，输出为跨语言合成语音。跨语言语音合成系统通常由多个关键模块组成，这些模块协同工作，实现从源语言文本到目标语言语音的高

质量转换。

Multilingual Tacotron 模型^[19]是通过分离语言特征和说话人特征实现跨语言语音合成的典型模型之一，其强调说话人保持和语言迁移能力。Multilingual Tacotron 的代表性跨语言结构框架（见图1）为后续如 Meta-TTS^[16]、YourTTS^[20]等跨语言语音合成模型提供重要结构参考。

该模型旨在通过多模块协同实现“文本内容—语义表征

“声学特征—语音输出”的跨语言映射，其整体结构可划分为五个通用核心模块（图中1.1 - 1.5），分别对应文本分析、语言无关语义编码、说话人特征提取、语义融合与声学建模、声码器等环节。具体而言，系统首先经由文本分析模块（1.1）对输入的源语言文本进行规范化、音素化与语言标注，得到统一的文本表示；随后，语言无关语义编码模块（1.2）将多语种文本映射到共享的语义空间中，以提取跨语言可迁移的语言内容特征；与此同时，来自参考语音的音色信息由说话人特征提取模块（1.3）编码为固定维度的说话人向量，确保个体声音特征在跨语言迁移中得以保持。接下来，语义融合与声学建模模块（1.4）将上述语义表征与说话人嵌入进行联合建模，通过注意力机制或条件生成结构生成目标语种下的声学特征（如梅尔频谱或离散声学标记）。最后，声码器模块（1.5）基于这些声学特征重建高保真音频波形，输出保留参考音色的目标语言语音，实现跨语言语音合成。




图1 Multilingual Tacotron 模型框架

Fig.1 Multilingual Tacotron Model Framework

以下将简要介绍目前跨语言语音合成模型五个通用核心模块及其作用。

1.1 文本分析

文本分析模块是跨语言语音合成系统的首要环节，负责将输入文本转化为适合声学建模的中间表示。其核心功能包括：字符规范化、分词、音素转换（Grapheme-to-Phoneme, G2P）、韵律预测（如重音、音长、停顿）以及语言标注等。在多语言环境下，该模块还需处理不同书写系统与语音映射差异，并构建跨语言统一表示以提升下游模块的泛化能力。

通常做法是采用统一的音素编码（如国际音标 IPA）或语言无关的符号体系，并在文本分析阶段引入语言 ID 或嵌入向量，以提供语言上下文提示。近年来，随着多语言预训练模型的发展，一些系统尝试直接用 Transformer 或 BERT 编码器替代传统规则或 G2P 模块，进行端到端语义建模；不过在大多数跨语言 TTS 框架中，显式文本分析仍是关键环节，尤其在低资源语种或对精度要求较高的场景中，其质量往往直接影响语音的自然度与可懂性。有关多语言文本分析方法可参看文献[21,22]。

单词	T	A	N	G	L	E
音素	T	AE	NG	G	AH:L	null

图2 G2P 示例

Fig.2 G2P example

1.2 语言无关语义编码

语言无关语义编码模块是跨语言语音合成系统中的关键组件，其核心目标是将条件不同的多语种文本转换为一类较为维度稳定、语义共享的中间表征。该模块通过架构语言无关的语义定向空间，在保留信息纯度和语义综合性的同时，实现不同语种文本的跨语言并行处理能力。

实现语言无关语义编码通常依赖于功能强大的多语种预训练语言模型，如 mBERT^[23]、XLM-R^[24]，或者是面向语音件的跨模态语言基础模型，如 wav2vec 2.0^[25]、HuBERT^[26]等。这些模型通过对大规模多语种输入进行预训练，能够展示出较好的跨语言语义定向能力。如图3所示，HuBERT 首先对连续语音帧进行离线聚类（如使用K-means），生成离散伪标签；然后通过 CNN+Transformer 对被掩码的帧进行预测，学习帧级语义层次；接着再对 Transformer 隐层输出重新聚类，不断优化标签，使模型逐步获得跨语言共享的语义表示。

通过这种形成的语义共享空间，语言无关语义编码模块不仅仅作为语本解码的一部分，更重要的是属于整个跨语言 TTS 系统中的核心接口。它一方面为后续语音系统提供稳定且规范化的输入表征，另一方面则保证不同语种下系统输入的统一处理和系统级的跨语言应用功能。




图3 语言无关语义编码（HuBERT 模型）

Fig.3 Language-Independent Semantic Encoding (HuBERT model)

1.3 说话人特征提取

说话人特征提取模块的核心目标是将一段说话人母语的参考语音编码为一个固定长度的说话人嵌入向量。该向量应具备以下三个关键属性：

- 1) 语言无关性：能够对不同语言的语音保持稳定、鲁棒的表示能力；
- 2) 说话人可分性：具备区分不同说话人音色的能力，以有效捕捉个体差异；
- 3) 语音内容无关性：不包含具体语音内容的信息，从

而避免对后续语义建模产生干扰。

说话人特征提取模块在跨语言语音合成中起着决定性作用,其性能直接影响合成语音是否能够准确保留参考语音中说话人的个性化特征,如音色、语调及说话风格等。

尤其在跨语言场景中,模型需要从一种语言中的语音中提取出语言无关的说话人特征,并将其迁移到另一种语言的语音合成过程中,可参考经典的提取说话人特征的模型如 d-vector^[27]、GE2E^[28]等。如图4, GE2E 模型首先对批次中多个说话人、每人多条语句特征进行编码,生成固定长度嵌入向量;接着计算每条嵌入与各说话人中心的余弦相似度,构建相似性矩阵;再通过说话人相似度损失,强化同一说话人嵌入聚合、不同说话人嵌入分离;该方法无需复杂样本筛选、训练收敛快、错误率显著降低,能生成区分度高且语言无关的说话人表征。




图4 说话人特征提取模块(以 GE2E 模型为例)

Fig.4 Speaker Feature Extraction Module(GE2E model)

1.4 语义融合与声学建模

语义融合与声学建模模块是跨语言语音合成系统中连接语义解码与语音生成的主要桥梁,其目标是将语言无关的语义表征与参考说话人的音色、载调、载节等语音特征有效融合,转换成能够描述目标语音特性的声学表征,为后续的声码器提供高质量的输入。这种声学表征通常为模拟指标,如梅尔频谱,或者为离散形式结构,如 VQ-VAE^[29] 类型生成的离散声学标识符,并保持说话人语音特征和语义输入之间的程度匹配。

语义和语音特征的融合可通过多种策略实现,包括简单的特征拼接、基于注意力机制的对齐和融合,以及条件生成网络等。如 RAD-TTS^[30] 或 YourTTS^[20] 选用以语义为核心的核心解码器给定条件生成声学特征,配合最终的生成声码器,实现高效的声转换。这种模型结构能够在保留参考语音情感、说话人风格与语义一致性的前提下,自然地生成目标语种下与输入一致的声学信息,是跨语言 TTS 设计中极关键的环节。




图5 语义融合与声学建模模块

Fig.5 Semantic Fusion and Acoustic Modeling Module

1.5 声码器

声码器模块作为语音合成系统的最后一个环节,负责将

模型生成的声学特征(如梅尔频谱或离散声学标识符)转换为高质量、聚真性强的音频波形信号,以完成整个 TTS 转换过程。这一模块的合成效果直接决定了最终语音输出的感知质量,因此其模型设计和性能是影响合成效果的重要因素。

现代声码器多采用基于深度神经网络的自回归或并行生成架构,其中典型以 WaveNet^[31] 为代表,通过因果膨胀卷积堆叠残差块来扩展感受野,同时避免未来信息泄露,每层使用门控单元配合残差与跳跃连接提取特征。随后,所有跳跃连接输出通过一系列 1×1 卷积 + ReLU + Softmax 层,预测下一个采样值的类别,重构高质量语音波形。后续开发出的 WaveGlow^[32]、Parallel WaveGAN^[33] 和 HiFi-GAN^[34] 等模型,通过深度平行生成、应用基于 GAN 的分别合成网络,在保证语音精细组织的同时,大幅降低了运算处理耗时,适合实时和轻量级应用场景。此外,近年提出的 Encodec 模型^[35]通过端到端的神经编解码框架实现高效的音频压缩与重建,能够在低比特率下保持高保真度语音合成,也逐渐成为跨语言语音合成任务中的重要选择之一。这类声码器已成为当前跨语言语音合成领域的标配技术。




图6 声码器 Wavenet 结构

Fig.6 WaveNet vocoder architecture




图7 跨语言语音合成流程图

Fig.7 Cross-language speech synthesis flowchart

2. 基于深度学习的跨语言语音合成模型

近年来,随着深度学习技术的迅猛发展,跨语言语音合成取得了显著进展。特别是在低资源、零样本条件下,研究者从多个方向探索了有效的建模策略,包括低资源适应、解耦表示学习、零样本建模、对抗训练、情感迁移和预训练大模型等。不同模型从多视角提升了跨语言语音的自然度、音色一致性与语言适应能力。本章将从八个关键研究方向展开介绍,并汇总近年来具有代表性的最新成果。

2.1 低资源条件下的跨语言语音合成

低资源语言是指在数据资源方面较为匮乏的语言,在语

音合成研究中,低资源语言的语料采集难度大、成本高,很难获取足够语音用于模型训练,用传统方法进行语音合成时容易出现模型过拟合现象^[36]。为此,研究者们积极探索多种创新方法以应对数据稀缺带来的挑战。

近年来,跨语言多说话人 TTS 系统在低资源场景下逐渐成为研究热点。He 等人提出的 Byte2Speech 模型^[37]使用 UTF-8 字节序列作为输入表示,跳过 G2P 过程与词典依赖,支持任意语言脚本输入,并在极少量语料(例如 40 秒配对语音)条件下仍能达到令人满意的可懂度与自然性。该模型在极低资源适配中表明,不依赖语言特定的处理模块也能较好地支持跨语言迁移。Wells 等人^[38]在低资源合成任务中提出用发音特征(如声门、鼻音、高低位)替代单一音素表示,以共享语言间语音属性减缓稀缺语料下音素差异带来的退化。Byambadorj 等人^[39]采用跨语言迁移 + 数据增强策略,在目标语种仅 30 分钟语料条件下,对单说话人与多说话人模型进行了对比实验,证明迁移与增强结合能显著改善自然性。文献[40]提出一种多语种迁移学习框架,在使用多个辅助语言共同训练时,可以在低资源语种上获得更好的语音合成效果,尤其在多语种共享特征方面表现突出。OuteTTS^[41]的 LLM + 音频离散化令牌 + CTC 对齐方法在中英文混合或低资源语言实验中具有一定参考价值。Saeki 等人^[42]提出利用仅有文本数据进行跨语言 TTS 迁移的思路,通过多语种文本预训练 + 有配对语音数据的微调,使得对于未见语种也能输出可懂语音,用以支撑极低资源语言合成的可能性。文献[43]针对泰语提出迁移学习策略,通过重新设计该语种的文本分析模块并选择发音相似的非低资源语种进行迁移,有效提升该低资源语种的合成质量。Kwon 等人^[44]提出适配器架构,用极少的目标语种数据(12 小时单说话人数据)进行跨语言 TTS 微调,同时保留多语言能力,对模型在低资源语种的扩展与适配具有参考价值。

2.2 基于解耦方法的跨语言语音合成

在跨语言语音合成中,解耦方法的核心是分离语音中的语言内容与说话人特征(如音色、音高、韵律及其他声学特征)。如图8所示,特征解耦有效解决了语音合成中语言和说话人特征相互干扰的问题,提高跨语言语音合成质量。




图8 特征解耦

Fig.8 Feature disentanglement

文献[45]提出了一种基于元学习的多语种语音合成方法,通过解耦发音和韵律特征来提升跨语言合成的效果。该

方法使用了两流模型,即分别使用独立的编解码器对发音和韵律进行专门学习,同时共享注意力机制,该方法增强了对不同语言的适应能力。StarGAN-VC2^[46]通过调控声学特征在特定域中转换,实现了说话人身份和语言内容的解耦。尽管其主要在英语语音数据上进行训练,但通过引入风格编码器和源分类器,模型能够在不同语言之间进行风格转换,为语音合成和语音转换领域提供了新的思路和方法。Kim 等人提出了 CrossSpeech^[47],解决了 TTS 系统中说话人和语言信息纠缠的问题。CrossSpeech 将语音生成过程分解为捕捉语言内容信息的说话人无关生成器和生成具有目标说话人音色的语音的说话人依赖生成器,并通过混合说话人统计数据来归一化隐藏层特征,减少说话人对语言的偏置,提升了跨语言语音质量。随后, Kim 等人又提出了 CrossSpeech++^[48],在 CrossSpeech 的基础上使用 Conformer 架构提升语音-文本编码效率,并通过在线时长对齐机制避免对并行语料的依赖。在单独的模块中更细化的处理语言和说话人信息,更有效地分离了语言和说话人表示,进一步提高了语言与说话人特征解耦能力。MaskGCT^[18]采用掩码生成编解码器变换器架构,首先预测语义标记,然后生成声学标记,这种双阶段分层式架构自然实现内容与声学特征的解耦,每个阶段专注一类信息。Khurana 等人提出的 HAC 模型^[49]则是通过结构性向量量化将语音编码拆分为:声学层、音素层和词汇层,利用两个知识蒸馏目标 HuBERT^[26]和 LaBSE^[50]确保各层语义信息彼此独立,生成的三种标记分别对应不同语言层级特征。在生成过程中,三个标记集合被联合输入解码器,实现自然、清晰且语义丰富的音频重建。虽然该方法主要用于编码结构,但其清晰层级的解耦特性为后续跨语言 TTS 提供了基础。

2.3 基于零样本条件的跨语言语音合成

零样本跨语言语音合成的核心挑战在于:在缺乏目标语言或目标说话人训练数据的条件下生成自然流畅的目标说话人语音。Chen 等人提出了一种跨语言多说话人端到端 TTS 方法^[51],使用一个单独训练的说话人嵌入网络,在多说话人语音识别任务上先行训练,学习到一个能够编码说话人音色和语言发音特征的高质量向量表示,然后再迁移到 TTS 系统中。这种分离式训练提高了对未见说话人的泛化能力。实验表明,该方法仅需新说话人几分钟的音频数据即可实现双语语音合成,且两种语言均能达到良好的自然度和相似度。Himawan 团队开发了一种零样本跨语言语音合成方法^[52],构建一个包含大量单语种和少数双语种的混合数据集进行训练。这种方式使模型学习到一个对语言与音色泛化能力强的底层声学表达,之后进行异语言微调以实现零样本合成。

文献[53]提出了一种基于神经网络嵌入的跨语言语音合成方法,通过联合使用说话人嵌入、音色嵌入并创新性的

加入音素-内容嵌入实现跨语言关系映射,从而建立不同语言音素间的合理关联,实现从未说过目标语言的说话人语音合成。Gong 等人提出的 ZMM-TTS 模型^[54]利用自监督学习(SSL)形成的离散语音表示代替传统的梅尔频谱图。这种离散表示自带语言与声纹分离能力,提升了模型在未见语种上的迁移能力。ZMM-TTS 是首个在零样本说话人和未见语种 TTS 上表现出色的模型,具有高度解耦和语种控制能力。Rubenstein 等人提出了基于 VITS 架构^[55]的 YourTTS 模型^[20],在流式解码器、后验和声码器三处模块中创新性的加入全局说话人嵌入进行条件控制。使模型无论在潜变量学习、生成过程还是最终波形生成,都能强烈保留说话人声音特质,从而实现在未见语言上的声音一致性与高自然度。文献[56]设计了可插拔低样本 VT (Voice Transfer) 模块,该模块由编码层、瓶颈层和残差适配器组成,其中的残差适配器插件可以在 TTS 模型的时序预测模块和特征解码模块的每层注入音色信息,插件参数轻量且集成时无需更改原 TTS 主架构。该模型使用单个英语参考语音,在九种目标语言中实现平均 73% 的语音相似度,展示出强大的跨语言语音克隆和合成能力。微软团队推出的 VALL-E X^[57]模型是以 VALL-E^[58]模型为基础的扩展模型,VALL-E X 模型使用单语语音和目标语言文本完成训练,设计语言 ID 引导模型输出目标语言发音,而不是直接翻译或复制原语言音素序列,且能有效缓解外语口音问题。CosyVoice 2 模型^[59]引入有限标量化改进语义标记的表示能力,提高文本到语义标记映射的精度。且 CosyVoice 2 还支持支持流式低延迟与离线合成模式一体化,适用于实时语音交互场景。相比于 CosyVoice^[60],CosyVoice2 将合成音频的发音错误率降低了 30% 至 50%,且支持更多语言及方言控制(如粤语、川话等)并提供情感与口音调节功能。此外,作为一种完全非自回归的双阶段模型,MaskGCT^[18]不依赖显式文本与音频对齐,也无需音素级时长预测,其掩码生成策略避免了传统 TTS 中语言与对齐信息耦合的瓶颈,直接从输入语音中学习声学特征,实现零样本迁移。

2.4 基于对抗学习方法的跨语言语音合成

对抗学习方法源于博弈论中的对抗思想,旨在通过让两个或多个相互对抗的模型进行竞争与协作来学习数据中的模式和特征,显著提升模型的性能和泛化能力。如图9所示,对抗学习方法通常由生成器和判别器组成,生成器负责生成数据样本,试图欺骗判别器;而判别器负责判断输入的数据是真实数据还是由生成器生成的虚假数据。对抗学习通过引入判别器优化生成语音的自然度和说话人音色一致性,成为跨语言语音合成的重要技术路线。




图9 GAN 基本架构图

Fig.9 Basic Architecture Diagram of GAN

Choi 等人提出的 StarGAN-VC^[61]是语音转换领域最早采用统一对抗框架进行多说话人音色迁移的系统之一。其借鉴了图像领域的 StarGAN^[62]结构,引入单一生成器和多任务判别器,实现多说话人之间的语音风格转换。在跨语言场景中,StarGAN-VC 模型框架为之后的说话人音色迁移提供了原型模板。Zhang 等人提出了基于 Tacotron^[63]的多说话人、多语言 TTS 模型^[64]。在 Tacotron 模型的编码器端加入一个语言分类器,在训练过程中,模型试图最大程度隐藏说话人的语言身份信息,通过反向传播,其编码器被强制学习对语言不敏感的中间表示;

同时保留说话人的特质,使说话人在目标语言合成中的声线仍能被识别。这种生成对抗式设计有效解耦了语言与说话人身份。文献[65]提出一种结合跨说话人音色迁移的多语种 TTS 合成方法 M³TTS,旨在改善语音的个性化和自然度。该方法用音色编码器提取语音中的情感、韵律等特征,但存在说话人身份信息混入音色编码器的风险,在风格编码器之后加上梯度反转层反向优化,从而减弱其对说话人身份信息的表达能力。这种对抗性训练机制可剥离音色与说话人之间的耦合,令模型在迁移到其他语言时,能够借用说话人风格,但不会带入其母语发音特征,显著减轻了外语口音问题。此外,Ho 等人也提出了一种结合变分自编码器和星型生成对抗网络的跨语言语音转换方法 VAE-StarGAN^[66],该方法使用 VAE 编码器提取语义内容向量与说话人嵌入,说话人嵌入向量可线性插值,用 StarGAN 的域分类器保持嵌入有效性,从而连续控制音色、生成不存在于训练集的声音。模型将对数基频作为额外通道直接注入解码器,再用 StarGAN 判别声学-基频组合的真实性,显著改善跨语言音高失真,提高了合成语音的质量。文献[67]利用语言、说话人和韵律三种全局语音风格嵌入来提升 TTS 模型的性能。对抗训练目标是使每个嵌入只专注于自己的属性,不含其他干扰信息。该方法能够在说话人的声音中合成不同语言和韵律的语音,而不受其自身语言和韵律的限制。

2.5 基于情感迁移的跨语言语音合成

近年来,跨语言情感语音合成(Cross-Lingual Emotional Speech Synthesis)成为语音合成领域的重要研究方向,旨在实现不同语言之间的情感迁移。这一任务的挑战在于如何在目标语言中保留源语言中的情感特征,同时避免外语口音的干扰^[68]。为此,研究者们提出了多种方法,以提高合成语音

的自然度和情感表达能力。

Zhu 等人提出了 METTS 模型^[69], 利用多尺度情感建模和向量量化情感匹配器, 实现了跨说话人和跨语言的情感迁移, 显著提升了合成语音的自然度和情感表达能力。该模型采用 DelightfulTTS^[70] 作为骨干网络, 提出了多尺度情感建模方法, 将语音韵律分解为粗粒度和细粒度两个尺度, 分别生成语言无关和语言特定的情感表示, 从而缓解了外语口音问题。此外, METTS 还引入了基于共振峰偏移的信息扰动方法作为预处理步骤, 有效地解耦了说话人音色信息。同时, Li 等人提出了 DiCLET-TTS 模型^[71], 采用正交投影情感解耦模块 OP-EDM, 学习一种与说话人无关但与情感显著对应的情感嵌入。在反向生成阶段, 模型的扩散解码器同时输入说话人嵌入与情感嵌入。该方法显著提升了跨语言情感合成的效果, 即使目标说话人没有情感语料也能表达精准的情感色彩。Li 等人提出了跨语言语音合成零样本情感迁移方法^[72], 该方法创新地在架构中引入非自回归预测编码模块 (NPC) 与 Hubert 多层次情绪编码机制。其中, NPC 模块通过自监督方式学习语言特定韵律特征, 使用预训练 HuBERT^[26] 提取包含语言无关但情感相关的特征, 即利用 HuBERT 多层中间表示, 将单一句子语音中的跨语言情感信息抽象为层次化的嵌入, 使得整体情绪和细节表达得以被精准捕捉和迁移。该方法实现了纯源语言情感到目标语言表达的零样本跨语言情感迁移。

文献[73]提出了短语级跨语言韵律迁移, 以短语为最小单位能更好地保留语音中的表达细节 (如语调、高低起伏、重音等), 实现情感色彩的更加自然传递。同时设计基于短语长度的正则项, 抑制短语编码器捕获内容信息, 保证它只表达韵律特征。Ashishkumar 等人提出了 VECL-TTS^[74] 系统, 结合多语言说话人和情感嵌入网络, 实现了语音身份和情感风格的可控跨语言语音合成, 实现高质量的自动配音。采用模块化设计, VECL-TTS 将语音身份、情感风格和语言内容的建模分开, 允许独立控制和生成这些组件。为了保持目标情感风格, VECL-TTS 还引入了情感一致性损失, 通过最大化生成语音与目标语音在情感嵌入空间的余弦相似度来实现。

Guo 等人提出了 X-E-Speech^[75] 模型, 通过在 TTS 模块中冻结与音色相关的模型组件, 并微调与内容相关的结构, 使得在没有目标语言情感训练数据的情况下, 也能实现跨语言情感语音合成。开创性地在 TTS 和 VC 之间引入跨任务情感一致性损失, 使得 VC 提取的内容特征与 TTS 前馈文本特征在情感表达层面达到一致。此外, Tran 等人提出了 STEN-TTS 模型^[76], 引入风格增强归一化模块 (STEN), 在扩散模型每层对隐藏特征进行归一化的同时, 注入来自说话人的风格信息, 该方法使反向扩散过程不仅还原音频内容, 还保留说话人的风格特质。实验结果表明,

STEN-TTS 在多语言情感语音合成任务中取得了优异的性能。

2.6 基于低延迟的跨语言语音合成

低延迟跨语言语音合成旨在在跨语言生成条件下, 将从输入 (如文本或参考音频) 到语音输出的延迟降至最小, 同时仍然保证语音自然度、说话人音色一致性和语言准确性。这在实时翻译、跨语对话、多语客服等应用场景中极为关键。传统自回归模型因为帧间串行依赖, 推理缓慢且容易出现漏读或重复, 因此难以满足低延迟跨语言需求。研究者通常从三个方向入手: 并行生成结构、流式生成机制, 以及跨语言迁移策略。

在结构设计层面, 非自回归或并行生成方式是减少延迟的核心路径。这类模型可以同时预测多个声学帧, 无需等待前一帧输出, 从而显著加速。在跨语言语境下, 这类结构还必须兼顾语言迁移能力和说话人音色保持。文献[56]将语音迁移模块设计为可插组件, 通过参考语音驱动跨语言音色迁移, 取得较好说话人一致性。CrossSpeech++^[48] 进一步将语言生成与说话人生成路径拆分设计, 使迁移与生成流程可分别优化, 从而更利于延迟控制。VECL-TTS^[74] 在此基础上进一步引入情感与风格控制模块, 并通过内容一致性及风格一致性损失增强跨语言迁移的稳定性, 使系统不仅能迁移音色, 也能控制表达风格。

在生成机制层面, 流式生成是降低总体延迟的重要策略。跨语言环境下, 系统需要在尚未接收完整目标语言输入时便开始发声, 这要求模型具有前瞻预测和动态校正能力。常见方法是短缓冲 + 预测机制: 系统延迟输出几帧, 同时利用语言模型或声学预测器预估未来音素或韵律走势以辅助当前帧合成; 待后续输入齐备后再做微调。这一策略在单语系统中已有应用, 但跨语言模型需额外处理预测误差、语言结构差异和校正机制设计问题。

在跨语言迁移策略层面, 关键在于将语言信息与说话人风格信息有效分离。训练语料中语言与说话人往往高度耦合, 若模型未能解耦二者, 则迁移目标语言时容易引入音色漂移或外语腔调。为此, 许多跨语言 TTS 系统将语言编码器与说话人编码器并行设计, 并通过对抗训练或对齐损失促使说话人嵌入不携带语言特征。VECL-TTS^[74] 的设计也采用了这种分离思路, 同时引入风格控制模块和一致性损失以增强迁移稳定性。若将这些迁移模块设计为轻量化适配器或可增量更新结构, 则更利于低延迟部署。

2.7 基于多模态的跨语言语音合成

多模态跨语言语音合成旨在融合文本、语音、图像等多源模态信息, 提升跨语言语音合成的自然度、可控性与个性化。与传统单模态 TTS 相比, 多模态方法通过引入语音提

示、文本描述或视觉信息,使模型能够在多语种下实现风格保持、情感迁移及上下文一致的语音生成。

基于语音提示的跨语言音色迁移通过输入目标说话人的参考音频,使模型在另一语言中复现相同的音色与语调。微软的 VALL-E X^[57]在神经编码器语言模型基础上引入语音与文本双提示,实现了零样本跨语言声音克隆。模型以数秒语音捕捉说话人特征,再结合目标语言文本生成声学标记,合成音色高度保真的目标语音。Meta 的 Voicebox^[77]进一步在 flow-matching 框架下统一 TTS、语音转换与语音填补任务,实现了跨语言音色迁移、语音去噪及上下文一致生成。与 VALL-E X 相比, Voicebox 的优势在于通过大规模多任务训练掌握了语音“填空”能力,使其在零样本跨语言 TTS 上词错率降低 50%以上。此外, YourTTS^[20]与 CosyVoice 系列模型^[59-60,87]在语音提示的条件控制上实现了开源可复现的方案,能够在中、英、日等多语种间迁移音色。总体来看,语音提示类方法自然度高、个性保真,但受限于训练数据规模与模型参数量,推理开销较大。

基于文本描述提示的多模态控制提供了更灵活的语音生成方式。微软提出的 PromptTTS^[78]首次将自然语言描述作为风格输入,用户可通过描述性短语(如“a gentle female voice speaking slowly”)直接控制生成语音的语气与节奏。Shimizu 等人^[79]进一步提出 PromptTTS++,通过拆分描述理解与声学合成模块,并共享语言无关的音色嵌入,实现了跨语言描述控制。例如使用英文描述即可控制日语语音风格,实现跨语言语义对齐。这类方法利用 LLM 的语义理解能力,将语音风格控制转化为语义映射问题,使跨语言 TTS 具备类似 ChatGPT 的自然指令理解能力。其挑战在于跨语种标注语料不足,需要借助多语言描述-语音配对数据集与自监督预训练来扩充模型泛化能力。

基于语音补全与编辑的跨模态生成拓展了 TTS 的应用边界。Google 提出的 SpeechPainter^[80]通过文本条件填补语音缺失片段,可在保证音色一致的前提下恢复语音内容,被视为语音领域的“inpainting”模型。Meta 的 Voicebox^[77]同样支持语音编辑与重合成,在跨语言配音场景中可保留原说话人节奏与风格。Google 的 AudioPaLM^[81]进一步整合 ASR、翻译与 TTS 能力,直接实现从源语音到目标语言语音的一步生成,在跨语言语音翻译中保持音色一致性。此外,以视频作为引导的 Dubber^[82]等系统通过视觉帧与语音时长对齐,实现跨语言口型同步,展示了语音与视觉融合的潜力。

2.8 基于预训练大模型的跨语言语音合成

近年来,预训练大模型凭借其庞大的参数规模、广泛的训练语料和优越的迁移能力,成为跨语言语音合成的重要发展方向,尤其在多模态应用场景中展现出显著优势。

Ren 等人提出的 FastSpeech 2^[83]作为高效的基础 TTS 框架,在非自回归建模与韵律特征控制方面表现出色。该模

型通过引入音高、能量和时长等韵律特征作为条件输入,实现了语音自然度与推理速度的双重提升,为后续大规模语音合成系统的设计奠定了技术基础。Chen 等人提出的 SpeechLM^[84]引入了音素单元和隐藏单元两种离散表示桥接语音与文本的差异,将“无标签语音”和“无标签文本”都映射到同一个离散语义空间,使得文本与语音在预训练阶段能够共享表示。这样就能在跨语言 TTS 中直接用文本驱动生成语音。这一架构不仅增强了模型的语言迁移能力,还显著改善了低资源语言场景下的语音生成质量,但模型复杂度较高,训练和推理成本较大。OpenAI 在2024年推出的 GPT-4o^[85]是首个具备原生语音输入输出能力的 GPT 模型,它不再依赖传统语音识别、语言模型、与语音合成三轮管道,而是通过单一模型直接理解语音内容并实时输出语音,识别、翻译、合成都在同一个网络中完成,可支持中文、英文等超过 50 多种语言的语音理解与合成,语音响应延迟低至 232 毫秒,接近人类对话水平。大规模语音-文本联合训练为其提供了强大的语言生成与交互能力,在多语言人机交互系统中具有广泛应用前景。另一项由 Microsoft 提出的 VALL-E X^[57]模型则通过大规模离散语音单元建模实现了高保真语音克隆。模型以源语言语音输入和目标语言文本为输入,直接预测目标语言声学标记。该模型可实现对说话人音色、语调与节奏的精确复制,特别适用于零样本跨语言语音合成任务。THUNLP 团队发布的 GLM-4-Voice^[86]基于 GLM-4-9B 文本大模型扩展,采用超过1万亿标记的语音和文本互嵌预训练,涵盖纯文本、纯语音、和语音-文本混合格式数据,实现语音原生输入输出生成。将中英文多轮对话语料纳入训练,通过多任务联合优化情感与语言建模,提升了生成语音的连贯性与情感一致性。模型采用基于 CosyVoice^[60]的流匹配解码器实现 10 token 首包延迟的低时延流式语音生成,适用于实时对话和跨语言语音输出。

CosyVoice 2^[59]更加注重模型的部署效率,通过压缩 TTS 模块结构提升语音自然度与推理效率,使其更适用于语音快速响应场景及资源受限场景。该模型支持中文、英文、日语、韩语以及多种中文方言(如粤语、四川话、上海话、天津话、武汉话等)的跨语言语音合成,与前一版本 CosyVoice^[60]相比, CosyVoice 2 在跨语言语音合成的保真度和表现力方面有显著提升。近期新推出的 CosyVoice 3^[87]基于 MinMo 模型^[88]并融合语音识别、情感、语种识别、音频事件检测、说话人分析等多种功能,实现更细粒度的韵律与情感表达捕捉。CosyVoice 3 模型语料扩增至100万小时,覆盖9种语言和18种方言;模型参数由 0.5B 扩容至 1.5B,生成质量显著增强。专为在自然环境下进行零样本多语言语音合成而设计,它采用了一种新的语音分词器,在内容一致性、说话人相似性和韵律自然度方面超越了 CosyVoice 2。

Meta 推出的 SeamlessM4T^[89]通过单一 UnitY 解码

器和多模态输入编码器实现真正“即插即用”的多语音合成功能，无需拆分为多个子模型。模型将文本到离散语音单位模块与多语言 HiFi-GAN 声码器^[34]结合，能从文本直接生成高质量语音。SeamlessM4T 在语音翻译和跨语言合成任务中，尤其在低资源环境下表现出色。Gemini 系列是Google 最新的多模态大模型，采用语音、文本与视觉融合机制，实现了多模态信息的深度整合。支持多语言与多声线，用户可调控语速、风格、口音，实现更具表现力与定制化的语音合成。目前 Gemini 2.5 Flash/Pro^[90] 已接入 Gemini API 原生文本转语音功能中，支持380多种声线、50多种语言选择，适配播客、客服、阅读等多场景。与 Gemini Live 配合可实现实时口语对话交互，含视觉+语音输入，跨语言场景更丰富。LLaSA-3B^[91] 是由 HKUST Audio 团队提出的首个基于 GPT-style 大语言模型进行端到端 TTS 的开源模型，标志着情感语音建模的进一步发展。该模型采用单一

Transformer 和单层向量量化编码架构，在中英情感播报任务中展现了良好的风格控制与语音表现力。但该模型主要支持中文和英文之间的跨语言合成，对其他语言的支持较为有限。Yin 等人于2025年提出的 MegaTTS3^[92] 结合扩散模型与非自回归架构，在潜在扩散 Transformer (DiT) 中加入稀疏对齐锚点，即采样部分音素对应的相对对齐位置，帮助模型快速建立隐式对齐，无需全程硬对齐，同时保留更灵活的学习空间。该模型无缝支持中文和英文的文本输入，甚至能在同一段语音中实现自然的中英文切换。其不仅具备零样本语言扩展能力与情感迁移能力，同时兼顾生成速度与输出质量，适用于高要求的实时合成与个性化语音交互场景。

目前国内的多种模型也逐渐完备了跨语言合成能力，具体模型的比较表格见表2。

表 2 国内外大语言模型跨语言合成能力比较

Table 2 Comparison of Cross-lingual Generation Capabilities of Domestic and International Large Language Models

模型	是否支持语音输入/输出	能否跨语言合成文本	能否跨语言合成语音	性能	所属公司
Deepseek V3 ^[93]	否	是	否	MoE 架构，671B 参数，37B 激活，推理快（60 tok/s），成本低，性能接近 GPT-4/Claude 3.5	Deepseek AI
盘古 5.5 ^[94]	是	是	是	MoE 架构，718B 参数，快慢思考融合，支持多模态与长序列推理，效率提升显著	华为
通义千问 ^[95]	是	是	是	Qwen-Audio 处理音频输入，Qwen-TTS 支持中英及方言语音合成	阿里
文心一言 ^[96]	是	是	是	可接入 ASR + TTS，实现多语言输入输出与对话	百度
豆包 ^[97]	是	是	是	Seed-ASR 精准识别，Seed-TTS 真人音质，支持跨语种迁移	字节跳动
元宝 ^[98]	是	是	是	支持语音通话、语音识别与合成，具备跨语言迁移能力	腾讯
星火 ^[99]	是	是	是	支持语音输入输出与情绪感知，具备多语言交互能力	科大讯飞
GPT-4o-mini-tts	否	是	是	GPT-4o 系列文本-语音子模型，支持风格指令控制，自然度高、延迟低	OpenAI
Claude Voice	是	是	是	集成 ElevenLabs TTS 技术，支持多声音风格，支持实时语音对话。	Anthropic
WaveForms AI	是	是	是	致力于端到端 Audio LLM，目标“通过 Speech 图灵测试”，强调情感共鸣与沉浸式语音生成，开发中但备受关注。	WaveForms AI

3. 数据集和评价指标

3.1 数据集

在跨语言语音合成研究中，数据集的选择和构建至关重要。优质的数据不仅为模型的训练提供了多样而丰富的语音与语言信息，还直接影响系统在多语言或低资源条件下的泛化能力与合成质量。跨语言场景下，不同语言的语音在音系结构、发音规则、语调韵律等方面存在显著差异，因此需要覆盖广泛语种、具备统一标注规范的数据资源以支撑语义迁

移、发音一致性及语言特征保真的建模目标。此外，跨语言语音合成还常涉及说话人迁移、音色保留和语种切换等挑战，对语音数据的说话人多样性、语种分布平衡和语料精度提出更高要求。因此，系统性的语音数据资源在构建高质量跨语言语音合成系统中发挥着基础性作用。

本节将常用的数据集分为三类：英语单语数据集、普通话单语数据集、双语及多语数据集。数据集的内容、数据量及其他详细信息见表3。

表 3 数据集汇总

Table 3 Dataset summary

类型	名称	数据量	内容	数据格式与存储	网址
英语数据集	CMU ARCTIC ^[100]	每人约 1150 句	日常对话、新闻报道	16-bit PCM WAV，采样率 16kHz	https://huggingface.co/datasets/MikhailIT/cmu-arctic
	LibriTTS ^[101]	~585 小时	文学作品朗读，涵盖小说、散文	16-bit PCM WAV，采样率 24kHz	https://openslr.org/60/
	VCTK ^[102]	~44 小时	新闻文章、彩虹段落和用于口音档案的引导段落	16-bit PCM WAV，采样率 48kHz（也提供 96kHz 版本）	https://datashare.ed.ac.uk/handle/10283/3443
	LJ Speech ^[103]	~24 小时	公共领域的非小说类书籍朗读	16-bit PCM WAV，采样率 22.05kHz	https://keithito.com/LJ-Speech-Dataset/

类型	名称	数据量	内容	数据格式与存储	网址
普通 话数 据集	AIShell-1 ^[104]	~178 小时开源 子集	日常对话、新闻、命 令	16-bit FLAC 压缩 WAV, 麦克风录 音采样率 44.1kHz, 手机录音采样率 16kHz	https://www.openslr.org/33/
	AIShell-3 ^[104]	~85 小时	情感中性的朗读语料	16-bit PCM WAV, 采样率 44.1kHz	https://openslr.org/93/
	THCHS-30 ^[106]	~30 小时	新闻、日常对话等	16-bit PCM WAV, 采样率 16kHz	http://openslr.org/18/
多语 种数 据集	CSS10 ^[107]	每种语言约 1 小时	10 种语言的文学作品 朗读	16-bit PCM WAV, 采样率 22.05kHz	https://github.com/Kyubyong/css10
	M-AILABS	~4000 小时	8 种语言文学作品朗 读	16-bit PCM WAV, 单声道, 采样率 16kHz	https://github.com/imdatceleste/m-ailabs-dataset
	Common Voice ^[108]	~14000 小时	60 多种语言日常对 话、短语	MP3, 采样率 48kHz	https://commonvoice.mozilla.org/datasets
	Multilingual LibriSpeech (MLS) ^[109]	~1,000 小时	8 种语言文学作品朗 读	16-bit PCM WAV, 采样率 16kHz	https://www.openslr.org/94/
	Covos ^[110]	约 2,000 小时	11 种语言到英文文本 翻译	16-bit PCM WAV, 采样率 16kHz	https://github.com/facebookresearch/covost
	Bstc ^[111]	~68 小时	中英双语演讲	16-bit PCM WAV, 采样率 16kHz	https://ai.baidu.com/broad/introduction?dataset=bstc
	CVSS ^[112]	不详	21 种语言的翻译语音 样本	16-bit PCM WAV, 采样率 16kHz	https://github.com/google-research-datasets/cvss
	CML-TTS ^[113]	~3,233.43 小时	12 种语言的多说话人 语音录音	16-bit PCM WAV, 采样率 24kHz	https://openslr.org/146/
	Emilia ^[114]	~101 小时	6 种语言的语音录音	16-bit PCM WAV 格式, 采样率 16kHz	https://huggingface.co/datasets/amphion/Emilia

为全面分析不同数据集在跨语言语音合成中的适用性,我们从语言类型、数据规模、标注质量与数据局限性四个维度对上述数据集进行归纳分析:

1) 语言类型: 单语种数据集(如LJSpeech、AIShell-1)在建模特定语言的声学规律方面具有优势,但缺乏跨语言映射信息;相比之下,多语种数据集(如Common Voice、MLS、CSS10)由于覆盖语言范围更广,更适合用于学习不同语种间的音素对应关系和韵律特征,从而支持跨语言建模。

2) 数据规模: 大规模数据集(如Common Voice、M-AILABS)能够有效提升模型的鲁棒性和泛化能力,但往往存在语音质量参差不齐的问题;小规模数据集(如CSS10)在方法验证与快速实验方面具有一定价值,但难以满足大模型训练所需的数据支撑。

3) 标注质量: 高质量标注数据集(如AIShell-3、VCTK)提供了可靠的语音与文本对齐信息,有助于保证模型在音色保持和可懂度上的表现;而基于众包方式构建的数据集(如Common Voice),虽然规模庞大,但标注一致性不足,可能对合成语音的准确性和自然度产生负面影响。

4) 局限性及适用性: 公共多语种语音数据集(如Common Voice、MLS等)语言覆盖广、语种丰富,但也面临录音设备差异、环境噪声、对齐质量不均、录音片段长度受限、正字法标准不一致、口音变异大等问题;部分低资源语种录音片段极短,韵律和语调表达可能不完整。尽管如此,这些数据集在跨语言模型训练中仍具备重要价值,如语种覆盖扩展、迁移预训练和模型泛化验证等场景。但若用于高质量语音合成,通常须配合数据清洗、对齐校正和优质说话人样本筛选,以提升在发音准确性、韵律自然性和说话人音色保持方面的表现。

总体而言,单语种的大规模高质量语料能增强模型在特

定语言内部的合成效果;而多语种数据集在跨语言迁移与泛化建模中发挥关键作用。两类数据集的互补使用,有助于兼顾音色保真性与跨语种自然度,从而为构建通用型跨语言TTS系统奠定稳固的数据基础。

3.2 评价指标

3.2.1 主观评价指标

主观评价指标是通过人类听感测试来评估生成语音质量的关键标准,它侧重于听众对合成语音的主观感受。由于语音合成的目标是生成尽可能接近真实人类语音的音频,主观评价便成为人类听觉系统对音色特征、韵律节奏、情感传达等复杂维度综合感知的有效方式。

平均意见分(Mean Opinion Score, MOS)是用于评估语音质量和可懂度的主观评价指标,广泛应用于语音合成、语音识别和语音通信等领域。MOS采用五点量表(1=极差,5=优异)量化语音质量和可理解性。该指标遵循国际电信联盟(ITU-T P.800)标准,要求被试者在消声室环境中,基于随机播放的语音样本,从自然度、清晰度、连贯性等维度进行独立评分。不过,MOS评分存在一定局限性,评分结果易受评分者个体差异(如年龄、听力敏锐度、语言背景等)的影响,同时组织专业听力测试团队进行测试的成本较高。

MOS的计算公式如下:

$$MOS = \frac{1}{n} \sum_{i=1}^n s_i \quad (1)$$

其中 n 是评分者的数量, s_i 是第 i 位评分者给出的分数(范围为1到5)。

ABX测试是一种用于评估语音相似性和区分度的主观评价方法。在ABX测试中,评估者会听到三个语音样本:

A、B 和 X，其中A和B是两个不同的语音样本，而X是A或B的复制或变体。评估者的任务是根据听到的语音样本判断 X 与 A 或 B 哪一个更为相似。这种方法的核心目的是检验人类听众在两种语音之间的感知差异。相较于 MOS 评分依据总体印象打分，它聚焦于语音样本之间的直接对比，能够提供更为精细的差异感知评估^[115]。然而，ABX 测试的结果受评估者听觉能力以及测试设计的影响较大，因此需要在严格控制的特定实验条件下开展。

主观评价指标的显著优势在于，它能够真实反映人类对语音合成的接受程度，但不可忽视的是，其测试结果会受到听众听觉能力、心理状态、语言背景等多种因素的干扰，并且在进行大规模评价测试时成本较高。因此，在实际应用中，主观评价通常会与客观评价相结合，以便全面、准确地衡量语音合成模型的性能。

3.2.2 客观评价指标

客观评价指标通过量化合成语音与原语音之间的距离或相似度来实现对语音合成模型性能的自动化评估。与侧重于人类主观感受的主观评价不同，客观评价从频谱、基频、字词等多个特征维度，为模型的优化提供了具体的数据支持。

梅尔倒谱失真 (Mel-Cepstral Distortion, MCD) 是评估合成语音与参考语音频谱差异的常用客观指标。MCD 通过计算梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCCs) 之间的差异来量化语音信号的相似度。先分别提取参考语音和合成语音的 MFCCs，再运用对数欧氏距离对比两者差异，最终得出 MCD 值。MCD 值越小，表明合成语音与参考语音在频谱特征上越相似，合成语音的音质越好。MCD 能够有效捕捉语音在音色和质量方面的特征，在语音合成、语音转换及语音质量评估等领域得到了广泛应用，成为衡量模型性能的重要标准之一。

MCD的计算公式如下：

$$MCD = \frac{1}{N} \sum_{n=1}^N \sqrt{\sum_{m=1}^M (c_m^{(n)} - \hat{c}_m^{(n)})^2} \quad (2)$$

其中 N 是帧的总数， M 是梅尔倒谱系数的维度， $c_m^{(n)}$

是第 n 帧的第 m 个梅尔倒谱系数（来自参考语音）， $\hat{c}_m^{(n)}$

是第 n 帧的第 m 个梅尔倒谱系数（来自合成语音）。

字符错误率 (Character Error Rate, CER) 和单词错误率 (Word Error Rate, WER) 代表生成文本与参考文本之间的差异程度。它通过统计生成文本相对于参考文本的插入、删除和替换字符数量，并与参考文本的总字符数进行计算，得出错误比例。CER 或 WER 值越低，表明生成文本与参考文本的相似程度越高，意味着语音合成系统在文本转换方面的准确性越高。

CER 或 WER 通常包括插入、删除和替换操作，计算公式如下：

$$CER(WER) = \frac{S + D + I}{N} \quad (3)$$

其中， S 是替换的字数或单词数， D 是删除的字数或单词数， I 是插入的字数或单词数， N 是参考文本的总字数或总单词数。

文本-语音分布评分 (Text-to-Speech Distribution Score, TTDS) 基于韵律、说话人身份、可懂度等多个维度提取分布特征，测量合成语音与真实语音间的分布距离，并将这些距离取平均作为最终得分。实验证明，该指标与 MOS 分数高度相关，适用于跨模型与跨时间段的对比评估^[116]。

说话人相似度 (Speaker Similarity, SIM) 用于衡量合成语音与目标说话人原始录音在说话人身份与音色方面的相似程度。通常采用预训练说话人验证模型提取两者的声音嵌入，再用余弦相似度或其它相似度度量计算。SIM 值越高，说明合成语音在说话人特征保持方面越好。此指标在跨语言语音合成及语音克隆任务中尤为重要，因为这类任务的核心之一正是保持说话人身份的一致性。

这些客观评价指标各自从不同维度出发，在语音合成模型的训练和评估中发挥着关键作用。然而，它们也存在一定局限性，难以全面反映语音合成在实际应用场景中的综合表现。在实际应用中，需将客观评价指标与主观评价指标相结合，综合考量模型在语音清晰度、自然度、可懂度、情感表达以及说话人相似性等多方面的表现，才能更全面、准确地评估跨语言语音合成模型的性能，为模型的优化和改进提供更可靠的参考。

4. 总结与展望

本文首先介绍了经典语音合成模型，随后从早期的跨语言语音合成方法，到低资源条件下的创新策略、预训练方法、解耦方法、零样本学习、对抗学习以及其他多种新兴技术，全面梳理了跨语言语音合成领域的技术发展脉络。同时，还对该领域研究中常用的数据集进行了汇总，包括英语、中文等单语言数据集以及多种多语言数据集，并介绍了常用的主观和客观评价指标，为模型评估提供了全面的参考依据。本文认为跨语言语音合成技术在未来可能会呈现如下研究趋势和发展方向：

1) 针对跨语言的韵律一致性问题，可以引入语言无关的韵律编码器，并结合动态韵律生成机制，使模型能够根据目标语言的文化习惯和语言特性自适应地调整语调模式。例如在中文合成中考虑声调变化，在英文合成中强调轻重音分布。

2) 现有零样本方法在音色保真度和语言适应性方面仍有限，未来可结合扩散模型和大规模预训练框架，构建更具

普适性的通用语音表示,同时在合成过程中捕捉并建模口音细节,以提升跨语种音色迁移的真实性。

3) 数据层面,可探索多语言、多口音、多情感融合的复合型数据集,同时加入真实场景下的噪声与干扰,从而增强模型在实际应用中的稳健性。进一步地,可以引入多模态资源(如视频、文本、语义标签)构建跨模态数据集,为韵律与情感建模提供更丰富的监督信号。

4) 在评价体系上,未来不仅需要分语言、分地区的MOS测试协议,还应探索自动化、多模态的综合评价方法。例如将主观感知、语音识别准确率、情感一致性等指标结合,以构建更客观、全面的评估框架。

5) 跨语言语音合成的研究还可以向更复杂的生成任务扩展,如跨语言歌声合成或跨语言影视配音。研究者可以先探索带背景音或环境音的跨语言合成(如纪录片解说),再逐步扩展到包含编曲与和声的跨语言歌声生成。

6) 此外,还可以将大语言模型和多模态生成模型的结合。大语言模型可为跨语言TTS提供更强的语义建模与推理能力,而多模态融合可帮助模型在跨语言交互中更好地理解上下文和场景,从而生成更加自然、符合语境的语音。

总之,跨语言语音合成技术的前景非常广阔,虽然各位研究者在技术层面上已经实现了从无到有、由劣到好的重大突破,但这仍是跨语言语音合成漫漫长路上的第一步,想要实现更便捷、更人性化的美好社会,还需每一位研究者的继续努力。

参考文献

- [1] REN P S, DU Y C, WANG H J. A Survey of Speech Style Transfer[J]. Software Guide, 2024,23(11):12-24.(in Chinese)
任蓬森,都云程,王洪俊.语音风格迁移研究综述[J].软件导刊,2024,23(11):12-24.
- [2] SHANG Z Q, ZHANG P Y, WANG L. Multilingual text-to-waveform with cross-speaker prosody transfer[J]. ACTA ACUSTICA, 2024, 49(1): 171-180.DOI:10.12395/0371-0025.2022146.(in Chinese)
尚增强,张鹏远,王丽.融合跨说话人韵律迁移的多语种文本到波形生成[J].声学学报,2024,49(01):171-180.DOI:10.12395/0371-0025.2022146.
- [3] GUO J M, ZHAO Y R, LIU G S. Contrastive meta-learning framework for few-shot cross-lingual text classification[J]. Chinese Journal of Network and Information Security, 2024,10(03):107-116.(in Chinese)
郭建铭,赵彧然,刘功申.用于小样本跨语言文本分类的元对比学习框架[J].网络与信息安全学报,2024,10(03):107-116.
- [4] LIU C. Research on cross-lingual text-to-speech of chinese and english[D]. Harbin Institute of Technology, 2021.DOI:10.27061/d.cnki.ghgdu.2021.006294. (in Chinese)
- 刘超.中英文跨语言语音合成方法研究[D].哈尔滨工业大学,2021.DOI:10.27061/d.cnki.ghgdu.2021.006294.
- [5] TONG X, XIA T, YANG M H, et al. Research on Factuality Issues in Large Language Models: Evaluation, Enhancement, and Prospects[J/OL]. Information studies: Theory & Application, 1-16[2025-04-28]. [\(in Chinese\)](http://kns.cnki.net/kcms/detail/11.1762.G3.20250305.1739.004.html)
全鑫,夏天,杨孟辉,等.大语言模型的事实性问题研究:评估、增强和展望[J/OL].情报理论与实践,1-16[2025-04-28].<http://kns.cnki.net/kcms/detail/11.1762.G3.20250305.1739.004.html>.
- [6] FU Z Y, CHEN S Y, CHEN J F, et al. Challenges and Opportunities of Large Language Model Security[J]. Journal of Cyber Security, 2024,9(05):26-55.DOI:10.19363/J.cnki.cn10-1380/tn.2024.09.02.(in Chinese)
付志远,陈思宇,陈骏帆,等.大语言模型安全的挑战与机遇[J].信息安全学报,2024,9(05):26-55.DOI:10.19363/J.cnki.cn10-1380/tn.2024.09.02.
- [7] YU Z T, DONG L, GAO S X. Research Progress of Low-Resource Speech Recognition[J]. Journal of Kunming University of Science and Technology(Natural Science), 2024,49(03):86-102.DOI:10.16112/j.cnki.53-1223/n.2024.03.231.(in Chinese)
余正涛,董凌,高盛祥.低资源语音识别研究进展[J].昆明理工大学学报(自然科学版),2024,49(03):86-102.DOI:10.16112/j.cnki.53-1223/n.2024.03.231.
- [8] PAN X Q, LU T L, DU Y H, et al. Overview of Speech Synthesis and Voice Conversion Technology Based on Deep Learning[J]. Computer Science, 2021,48(08):200-208.(in Chinese)
潘孝勤,芦天亮,杜彦辉,等.基于深度学习的语音合成与转换技术综述[J].计算机科学,2021,48(08):200-208.
- [9] AZZUNI H, SADDIK A E. Voice Cloning: Comprehensive Survey[J]. arXiv preprint arXiv:2505.00579, 2025.
- [10] ATHRI K H, BHOOMIKA B K, DHEERAJ T N, et al. A Survey on Multilingual Text Conversion and Speech Generation Workflow[J]. International Journal of Scientific Research in Computer Science Engineering and Information Technology, 2025, 11(2): 3471-3479. DOI:10.32628/CSEIT25112826.
- [11] SHEN J, PANG R, WEISS R J, et al. Natural tts synthesis by conditioning wavenet on mel spectrogram predictions[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 4779-4783.
- [12] REN Y, RUAN Y, TAN X, et al. FastSpeech: Fast, robust and controllable text to speech[J]. Advances in neural information processing systems, 2019, 32.

- [13] KIM J, KIM S, KONG J, et al. Glow-tts: A generative flow for text-to-speech via monotonic alignment search[J]. Advances in Neural Information Processing Systems, 2020, 33: 8067-8077.
- [14] YAO J, WANG Q, GUO P, et al. MUSA: Multi-lingual speaker anonymization via serial disentanglement[J]. IEEE Transactions on Audio, Speech and Language Processing, 2025.
- [15] PING W, PENG K, GIBIANSKY A, et al. Deep voice 3: Scaling text-to-speech with convolutional sequence learning[J]. arXiv preprint arXiv:1710.07654, 2017.
- [16] HUANG S F, LIN C J, LIU D R, et al. Meta-tts: Meta-learning for few-shot speaker adaptive text-to-speech[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 1558-1571.
- [17] NACHMANI E, WOLF L. Unsupervised polyglot text-to-speech[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 7055-7059.
- [18] WANG Y C, ZHAN H Y, LIU L W, et al. MaskGCT: Zero-shot text-to-speech with masked generative codec transformer[J/OL]. arXiv preprint, 2024.
- [19] ZHANG Y, WEISS R J, ZEN H, et al. Learning to speak fluently in a foreign language: Multilingual speech synthesis and cross-language voice cloning[J]. arXiv preprint arXiv:1907.04448, 2019.
- [20] CASANOVA E, WEBER J, SHULBY C D, et al. Yourtts: Towards zero-shot multi-speaker tts and zero-shot voice conversion for everyone[C]//International conference on machine learning. PMLR, 2022: 2709-2720.
- [21] TOSHNIWAL S, LIVESCU K. Jointly learning to align and convert graphemes to phonemes with neural attention models[C]//2016 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2016: 76-82.
- [22] YOLCHUYEVA S, NÉMETH G, GYIRES-TÓTH B. Transformer based grapheme-to-phoneme conversion[J]. arXiv preprint arXiv:2004.06338, 2020.
- [23] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [24] CONNEAU A, KHANDELWAL K, GOYAL N, et al. Unsupervised cross-lingual representation learning at scale[J]. arXiv preprint arXiv:1911.02116, 2019.
- [25] BAEVSKIA, ZHOU Y, MOHAMED A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations[J]. Advances in neural information processing systems, 2020, 33: 12449-12460.
- [26] HSU W N, BOLTE B, TSAI Y H H, et al. Hubert: Self-supervised speech representation learning by masked prediction of hidden units[J]. IEEE/ACM transactions on audio, speech, and language processing, 2021, 29: 3451-3460.
- [27] LI L, WANG D, ZHANG Z, et al. Deep speaker vectors for semi text-independent speaker verification[J]. arXiv preprint arXiv:1505.06427, 2015.
- [28] WAN L, WANG Q, PAPIR A, et al. Generalized end-to-end loss for speaker verification[C]//2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2018: 4879-4883.
- [29] VAN DEN OORD A, VINYALS O. Neural discrete representation learning[J]. Advances in neural information processing systems, 2017, 30.
- [30] SHIH K J, VALLE R, BADLANI R, et al. RAD-TTS: Parallel flow-based TTS with robust alignment learning and diverse synthesis[C]//ICML Workshop on Invertible Neural Networks, Normalizing Flows, and Explicit Likelihood Models. 2021.
- [31] VAN DEN OORD A, DIELEMAN S, ZEN H, et al. Wavenet: A generative model for raw audio[J]. arXiv preprint arXiv:1609.03499, 2016, 12.
- [32] PRENGER R, VALLE R, CATANZARO B. Waveglow: A flow-based generative network for speech synthesis[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 3617-3621.
- [33] YAMAMOTO R, SONG E, KIM J M. Parallel WaveGAN: A fast waveform generation model based on generative adversarial networks with multi-resolution spectrogram[C]//ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 6199-6203.
- [34] KONG J, KIM J, BAE J. Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis[J]. Advances in neural information processing systems, 2020, 33: 17022-17033.
- [35] DÉFOSSEZ A, COPET J, SYNNAEVE G, et al. High fidelity neural audio compression[J]. arXiv preprint arXiv:2210.13438, 2022.
- [36] ZHANG J L, MAIRIDAN W, GULANBAIER T. Review of Speech Synthesis Methods Under Low-Resource Condition[J]. Computer Engineering and Applications, 2023,59(15):1-16.(in Chinese)
- 张佳琳,买日旦·吾守尔,古兰拜尔·吐尔洪.低资源条件下的语音合成方法综述[J].计算机工程与应用,2023,59(15):1-16.
- [37] HE M, YANG J, HE L, et al. Multilingual byte2speech models for scalable low-resource speech synthesis[J]. arXiv preprint arXiv:2103.03541, 2021.
- [38] WELLS D, RICHMOND K. Cross-lingual transfer of phonological features for low-resource speech synthesis[C]//The 11th ISCA Speech Synthesis Workshop (SSW11). 2021.
- [39] BYAMBADORJ Z, NISHIMURA R, AYUSH A, et al. Text-to-speech system for low-resource language using cross-lingual transfer learning and data augmentation[J]. EURASIP Journal on Audio, Speech, and Music Processing,

- 2021, 2021(1): 42.
- [40] AMALAS A, GHOGHO M, CHETOUANI M, et al. A multilingual training strategy for low resource Text to Speech[J]. arXiv preprint arXiv:2409.01217, 2024.
- [41] OuteAI. OuteTTS-0.1-350M: Teaching Language Models to Speak via Audio Tokens and Forced Alignment. OuteAI Blog, 2024.
- [42] SAEKI T, MAITI S, LI X, et al. Learning to speak from text: Zero-shot multilingual text-to-speech with unsupervised text pretraining[J]. arXiv preprint arXiv:2301.12596, 2023.
- [43] ZHANG X R, YANG J, WANG ZHAN. Thai Speech Synthesis Based on Cross-language Transfer Learning and Joint Training[J]. Computer Science, 2024,51(S1):310-316.(in Chinese)
- 张欣瑞,杨鉴,王展.基于跨语言迁移学习及联合训练的泰语语音合成[J].计算机科学,2024,51(S1):310-316.
- [44] KWON K J, SO J H, LEE S H. Parameter-Efficient Fine-Tuning for Low-Resource Text-to-Speech via Cross-Lingual Continual Learning[C]//Proc. Interspeech 2025. 2025: 1613-1617.
- [45] PENG Y, LING Z. Decoupled pronunciation and prosody modeling in meta-learning-based multilingual speech synthesis[J]. arXiv preprint arXiv:2209.06789, 2022.
- [46] KANEKO T, KAMEOKA H, TANAKA K, et al. Stargan-vc2: Rethinking conditional methods for stargan-based voice conversion[J]. arXiv preprint arXiv:1907.12279, 2019.
- [47] KIM J H, YANG H S, JU Y C, et al. CrossSpeech: Speaker-independent acoustic representation for cross-lingual speech synthesis[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [48] KIM J H, YANG H S, JU Y C, et al. CrossSpeech++: Cross-lingual speech synthesis with decoupled language and speaker generation[J/OL]. arXiv preprint arXiv:2412.20048, 2024.
- [49] KHURANA S, KLEMENT D, LAURENT A, et al. Factorized RVQ-GAN For Disentangled Speech Tokenization[J]. arXiv preprint arXiv:2506.15456, 2025.
- [50] FENG F, YANG Y, CER D, et al. Language-agnostic BERT sentence embedding[J]. arXiv preprint arXiv:2007.01852, 2020.
- [51] CHEN M, CHEN M, LIANG S, et al. Cross-lingual, multi-speaker text-to-speech synthesis using neural speaker embedding. Proceedings of Interspeech 2019. ISCA.
- [52] HIMAWAN I, ARYAL S, OUYANG I, et al. Speaker adaptation of a multilingual acoustic model for cross-language synthesis[C]//ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 7629-7633.
- [53] NOSEK T V, SUZIĆ S B, PEKAR D J, et al. Cross-lingual neural network speech synthesis based on multiple embeddings[J]. 2021.
- [54] GONG C, WANG X, COOPER E, et al. Zmm-tts: Zero-shot multilingual and multispeaker speech synthesis conditioned on self-supervised discrete speech representations[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024.
- [55] KIM J, KONG J, SON J. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech[C]//International Conference on Machine Learning. PMLR, 2021: 5530-5540.
- [56] BIADSY F, CHEN Y, ELIAS I, et al. Zero-shot cross-lingual voice transfer for tts[J]. arXiv preprint arXiv:2409.13910, 2024.
- [57] ZHANG Z, ZHOU L, WANG C, et al. Speak foreign languages with your own voice: Cross-lingual neural codec language modeling[J]. arXiv preprint arXiv:2303.03926, 2023.
- [58] WANG C, CHEN S, WU Y, et al. Neural codec language models are zero-shot text to speech synthesizers[J]. arXiv preprint arXiv:2301.02111, 2023.
- [59] XIANG L, WANG Y, ZHAO T, et al. Build LLM-Based Zero-Shot Streaming TTS System with Cosyvoice[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. ICASSP, 2025: 1-2.
- [60] DU Z, CHEN Q, ZHANG S, et al. Cosyvoice: A scalable multilingual zero-shot text-to-speech synthesizer based on supervised semantic tokens[J]. arXiv preprint arXiv:2407.05407, 2024.
- [61] KAMEOKA H, KANEKO T, TANAKA K, et al. Stargan-vc: Non-parallel many-to-many voice conversion using star generative adversarial networks[C]//2018 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2018: 266-273.
- [62] CHOI Y, CHOI M, KIM M, et al. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8789-8797.
- [63] WANG Y, SKERRY-RYAN R J, STANTON D, et al. Tacotron: Towards end-to-end speech synthesis[J]. arXiv preprint arXiv:1703.10135, 2017.
- [64] ZHANG Y, WEISS R J, ZEN H, et al. Learning to speak fluently in a foreign language: Multilingual speech synthesis and cross-language voice cloning. arXiv preprint arXiv: 1905.08529, 2019.
- [65] SHANG Z, HUANG Z, ZHANG H, et al. Incorporating Cross-Speaker Style Transfer for Multi-Language Text-to-Speech. In: Interspeech 2021; 2021.
- [66] HO T V, AKAGI M. Cross-lingual voice conversion with controllable speaker individuality using variational autoencoder and star generative adversarial network[J]. IEEE Access, 2021, 9: 47503-47515.
- [67] KIM M K, CHANG J H. Adversarial and Sequential

- Training for Cross-lingual Prosody Transfer TTS[C]/INTERSPEECH. 2022: 4556-4560.
- [68] SHI H X, ZHANG X L, WANG J Z, et al. A survey of emotional speech synthesis[J]. BIG DATA RESEARCH, 2024,10(05):56-73.(in Chinese)
- 施昊翔,张旭龙,王健宗,等.情感语音合成综述[J].大数据,2024,10(05):56-73.
- [69] ZHU X, LEI Y, LI T, et al. Metts: Multilingual emotional text-to-speech by cross-speaker and cross-lingual emotion transfer[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024, 32: 1506-1518.
- [70] LIU Y, XU Z, WANG G, et al. Delightfultts: The microsoft speech synthesis system for blizzard challenge 2021[J]. arXiv preprint arXiv:2110.12612, 2021.
- [71] LI T, HU C, CONG J, et al. Diclet-tts: Diffusion model based cross-lingual emotion transfer for text-to-speech—a study between english and mandarin[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 3418-3430.
- [72] LI Y, ZHU X, LEI Y, et al. Zero-shot emotion transfer for cross-lingual speech synthesis[C]/2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU). IEEE, 2023: 1-8.
- [73] SWIATKOWSKI J, WANG D, BABIANSKI M, et al. Expressive machine dubbing through phrase-level cross-lingual prosody transfer[J]. arXiv preprint arXiv:2306.11662, 2023.
- [74] GUDMALWAR A, SHAH N, AKARSH S, et al. VECL-TTS: voice identity and emotional style controllable cross-lingual text-to-speech[J]. arXiv preprint arXiv:2406.08076, 2024.
- [75] GUO H, LIU C, ISHI C T, et al. XE-Speech: Joint Training Framework of Non-Autoregressive Cross-lingual Emotional Text-to-Speech and Voice Conversion[C]/Proc. Interspeech 2024. 2024: 4983-4987.
- [76] TRAN C, LUONG C M, SAKTI S. STEN-TTS: Improving Zero-shot Cross-Lingual Transfer for Multi-Lingual TTS with Style-Enhanced Normalization Diffusion Framework[J]. INTERSPEECH 2023, ISCA: ISCA, 2023: 4464-4468.
- [77] LE M, VYAS A, SHI B, et al. Voicebox: Text-guided multilingual universal speech generation at scale[J]. Advances in neural information processing systems, 2023, 36: 14005-14034.
- [78] GUO Z, LENG Y, WU Y, et al. Prompttts: Controllable text-to-speech with text descriptions[C]/ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [79] SHIMIZU R, YAMAMOTO R, KAWAMURA M, et al. Prompttts++: Controlling speaker identity in prompt-based text-to-speech using natural language descriptions[C]/ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 12672-12676.
- [80] BORSOS Z, SHARIFI M, TAGLIASACCHI M. Speechpainter: Text-conditioned speech inpainting[J]. arXiv preprint arXiv:2202.07273, 2022.
- [81] RUBENSTEIN P K, ASAWAROENGCHAI C, NGUYEN D D, et al. Audiopalm: A large language model that can speak and listen[J]. arXiv preprint arXiv:2306.12925, 2023.
- [82] SAHIPJOHN N, GUDMALWAR A, SHAH N, et al. Dubwise: Video-guided speech duration control in multimodal llm-based text-to-speech for dubbing[J]. arXiv preprint arXiv:2406.08802, 2024.
- [83] REN Y, HU C, TAN X, et al. Fastspeech 2: Fast and high-quality end-to-end text to speech[J]. arXiv preprint arXiv:2006.04558, 2020.
- [84] ZHANG Z, CHEN S, ZHOU L, et al. Speechlm: Enhanced speech pre-training with unpaired textual data[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024.
- [85] OpenAI. (2024). GPT-4o(Omni)[多模态大型语言模型]. 检自 <https://openai.com/index/hello-gpt-4o>
- [86] ZENG A, DU Z, LIU M, et al. Glm-4-voice: Towards intelligent and human-like end-to-end spoken chatbot[J]. arXiv preprint arXiv:2412.02612, 2024.
- [87] DU Z, GAO C, WANG Y, et al. CosyVoice 3: Towards In-the-wild Speech Generation via Scaling-up and Post-training[J]. arXiv preprint arXiv:2505.17589, 2025.
- [88] CHEN Q, CHEN Y, CHEN Y, et al. Minmo: A multimodal large language model for seamless voice interaction[J]. arXiv preprint arXiv:2501.06282, 2025.
- [89] BARRAULT L, CHUNG Y A, MEGLIOLI M C, et al. SeamlessM4T: Massively Multilingual & Multimodal Machine Translation[J]. arXiv preprint arXiv:2308.11596, 2023.
- [90] COMANICI G, BIEBER E, SCHAEKERMANN M, et al. Gemini 2.5: Pushing the Frontier with Advanced Reasoning, Multimodality, Long Context, and Next Generation Agentic Capabilities[J]. arXiv preprint arXiv:2507.06261, 2025.
- [91] YE Z, ZHU X, CHAN C M, et al. Llasa: Scaling train-time and inference-time compute for llama-based speech synthesis[J]. arXiv preprint arXiv:2502.04128, 2025.
- [92] JIANG Z, REN Y, LI R, et al. Megatts 3: Sparse alignment enhanced latent diffusion transformer for zero-shot speech synthesis[J]. arXiv preprint arXiv:2502.18924, 2025.
- [93] DeepSeek AI. (2025). DeepSeek-V3(MoE 多语言大模型)[开源大型语言模型]. 检自 <https://www.deepseek.com/>
- [94] Huawei Cloud. (2024). PanGu- Σ (多语言大模型)[文本推理模型]. 检自 <https://support.huawei.com/enterprise>
- [95] Alibaba Cloud. (2023). Qwen-Audio(多模态音频语言模型)[音频输入理解系统]. 检自 <https://github.com/QwenLM/Qwen-Audio>
- [96] Baidu. (2023). ERNIE Bot[语音识别与生成助手]. 检自

- <https://cloud.baidu.com/product/speech.html>
- [97] ByteDance. (2024). 豆包 Seed-TTS(语音克隆大模型)[跨语言语音合成系统]. 检自 <https://team.doubao.com/en/publication/seed-tts-a-family-of-high-quality-versatile-speech-generation-models>.
- [98] Tencent. (2025). Yuanbao(多模态语音交互助手)[中英语音对话平台]. 检自 <https://www.tencentcloud.com/product/tts>
- [99] 科大讯飞. (2025). 星火语音大模型(版本 4.0)[商业语音合成系统]. 检自 <https://www.iflytek.com/spark-voice>
- [100] KOMINEK J, BLACK A W. The CMU Arctic speech databases[C]//SSW. 2004: 223-224.
- [101] ZEN H, DANG V, CLARK R, et al. Libritts: A corpus derived from librispeech for text-to-speech[J]. arXiv preprint arXiv:1904.02882, 2019.
- [102] YAMAGISHI J, VEAUX C, MACDONALD K. CSTR VCTK Corpus: English multi-speaker corpus for CSTR voice cloning toolkit (version 0.92)[J]. University of Edinburgh. The Centre for Speech Technology Research (CSTR), 2019: 271-350.
- [103] ITO K, JOHNSON L. (2017). The LJ Speech Dataset. [Online]. Available: <https://keithito.com/LJ-Speech-Dataset/>
- [104] BU H, DU J, NA X, et al. Aishell-1: An open-source mandarin speech corpus and a speech recognition baseline[C]//2017 20th conference of the oriental chapter of the international coordinating committee on speech databases and speech I/O systems and assessment (O-COCOSDA). IEEE, 2017: 1-5.
- [105] SHI Y, BU H, XU X, et al. Aishell-3: A multi-speaker mandarin tts corpus and the baselines[J]. arXiv preprint arXiv:2010.11567, 2020.
- [106] WANG D, ZHANG X. Thchs-30: A free chinese speech corpus[J]. arXiv preprint arXiv:1512.01882, 2015.
- [107] PARK K, MULC T. Css10: A collection of single speaker speech datasets for 10 languages[J]. arXiv preprint arXiv:1903.11269, 2019.
- [108] ARDILA R, BRANSON M, DAVIS K, et al. Common voice: A massively-multilingual speech corpus[J]. arXiv preprint arXiv:1912.06670, 2019.
- [109] PRATAP V, XU Q, SRIRAM A, et al. Mls: A large-scale multilingual dataset for speech research[J]. arXiv preprint arXiv:2012.03411, 2020.
- [110] WANG C, PINO J, WU A, et al. Covost: A diverse multilingual speech-to-text translation corpus[J]. arXiv preprint arXiv:2002.01320, 2020.
- [111] ZHANG R, WANG X, ZHANG C, et al. Bstc: A large-scale chinese-english speech translation dataset[J]. arXiv preprint arXiv:2104.03575, 2021.
- [112] JIA Y, RAMANOVICH M T, WANG Q, et al. CVSS corpus and massively multilingual speech-to-speech translation[J]. arXiv preprint arXiv:2201.03713, 2022.
- [113] OLIVEIRA F S, CASANOVA E, JUNIOR A C, et al. Cml-tts: A multilingual dataset for speech synthesis in low-resource languages[C]//International Conference on Text, Speech, and Dialogue. Cham: Springer Nature Switzerland, 2023: 188-199.
- [114] HE H, SHANG Z, WANG C, et al. Emilia: An extensive, multilingual, and diverse speech dataset for large-scale speech generation[C]//2024 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2024: 885-890..
- [115] CLARK D. High-resolution subjective testing using a double-blind comparator[J]. Journal of the Audio Engineering Society, 1982, 30(5): 330-338.
- [116] MINIXHOFFER C, KLEJCH O, BELL P. TTSDS-Text-to-Speech Distribution Score[C]//2024 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2024: 766-773.

周祉彤，出生于 2002 年，女，硕士研究生，CCF 学生会员 (Z6464G)，研究方向为语音合成、跨语言语音合成；

周若华，出生于 1972 年，男，博士，教授、博士生导师、中科院优秀人才入选者，CCF 会员 (c2086m)，研究方向为声纹识别、机器学习、语音及音乐信号处理。

郭子夜，出生于 1997 年，女，博士研究生，研究方向为信号处理、超声无损检测；

赵明园，出生于 2000 年，女，硕士研究生，CCF 学生会员 (Z5315G)，研究方向为音乐生成。



Zhou Zhitong, born in 2002, postgraduate , is a member of CCF(No.Z6464G). Her main research interests include speech synthesis and cross-lingual speech synthesis.



Zhou Ruohua , born in 1972, Ph.D, professor, Ph.D supervisor, is a member of CCF(No.c2086m) and recipient of the Excellent Talents Program of the Chinese Academy of Sciences.. His main research interests include speaker verification, machine learning, and speech & music signal processing.