

基于纯净韵律表征的表现力语音合成研究

周燕,刘凌志*,周月霞,刘翔宇

(佛山大学 计算机与人工智能学院,广东 佛山 528225)

摘要:针对传统 DDPM 模型在语音合成中对动态韵律特征捕捉不足、不适配语音特性的问题,提出了一种纯净韵律增强语音合成算法。首先,设计了一种基于分布建模的韵律编码网络,该网络能有效抑制噪声的干扰,学习到纯净的韵律特征嵌入。其次,提出了一种新型扩散模型 HarmoVDiff 并作为声学模型,比传统 DDPM 更适配语音特性。最后,进一步构建了一种两阶段语音合成框架 HVDIF-TTS,可实现富有表现力和自然度的语音合成。实验结果表明:所提算法在 LJSpeech 数据集上的 BAPD 值达 3.681 4, GPE 值达 0.150 2, NISQA-MOS 值达 3.77。

关键词:DDPM 模型;韵律特征;韵律编码网络;HarmoVDiff 声学模型;语音合成

中图分类号:TN912.33

文献标志码:A

DOI:10.13797/j.cnki.jfosu.1008-0171.2026.0016

语音合成技术致力于将文本信息转化为清晰自然的语音^[1],该技术已在多个场景广泛应用并发挥重要作用。如何合成出高度逼真的类人音频,实现媲美人类语音的自然度和表现力,这既需精准还原声学特征,也需复刻语言特有的韵律起伏与张力。近年来,随着深度学习技术的持续迭代与快速发展,其技术应用已渗透到各行各业^[2-3],深刻推动着各领域的创新变革与产业升级。在图像合成领域表现卓越的扩散模型也逐渐被引入语音合成^[4],为传统两阶段框架带来突破性进展,正成为推动技术升级的核心方向。

一些研究者通过将扩散模型与声学模型融合来提升合成效率,例如,Liu等^[5]基于潜在扩散提出了一种新型文本转语音模型,采用了最新的扩散模型生成逆问题求解算法。Popov等^[6]基于随机微分方程构建,使用基于 Glow 的流模型将梅尔频谱图转为语音波形。Huang等^[7]提出基于生

成器的参数化方法,通过知识蒸馏降低数据方差。Lian等^[8]在去噪扩散概率模型中额外融合柯西噪声,解决了处理不平衡语音数据时出现的模式崩溃问题。Li等^[9]引入时间依赖采样与自适应扩散调度机制。另一些研究者则聚焦于声码器的设计优化。Koizumi等^[10]基于分数匹配与直接波形建模,实现了高保真度的非自回归语音生成。Yang等^[11]利用扩散模型迭代预测梅尔频谱图,实现了比自回归方法更高的语音质量和更快的生成速度。为进一步通过加速 DDPM 提升效率,Deng等^[12]使用 GAN 替代高斯函数来建模去噪分布,增大去噪步长并减少去噪步骤数,加快扩散模型的采样速度。Chen等^[13]提出将推理过程融入训练环节实现高效推理。Wang等^[14]使用分层去噪扩散生成对抗网络建模直接预测潜在变量来参数化去噪模型,仅需 1 个去噪步骤即可生成高保真语音波形。同时,一些工作也延伸到提升语

收稿日期:2025-07-31

基金项目:国家自然科学基金资助项目(61972091)

作者简介:周燕(1979-),女,江西抚州人,佛山大学教授。

*通信作者:刘凌志(2001-),女,湖南株洲人,佛山大学硕士研究生。

音自然度与表现力方面。Shen 等^[15]利用带有残差矢量量化器的神经音频编解码器来获得量化的潜在矢量,并使用扩散模型来生成这些潜在矢量,实现高质量的语音合成。Oh 等^[16]通过融合扩散潜在韵律生成器与条件对抗训练机制,增强韵律表达的丰富性。Chen 等^[17]创新性地提出以韵律草图实现对韵律特征的精准控制。

尽管基于扩散模型的建模方法已在语音合成领域取得显著进展,但仍存在两项关键局限:其一,现有方法多聚焦于声学特征建模,对语音特有的动态韵律特征的捕捉能力有限,导致合成语音在自然度与表现力上与真实语音存在可感知差距;其二,由于底层框架直接迁移自图像合成领域,模型设计与语音信号特性的适配性不足,在维持长时程依赖和谐波结构完整性方面表现欠佳,尤其在低迭代次数时,易出现频谱细节模糊、基频轨迹断裂等问题。

针对上述问题,本文提出一种纯净韵律增强语音合成算法,该算法构建了一种基于分布建模的韵律编码网络,同时设计了一种新型声学模型 HarmoVDiff,构建了谐波扩散语音合成框架(HVDIF-TTS),有效实现细粒度韵律建模和高保真语音输出。在 LJSpeech 英文数据集上,HVDIF-TTS 在 NISQA-MOS 指标上^[18]相较于 vits、DEX-TTS、DiffSpeech、FastSpeech2、NaturalSpeech2 模型分别提升了 1.34%、25.67%、2.45%、31.8%、0.80%。

1 纯净韵律增强语音合成算法

本文提出的纯净韵律增强语音合成算法主要包括以下两部分:1)针对现有方法在提升语音自然度与表现力方面存在的显著局限,设计了基于分布建模的韵律编码网络;2)针对当前方法在适配语音信号特性上的不足等问题,设计了新型扩散模型 HarmoVDiff。

1.1 基于分布建模的韵律编码网络

为了改进语音合成中韵律特征建模,抑制噪声的干扰,本文提出一种基于分布建模的韵律编码网络,如图 1 所示。该编码网络通过迭代去噪机制逐层优化韵律表示,其核心优势在于借助扩散过程的随机特性,高效捕捉音高、能量等韵律特征的上下文相关动态波动,并有效抑制噪声对

特征提取的干扰。网络架构以改进 VQVAE 和改进 UNet 扩散网络为核心骨干,初始阶段引入特征编码器对输入音频波形进行初步特征提取,生成高质量的时序表示;随后,特征进入改进 UNet 主干结构进行扩散处理,利用其多层瓶颈网络与多尺度跨注意力机制进一步增强特征表达能力,最后经过改进 VQVAE 得到匹配的韵律嵌入。



图 1 韵律编码网络结构图

改进 UNet 扩散网络总体结构图如图 2 所示。在改进 UNet 主干结构的设计方面,基于标准一维 UNet 架构进行了系统性的结构性增强,以显著提升其在复杂语音序列建模任务中的表现力。具体而言,所采用的改进型 UNet 主干结构以标准 UNet 的编码器-解码器对称框架为基础,融合了多层瓶颈结构、跨尺度残差模块以及解码阶段的交叉注意力机制,形成了具备高建模容量与强上下文感知能力的韵律建模模块。在编码路径中,网络采用了 6 层递进式的下采样结构,各层均引入具有残差连接的子模块以增强特征提取的稳定性与深层信息的传递能力。每一残差块内部进一步集成了 FiLM 条件调制机制,该机制通过引入时间嵌入信息实现对通道特征的动态调节,使模型在多时间尺度下均具备稳健的建模能力,从而有效捕捉语音中存在的不同节奏和韵律变化。在解码路径中,额外引入了多头交叉注意力机制,用于显式建模解码阶段与各编码层输出之间的跨尺度语义关联。该机制在保留局部时序特征的基础上,进一步融合了编码过程中提取的全局上下文信息,使得模型在生成阶段能够充分利用原始输入的长程依赖,从而克服浅层模型在建模长时间结构中表现出的局限性。该结构在有声与无声区域的边界建模中尤为有效,有助于提升模型对音高突变、能量过渡等复杂韵律现象的表达能力。总体而言,该改进型 UNet 结构不仅能有效提升模型的表示能力和建模深度,同时为实现更自然、更具表现力的语音合成提供了结构基础,为后续模块的建模提供了更高质量的中间特征表示。




图 2 改进 UNet 扩散网络结构图

改进 VQVAE 总体结构图如图 3 所示。为了更有效地提取和重构语音中的关键韵律特征,针对传统的 VQVAE 模块进行了结构性改进,构建了一种面向语音韵律建模任务的高效时序压缩与重建框架。在编码器部分,采用了由多个一维卷积与 ReLU 激活函数堆叠而成的深层前馈结构,替代传统 VQVAE 中相对浅层的编码设计。该编码器结构能够在保持模型计算效率的同时,深入挖掘中间特征表示中的时序相关性,得到更具纯净度、鲁棒性与表达力的特征表示,尤其适用于音高和能量等韵律特征的编码压缩。在量化阶段,模型采用一个大规模、均匀初始化的嵌入码本对特征表示进行矢量量化,以压缩冗余信息,并在保持韵律关键信息的前提下,实现语音特征的离散化编码。针对传统 VQVAE 常见的码本折叠问题,即部分嵌入项在训练中长时间未被访

问,导致嵌入空间利用率不足,额外引入了一种基于特征映射的中间转换机制,通过加入 LayerNorm 与两层全连接网络,将编码器输出先进行映射处理再送入量化模块,从而提升了不同嵌入项之间的区分度与可学习性。该设计有效增强了码本在表示空间中的覆盖能力,提高了嵌入项的激活频率,显著改善了 VQVAE 在长期训练中的稳定性与收敛速度。在解码器部分,采用与编码器对称的 ConvTranspose1D-ReLU 结构,设计为逐层上采样还原的路径,以实现量化嵌入的高保真重建,并辅以残差连接进一步保留细节信息,从而保证重构过程中韵律信息的完整性与时间结构的一致性。该改进后的 VQVAE 模块在整体架构中起到了关键性作用,在保证生成语音自然度的同时,进一步提升了韵律建模的精度与灵活性。




图 3 改进 VQVAE 结构图

1.2 新型扩散模型 HarmoVDiff

为了解决现有方法在语音信号适配性、长时依赖维持、谐波结构完整性保持等方面的不足,本文将新型扩散模型 HarmoVDiff 作为声学模型,通过引入谐波感知隐空间建模和动态噪声调度机制,实现语音合成质量与效率的协同优化。HarmoVDiff 沿用传统 DDPM 的核心训练步骤,但对预测目标、加噪机制及损失函数约束这三个关

键维度进行了改进,其训练流程如图 4 所示。

训练 HarmoVDiff 时,先从数据分布中采样原始干净潜变量 $z_0 \sim q_{\text{data}}$; 同时从标准正态分布中采样噪声, HarmoVDiff 会采集三类差异化噪声 $\varepsilon \sim N(0, I)$, 为后续混合加噪奠定基础。得到二者后,针对每个扩散时间步 t , HarmoVDiff 逐步计算噪声潜变量 z_t , 即




图 4 HarmoVDiff 的训练图

$$z_t = \sqrt{\partial_t} z_0 + \sqrt{1 - \partial_t} (\varepsilon_{\text{base}} + 0.1 \cdot \frac{t}{T} \cdot \varepsilon_{\text{HF}}) + \varepsilon_{\text{comp}}, \quad (1)$$

其中, ∂_t 来自噪声调度, $\varepsilon_{\text{base}}$ 是基础噪声, ε_{HF} 是高频谐波噪声, $\varepsilon_{\text{comp}}$ 是稳定性补偿噪声项。噪声注入阶段, HarmoVDiff 采用混合噪声策略: 针对语音高频谐波成分, 设计梅尔频段约束的拉普拉斯噪声注入, 提升爆破音和清浊音的清晰度; 同时引入稳定性补偿机制, 通过梯度感知的噪声调度抑制采样末期数值不稳定, 保证生成稳定性。

在对 z_0 完成加噪后, 借助 HarmoVDiff 模型 θ 预测速度场 $v_t = \theta(z_t, \text{cond}, t')$ 。同时, 基于初始 z_0 计算出目标速度场 $v_t^{\text{target}} = \nabla z_0$ 。HarmoVDiff 采用预测速度场的范式, 通过建模语音信号的动态演化路径来保留噪声分布特性, 精准捕捉语音信号的时变梯度特征, 从而提升基频轨迹的预测精度, 减少语音合成中的基频误差。

获取预测与目标速度场后, HarmoVDiff 则分步优化损失。相较于传统 DDPM 仅用 L_2 损失约束, 其采用多损失综合策略提升 UNet 预测能力: 在 L_2 基础上, 整合多尺度金字塔频谱约束损失, 并且引入梯度加权与基于频带能量分布的通道注意力。这三层约束分别优化长时频谱连续性、清浊音过渡清晰度及关键频带特征增强, 提升生成精准度与自然度。首先, 计算两者的 L_2 基础损失, 即

$$L_{l2} = \frac{1}{N} \sum_{i=1}^N \|v_i - v_i^{\text{target}}\|^2. \quad (2)$$

得到 L_2 损失后, HarmoVDiff 再计算金字塔损失, 以约束长时频谱的连续性, 即

$$L_{\text{MSP}} = \sum_{s \in \{1, 2, 4\}} \frac{1}{\sqrt{s}} \|P_s(v_t) - P_s(v_t^{\text{target}})\|^2, \quad (3)$$

其中, s 为下采样尺度因子, P_s 是尺度为 s 的金字塔分解算子。基于式(2)~(3)计算得到的损失, 进一步求解合成损失, 即

$$L_{\text{com}} = L_{l2} + 0.3 \cdot L_{\text{MSP}}. \quad (4)$$

同时, HarmoVDiff 计算梯度敏感加权因子和通道注意力加权因子, 分别用于提升清浊音过渡清晰度以及增强关键频带特征, 即

$$W_{\text{grad}}(x, y) = \text{clip}(\sqrt{(\partial_x z_0)^2 + (\partial_y z_0)^2}, 1.0, 2.0), \quad (5)$$

其中, $\partial_x z_0$ 表示 z_0 在时间轴的变化率, $\partial_y z_0$ 表示 z_0 在频率轴的变化率, clip 截断函数将梯度幅值限制在 $[1.0, 2.0]$, 避免极端值干扰。

$$W_{\text{attn}} = 1 + \frac{E_c}{\max_c(E_c)}, \quad (6)$$

其中, E_c 表示第 c 个频带的平均能量。基于式(4)得到的损失, 再结合式(5)~(6), HarmoVDiff 得到训练中的总损失, 即

$$L = L_{\text{com}} \times W_{\text{grad}} \times W_{\text{attn}}. \quad (7)$$

根据总损失 L 对 HarmoVDiff 模型执行梯度下降, 最小化 L 。重复上述训练过程, 直到最终 HarmoVDiff 收敛。

2 HVDIF-TTS 设计

本文基于上述方法进一步提出了两阶段语音合成框架 HVDIF-TTS。针对现有方法在提升语音自然度与表现力方面的局限采用 1.1 中设计的韵律编码网络学习纯净韵律参考嵌入; 针对当前方法不适配语音特性等问题采用 1.2 中设计的 HarmoVDiff 扩散模型作为声学模型。HVDIF-TTS 的结构参考了非自回归语音合成模型 FastSpeech2^[19], 它被设计为一个完全可微分且高效的架构, 其框架结构如图 5 所示。




图 5 HVDIF-TTS 框架结构图

HVDIF-TTS 一共包含 7 个模块：文本编码器、持续时间预测模块、韵律编码网络、VAE 编码器、HarmoVDiff、解码器以及 BigVGAN^[20]声码器。音素序列经文本编码器转换为文本嵌入，再通过持续时间预测器和长度调节器实现帧级对齐。与此同时，参考语音被并行处理：一方面经 VAE 编码器生成隐变量 z ，该变量后续被输入 HarmoVDiff 进行加噪；另一方面通过韵律编码网络学习韵律参考嵌入，这一嵌入与帧级文本嵌入结合形成条件参数，与时间步 t 共同输入 HarmoVDiff。模型采样生成的隐变量 z 经解码器转换为梅尔频谱图，最后通过 BigVGAN 声码器合成最终语音波形。

3 实验结果与分析

3.1 实验设置

本文实验所使用的软件平台是 pytorch 2.7.0, python 3.9.23; 硬件平台是 RTX 4090 24G GPU。采用 LJSpeech 英文数据集进行训练, 该数据集是一个单说话人语料库, 包含 13 100 个短音频片段; 训练时将数据集随机分为 3 个子集: 12 500 个样本用于训练, 300 个样本用于验证, 300 个样本用于测试, 采样率为 22 050 Hz。

HVDIF-TTS 框架中使用的 VAE 编码器采用了文献[21]中的结构和配置。首先对所提出的韵律编码网络进行训练, 使其达到收敛。再对 VAE 编码器进行 80 000 步训练, 批量大小为 8。随后, VAE 编码器、韵律编码网络和 BigVGAN 声码器保持冻结, 而其他模块与所提出的 HarmoVDiff 一起进行 60 000 步训练, 批量大小为 32, 直至训练到模型收敛。训练期间使用 Adam^[22]优化器更新 VAE, 使用 AdamW^[23]优化器更新 HarmoVDiff 及

其他模块, 并遵循文献[21]中相同学习率计划。

3.2 评估指标

本文选用 BAPD (基频平均绝对偏差)、GPE (音高误差率)^[24]和 NISQA-MOS 作为核心评估指标, 其中, BAPD 与 GPE 用于对比模型在基频轮廓构建精度及音高预测准确性方面的表现, 可有效区分不同模型在韵律基础特征还原能力上的差异; 而 NISQA-MOS 作为基于大规模主观评测数据训练的质量评估指标, 能够综合反映语音在自然度、音质纯净度等多维度的主观感知质量, 可体现人类听觉系统对韵律流畅性与适配性的整体感知, 避免单一参数优化与实际听觉体验出现脱节的问题。

为了充分验证所提出方法的有效性, 本文在 LJSpeech 数据集上与语音合成领域中主流的一些方法开展了性能对比实验, 需说明的是, 由于 FastSpeech2、NaturalSpeech2 未提供官方实现版本, 实验采用了 GitHub 平台上被广泛应用的 FastSpeech2 公开实现版本以及 Amphion 提供的 NaturalSpeech2 检查点作为对比基准。比较结果如表 1 所示, 从表 1 中可以看出, 所提出方法的综合性能优于所有对比的主流方法, 并且在 GPE 和 NISQA-MOS 上有着最好的效果, 分别达到了 0.150 2 和 3.77。实验结果表明: 所构建的

表 1 与其他方法比较结果

Method	BAPD ↓	GPE ↓	NISQA-MOS ↑
VITS ^[25]	4.028 2	0.170 2	3.72
DEX-TTS ^[26]	4.313 8	0.182 6	3.00
DiffSpeech ^[27]	3.920 1	0.211 4	3.68
FastSpeech2 ^[19]	4.387 2	0.171 2	2.86
NaturalSpeech2 ^[15]	3.532 7	0.182 0	3.74
HVDIF-TTS(本文)	3.681 4	0.150 2	3.77

HVDIF-TTS 能够进一步增强语音合成的自然度,有效提升韵律特征与语音物理特性的匹配精度,最终合成出更具自然度与表现力的语音样本。

3.3 可视化结果

为了验证所构建框架的合理性,本文随机选取样本语句“detained for one shilling nine pence, with costs of five shillings”、“that debtors who could afford the cabin and master's side were not permitted to share in the prison charities”以及“that society and its leaders had combined to thwart him. It will require every available resource of our Government”,利用表 1 中的 vits、FastSpeech2、NaturalSpeech2 模型和 HVDIF-TTS 进行语音合成,随后,绘制出合成语音的对数梅尔频谱图,可视化结果分别如图 6~8 所示。

从图 6 可以看出,VITS 的频谱图在低频部分基频结构清晰,中频区域共振峰模糊,高频区域部分细节丢失,泛音结构模糊,能量分布略显不均;FastSpeech2 的频谱图在低频区域能量分布较为集中,基频可见,但中高频区域谐波结构不清晰,无细节,整体过于平滑;NaturalSpeech2 的频谱图在中频区域表现稍好,共振峰略有体现,但低频和高频部分的细节不足,泛音结构稀疏;HVDIF-TTS 的频谱图在低频、中频和高频区域基频和泛音结构清晰,共振峰细节准确,能量分布一致,相较于其他模型在谐波结构的清晰度、能量分布的均匀性以及细节保留能力上表现较优,整体更能呈现出自然语音的频率层次感和动态特性。




图 6 样本语句 1 合成语音梅尔频谱图

从图 7 可以看出,VITS 的频谱图部分频率条带较为模糊,高频区域部分细节出现丢失;FastSpeech2 的频谱图频率条带间隙较小,整体过于平滑,缺乏高频细节和动态范围,低频部分的能量分布分散,谐波结构不明显;NaturalSpeech2 在低频部分的还原效果较好,频率条带有一定清

晰度,但中高频区域的频率分布不够清晰,细节表现不足,能量衰减较快;HVDIF-TTS 生成的频谱图频率条带分布清晰,间隙分明,在中高频区域的细节还原较其它模型更准确,谐波纹理细腻,动态范围接近真实语音。




图 7 样本语句 2 合成语音梅尔频谱图

从图 8 可以看出,VITS 的频谱图低频区域频率条带有一定清晰度,高频区域细节丢失严重,整体分布平滑,缺乏层次感;FastSpeech2 的频谱图频率条带间对比不足,高频区域部分无细节,低频区域部分能量分布较平坦,语音特征不突出;NaturalSpeech2 的频谱图在中低频部分的频

率分布出现过度平滑,高频区域细节不足,能量衰减明显;HVDIF-TTS 的频谱图频率条带清晰且较其它模型分布更加均匀,动态范围和细节还原能力较强,在高频区域的纹理更加细腻,谐波结构完整。

可视化结果证明,HVDIF-TTS 相较于上述模




图8 合成语音梅尔频谱图

型在保持共振峰连续及优化能量分布方面展现出相对优势,合成语音在自然度与稳定性上更具竞争力。

3.4 消融实验

本文对韵律编码网络 (prosody-Encoder) 和 HarmoVDiff 进行消融实验,验证其独立作用及协同效果。实验采用严格控制变量设计以保证框架可运行:在基准模型消融中,以真实音频提取的韵律参考嵌入结合传统 DDPM 替代;在 HarmoVDiff 消融中,以 prosody-Encoder 学习到的韵律参考嵌入结合传统 DDPM 替代;在 prosody-Encoder 消融中,以真实音频提取的韵律参考嵌入结合 HarmoVDiff 替代,实验结果如表 2 所示。

从表 2 中可以看出,当同时移除 prosody-

Encoder 和 HarmoVDiff 时,BAPD 指标为 4.031 1,GPE 指标为 0.155 8,经 NISQA 模型评估的 MOS 值达 3.23;仅保留 prosody-Encoder 而移除 HarmoVDiff 时,BAPD 指标为 3.912 4,GPE 指标为 0.158 0,MOS 值为 3.33;仅保留 HarmoVDiff 而移除 prosody-Encoder 时,BAPD 指标为 3.948 6,GPE 指标为 0.153 9,MOS 值为 3.32;当同时启用 prosody-Encoder 和 HarmoVDiff 时,系统取得了最优性能,其 BAPD 指标为 3.681 4,GPE 指标为 0.150 2,经 NISQA 模型评估的 MOS 值达 3.77。

消融实验表明,prosody-Encoder 与 HarmoVDiff 通过协同形成高效互补机制:两者结合时各项指标均显著优于单一模块留存场景,不仅提升了韵律预测精准度,更增强了语音合成的自然度与表现力。

表2 消融实验结果

Method	prosody-Encoder	HarmoVDiff	BAPD ↓	GPE ↓	NISQA-MOS ↑
HVDIF-TTS	×	×	4.031 1	0.155 8	3.23
	✓	×	3.912 4	0.158 0	3.33
	×	✓	3.948 6	0.153 9	3.32
	✓	✓	3.681 4(↓ 8.67%)	0.150 2(↓ 3.59%)	3.77(↑ 16.72%)

4 结语

本文提出一种纯净韵律增强语音合成算法,首先设计了一种韵律编码网络,与直接从嘈杂参考音频中提取韵律参考特征不同,该韵律编码网络可以学习到更为纯净的韵律特征表示;同时为使传统 DDPM 更适配语音特性,提出基于谐波增强速度场预测的扩散模型 HarmoVDiff,通过多尺

度频域感知机制重构噪声注入过程,提升声学特征建模能力。基于上述工作,进一步构建 HVDIF-TTS 语音合成框架,采用时频解耦的速度场预测器,结合梯度敏感加权和通道注意力机制实现文本到语音合成。实验结果表明:该方法较传统方法显著提升了合成质量,鲁棒性和泛化能力更优。

参考文献:

- [1] NING Y, HE S, WU Z, et al. A review of deep learning based speech synthesis[J]. Applied Sciences, 2019, 9(19):

4050.

- [2] 黄良汇, 许祥丛, 谭海曙, 等. 基于深度学习的 B 超图

- 像肝癌病灶自动定位[J]. 佛山科学技术学院学报(自然科学版), 2022, 40(6): 21–27.
- [3] 柴华, 辜晓纯, 苏咏纯, 等. 基于自监督深度学习的抗癌药物敏感性评估方法研究[J]. 佛山科学技术学院学报(自然科学版), 2024, 42(1): 19–25.
- [4] KIM H, KIM S, YOON S. Guided-tts: A diffusion model for text-to-speech via classifier guidance [C]//International Conference on Machine Learning. Baltimore, MD, USA: PMLR, 2022: 11119–11133.
- [5] LIU Z, GUO Y, YU K. Diffvoice: Text-to-speech with latent diffusion [C]//ICASSP 2023 IEEE International Conference on Acoustics, Speech and Signal Processing. Rhodes Island, Greece: IEEE, 2023: 1–5.
- [6] POPOV V, VOVK I, GOGORYAN V, et al. Grad-tts: A diffusion probabilistic model for text-to-speech [C]//International Conference on Machine Learning. [s.l.]: PMLR, 2021: 8599–8608.
- [7] HUANG R, ZHAO Z, LIU H, et al. Prodiff: Progressive fast diffusion model for high-quality text-to-speech [C]//Proceedings of the 30th ACM International Conference on Multimedia. Lisboa, Portugal: ACM, 2022: 2595–2605.
- [8] LIAN Q, QI Y, WANG Y. Cauchy Diffusion: A Heavy-tailed Denoising Diffusion Probabilistic Model for Speech Synthesis [C]//Proceedings of the AAAI Conference on Artificial Intelligence. Philadelphia, PA, USA: AAAI, 2025, 39(23): 24549–24557.
- [9] LI Y A, HAN C, RAGHAVAN V, et al. Styletts 2: Towards human-level text-to-speech through style diffusion and adversarial training with large speech language models[J]. Advances in Neural Information Processing Systems, 2023, 36(19): 19594–19621.
- [10] KOIZUMI Y, YATABE K, ZEN H, et al. WaveFit: An iterative and non-autoregressive neural vocoder based on fixed-point iteration [C]//2022 IEEE Spoken Language Technology Workshop (SLT). Doha, Qatar: IEEE, 2023: 884–891.
- [11] YANG D, YU J, WANG H, et al. Diffsound: Discrete diffusion model for text-to-sound generation[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31(7): 1720–1733.
- [12] DENG Y, WU N, QIU C, et al. MixGAN-TTS: Efficient and stable speech synthesis based on diffusion model [J]. IEEE Access, 2023, 11(5): 57674–57682.
- [13] CHEN Z, TAN X, WANG K, et al. Infergrad: Improving diffusion models for vocoder by considering inference in training [C]//ICASSP 2022 IEEE International Conference on Acoustics, Speech and Signal Processing. Singapore: IEEE, 2022: 8432–8436.
- [14] WANG L, YU Z, GAO S, et al. DETS: End-to-end single-stage text-to-speech via hierarchical diffusion GAN models [C]//ICASSP 2024 IEEE International Conference on Acoustics, Speech and Signal Processing. Seoul, Korea: IEEE, 2024: 10916–10920.
- [15] SHEN K, JU Z, TAN X, et al. Naturalspeech 2: Latent diffusion models are natural and zero-shot speech and singing synthesizers[J]. arXiv preprint arXiv: 2304.09116, 2023.
- [16] OH H S, LEE S H, LEE S W. Diffprosody: Diffusion-based latent prosody generation for expressive speech synthesis with prosody conditional adversarial training[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024, 32(25): 2654–2666.
- [17] CHEN W, YANG S, LI G, et al. DrawSpeech: Expressive Speech Synthesis Using Prosodic Sketches as Control Conditions [C]//ICASSP 2025 IEEE International Conference on Acoustics, Speech and Signal Processing. Hyderabad, India: IEEE, 2025: 1–5.
- [18] MITTAG G, NADERI B, CHEHADI A, et al. NISQA: A deep CNN-self-attention model for multidimensional speech quality prediction with crowdsourced datasets[J]. arXiv preprint arXiv: 2104.09494, 2021.
- [19] REN Y, HU C, TAN X, et al. Fastspeech 2: Fast and high-quality end-to-end text to speech[J]. arXiv preprint arXiv: 2006.04558, 2020.
- [20] QI H, FU D, HU W. Research on Silent Speech Reconstruction Based on the BigVGAN Network [C]//2024 4th International Conference on Electronic Information Engineering and Computer Communication (EIECC). Wuhan: IEEE, 2024: 478–482.
- [21] LIU H, YUAN Y, LIU X, et al. Audioldm 2: Learning holistic audio generation with self-supervised pretraining [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024, 32(10): 2871–2883.
- [22] PÉREZ M. An Investigation of ADAM: A Stochastic Optimization Method [C]//Proceedings of the 39th International Conference on Machine Learning. Baltimore, MD, USA: PMLR, 2022: 17–23.
- [23] ZHOU P, LIN Z. Towards understanding convergence and generalization of AdamW[J]. IEEE transactions on pattern analysis and machine intelligence, 2024, 46(9): 6486–6493.
- [24] BARAKAT H, TURK O, DEMIROGLU C. Deep

- learning-based expressive speech synthesis: a systematic review of approaches, challenges, and resources [J]. EURASIP Journal on Audio, Speech, and Music Processing, 2024(1): 11.
- [25] KIM J, KONG J, SON J. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech[C]//International Conference on Machine Learning. [s.l.]: PMLR, 2021: 5530–5540.
- [26] PARK H J, KIM J S, SHIN W, et al. Dex-tts: Diffusion-based expressive text-to-speech with style modeling on time variability[J]. arXiv preprint arXiv: 2406.19135, 2024.
- [27] LIU J, LI C, REN Y, et al. Diffsinger: Singing voice synthesis via shallow diffusion mechanism [C]//Proceedings of the AAAI conference on artificial intelligence. [s.l.]: AAAI Press, 2022: 11020–11028.

【责任编辑:王桂珍】

Expressive speech synthesis based on pure prosodic representation

ZHOU Yan, LIU Lingzhi, ZHOU Yuexia, LIU Xiangyu

(School of Computer Science and Artificial Intelligence, Foshan University, Foshan 528225, China)

Abstract: Aiming at the deficiencies of traditional DDPM models in capturing dynamic prosodic features and their incompatibility with speech characteristics in speech synthesis, this paper proposes an expressive speech synthesis algorithm based on pure prosodic representation. Firstly, a prosody encoding network based on distribution modeling is designed, which can effectively suppress noise interference and learn pure prosodic feature embeddings. Secondly, a new diffusion model, HarmoVDiff, is proposed as the acoustic model, which is more compatible with speech characteristics than traditional DDPMs. Finally, a two-stage speech synthesis framework, HVDIF-TTS, is further constructed to achieve expressive and natural speech synthesis. Experimental results on the LJSpeech dataset show that the proposed algorithm achieves a BAPD value of 3.681 4, a GPE value of 0.150 2, and a NISQA-MOS value of 3.77.

Key words: DDPM model; prosodic features; prosodic encoding network; HarmoVDiff acoustic model; speech synthesis