

基于统计和语义相似度的智能文档分块方法

李 慧 刘 宇 张凯翔 裴天鹏
中国铁塔股份有限公司江苏省分公司

摘 要: 当前, 检索增强生成 (Retrieval-Augmented Generation, RAG) 系统主要用于与大模型 (large language models, LLMs) 结合在专业领域生成高质量的答案。在 RAG 系统中, 文档分块技术如何平衡文档数据粒度与语义完整性之间的关系, 是实际应用中的一个难点。为此, 本文提出了一种基于统计和语义相似度的智能文档分块方法, 利用自然语言处理模型计算段落语义相似度, 并结合统计方法进行标题鉴别, 最后制定段落合并策略。在 Wiki-727K 数据集上的实验结果表明, 该方法在分块性能指标上优于其他两种算法。

关键词: 文档分块; 检索增强生成 (RAG); 大模型 (LLMs)

Intelligent document chunking method based on statistical and semantic similarity

LI Hui, LIU Yu, ZHANG Kaixiang, PEI Tianpeng
China Tower Co., Ltd. Jiangsu Branch

Abstract: Currently, Retrieval-Augmented Generation (RAG) system is primarily used in conjunction with Large Language Models (LLMs) to generate high-quality answers in professional fields. In RAG systems, how to balance the relationship between the granularity of document data and semantic integrity is a key point in practical applications. To this end, the paper proposes an intelligent document chunking method based on statistical analysis and semantic similarity. This approach utilizes natural language processing models to calculate paragraph-level semantic similarity, incorporates statistical methods for title discrimination, and formulates a paragraph merging strategy. Experimental results on the Wiki-727K dataset show that the proposed method outperforms two existing algorithms in terms of chunking performance metrics.

Key words: document chunking, retrieval-augmented generation (RAG), large language models (LLMs)

0 引言

在过去几年中, 深度学习技术、大规模的 transformer 模型以及海量数据推动大模型 (large language models, LLMs) 技术发展。比如 OpenAI 在 2023 年提出的 GPT-4^[1] 和 Touvron 等人提出的 Llama 2^[2], 在编码、医学、法律、农业和心理学等各个领域展示了巨大的潜力, 拥有接近人类水平的专业能力^[3-4]。例如, 在医疗领域, LLMs 可用来预测患者风险并提

高诊断准确性^[5]; 在制造业中, LLMs 有助于提升操作效率, 减少停机时间, 改善产品质量^[6]。尽管 LLMs 在这些领域取得了较大的成功, 但在企业内部知识库、农业等特定领域中, 由于缺乏专门的训练数据, LLMs 应用仍然受到限制^[7]。为解决 LLMs 在专业领域应用的问题, 当前较多研究将检索增强生成 (Retrieval-Augmented Generation, RAG) 技术与 LLMs 结合来用于在特定领域生成高质量的答案。

RAG 技术主要用于从专业领域的文档语料库中检索相关

信息,并通过实现上下文学习(in-context learning, ICL)来增强 LLMs 的响应生成。RAG 应用流程主要包含两个阶段:数据准备阶段和应用阶段。其中数据准备阶段主要包括文档解析、文档分块、向量化、数据入库,应用阶段主要包括用户提问、数据检索(召回)、注入大模型提示词(Prompt)、LLMs 生成答案。

在 RAG 系统中文档分块的主要作用有以下两点:第一,避免由于整个文档内容过多、文本粒度较大,造成向量化阶段丢失较多的文本信息,不利于后续的文档检索。第二,当文本粒度较大时,易导致检索阶段召回的文本内容较多,会存在部分干扰信息,影响 LLMs 的答案生成,只有相关的高质量文本的召回,才能有助于 LLMs 提供正确的答案。当前常见的文本分块方法有基于字符的分块、基于句子的分块、基于段落的分块。其中基于字符的分块方法,通常设定一个固定的长度,按照字符序列进行切分,这种方法简单,但容易造成拥有完整语义的句子被分割。基于句子的分块方法,虽然可采用自然语言工具包(Natural Language Toolkit, NLTK)和自然语言处理库(Spacy)来识别句子的边界,但也忽略了段落语义信息的完整。基于段落的分块方法被提出来解决此问题,但该方法无法保证处于同一标题层级下的段落不被分割,容易造成主题语义的不完整。

为进一步平衡文档数据粒度与语义完整之间的关系,本文提出了基于统计和语义相似度的智能文档分块方法。

本文的主要工作体现在以下三个方面:

(1) 利用自然语言处理模型进行段落语义相似度计算,捕捉段落与段落之间的相似性,自动鉴别段落与段落之间是否可以进行合并。

(2) 通过统计的方法进行标题鉴别,提升文档分割的质量。

(3) 提供段落合并策略,来平衡分块粒度大小与语义完整性之间的关系。

1 相关技术

LLMs 在特定领域或知识密集型任务中^[8],尤其是在处理超出其训练数据范围或需要查询实时数据时,可能出现“幻觉”^[9]。为了解决这一问题,RAG 通过从外部知识库检索相关文档片段,输入到 LLMs 来生成对应的回答。通过引用外部知识,RAG 有效地减少了生成错误内容。

RAG 主要可分为索引建立过程(图 1 中的橙色箭头)、相关信息检索阶段(图 1 中的紫色箭头)和答案生成阶段(图 1 中的蓝色箭头)。其中索引主要包含文档解析、文档分块、向量化、数据入库等过程,文档解析步骤主要负责清理和提取各种格式的原始数据,如 PDF、HTML、Word 和 Markdown,然后将其转换为统一的纯文本格式。文档分块则主要是为了适应语言模型的上下文限制,文本需要被分割成更小且保证语义完整的文本块。向量化过程则是将分割的文本块输入到向量化(embedding)模型进行向量化的语义表示,并存储在向量数据库中。向量数据库不仅支持向量的高效写入与查询,还提供对元数据的管理能力,便于后续检索时进行过滤、排序或关联原始内容。为了提升大规模向量数据的检索效率并降低计算开销,系统通常会使用近似最近邻(Approximate Nearest Neighbor, ANN)算法(如 Faiss、Annoy、HNSW 等)构建索引结构。

RAG 的信息检索阶段主要是指当接收到用户请求数据时,




图 1 RAG 系统的整个流程

利用与索引阶段相同的 embedding 模型，将用户请求的文本数据转换为向量表示。随后计算查询向量与索引语料库中文本的相似性分数。RAG 检索出与用户请求数据最相似的前若干个（K，具体数量 K 根据实际场景确认）文本块。这些文本块将被用作提示（prompt）中的上下文信息。RAG 中的生成阶段主要是指将检索阶段检索到的相关文档信息与 prompt 结合，给 LLMs 提供专业领域的相关知识，并可通过 prompt 将 LLMs 的生成范围限定在相关知识的领域内，减少 LLMs “幻觉”现象的产生。此外，在进行的对话中，任何现有的对话历史都可被整合到 prompt 中，使模型能够有效地进行多轮对话交互。

2 智能文档分块方法

RAG 系统技术常用于 LLMs 在特定专业领域的问答系统。在 RAG 系统中，为确保检索阶段高相关文档的检索，需在索引阶段有效地对专业领域知识进行文本解析、文本分块、向量化等操作。由于受到 LLMs 输入长度的限制，文本分块阶段如何在数据粒度以及语义完整性上保持平衡，成为了 RAG 技术实际运用中的一个难点。为解决这一问题，本文提出了基于统计和语义相似度的智能文档分块方法，主要包括段落语义相似度计算、标题鉴别以及合并策略。

2.1 段落语义相似度计算

在自然语言处理领域，BERT（Bidirectional Encoder Representations from Transformers）模型以其强大的语义理解能力而广泛应用。在 BERT 的预训练过程中，设计了一项二分类任务，以帮助模型学习句子间的上下文关系。具体而言，该任务旨在预测第二个句子是否为第一个句子的下一个句子。这种设计的核心在于通过句子的上下文信息增强模型的语义理解能力。

受到这种任务设计的启发，本文提出利用 BERT 的预训练模型计算段落的向量表示（embedding 模型），以捕捉段落之间的语义相似度。在该方法中，当两个段落之间的语义相似度较高时，系统认为这两个段落可以合并；相反，当两个段落之间的语义相似度较低时，则在两个段落之间进行分割。这种方法旨在通过量化段落间的语义关系来优化文本的结构，从而提高文本处理的准确性和效率。

然而，当处理较长的段落时，利用 BERT 的预训练模型来进行向量化可能会丢失大量的细节信息。为了应对这一挑战，本文引入了 LLMs 作为补充手段来解决此问题。具体而言，首先将较长的段落输入到 LLMs 中，通过 LLMs 对段落中的关键信息进行提取，然后将提取后的信息输入到 BERT 的预训练模型中进行向量化表示。这一过程旨在通过 LLMs 的强大信息提

取能力来保留段落中的重要内容，进而提高最终的向量化表示的质量和准确性。这种方法不仅提升了段落之间语义相似度计算的精确度，也有效缓解了长段落信息丢失的问题。

在完成段落的向量化表示后，本文采用余弦相似度来计算两个向量之间的相似值，为后续的段落合并提供参照依据。计算过程如表 1 所示。

表 1 段落语义相似度的计算步骤

序号	主要内容
步骤 1	判断相邻两段文本的长度是否超过 embedding 模型的输入限制，超过时，调用 LLMs 进行摘要提取。
步骤 2	经过步骤 1 处理后的段落信息，输入到 embedding 模型，得到每个段落的向量化特征。
步骤 3	采用余弦相似度计算两个段落向量化特征的相似度。

2.2 标题鉴别

在实际文档分析中，标题的提取常常具有挑战性，因此，标题所在的文本信息通常被视为段落进行处理。本文发现，标题（包括一级标题、二级标题、三级标题等）通常是对后续内容的高度概括，且一般较短。为此，本文提出了一种基于统计的方法来判断段落是否为标题。具体方法为：首先统计整篇文章中每个段落的字数。由于标题通常较为简洁，作为对段落信息的总结，其长度一般不会超过整篇文章段落长度的第一个三分位数。基于这一统计特征，当段落长度未超过该三分位数时，认为该段落有可能为标题，这种方法能够有效地识别出文章中的标题，提高文档分析的准确性。表 2 简要描述了标题鉴别的计算流程。

表 2 标题鉴别的计算步骤

序号	主要内容
步骤 1	统计整篇文章中每个段落的字数。
步骤 2	计算整篇文章段落长度的第一个三分位数。
步骤 3	将段落长度与整篇文章段落长度的第一个三分位数进行比较；如果段落长度小于该三分位数，则视为标题，否则视为普通段落。

2.3 段落合并策略

若段落在标题鉴别阶段被标识为标题，在判断是否可以进行合并时，设定较高的相似度阈值，这是因为标题通常代表语义上的重要分割，具有较强的指示性。相对而言，对于未被识别为标题的段落，则表示这两段内容有较大的可能是

处在同一标题层级下的，可设置较低的相似度阈值，避免不必要的分割。

为了确保合并后的文本块长度符合 LLMs 允许的词元数量（token）限制，本研究还设计了长度校验机制。当合并后的段落长度超出 LLMs 的 token 限制时，将利用 LLMs 对段落进行摘要提取，将原本的段落合并调整为基于摘要的合并方式。这种方法不仅能有效控制文本块的长度，还能保持合并结果的语义连贯性和有效性。表 3 中为段落合并策略的计算步骤。

表 3 段落合并策略的计算步骤

序号	主要内容
步骤 1	若段落被标识为标题，设定较高的相似度阈值进行合并。
步骤 2	若段落未被标识为标题，设定较低的相似度阈值进行合并。
步骤 3	设计长度校验机制，确保合并后的文本块符合 LLMs 的 token 限制。
步骤 4	超出限制时，利用 LLMs 对段落进行摘要提取，调整合并方式。

3 实验

为验证智能文档分块的方法相比基于字符长度分割、基于段落分割的有效性，本文在 Wiki-727K 数据集^[10]上进行了实验。

（1）数据集

Wiki-727K 数据集包含 72.7 万篇英文维基百科文章，随机划分为训练、验证和测试集，主要用于预测章节边界。每篇文档平均分为 3.5 个块，平均长度为 13.6 个句子。由于本文方法无需训练，主要使用其测试集验证有效性。

（2）实验设置

在本实验中，当预测段落为标题时，合并的阈值（title_combine_threshold）为 0.6；段落不为标题时，合并的阈值（combine_threshold）设置为 0.5。

（3）实验数据

根据当前文本分块的评估指标^[11-12]，本文仅对段落内部的边界使用精确度（Precision）、召回率（Recall）和 F1 分数（精确率和召回率的调和平均数）进行评估。值得注意的是，本文评估未包含每个文档的最后一个边界，因为在所有文本分块方法中，该边界的正确划分是必然的。若将其纳入评估，会导致整体性能结果偏高。

表 4 展示了基于字符长度分割、基于段落分割以及本文

提出的智能文本分块方法在 Wiki-727K 测试集上的 Precision、Recall 和 F1 值。从表中数据可以看出，智能文档分块方法在所有评估指标上均表现出显著的性能优势。具体来说，智能文档分块的 Precision 为 0.64，Recall 为 0.95，F1 值为 0.76，明显高于基于字符长度分割的 Precision（0.57）、Recall（0.54）和 F1 值（0.55），以及基于段落分割的 Precision（0.43）、Recall（0.89）和 F1 值（0.58）。

此外，为进一步验证本文提出的标题鉴别和段落语义相似度在整个算法过程中的有效性，本文做了消融实验。从表 4 可看出，在智能文档分块方法中，去除基于统计方法的标题鉴别，仅采用段落语义相似度进行分块时，整个 F1 数值从 0.76 下降到 0.71。而当在智能文档分块方法中去除段落相似度，仅采用基于统计方法的标题鉴别进行分割后，F1 的数值下降更明显，从 0.76 下降到 0.49。这一数据表明，单纯地基于统计方法的标题鉴别进行分块，甚至低于基于字符长度分割和基于段落分割的方法，而将标题鉴别方法与段落语义相似度的计算结合后，能进一步提升段落语义相似度分块的效果。

表 4 智能文档分块方法在 Wiki-727K 数据集上的性能

方法	Precision	Recall	F1
基于字符长度分割	0.57	0.54	0.55
基于段落的分割	0.43	0.89	0.58
智能文档分块	0.64	0.95	0.76
智能文档分块 - 无标题鉴别	0.56	0.97	0.71
智能文档分块 - 无段落相似度	0.95	0.33	0.49

4 结束语

本文主要针对 RAG 系统中的文本分块进行研究，提出采用基于统计和语义相似度的智能文本分块方法来平衡文本分块中的数据粒度和语义完整性之间的关系。在 Wiki-727K 的测试集上进行了实验，并与以往基于字符长度分割和基于段落分割的方法进行了比较，实验结果表明，本文提出的基于统计和语义相似度的智能文本分块方法在 3 个性能指标上均优于其他 2 种方法。此外，本研究也通过消融实验表明，标题鉴别和段落语义相似度的结合更有利于文本分块效果的提升。

参考文献：

[1] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical

（下转第 111 页）

learning of dense optical flow, depth and egomotion with event-based sensors[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 5831-5838.

[19] Rebecq H, Horstschäfer T, Gallego G, et al. Evo: A geometric approach to event-based 6-dof parallel tracking and mapping in real time[J]. IEEE Robotics and Automation Letters, 2016, 2(2): 593-600.

[20] Zhou Y, Gallego G, Shen S. Event-based stereo visual odometry[J]. IEEE Transactions on Robotics, 2021, 37(5): 1433-1450.

[21] Jiao J, Huang H, Li L, et al. Comparing representations in tracking for event camera-based slam[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 1369-1376.

[22] Zuo Y F, Yang J, Chen J, et al. DEVO: Depth-Event

Camera Visual Odometry in Challenging Conditions[J]. arXiv preprint arXiv:2202.02556, 2022.

[23] Le Gentil C, Tschopp F, Alzugaray I, et al. Idol: A framework for imu-dvs odometry using lines[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 5863-5870.

[24] Mueggler E, Rebecq H, Gallego G, et al. The event-camera dataset and simulator: Event-based data for pose estimation, visual odometry, and SLAM[J]. The International Journal of Robotics Research, 2017, 36(2): 142-149.

作者简介:

杨立仁 (1996-), 男, 河南洛阳人, 工程师, 硕士; 研究方向: 人工智能、SLAM、三维重建、边缘计算等。

(收稿日期: 2024-08-10; 责任编辑: 王红)

(上接第 95 页)

report[J]. arXiv preprint arXiv:2303.08774, 2023.

[2] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.

[3] Bubeck S, Chandrasekaran V, Eldan R, et al. Sparks of artificial general intelligence: Early experiments with gpt-4[J]. arXiv preprint arXiv:2303.12712, 2023.

[4] Nori H, King N, McKinney S M, et al. Capabilities of gpt-4 on medical challenge problems[J]. arXiv preprint arXiv:2303.13375, 2023.

[5] Wang C, Lye X, Kaalia R, et al. Deep learning and multi-omics approach to predict drug responses in cancer[J]. BMC bioinformatics, 2021, 22(Suppl 10): 632.

[6] Shi F, Zhang Y, Qu C, et al. Leveraging the power of large language models to drive progress in the manufacturing industry[C]//9th International Conference on Financial Innovation and Economic Development (ICFIED 2024). Atlantis Press, 2024: 125-133.

[7] Sharma S, Sharma S, Liu L, et al. Knowledge Guided Representation Learning and Causal Structure Learning in Soil Science[J]. arXiv preprint arXiv:2306.09302, 2023.

[8] Kandpal N, Deng H, Roberts A, et al. Large language models struggle to learn long-tail knowledge[C]//International Conference on

Machine Learning. PMLR, 2023: 15696-15707.

[9] Zhang Y, Li Y, Cui L, et al. Siren's song in the AI ocean: a survey on hallucination in large language models[J]. arXiv preprint arXiv:2309.01219, 2023.

[10] Koshorek O, Cohen A, Mor N, et al. Text segmentation as a supervised learning task[J]. arXiv preprint arXiv:1803.09337, 2018.

[11] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.

作者简介:

李慧 (1996-), 女, 湖南长沙人, 研发工程师, 硕士; 研究方向: 计算机视觉、自然语言处理模型、神经网络架构搜索。

刘宇 (1989-), 男, 江苏徐州人, 工程师, 硕士; 研究方向: 边缘计算、云计算。

张凯翔 (1991-), 男, 宁夏银川人, 硕士; 研究方向: 计算机视觉。

裴天鹏 (1998-), 男, 山西运城人, 硕士; 研究方向: 计算机视觉。

(收稿日期: 2025-04-29; 责任编辑: 王红)