

微电子学与计算机
Microelectronics & Computer
ISSN 1000-7180, CN 61-1123/TN

《微电子学与计算机》网络首发论文

题目：大模型发展综述：从 BERT 到 Deepseek 的技术演进
作者：赵凯博，李宇楠，彭成，李珺玮，鲍亮
网络首发日期：2026-04-16
引用格式：赵凯博，李宇楠，彭成，李珺玮，鲍亮. 大模型发展综述：从 BERT 到 Deepseek 的技术演进[J/OL]. 微电子学与计算机.
<https://link.cnki.net/urlid/61.1123.TN.20260416.1137.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

大模型发展综述：从 BERT 到 Deepseek 的技术演进

赵凯博¹, 李宇楠¹, 彭成², 李珺玮², 鲍亮¹

(1 西安电子科技大学计算机科学与技术学院, 陕西西安 710071; 2 河北钢铁集团滦县司家营铁矿有限公司, 河北唐山 063701)

摘要：随着人工智能技术的快速发展，大模型已成为推动自然语言处理、多模态理解和复杂推理任务突破的核心驱动力。本文系统性梳理了大模型的发展历程与技术演进，从基础语言模型、多模态大模型到推理大模型的分层框架出发，深入分析了以 Transformer 为核心的模型架构设计及其关键技术改进。在语言模型领域，重点探讨了从 BERT、GPT 系列到 LLaMA、GLM-130B 等模型的预训练范式创新，以及基于指令微调的 T0、Flan-LM 等模型在任务泛化能力上的提升。针对多模态领域，剖析了 GPT-4、Qwen-VL 等模型在跨模态对齐与联合表征方面的技术突破。在推理大模型方向，通过 OpenAI-o1、DeepSeek-R1 等案例揭示了混合专家系统 (MoE) 与强化学习策略优化的协同作用。本文完整呈现了 DeepSeek-R1 的技术体系，包括 DeepSeekMoE 架构设计、多头潜在注意力 (MLA) 机制和群体相对策略优化方法，并通过其三级训练流程验证了长文扩展与推理对齐的有效性。研究表明，模型规模的持续扩展需与训练效率优化、知识注入策略以及人机对齐技术相结合，而多阶段强化学习与拒绝采样机制可显著提升复杂场景下的推理可靠性。本综述为理解大模型技术脉络提供了结构化视角，对下一代通用人工智能系统的研发具有重要参考价值。

关键词：大模型；指令微调；多模态；注意力机制

中图分类号：TP37 **文献标识码：**A

A Review of Large Model Development: Technological Evolution from BERT to Deepseek

Kaibo Zhao¹, Yunan Li¹, Cheng Peng², Junwei Li², Liang Bao¹

(1 School of Computer Science and Technology, Xidian University, Xi'an 710071, China; 2 Hebei Iron and Steel Group Luanxian Sijiaoying Iron Ore Co., Ltd., Tangshan, Hebei 063701, China)

Abstract: With the rapid development of artificial intelligence technology, large models have become the core driving force behind breakthroughs in natural language processing, multimodal understanding, and complex reasoning tasks. This paper systematically reviews the development and technological evolution of large models, categorizing them into foundational language models, multimodal large models, and reasoning large models. It provides an in-depth analysis of model architecture designs centered around Transformer and key technological improvements. In the field of language models, we focus on innovations in pretraining paradigms, tracing the progress from BERT and the GPT series to models such as LLaMA and GLM-130B, as well as the advancements in task generalization enabled by instruction-tuned models like T0 and Flan-LM. For multimodal models, we examine technical breakthroughs in cross-modal alignment and joint representation learning, exemplified by models such as GPT-4 and Qwen-VL. Regarding reasoning large models, we explore cases such as OpenAI-o1 and DeepSeek-R1, highlighting the synergy between mixture-of-experts (MoE) systems and reinforcement learning optimization strategies. This paper presents a comprehensive overview of the technical framework of DeepSeek-R1, covering its DeepSeekMoE architecture, multi-head latent attention (MLA) mechanism, and group relative policy optimization methods. Additionally, we validate the effectiveness of its three-stage training process in extending long-text capabilities and refining reasoning alignment. Research findings indicate that the continuous scaling of model size must be coupled with training efficiency optimization, knowledge integration strategies, and human-AI alignment techniques. Furthermore, multi-stage reinforcement learning and rejection sampling mechanisms

基金项目：河北省重点研发计划 (No.23310302D)；陕西省重点研发计划 (No.2024GX-ZDCYL-01-11)。

can significantly enhance reasoning reliability in complex scenarios. This review provides a structured perspective on the technical trajectory of large models and serves as a valuable reference for the development of next-generation general artificial intelligence systems.

Key words: Large Models; Instruction Fine-Tuning; Multimodal; Attention Mechanism

1 引言

人工智能领域近年来迎来以大模型为核心的范式变革, 基于海量数据与大规模算力的预训练模型在语言理解、多模态交互和复杂推理任务中展现出前所未有的能力。自 2017 年 Transformer 架构提出以来, 以 BERT 和 GPT 为代表的语言模型通过自监督预训练实现了通用表征学习的突破, 而 GPT-3 等千亿参数模型的涌现则验证了模型规模扩展对上下文学习能力的显著提升。随着技术演进, 研究重心逐渐从单一模态向多模态融合延伸, GPT-4V 等视觉语言联合模型通过跨模态注意力机制实现了图文协同理解, 同时 Qwen-VL 等开源方案推动了多模态技术的普惠化发展。在推理能力构建方面, 传统语言模型受限于自回归生成特性, 而 DeepSeek-R1 等新型架构通过混合专家系统与强化学习策略优化, 在数学证明和逻辑推理任务中取得突破性进展。当前大模型发展面临三方面挑战: 模型规模扩展带来的计算成本指数增长、多任务泛化能力与专业领域知识获取的平衡困境, 以及人机价值观对齐的伦理风险。本文从技术发展脉络出发, 系统梳理语言模型、多模态模型和推理大模型的关键技术路线, 深入解析 Transformer 架构改进、MoE 参数高效化设计以及强化学习对齐策略, 并通过 DeepSeek-R1 的完整训练流程揭示大模型工程化落地的技术要点, 为后续研究提供理论框架与实践参

考。

1.1 大模型发展历程

大模型的发展历程始于 2017 年 Transformer 架构的提出, 这一基于自注意力机制的创新模型为后续自然语言处理技术奠定了基础。2018 年, OpenAI 发布了 GPT, 通过大规模无监督预训练展示了生成式模型的强大潜力; 同年, Google 推出的 BERT 则引入了双向编码器和多种预训练任务, 显著提升了模型在多个 NLP 任务上的表现。随后, GPT-2 (2019 年) 和 GPT-3 (2020 年) 相继问世, 参数量不断增大, 生成能力持续增强, 尤其是 GPT-3 以超过 1750 亿参数成为当时最大规模的预训练模型之一。进入 2021 年后, T5、FLAN 等模型进一步优化了文本转换和事实理解能力, 而 ChatGPT (2022 年) 则凭借出色的对话理解和生成能力掀起了一场对话式 AI 的革命。近年来, 随着 LLaMA 系列 (2023 年) 等开源模型的出现, 学术界对大模型的研究得到了极大推动, 同时 GPT-4 及其后续版本 (2023-2024 年) 展现了更强大的多模态处理能力和性能优化。这些里程碑式的进展不仅标志着模型规模和技术能力的飞跃, 也推动了大模型在各行各业中的广泛应用, 从文本生成到信息检索再到多模态处理, 彻底改变了人工智能的技术格局。大模型发展历程如图 1 所示:




图 1 大模型发展历程^[88]

Fig. 1 The Development History of LLM^[88]

1.2 大模型

大模型是指参数量巨大、计算资源需求高的机器学习模型, 通常基于深度学习技术, 通过海量数据和强大的计算能力进行训练。这些模型具备极强

的表征能力和泛化能力, 能够处理复杂的任务, 如自然语言处理、图像识别、语音合成等。大模型的核心特点在于其规模 (参数量通常在数十亿到数千亿甚至更多) 以及通过预训练学习到的通用知识, 使其能够在多种下游任务中表现出色。典型的大模

型包括大语言模型（如 GPT、BERT）、多模态大模型（如 GPT-4V、Qwen2-VL）以及推理大模型（如 OpenAI-o1），它们在各自领域推动了人工智能技术的突破和应用，如表 1 所示。

表 1 大模型应用领域分类表

Tab. 1 Classification Table of Application Domains for Large Models

分类	代表应用领域	关键支撑技术	代表模型	时间线特征
大语言模型	文本生成、问答、摘要、翻译、对话	Transformer、预训练-微调范式、大规模语料建模	BERT、GPT 系列、PaLM、LLaMA、GLM-130B	2018–至今
多模态模型	图文问答、图像描述、图像理解、代码图表生成	图文对齐（CLIP）、跨模态融合、视觉编码器+LLM 结构	GPT-4V、Flamingo、Qwen-VL、Kosmos-1	2022–至今
推理大模型	数学与逻辑推理、复杂任务规划与策略生成	MoE、指令微调、多任务训练、强化学习	DeepSeek-R1、OpenAI-o1、QvQ-72B	2023 末–至今

随着大模型能力的持续提升，其实际部署方式和应用生态也在不断完善，逐步从学术研究走向工业实践。目前，主流的大模型服务已广泛提供多种客户端和 API 接口，便于用户在不同场景中快速调用与集成。例如，OpenAI 的 ChatGPT、Anthropic 的 Claude、Google 的 Gemini，以及国内的文心一言、通义千问、智谱清言等系统，均支持基于 Web 的交互式使用和 RESTful API 接入，同时提供 Python SDK、本地化部署和企业级定制方案。在部署方面，面向推理效率与可扩展性的开源推理框架，如 vLLM、Text Generation Inference（TGI）、TensorRT-LLM 和 FastServe 等，支持高吞吐低延迟的多并发部署，具备动态批处理、KV 缓存复用、权重量化等优化能力。针对私有化需求，一些开源平台（如 LMDeploy、OpenChat、DeepSeek-Vision 等）则集成了模型量化、微调训练、容器封装与多模态接入等完整部署链路，为多场景落地提供了技术支撑。综合来看，不同模型在推理性能、接口灵活性、上下文长度支持、工具调用能力及插件生态等方面仍存在差异。因此，系统对比当前大模型的实际部署流程与接口能力，不仅有助于评估其技术成熟度，也为模型的实际应用与迁移部署提供了重要参考。

1.2.1 大语言模型

大语言模型（Large Language Models, LLMs）是基于深度学习技术、参数量巨大的语言模型，通常包含数十亿甚至数千亿个参数（如 GPT-3 的

1750 亿参数），是传统语言模型（Language Models, LMs）的扩展和升级。LLMs 通过海量文本数据进行预训练，学习语言的统计规律和语义信息，并利用 Transformer 等先进架构实现高效的上下文理解和生成能力。与传统语言模型相比，LLMs 的显著特点在于其规模更大、训练数据更丰富，因此在广泛的任务中表现出卓越的性能，如文本生成、翻译、问答、代码编写等。自 2018 年 BERT 和 GPT-1 等基于 Transformer 的模型出现以来，LLMs 逐渐受到关注，而 2020 年 GPT-3 的发布进一步推动了这一领域的发展，展示了其在自然语言处理中的重大影响力和强大能力。

1.2.2 多模态大模型

多模态大模型是一种能够同时处理和理解多种类型数据（如文本、图像、音频、视频等）的机器学习模型，通常基于深度学习技术并具有大规模参数量。这类模型通过联合学习不同模态之间的关联，实现跨模态的信息交互和生成，例如根据文本生成图像、通过图像生成描述，或结合文本和音频进行多模态推理。多模态大模型的核心特点在于其能够整合多种数据类型的特征，并在复杂任务中展现出强大的泛化能力和适应性。代表性模型包括 OpenAI 的 GPT-4V，以及阿里的 Qwen-VL。这些模型推动了人工智能在跨模态理解和生成领域的突破，广泛应用于内容创作、智能交互和多媒体分析等场景。

1.2.3 推理大模型

推理大模型是一类专注于逻辑推理、复杂问题求解以及多模态理解的高性能人工智能模型，通常具有大规模参数量和先进的架构设计。这类模型不仅能够处理传统的语言任务，还擅长数学推导、符号推理、多模态数据融合等复杂场景，展现出强大的推理能力和可解释性。推理大模型通过结合深度学习与符号推理技术，能够在科学计算、策略规划、跨模态分析等领域实现高效的问题解决。代表性模型包括 OpenAI 的 OpenAI-o1、深度求索的 DeepSeek-R1，以及多模态推理大模型 QWen-72B-Preview，这些模型在逻辑推理、多模态理解和复杂任务处理中展现了卓越的性能，推动了人工智能在推理能力上的突破和应用。

2 Transformer 介绍

Transformer 是一种基于注意力机制的深度学习模型架构，由 Vaswani 等人在 2017 年的论文《Attention Is All You Need》中首次提出^[1]。该模型在自然语言处理（NLP）领域取得了巨大的成功，广泛应用于机器翻译、语言建模、序列标注和文本分类等任务。




图 2 Transformer 架构

Fig. 2 Transformer Framework

Transformer 基本结构包括编码器（Encoder）和解码器（Decoder）两个部分，每个部分由多个相同的层堆叠组成。如图 2 所示。每层编码器主要由多头自注意力机制和前馈神经网络组成，而解码器则在此基础上增加了用于处理已生成序列的掩码多头注意力层。Transformer 的关键优势在于其能够并行处理序列数据，并通过注意力机制捕捉序列中不同位置之间的全局依赖关系。

3 大语言模型

3.1 基础语言模型

基础语言模型是指只在大规模文本语料中进行了预训练的模型，未经过指令和下游任务微调、以及人类反馈等任何对齐优化。预训练模型（Pre-trained Model）是指在大规模数据集上经过初步训练的深度学习模型，旨在学习通用的特征表示，随后可通过微调（Fine-tuning）在特定任务上进一步优化。预训练模型通常采用自监督学习或无监督学习策略，通过预测缺失信息（如 BERT 的掩码语言模型）或生成序列（如 GPT 的自回归语言模型）来学习语言分布和语义结构。在 NLP 领域，基于 Transformer^[1]的预训练模型（如 BERT、GPT、T5 等）已成为主流，广泛应用于文本理解、文本生成和多模态任务。基础语言模型展示在表 2 中。

3.1.1 BERT

BERT（Bidirectional Encoder Representations from Transformers）^[2]是由 Google AI 团队于 2018 年推出的一种预训练语言表示模型。BERT 的推出标志着自然语言处理（NLP）领域的一个重要里程碑，因为它通过引入双向 Transformer 编码器和掩码语言模型（Masked Language Model, MLM）等新技术，显著提升了多项 NLP 任务的性能。

BERT 模型由多层 Transformer 编码器堆叠而成。具体来说，BERT-base 模型包含 12 层 Transformer 编码器，每层有 12 个注意力头，隐藏层维度为 768，总参数量约为 1.1 亿；而 BERT-large 模型则包含 24 层 Transformer 编码器，每层有 16 个注意力头，隐藏层维度为 1024，总参数量约为 3.4 亿。每一层 Transformer 编码器都包含两个主要子层：多头自注意力机制和前馈神经网络。每个子层后都应用了残差连接（Residual Connection）和层归一化（Layer Normalization），以加速训练并提升模型稳定性。如图 3 所示。

BERT 的训练分为两个阶段：预训练（Pre-training）和微调（Fine-tuning）。预训练阶段

是 BERT 的核心创新之一，它通过大规模无标注文本数据学习通用的语言表示。微调阶段则是在特定任务上对预训练模型进行进一步训练，以适应具体任务的需求。BERT 的预训练采用了两种无监督任务：掩码语言模型（Masked Language Model, MLM）和下一句预测（Next Sentence Prediction, NSP）。掩码语言模型是 BERT 的核心创新之一。传统的语言模型（如 GPT）是单向的，只能从左到右或从右到左预测下一个词。而 BERT 通过随机掩码输入序列中的部分词（通常为 15%），并让模型预测这些

被掩码的词，从而实现了双向上下文建模。这种双向性使得 BERT 能够更好地捕捉词语之间的上下文关系。下一句预测（NSP）任务用于训练模型理解句子之间的关系。具体来说，模型需要判断两个句子是否是连续的。这一任务对于需要理解句子间关系的任务（如问答和自然语言推理）尤为重要。BERT 的预训练数据通常来自大规模文本语料库，如 BooksCorpus 和英文维基百科。通过这两种任务的联合训练，BERT 能够学习到丰富的语言表示。

表 2 基础 LLM 信息表

Tab. 2 Basic LLM Information Table

模型名称	发布时间	发布机构	参数规模	Tokens 规模	模型结构	是否开源
T5	2019-10	Google	13B	-	T5-style	√
GPT-3	2020-05	OpenAI	175B	300B	GPT-style	x
LaMDA	2021-05	Google	137B	2.8T	GPT-style	X
Jurassic	2021-08	AI21	178B	300B	GPT-style	x
MT-NLG	2021-10	Microsoft、 NVIDIA	530B	270B	GPT-style	x
ERNIE 3.0 Titan	2021-12	Baidu	260B	300B	Multi-task	x
Gopher	2021-12	DeepMind	280B	300B	GPT-style	x
Chinchilla	2022-04	DeepMind	70B	1.4T	GPT-style	x
PaLM	2022-04	Google	540B	780B	GPT-style	x
OPT	2022-05	Meta	125M-175B	180B	GPT-style	√
BLOOM	2022-07	BigScience	176B	366B	GPT-style	√
GLM-130B	2022-08	Tsinghua	130B	400B	GLM-style	√
LLaMA	2023-02	Meta	7B-65B	1.4T	GPT-style	√




图 3 BERT 架构

Fig. 3 BERT Framework

在预训练完成后，BERT 可以通过微调适应各种下游任务。微调过程通常只需要在预训练模型的基础上添加一个简单的任务特定输出层（如分类层或序列标注层），并在特定任务的数据集上进行少量训练。由于 BERT 在预训练阶段已经学习到了通用的语言表示，微调过程通常收敛较快，且效果显著。

BERT 的成功得益于多项关键技术创新，主要包括以下几个方面：

双向上下文建模：传统的语言模型（如 GPT）是单向的，只能从左到右或从右到左预测下一个词。而 BERT 通过 MLM 任务实现了双向上下文建模，能够同时利用词语的左右上下文信息，从而显著提升了模型的语言理解能力。

掩码语言模型 (MLM)：MLM 任务通过随机掩码输入序列中的部分词，并让模型预测这些被掩码的词，从而实现了双向上下文建模。这一任务使得 BERT 能够更好地捕捉词语之间的上下文关系。

下一句预测 (NSP)：NSP 任务通过判断两个句子是否是连续的，帮助模型理解句子之间的关系。这一任务对于需要理解句子间关系的任务（如问答和自然语言推理）尤为重要。

Transformer 编码器：BERT 完全采用了 Transformer 的编码器结构，利用多头自注意力机制和前馈神经网络捕捉长距离依赖关系。相比于传统的递归神经网络 (Recurrent Neural Network, RNN) 和卷积神经网络 (Convolutional Neural Networks, CNN)，Transformer 能够更好地处理长序列数据，并且具有更高的并行计算效率。

大规模预训练：BERT 通过在大规模无标注文本数据上进行预训练，学习到了通用的语言表示。这种预训练方式使得 BERT 能够在各种下游任务上取得优异的表现，而无需从头开始训练。

3.1.2 GPT-1：探索生成式预训练

GPT (Generative Pre-trained Transformer) 系列模型^[90]是自然语言处理领域的重要里程碑，它通过训练模型学习恢复预训练文本数据，利用基于解码器的 Transformer 架构将广泛的世界知识压缩到模型中，使模型具备全面的能力。这一过程的关键在于开发能够准确预测下一个词的语言模型，并不断扩展语言模型和预训练数据的规模。GPT 是一个单向的语言模型，它使用左侧的上下文生成右侧的文本。这种单向性质使其特别适用于生成任务，如文本生成和对话生成，GPT 模型架构如图 4 所示。




图 4 GPT 架构

Fig. 4 GPT Framework

2017 年，Google 推出了 Transformer 模型，其在性能上的显著优势迅速吸引了 OpenAI 团队的关注。受此启发，OpenAI 将研发重心转向 Transformer 架构，并于 2018 年发布了第一代生成式预训练模型——GPT-1^[3]。

GPT-1 采用了仅包含解码器的 Transformer 架构，专注于预测下一个词元的任务。尽管参数规模相对较小，但它结合了无监督预训练和有监督微调 (Supervised Fine-Tuning, SFT) 的方法，以增强模型的通用任务求解能力。同年，Google 推出了 BERT 模型，该模型专注于自然语言理解 (Natural Language Understanding, NLU)，并使用了 Transformer 的编码器部分。BERT-Large 在多个 NLU 任务上取得了突破性进展，成为当时的明星模型。

虽然 GPT-1 的参数规模与 BERT-Base 相当，且在公开评测数据集上的表现未能超越 BERT，但它的出现为后续更强大的 GPT 模型奠定了基础。GPT-1 和 BERT 分别代表了自然语言生成和自然语言理解两个领域的早期探索，它们共同推动了 Transformer 架构的发展。

3.1.3 GPT-2：扩大规模与多任务学习

GPT-2 继承了 GPT-1 的核心架构，但将参数规模大幅扩展至 15 亿，并使用大规模网页数据集 WebText 进行预训练。相比 GPT-1，GPT-2 的创新之处在于尝试通过增加模型参数规模来提升性能，同时去除了针对特定任务的微调环节，探索了一种全新的多任务学习框架。

GPT-2 的核心思想是将各种下游任务统一为文本生成问题^[4]。具体而言，输入、输出和任务信息均以自然语言的形式描述，从而将任务求解过程转化为对文本序列的预测。这种设计使得 GPT-2 能够在无需显式标注数据的情况下解决多种任务。

OpenAI 团队在论文中解释了无监督预训练为何能在下游任务中取得良好效果。他们指出，特定任务的有监督学习目标与无监督学习目标（语言建模）本质上是一致的，都旨在预测下一个词元。因此，优化无监督的全局学习目标实际上也在优化有监督的任务学习目标。OpenAI 创始人在采访中提到，神经网络学到的是一种生成文本的表示形式，这些模型生成的文本实际上是真实世界的投影。语言模型对下一个单词的预测越准确，其对世界知识的理解就越深入，分辨能力也越高。GPT-2 通过扩大参数规模和采用无监督预训练的方式，显著提升了模型的通用性和灵活性，减少了对特定任务微调

的依赖,进一步强调了语言模型在理解和生成自然语言中的核心作用。

3.1.4 GPT-3: 上下文学习与超大规模扩展

2020 年, OpenAI 推出了具有划时代意义的 GPT-3 模型^[5],其参数规模达到了惊人的 175B(1750 亿),相较于 GPT-2 提升了 100 余倍。这一成就标志着对模型扩展极限的一次大胆尝试。

在 GPT-3 的研发过程中, OpenAI 进行了大量的实验探索,包括小版本模型的测试、数据收集与清洗、以及高效的并行训练技巧等。这些前期工作为 GPT-3 的成功奠定了坚实的基础。

GPT-3 首次提出了“上下文学习”(In-Context Learning)的概念,允许大语言模型通过少样本学习解决各种任务,而无需针对新任务进行微调。这种学习方式将预训练阶段和使用阶段统一为语言建模的形式:在预训练阶段,模型根据给定上下文预测后续文本序列;在使用阶段,模型根据任务描述和示例数据推理出正确的解决方案。

研究表明,上下文学习对大模型的性能增益尤为显著,而对于小模型则收益有限。GPT-3 在自然语言处理任务中表现出色,尤其在需要复杂推理或领域适配的任务中展现了强大的能力。

GPT-3 的成功证明了将神经网络扩展到超大规模可以显著提升模型性能,并开创了基于提示学习(Prompt-based Learning)的技术路线。这为大语言模型的未来发展提供了新的思路和方法。

3.1.5 T5

T5(Text-to-Text Transfer Transformer)是 Google 在 2019 年推出的一种基于 Transformer 架构的预训练语言模型,其核心思想是将所有自然语言处理(NLP)任务统一为“文本到文本”(Text-to-Text)的形式^[6]。这一创新在于,无论是机器翻译、文本摘要、问答系统还是文本分类,输入和输出都被视为文本字符串。例如,在翻译任务中,模型会接收“translate English to German: That is good”作为输入,并输出“Das ist gut”。这种统一框架不仅简化了模型的设计和训练过程,还使得 T5 能够通过一个模型处理多种任务,只需在输入文本前添加任务特定的前缀即可。

在模型架构方面,T5 采用了标准的 Transformer Encoder-Decoder 结构。编码器部分负责将输入文本编码为固定长度的向量表示,采用双向注意力机制来捕捉上下文信息。解码器则根据编码器的输出生成目标文本,采用自回归方式,即当前时间步只能

看到之前时间步的信息。T5 在选择这一结构时,对比了其他模型如 Decoder-only 和 Prefix LM,发现 Encoder-Decoder 结构在自然语言生成任务(Natural Language Generation, NLG)上表现最佳。

T5 的训练过程包括预训练和微调两个阶段。预训练阶段使用大规模无监督数据进行自监督学习,主要方法是 BERT-style 的掩码语言模型(MLM),即随机遮盖部分文本并预测被遮盖的内容。此外,T5 还引入了“Replace Span”策略,即连续遮盖多个词并预测这些词,实验证明这种方法效果更佳。预训练数据来自 C4(Colossal Clean Crawled Corpus),这是一个从 Common Crawl 中清洗得到的高质量文本数据集,为 T5 提供了丰富的语言表示能力。微调阶段则是在特定任务的有监督数据上进行,以适应具体任务的需求。

T5 的贡献与优势在于其统一的框架、多任务处理能力、零样本学习以及多语言支持。通过将所有 NLP 任务统一为“文本到文本”的形式,T5 简化了模型设计和训练流程,并能够在一个模型中处理多种任务。此外,T5 展示了强大的泛化能力,能够在没有任务特定数据的情况下进行推理。除了英文版本,Google 还发布了支持 101 种语言的 mT5,进一步扩展了 T5 的应用范围。在实际应用场景中,T5 在机器翻译、文本摘要、问答系统和文本分类等多个 NLP 任务中表现出色。

3.1.6 PaLM

PaLM^[14]是谷歌于 2022 年推出的一款超大规模语言模型,其参数规模达到了 5400 亿(540B),在当时属于业界领先的水平。该模型采用了 GPT-style 的 decoder-only 单向自回归架构,这种结构设计特别适合处理 few-shot 学习任务,能够有效提升模型在少量样本条件下的泛化能力。通过这种架构,PaLM 能够在面对新任务时快速适应并生成高质量的结果。

PaLM 的训练过程依托于谷歌自主研发的 Pathways 系统,这是一种创新性的机器学习框架,能够在多个 TPU Pod 上实现高效的分布式训练。具体而言,PaLM 的训练是在 6144 块 TPU v4 芯片上完成的,这些芯片被组织成两个 Cloud TPU v4 Pods,通过数据并行的方式扩展训练规模。与此前大多数大型语言模型相比,PaLM 的训练规模实现了显著的增长,同时其硬件 FLOPs 利用率达到了 57.8%,这是当时已知的在如此大规模模型中实现的最高效率。

在性能表现方面,PaLM 在数百种语言理解和生成基准测试中展现了卓越的 few-shot 学习能力,

证明了模型规模扩展所带来的显著优势。特别是在多步推理任务中, PaLM 540B 展现出了超越经过微调的最先进模型的表现, 这一成果标志着大模型在复杂推理任务中的突破性进展。此外, 大量来自 BIG-bench 的任务结果表明, 随着模型规模的扩大, 其性能会出现非线性的提升, 尤其是在达到最大规模时, 性能的提升尤为显著。

3.1.7 LLaMA

LLaMA (Large Language Model Meta AI) 是由 Meta (前 Facebook) 开发的一系列大型语言模型^{[15][35]}, 旨在提升自然语言处理任务的性能。自发布以来, LLaMA 系列模型经历了多次迭代, 最新版本为 LLaMA 3^[17]。

LLaMA 模型基于 Transformer 架构, 采用了仅包含解码器的设计。与其他模型相比, LLaMA 在架构上进行了多项改进, 包括使用 RMSNorm 预归一化、SwiGLU 激活函数^[37]以及旋转位置嵌入 (RoPE^[36])。这些改进旨在提高模型的训练稳定性和性能表现。

在参数规模方面, LLaMA 系列提供了多种选择, 参数量从 70 亿到 700 亿不等。值得注意的是, LLaMA-13B 在许多任务上的表现优于 GPT-3 (175B), 而 LLaMA-65B 的性能可与 Chinchilla-70B 和 PaLM-540B 等最先进的语言模型相媲美。2024 年 4 月 18 日, Meta 推出了 LLaMA 3, 包括具有 80 亿和 700 亿参数的预训练和指令微调模型。这一版本在一系列行业标准基准测试中展示了最先进的性能, 并提供了新的功能, 包括改进的推理能力。此外, LLaMA 3.1 Omni^[32]模型实现了文本与语音的双输出, 打破了传统的文字生成边界, 具备了真正的多模态能力。这一特性为 AI 应用的多样化发展提供了新的可能性。总体而言, LLaMA 系列模型在多个自然语言处理任务中表现出色, 包括文本分类、情感分析和生成式问答等。其架构的创新设计和多样化的参数规模, 使其在实际应用中展现出显著的潜力和灵活性。

3.1.8 GLM-130B

GLM-130B^[39]是由清华大学知识工程实验室团队开发的一款开源双语 (中文和英文) 预训练语言模型, 拥有 1300 亿参数。该模型于 2022 年 8 月正式发布, 并在多个自然语言处理任务中展现出卓越的性能, 尤其是在中英文双语任务上表现尤为突出。

GLM-130B 的提出背景源于对大规模语言模型普惠性的追求。当时, GPT-3 等千亿级模型虽然表

现出色, 但其参数并未开源, 且对算力要求极高, 限制了研究者和企业的使用。GLM-130B 的目标是打造一个开源、高性能的双语模型, 能够在较低配置的硬件上运行, 从而推动大模型技术的普及。

在性能方面, GLM-130B 在多个基准测试中表现优异。例如, 在英文任务 LAMBADA 上, 其准确率优于 GPT-3 175B (+4.0%)、OPT-175B (+5.5%) 和 BLOOM-176B (+13.0%); 在中文任务 CLUE 和 FewCLUE 数据集上, 其表现也显著优于 ERNIE TITAN 3.0 260B。此外, GLM-130B 还支持 INT4 量化, 能够在 RTX 3090 等消费级显卡上高效推理, 极大降低了使用门槛。GLM-130B 的架构基于通用语言模型 (GLM), 采用了自回归空白填充 (autoregressive blank infilling) 作为主要预训练目标。这种方法允许模型在生成文本时同时考虑上下文信息, 从而增强对语言结构的理解和生成能力。此外, GLM-130B 还引入了旋转位置编码 (RoPE^[36])、深度归一化 (DeepNorm^[38]) 等技术, 进一步提升了模型的训练稳定性和性能。GLM-130B 的研发过程充满了挑战。团队在训练过程中遇到了硬件故障、梯度爆炸、内存溢出等问题, 但通过与清华 PACMAN 团队的合作, 最终成功解决了这些技术难题。训练完成后, GLM-130B 不仅支持在 NVIDIA GPU 上运行, 还适配了国产的海光 DCU、华为昇腾 910 等平台, 展现了其跨平台的兼容性。总的来说, GLM-130B 不仅是一次技术上的突破, 更是对开源生态的重要贡献。它的发布为研究者和开发者提供了一个高性能、低门槛的双语大模型, 推动了人工智能技术的普及和应用。

3.2 基于指令微调的语言模型

基于指令微调的语言模型是一种通过特定指令或任务数据进行微调的大规模预训练语言模型, 旨在提升模型在特定任务或指令下的表现。这类模型通常在大规模通用语料上进行预训练, 随后通过指令数据集 (如自然语言指令和对应的任务示例) 进行微调, 使其能够更好地理解和执行多样化的人类指令。这种微调方式使模型具备更强的泛化能力, 能够适应多种任务和语言场景, 例如问答、翻译、文本生成等。典型的例子包括 GPT-3.5、FLAN、T0 等, 它们在多语言或多模态任务中展现了强大的性能。

3.2.1 T0

T0^[40]是由 Hugging Face 联合 42 位研究人员共同开发的一个基于 T5 模型^[6]的改进版本。该模型的核心目标是通过在大规模多任务数据集上

进行微调,提升其在未知任务上的泛化能力(即 zero-shot 性能),同时增强其对 prompt 措辞变化的鲁棒性。为了实现这一目标,研究团队开发了一套系统,能够将任何自然语言任务映射为人类可读的 prompt 形式,并将大量有监督的数据集转换为多任务训练数据。每个数据集都配备了多个 prompt 和不同的措辞表达,从而确保了模型在训练过程中能够接触到多样化的任务描述和语言表达方式。

T0 模型基于 encoder-decoder 架构的 T5 模型,通过多任务数据集上进行微调,使其能够在不需要显著增加模型规模的情况下,显著提升 zero-shot 性能。模型的提示词格式如下图所示。这种多任务训练方法不仅涵盖了广泛的任务类型,还通过多样化的 prompt 设计,使模型能够更好地理解和适应不同任务的需求。研究表明,T0 在多个标准数据集上的 zero-shot 性能显著优于比其大 16 倍的 GPT-3 模型^[5],这一成果展示了多任务微调在提升模型泛化能力方面的巨大潜力。此外,T0 的研究还强调了 prompt 设计在模型性能中的重要性。通过引入多样化的 prompt 措辞,T0 能够更好地应对不同任务描述的变化,从而减少了对特定 prompt 措辞的依赖。这种设计不仅提高了模型的鲁棒性,还为未来研究提供了新的思路,即通过改进 prompt 设计来进一步提升模型的 zero-shot 性能。总体而言,T0 的研究为自然语言处理领域提供了一种有效的方法,能够在保持模型规模相对较小的情况下,显著提升其在多样化任务上的表现。




图 5 T0 模型和提示词格式

Fig. 5 T0 model and prompt format

3.2.2 Flan-LM

Flan-LM^[41]是谷歌基于其已有的 T5、PaLM 和 U-PaLM 等基础模型,通过指令微调(Instruction Tuning)技术开发的一系列语言模型。这些模型包括 Flan-T5 (11B)、Flan-PaLM (540B) 和

Flan-U-PaLM (540B) 等不同规模版本。指令微调是一种通过在多样化任务数据集上进行微调来提升模型性能的方法,旨在增强模型对未知任务的泛化能力和指令遵循能力。

Flan-LM 的核心创新在于其大规模指令微调策略。谷歌整合了多个现有的指令数据集,包括 Muffin (80 个任务)、T0-SF (193 个任务)、NIV2 (1554 个任务) 和 CoT (9 个任务),将微调任务总数扩展至 1,836 个。这种多样化的任务覆盖范围使模型能够在广泛的场景中表现出色。此外,Flan-LM 还特别针对链式推理(Chain-of-Thought, CoT)^[42]数据进行了微调,以提升模型的逻辑推理能力。Flan-LM 的微调和推理如图 6 所示。




图 6 Flan-LM 的微调和推理

Fig. 6 Fine tuning and reasoning of Flan-LM

实验结果表明,指令微调显著提升了预训练语言模型的性能和通用性。例如,在 1,836 个任务上微调的 Flan-PaLM 540B 模型在多个基准测试中表现优异,相较于未微调的 PaLM 540B 模型,平均性能提升了 9.4%。这种性能提升不仅体现在零样本(Zero-shot)和少样本(Few-shot)任务中,还在链式推理任务中展现了强大的逻辑推理能力。

Flan-LM 的成功证明了指令微调是一种有效的通用方法,能够显著提升语言模型在多样化任务中的表现。这一研究为未来大规模语言模型的开发和应用提供了重要的技术参考,尤其是在提升模型对复杂指令的理解和执行能力方面具有重要意义。

3.2.3 GPT-3.5

GPT-3.5^[43]是由 OpenAI 提出的一系列基于 GPT-3 的优化和演进模型,其发展历程始于 2020 年 7 月发布的 GPT-3 基础模型。GPT-3 最初包含四个版本: davinci、curie、ada 和 babbage,其中 davinci 是功能最强大的版本,后续的优化均基于此模型展开。

2021 年 7 月,OpenAI 发布了 Codex^[87],这

是通过在代码数据上对 GPT-3 进行微调得到的模型，主要包含 code-davinci-001 和 code-cushman-001 两个版本。Codex 在代码生成和自然语言到代码的翻译任务中表现出色，成为开发者工具的重要基础。同年 3 月，OpenAI 提出了 InstructGPT 模型^[44]，通过对 GPT-3 进行指令微调，生成了 davinci-instruct-beta1 模型。这一模型在指令数据和经过人工评分的生成样例数据上进一步微调，最终形成了 text-davinci-001 模型。InstructGPT 的提出标志着模型在响应人类指令和任务泛化能力上的显著提升。2021 年 6 月，OpenAI 发布了 code-davinci-002，这是功能最强大的 Codex 型号，结合了文本和代码数据的训练，特别擅长自然语言到代码的翻译和代码补全任务。随后，text-davinci-002 模型在 code-davinci-002 的基础上通过有监督指令微调得到，进一步增强了模型的指令执行能力。2021 年 11 月，OpenAI 推出了 text-davinci-003 和 ChatGPT，这两个模型均在 text-davinci-002 的基础上，利用人类反馈强化学习（RLHF）进行优化。ChatGPT 特别注重对话交互能力的提升，通过引入“文本块切分”技术，能够更有效地处理长对话并生成连贯的回复。总体而言，GPT-3.5 系列的演进过程体现了 OpenAI 在模型优化上的持续努力，包括指令微调、代码训练和人类反馈强化学习等技术的应用。这些改进使得 GPT-3.5 在自然语言生成、理解和对话交互等任务中表现出色，成为当前最先进的自然语言处理模型之一。

3.2.4 ChatGPT

ChatGPT^[45]是由 OpenAI 开发的一款基于生成式预训练变换器（GPT）架构的大型语言模型，首次发布于 2022 年 11 月 30 日。该模型基于 GPT-3.5 架构，并通过强化学习从人类反馈（RLHF^{[46]~[51]}）进行训练，使其能够生成符合人类偏好的文本响应。ChatGPT 不仅能够进行自然语言对话，还具备文本生成、编程辅助、问答等多种功能，迅速成为全球范围内广受关注的人工智能工具。ChatGPT 的发展历程体现了人工智能技术的快速迭代。在 ChatGPT 之前，OpenAI 已经推出了多个版本的 GPT 模型，包括 GPT-3 和 InstructGPT。InstructGPT 通过指令微调和人类反馈强化学习技术，显著提升了模型的输出质量。ChatGPT 在此基础上进一步优化，使其能够更好地理解用户意图并生成高质量的文本响应。

上述大语言模型均基于 Transformer 架构，但存在诸多差异与联系：BERT 以双向上下文建模和

MLM、NSP 任务创新提升了语言理解能力；GPT 系列从 GPT-1 到 GPT-3.5、ChatGPT，参数规模不断扩大，从单向生成到引入指令微调、人类反馈强化学习等，不断提升生成能力和任务泛化性；T5 将所有 NLP 任务统一为“文本到文本”形式，简化设计与训练；PaLM、LLaMA、GLM-130B 等模型在参数规模、训练数据、架构改进、优化策略等方面各有特色，有的注重多任务处理，有的平衡模型大小与训练数据量，有的提升推理能力等；而 T0、Flan-LM、GPT-3.5 等基于指令微调的语言模型，则通过指令数据集微调提升在特定任务或指令下的表现，与基础语言模型相辅相成，共同推动自然语言处理技术发展。

4 多模态大模型

4.1 GPT-4

GPT-4^[52]是由 OpenAI 于 2023 年 3 月 14 日正式发布的大型多模态语言模型，标志着 GPT 系列模型的又一次重大升级。作为 OpenAI 的最新成果，GPT-4 在技术上实现了从单一文本输入到图文双模态输入的突破，能够同时处理文本和图像信息，并生成高质量的文本输出。这一创新使其在复杂任务处理和多模态理解方面展现出显著优势。

GPT-4 的开发基于 OpenAI 在深度学习领域的长期积累，其前身 GPT-3.5 于 2022 年 11 月发布，并为 ChatGPT 提供了技术支持。GPT-4 的推出距离 ChatGPT 发布仅四个月，体现了 OpenAI 在模型迭代和技术创新上的高效性。OpenAI 团队在 GPT-4 的开发过程中，特别注重模型的安全性和对齐性，通过六个月的对抗性测试和迭代调整，显著提升了模型在真实性、可操纵性以及拒绝不当请求方面的能力。

在性能方面，GPT-4 在多项专业和学术基准测试中表现优异。例如，在模拟律师考试中，GPT-4 的成绩排名前 10%，远高于 GPT-3.5 的后 10%^{[53]~[54]}；在 GRE 考试中，GPT-4 几乎以满分通过，显示出其在复杂问题解决和逻辑推理方面的强大能力。此外，GPT-4 在多语言处理上也取得了显著进展，测试的 26 种语言中有 24 种的表现优于 GPT-3.5，其中中文的准确性达到 80.1%，较 GPT-3.5 提升了 10%。

GPT-4 的技术创新不仅体现在性能提升上，还在于其安全机制的完善。OpenAI 引入了“红队攻击”机制，通过模拟恶意攻击来减少模型生成有害内容的可能性。同时，GPT-4 的训练基础架构引入了可预测扩展机制，能够在训练过程中以较低的计算开销准确预测模型的最终性能，这为未来更大规模模

型的开发奠定了基础。微软研究团队对 GPT-4 进行了大规模测试,认为其展现出通用人工智能的潜力,尤其是在多模态理解和复杂任务处理方面。微软德国首席技术官安德烈亚斯·布劳恩曾表示,GPT-4 的多模态支持为 AI 应用开辟了全新的可能性,例如视频处理和跨语言理解。总体而言,GPT-4 的发布不仅是 OpenAI 技术发展的重要里程碑,也为人工智能领域的多模态模型和通用人工智能研究提供了新的方向。其强大的性能、完善的安全机制以及可扩展的训练架构,使其在学术、商业和社会应用中具有广泛的前景。

4.2 GPT-4V

GPT-4V 模型^[55]是由 OpenAI 于 2023 年 9 月推出的重要技术升级版本,专注于增强模型的视觉输入能力及其安全部署。该模型的提出标志着 OpenAI 在多模态人工智能领域的进一步探索,特别是在结合视觉与语言处理方面取得了显著进展。GPT-4V 的发布旨在解决视觉输入在人工智能应用中的复杂性和潜在风险,同时提供更高效、更安全的视觉信息处理方案。GPT-4V 的开发背景源于对多模态模型需求的日益增长。随着人工智能技术的普及,单一文本输入已无法满足多样化的应用场景,尤其是在医疗、自动驾驶、工业检测等领域,视觉信息的处理能力显得尤为重要。OpenAI 通过 GPT-4V 的推出,不仅扩展了模型的功能范围,还为其在视觉任务中的安全性设定了新的标准。该模型在训练过程中采用了大量高质量的视觉数据,并结合了先进的自然语言处理技术,使其能够更准确地理解和生成与视觉内容相关的文本输出。

在技术实现上,GPT-4V 采用了多模态融合架构,能够同时处理图像和文本输入,并生成连贯的多模态输出。这一架构的核心在于其视觉编码器和语言模型的深度集成,使得模型能够从图像中提取关键信息,并将其与文本上下文相结合,从而完成复杂的多模态任务^{[56][57]}。此外,OpenAI 在 GPT-4V 的开发过程中特别注重安全性,针对视觉输入可能带来的风险(如隐私泄露、误导性信息生成等)进行了全面的评估,并提出了相应的缓解策略。GPT-4V 的发布不仅是技术上的突破,也为人工智能应用的未来发展提供了新的方向。通过增强视觉能力,该模型在多个领域展现出广泛的应用潜力,例如在医疗影像分析中辅助诊断、在教育领域提供视觉化学习支持、在创意产业中生成视觉内容等。同时,OpenAI 通过 GPT-4V 的推出,进一步巩固了其在多模态人工智能领域的领先地位,并为后续模型的开发奠定了坚实的基础。

4.3 Qwen-VL

Qwen2-VL^[58]和 Qwen2.5-VL^[59]是由阿里巴巴通义千问团队开发的多模态视觉语言模型,分别于 2024 年 8 月和 2025 年 1 月发布。这两个模型在视觉语言理解领域取得了显著进展,广泛应用于图像、视频和文本的多模态任务中。

Qwen2-VL 于 2024 年 8 月 30 日正式发布,是通义千问团队在 Qwen-VL 基础上的第二代视觉语言模型。其主要创新点包括动态分辨率支持和多模态旋转位置嵌入(Multimodal Rotary Position Embedding, M-ROPE)。动态分辨率支持使模型能够处理任意分辨率的图像,而无需将其分割成块,从而更好地保留图像的固有信息。M-ROPE 技术则将旋转位置嵌入分解为时间、空间(高度和宽度)三个部分,使模型能够同时处理 1D 文本、2D 视觉和 3D 视频信息,显著提升了多模态推理能力。Qwen2-VL 提供了 2B 和 7B 两个参数规模的模型,其中 7B 模型在图像、多图像和视频输入任务中表现出色,而 2B 模型则针对移动端优化,适合资源受限的环境。

Qwen2.5-VL 于 2025 年 1 月 28 日发布,是 Qwen2-VL 的升级版本,进一步提升了视觉语言理解能力^[59]。该模型在 Qwen2-VL 的基础上增加了对超长视频(超过 1 小时)的理解能力,并引入了动态帧率训练和绝对时间编码技术,使其能够精确定位视频中的关键事件。此外,Qwen2.5-VL 还增强了图像中的目标定位能力,支持通过边界框或点进行精确对象定位,并生成标准化的 JSON 输出,适用于金融、商业等领域的结构化数据处理。Qwen2.5-VL 提供了 3B、7B 和 72B 三个参数规模的模型,其中 72B 模型在多项权威评测中表现优异,这两个模型的提出者均为阿里巴巴通义千问团队,其目标是通过开源多模态模型推动视觉语言理解技术的发展。Qwen2-VL 和 Qwen2.5-VL 的发布不仅为开发者提供了强大的工具,也为学术界和工业界的研究与应用提供了重要支持。截至 2025 年,Qwen 系列模型的全球下载量已超过 4000 万次,成为业界最受欢迎的多模态模型之一。GPT-4o^{[61][62]}和 Claude3.5^[60]等竞争对手。

5 推理大模型

5.1 OpenAI-o1

OpenAI 于 2024 年 9 月 13 日正式发布了 o1 模型^[84],这一模型标志着人工智能领域在推理能力上的重大突破。o1 模型的核心贡献者包括 OpenAI 的研究团队,其中多位华人科学家如 Jason Wei 和

Lilian Weng 在模型的开发和优化中发挥了重要作用。Jason Wei 是思维链 (Chain of Thought, CoT) 技术的提出者, 这一技术通过模拟人类的思考过程, 使模型能够逐步分解复杂问题并生成系统性解决方案。Lilian Weng 则负责模型的安全性和稳健性, 确保 o1 在提升推理能力的同时, 也具备较高的安全标准。

o1 模型的设计理念是通过强化学习和思维链技术结合, 显著提升 AI 在复杂任务中的表现。与传统的语言模型不同, o1 在生成答案前会花费额外时间进行“思考”, 通过生成思维链来增强推理能力。这一过程使得模型在科学、数学和编程等领域表现出色, 尤其是在处理多步骤任务时, 能够逐步完善其推理策略并纠正错误。例如, 在美国数学邀请赛中, o1 模型解决了 83% 的问题, 远高于 GPT-4o 的 13%。此外, o1 在 Codeforces 编程竞赛中排名第 89 百分位, 展示了其在编程任务中的卓越能力。

o1 模型套件包括 o1、o1-mini 和 o1-preview 三个版本。o1-mini 在保持高性能的同时, 具有更高的成本效益, 特别适用于编程和 STEM 相关任务。尽管 o1-mini 在广泛的世界知识上略逊于 o1-preview, 但其在特定领域的表现依然令人瞩目。o1-preview 则在物理、化学和生物学的基准测试中达到了博士水平的表现, 进一步证明了其在科学领域的强大推理能力^[85]。OpenAI 的 o1 模型不仅在技术上取得了显著进展, 还引发了业界对 AI 未来发展的广泛讨论。其结合生成和推理能力的设计, 展示了 AI 在模拟人类思维和行动方面的潜力。随着技术的不断演进, 推理模型有望在更多复杂领域解锁新的应用场景, 例如新药研发、金融分析和复杂系统优化等。此外, 微软已将 o1 模型集成到其 Copilot 平台中, 通过“深度思考”功能为用户提供高质量的推理支持, 进一步推动了 AI 在日常工作和生活中的应用。总的来说, OpenAI 的 o1 模型不仅代表了人工智能技术的一次重要飞跃, 也为未来的 AI 研究和应用开辟了新的方向。其强大的推理能力和广泛的应用前景, 预示着 AI 将在更多领域发挥重要作用, 推动社会各行业的转型与升级。

5.2 QvQ-72B-Preview

QVQ-72B-Preview^[86]是由阿里云通义千问团队开发的一款开源多模态推理模型, 专注于提升视觉推理能力。该模型于 2024 年 12 月 25 日正式发布, 是基于 Qwen2-VL-72B 架构构建的实验性研究模型, 旨在处理涉及文本和图像的复杂任务, 特别是在数学、物理和科学领域的推理问题上表现出色。

QVQ-72B-Preview 的核心目标是增强视觉推理

能力, 使其能够像人类一样通过逻辑推理解决复杂问题。该模型在多个基准测试中展现了卓越的性能, 包括 MMMU (大学级别的多学科多模态评测集)、MathVista (数学相关的视觉推理测试集)、MathVision (高质量多模态数学推理测试集) 以及 OlympiadBench (奥林匹克竞赛级别的双语多模态科学基准测试集)。在 MMMU 基准测试中, QVQ-72B-Preview 取得了 70.3 的高分, 显著超越了其前身 Qwen2-VL-72B-Instruct, 并在数学和科学推理任务中缩小了与领先模型如 o1 和 GPT-4 的差距。

该模型的技术亮点在于其能够同时处理图像和文本信息, 进行深度推理, 并支持从图片中推断物体的高度、数量等具体信息, 甚至能识别图片的深层含义, 如“梗图”内涵。此外, QVQ-72B-Preview 还支持逐步推理, 能够像科学家一样思考并给出准确答案。尽管 QVQ-72B-Preview 在多个领域表现出色, 但仍存在一些局限性。例如, 模型可能会意外混合语言或在语言之间切换, 影响响应的清晰度; 在多步骤视觉推理过程中, 模型可能会逐渐失去对图像内容的关注, 导致幻觉现象; 此外, 模型的安全性和伦理问题也需要进一步优化。QVQ-72B-Preview 基于 Apache 2.0 开源协议发布, 用户可以免费使用和修改。该模型的应用领域广泛, 包括教育、科研、多模态交互等场景, 为复杂图像理解和推理任务提供了更高效、更智能的解决方案。用户可以通过 Hugging Face 平台或本地部署的方式体验该模型, 具体部署步骤包括安装依赖库、加载模型和处理器, 并通过 API 调用进行推理。总体而言, QVQ-72B-Preview 的发布标志着多模态推理领域的重要进展, 其强大的视觉推理能力和开源特性为 AI 研究和应用开辟了新的可能性。然而, 模型的实验性质也意味着其仍需进一步优化和完善, 以解决当前存在的局限性并确保其在实际应用中的稳健性和安全性。

5.3 DeepSeek-R1

DeepSeek-R1 是由中国 AI 公司深度求索 (DeepSeek) 于 2025 年 1 月 20 日正式发布的一款高性能推理模型。该模型由深度求索团队开发, 其母公司为幻方量化, 后者在 AI 领域拥有丰富的技术积累和计算资源支持。DeepSeek-R1 的最大亮点在于其完全通过强化学习训练, 无需依赖监督微调或人工标注数据, 这一创新显著提升了模型在数学、编程和自然语言推理等任务上的表现, 性能比肩 OpenAI 的 o1 正式版。在后面章节详细会论述 DeepSeek-R1 中关键技术、训练方法等内容。

大语言模型 (LLMs) 技术演进经历了从规模

化文本预训练到多模态融合，再到深度推理能力的逐步发展。早期模型如 BERT、GPT 系列侧重文本理解与生成，架构从 Encoder-Decoder 向 Decoder-only 转变，指令调优提升了模型的实用性。随后，多模态模型如 GPT-4 及 Qwen-VL 实现了跨模态信息融合，拓展了应用场景。推理大模型如 OpenAI-o1 和 DeepSeek-R1 聚焦复杂逻辑推理与问题解决，推动模型向通用人工智能迈进。整体来看，大模型正朝着更强的通用性、更深层次的理解及高级认知能力方向演进，为智能系统的发展奠定基础。

6 DeepSeek-R1

6.1 关键技术

DeepSeek-V3^[1]模型采用了经典的 Transformer 架构，并在多个关键组件上进行了创新性改进。该模型在预训练阶段使用了 14.8 万亿个高质量 Token，并在后期进行了监督微调和强化学习优化。

在模型架构方面，DeepSeek-V3 主要进行了以下创新：首先，在前馈网络部分采用了自主研发的 DeepSeekMoE 架构，该架构结合了无辅助损失负载均衡策略，有效提升了模型的表达能力；其次，在注意力机制方面引入了 MLA (Multi-Level Attention) 架构，这一设计已在 DeepSeek-V2^[96]模型中得到了充分验证。此外，模型还采用了群体相对策略优化 GROP 强化学习算法进行优化，进一步提升了模型的性能表现。

6.1.1 DeepSeekMoE

GShard 架构^[97]首次将混合专家 (Mixture of Experts, MoE) 机制引入 Transformer 网络，相较于传统的大规模模型架构，MoE 架构在数据流过程中创新性地集成了专家网络层。传统 MoE 架构主要由两个核心组件构成：门控网络 (Gating Network) 和稀疏 MoE 层。然而，DeepSeekMoE 在传统架构的基础上进行了显著优化，采用了更细粒度的专家划分策略，并将部分专家隔离为共享专家，从而有效降低了专家间的知识冗余，DeepSeekMoE 框架图如图 7 所示。

在门控网络的路由策略方面，TopK 机制通过计算第 t 个 Token 与所有路由专家之间的亲和力分数，选取其中 K 个最高分数构成集合。DeepSeek V3 进一步改进了这一机制，采用 sigmoid 函数计算亲和力分数，并在所有选定的亲和力分数上应用归一化处理以生成门控值。然而，在 MoE 模型的训练过程中，由于路由策略的影响，不同专家接收到的训练数据分布往往不均衡，导致部分专家可能无法

得到充分训练。为解决这一问题，业界通常采用引入辅助损失的方法，但过大的辅助损失可能会对模型性能产生负面影响。




图 7 DeepSeekMoE 框架图

Fig. 7 DeepSeekMoE Framework

为在负载均衡与模型性能之间实现更优的平衡，DeepSeek 提出了一种无需辅助损失的负载均衡策略。该策略通过为每个专家引入一个偏差项，并将其添加到相应的亲和力分数中以确定 top-K 路由。具体而言，当某专家过载时，其偏差项将减少；而当专家负载不足时，偏差项则增加。门控网络本质上是一个结合了 softmax 函数的分类网络，而辅助 loss 通常作为惩罚项添加，对过大的 logits 输出进行惩罚，以鼓励模型生成更为适度的 logits 值，从而避免模型产生过于极端的输出。

6.1.2 MLA 多头潜在注意力

在大语言模型的推理过程中，KV Cache 机制往往成为限制推理效率的主要瓶颈之一。传统 Transformer 架构中的多头注意力机制 (Multi-Head Attention, MHA) 会产生大量的 KV Cache，这对内存资源和计算效率都带来了显著挑战。为应对这一问题，研究者们提出了多种优化方案，包括 PagedAttention、多查询注意力 (Multi-Query Attention, MQA) 和分组查询注意力 (Grouped-Query Attention, GQA) 等。然而，这些方法在减少 KV Cache 的同时，往往会在模型性能上做出一定程度的妥协。

针对这一挑战，DeepSeek-V2 提出了一种创新的注意力机制：多头潜在注意力 (Multi-head Latent Attention, MLA)，如图 8 所示。与 MQA 采用的 KV 共享机制和 GQA 的分组策略不同，MLA 的核心创新在于实现了注意力键 (Key) 和值 (Value)

的低秩联合压缩。这种机制不仅显著减少了推理过程中的 KV 缓存需求，而且在性能表现上超越了传统的 MHA。具体而言，MLA 通过引入潜在表示空间，在保持模型表达能力的同时，有效地降低了内存占用和计算复杂度，为大规模语言模型的推理效率提升提供了新的解决方案。




图 8 多头潜在注意力

Fig. 8 Multi-Head Latent Attention

6.1.3 群体相对策略优化

群体相对策略优化 (Group Relative Policy Optimization, GRPO) [93] 作为一种先进的在线学习算法，通过利用训练过程中模型自身生成的数据进行迭代优化，在强化学习领域展现出显著优势。GRPO 的核心目标在于最大化生成补全的优势函数，同时确保模型策略始终保持在参考策略的合理范围内。图 9 为 GRPO 的工作原理图。




图 9 群体相对策略优化

Fig. 9 Group Relative Policy Optimization

为深入理解 GRPO 的工作原理，将其算法流程系统地分解为以下四个关键步骤：

1. 补全生成

在每个训练步骤中，算法首先从提示语料库中采样一个批次数据，并为每个提示生成 G 个补全序列，记为 o_i 。

2. 优势值计算

对于每个生成序列 G ，我们利用奖励模型 (reward model) 计算其对应的奖励值 (reward)。为了确保与奖励模型的比较性质保持一致且考虑到奖励模型通常是在同一问题的不同输出之间的对比数据集上进行训练的，优势值的计算需要准确反映这些相对比较关系。具体而言，优势值的归一化计算遵循以下公式：

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}(\mathbf{r})}{\text{std}(\mathbf{r})} \quad (1)$$

其中 $\text{mean}(\cdot)$ 和 $\text{std}(\cdot)$ 分别求向量的均值方差。

GRPO 通过优化 PPO 算法，解决了传统方法中计算优势值时需要同时依赖奖励模型的问题。该方法成功移除了对价值模型的依赖，从而显著降低了推理阶段的内存占用和计算时间开销。优势值的核心意义在于为模型输出提供更为精确的评估，不仅能够衡量生成答案的绝对质量，还能通过与其他候选答案的相对比较，更全面地评估其优劣。这一改进使得模型在生成任务中的表现评估更加准确和高效。

3. KL 散度估计

在实现过程中，直接计算 Kullback-Leibler (KL) 散度可能会面临若干挑战。KL 散度的定义涉及对两个概率分布的对数比值的期望计算，对于复杂的策略分布，直接计算 KL 散度可能需要大量的计算资源，这在实际应用中往往是不现实的。在实际计算中，直接计算 KL 散度还可能会遇到数值不稳定的问题，尤其是当两个策略的概率分布非常接近时，对数比值可能会趋近于零或无穷大，导致计算结果失真，近似器可以通过引入一些数值稳定性的技巧（如截断或平滑）来有效避免这些问题。在线学习的需求也增加了计算 KL 散度的难度，在强化学习中，策略通常也需要在每一步或每几步更新一次，如果每次更新都需要精确计算 KL 散度，可能会导致训练过程变得非常缓慢。

针对上述问题，Schulman 等人 [95] 提出了一种高效的近似器。该近似器能够根据当前策略和参考策略的差异动态调整估计的精度，从而在保证计算效率的同时，尽可能减少估计误差。其定义如下：

$$\mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}] = \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1 \quad (2)$$

其中第一项是参考策略与当前策略的概率比值。这一项反映了两个策略之间的直接差异。第二项是对数概率比值。通过对数变换,可以更好地捕捉概率比值的细微变化,从而提高估计的准确性。第三项-1是一个常数项,用于调整近似器的偏差,确保估计结果的无偏性。

这个近似器的优势在于它只需要计算当前策略和参考策略的概率比值,而不需要直接计算 KL 散度的积分或期望。因此,它可以在保证一定精度的同时,显著降低计算复杂度,适用于大规模和实时性要求高的应用场景。

4. 损失函数计算

GRPO 的损失函数设计体现了优势最大化和策略稳定性之间的平衡,其定义为:

$$\mathcal{L}_{\text{GRPO}}(\theta) = -\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left[\frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{[\pi_{\theta}(o_{i,t}|q, o_{i,<t})]_{\text{ao grad}}} \hat{A}_{i,t} - \beta \mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}] \right] \quad (3)$$

其中第一项表示缩放后的优势,第二项通过 KL 散度惩罚与参考策略的偏离。

完整的 GRPO 算法如下所示:

GRPO 算法: 群体相对策略优化

输入: 初始的策略模型 $\pi_{\theta_{\text{init}}}$, 奖励模型 r_{ϕ} , 提示语料库 D , 超参数 ϵ, β, μ

- 1: 策略模型 $\pi_{\theta} \leftarrow \pi_{\theta_{\text{init}}}$
- 2: **for** $i = 1, \dots, I$ **do**
- 3: 参考模型 $\pi_{\text{ref}} \leftarrow \pi_{\theta}$
- 4: **for** $\text{step} = 1, \dots, M$ **do**
- 5: 从提示语料库 D 中采样一批次 D_b
- 6: 更新旧的策略模型 $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$
- 7: 对于每一个 $q \in D_b$ 生成 G 个输出 $\{o_i\}_1^G \sim \pi_{\theta_{\text{old}}}$
- 8: 输出每一个 o_i 到奖励模型 r_{ϕ} 得到奖励 $\{r_i\}_1^G$
- 9: 通过公式 1 计算每一个 token 的 $\hat{A}_{i,t}$
- 10: **for** GROP $j = 1, \dots, \mu$ **do**
- 11: 通过优化公式 3 更新策略模型 π_{θ} 参数
- 12: 通过使用回放机制进行持续训练来更新奖励模型 r_{ϕ}

输出: π_{θ}

6.2 DeepSeek V3 训练流程

在深入探索 DeepSeek R1 的训练机制之前,需要先对 DeepSeek V3 的训练流程进行全面介绍。DeepSeek V3 的训练过程精细复杂,涵盖了预训练(包括基础预训练和上下文长度扩展)及后训练两大核心阶段,如图 10 所示。




图 10 DeepSeek V3 训练过程

Fig. 10 DeepSeek V3 Training Process

6.2.1 预训练阶段

6.2.1.1 基础预训练

DeepSeek-V3 模型规模庞大,总计包含 671B 参数,其中每个 Token 激活 37B 参数。在路由专家机制中,每个 Token 激活 8 个专家,并严格控制每个 Token 最多发送至 4 个节点,旨在优化通信资源利用效率。此外,模型采用多 Token 预测(Multi-Token Prediction, MTP)深度为 1 的配置,即每个 Token 除了预测下一个 Token 外,还需额外预测一个 Token。

在构建 14.8 万亿规模的预训练数据集时,DeepSeek-V3 采取了多项策略以提升模型性能:首先,通过提高数学和编程样本的比例,优化预训练语料库,从而增强模型的推理能力;其次,整合了更多中国互联网上的中文数据,使模型能够更好地理解和生成中文内容;再者,将多语言覆盖范围扩展至英文和中文之外,提升模型的跨语言处理能力;同时,优化数据处理和过滤算法,既保持语料库的多样性,又最大限度地减少信息冗余,并过滤掉有争议的内容,以减少数据偏差;最后,通过文档打包技术,减少在短文本块训练中的资源浪费,且在训练过程中未使用交叉样本注意力屏蔽。

在训练数据构建方面,DeepSeek-V3 采用前缀-后缀-中间框架来生成 Fill-in-Middle (FIM) 训练数据。FIM 策略使模型能够学习利用上下文语境来预测文段中间缺失的部分,同时不影响下一个 Token 预测能力。模型使用 AdamW 优化器进行预训练,并采取了一些措施避免过拟合。

6.2.1.2 长文扩展训练

在完成基础预训练后，DeepSeek-V3 利用 YARN 技术^[94]将上下文长度分阶段扩展至 128K。这一扩展过程分为两个阶段，每个阶段包含 1000 步训练。在第一阶段，使用 32K 的序列长度和 1920 的批量大小进行训练；在第二阶段，则采用 128K 的序列长度和 480 个序列的批量大小进行训练。

6.2.2 后训练阶段

6.2.2.1 有监督微调

DeepSeek-V3 的有监督微调过程涉及多个方面，梳理并构建了包含 150 万个实例的指令微调数据集，这些实例跨越多个领域，每个领域都采用了定制化的数据合成方法；利用 DeepSeek-R1 模型合成与推理相关的 SFT 数据集，实现基于 R1 来微调 V3，再基于 V3 冷启动 R1 的循环；为特定领域（如代码、数学或一般推理）构建了量身定制的专家模型数据合成器，并使用有监督微调和强化学习进行训练；建立了高质量提示体系，引导模型形成自身的反馈与验证机制，并整合了来自 R1 合成的数据，通过强化学习加强这一能力；对于非推理数据（如创意写作、角色扮演和简单问答），利用 DeepSeek-V2.5 生成数据，并通过人工注释验证数据的准确性。

6.2.2.2 强化学习

DeepSeek-V3 的强化学习部分包括奖励模型与群体相对策略优化。奖励模型分为基于规则的奖励模型和基于模型的奖励模型两种。对于可以使用特定规则验证的问题，采用基于规则的奖励模型；对于不具有收敛性的问题，则依靠模型判断来进行强化学习。在训练过程中，构建了特殊的偏好数据，以降低特定任务中的奖励破解攻击风险。

与以往大模型训练中常用的 PPO 策略相比，DeepSeek-V3 采用了 GRPO 策略。GRPO 策略无需显式的价值网络，仅需在分组内进行多个采样输出的比较，并根据比较结果选择较优的策略。这一策略降低了显存占用，提高了训练速度。

6.3 DeepSeek R1-Zero 训练流程

DeepSeek R1-Zero 以 DeepSeek-V3-Base 为基础模型，通过 GRPO 算法进行强化学习训练，专注于提升推理能力。训练中采用准确度奖励和格式

奖励两种机制，分别确保输出内容的正确性和推理过程的结构化表达（使用“<think>”和“</think>”标签封装）。在此过程中，R1-Zero 形成了复杂的推理能力，包括反思先前回答并探索替代解决方案的“顿悟时刻”（Aha Moment），显著增强了其问题解决能力和自适应性。

6.4 DeepSeek R1 训练流程

DeepSeek-R1 的训练过程采用分阶段迭代优化策略，旨在构建具备全场景推理能力的通用大规模语言模型。整个训练流程分为四个关键阶段：冷启动（Cold Start）、面向推理的强化学习、拒绝采样与有监督微调，以及面向全场景的强化学习与对齐，如图 13 所示。




图 11 DeepSeek R1 训练和蒸馏框架图

Fig. 11 DeepSeek R1 Training and Distillation Framework

6.4.1 冷启动

在初始阶段，DeepSeek-R1 以 R1-Zero 创建样本、人工标注样本以及其他高质量的思维链（Chain-of-Thought, CoT）数据为基础，对 DeepSeek-V3-Base 模型进行有监督微调。这一阶段的核心目标是通过引入人类先验知识，克服强化学习早期训练中的不稳定性。为了构建长 CoT 数据集，研究团队采用了多种合成方法，包括使用 Few-Shot 提示生成详细回答、反思验证机制、以及人工标注员后处理模型输出。最终，收集了数千个冷启动样本用于微调。值得注意的是，输出格式被设计为包含推理过程和摘要的特殊标记结构，即 |special_token|<reasoning_process>|special_token|<summary>，以增强模型的可读性和逻辑性。

6.4.2 面向推理的强化学习

完成冷启动后，DeepSeek-R1 进入强化学习阶段，重点提升模型在推理密集型任务中的表现。此

阶段基于 GRPO 框架展开,并引入了多维度奖励信号,包括准确度、格式一致性以及语言一致性。其中,语言一致性奖励通过计算目标语言单词的比例来评估生成内容的语言纯度,语言纯度是指其在生成目标语言文本时,能够保持内容语言的一致性、不夹杂其他语言词汇或语法结构的能力。该阶段的主要任务领域涵盖编码、数学、科学和逻辑推理等,涉及定义明确且解决方案清晰的问题。

6.4.3 拒绝采样与 SFT

第三阶段结合了拒绝采样技术和有监督微调,进一步扩展模型的能力范围。此阶段的数据集规模为 800k,其中包括 600k 推理数据和 200k 非推理数据。具体而言:

推理数据:通过拒绝采样从上一轮强化学习检查点生成,筛选出符合规则奖励或奖励模型评估的高质量推理轨迹。此外,还过滤掉了混合语言、长段落和复杂代码块的 CoT 数据。

非推理数据:复用 DeepSeek-V3 的部分 SFT 数据集,并通过提示生成多样化任务的回答,涵盖写作、事实问答、自我认知和翻译等领域。

拒绝采样作为一种蒙特卡洛方法,在目标分布难以直接采样的情况下,利用易于采样的建议分布近似复杂分布,从而确保生成数据的质量和多样性。

6.4.4 面向全场景的强化学习与对齐

最后阶段的目标是实现模型在全场景任务中的综合性能优化,同时确保其无害性和与人类偏好的一致性。此阶段整合了来自不同管道的数据,采用多样化的提示分布和奖励信号进行训练。具体措施包括:

推理数据训练:利用基于规则的奖励信号指导数学、代码和逻辑推理领域的训练过程。

一般数据训练:通过奖励模型捕捉复杂场景中的人类偏好,可以参考 DeepSeek-V3 的训练流程。

有用性保障:关注最终摘要的实用性和相关性,减少底层推理过程的干扰。

无害性评估:全面分析模型生成内容,包括推理过程和摘要,识别并缓解潜在风险、偏见或有害信息。

7 结束语

DeepSeek 作为一款先进的 AI 模型,在部署与应用中面临高成本、技术适配难、数据安全与合规性、API 性能及边缘计算实时性等挑战。然而,通过优化部署方案、技术赋能、加强数据安全与隐私保护、API 性能优化及边缘计算优化等措施,这些问题正在逐步解决。未来,DeepSeek 有望在行业应用、技术创新、边缘计算及开源生态建设等方面取

得更大突破,为 AI 行业带来更多机遇和价值。

参考文献:

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [2] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [3] Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training[J]. 2018.
- [4] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI blog, 2019, 1(8): 9.
- [5] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.
- [6] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of machine learning research, 2020, 21(140): 1-67.
- [7] Thoppilan R, De Freitas D, Hall J, et al. Lamda: Language models for dialog applications[J]. arXiv preprint arXiv:2201.08239, 2022.
- [8] Lieber O, Sharir O, Lenz B, et al. Jurassic-1: Technical details and evaluation[J]. White Paper. AI21 Labs, 2021, 1(9): 1-17.
- [9] <https://docs.ai21.com/>
- [10] Smith S, Patwary M, Norick B, et al. Using deepspeed and megatron to train megatron-turing nlG 530b, a large-scale generative language model[J]. arXiv preprint arXiv:2201.11990, 2022.
- [11] Shueybi M, Patwary M, Puri R, et al. Megatron-lm: Training multi-billion parameter language models using model parallelism[J]. arXiv preprint arXiv:1909.08053, 2019.
- [12] Rae J W, Borgeaud S, Cai T, et al. Scaling language models: Methods, analysis & insights from training gopher[J]. arXiv preprint arXiv:2112.11446, 2021.
- [13] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[J].

arXiv preprint arXiv:2203.15556, 2022.

[14] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.

[15] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.

[16] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.

[17] Dubey A, Jauhri A, Pandey A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.

[18] Zhang R, Han J, Liu C, et al. Llama-adapter: Efficient fine-tuning of language models with zero-init attention[J]. arXiv preprint arXiv:2303.16199, 2023.

[19] Gao P, Han J, Zhang R, et al. Llama-adapter v2: Parameter-efficient visual instruction model[J]. arXiv preprint arXiv:2304.15010, 2023.

[20] Chu X, Su J, Zhang B, et al. Visionllama: A unified llama backbone for vision tasks[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 1-18.

[21] Zhang H, Li X, Bing L. Video-llama: An instruction-tuned audio-visual language model for video understanding[J]. arXiv preprint arXiv:2306.02858, 2023.

[22] Roziere B, Gehring J, Gloeckle F, et al. Code llama: Open foundation models for code[J]. arXiv preprint arXiv:2308.12950, 2023.

[23] Xie Q, Chen Q, Chen A, et al. Me-llama: Foundation large language models for medical applications[J]. Research square, 2024: rs. 3. rs-4240043.

[24] Xia M, Gao T, Zeng Z, et al. Sheared llama: Accelerating language model pre-training via structured pruning[J]. arXiv preprint arXiv:2310.06694, 2023.

[25] Kavehzadeh P, Valipour M, Tahaei M, et al. Sorted LLaMA: Unlocking the potential of intermediate layers of large language models for dynamic inference[J]. arXiv preprint arXiv:2309.08968, 2023.

[26] Li S, Tran T, Lin H, et al. Geo-Llama: Leveraging LLMs for Human Mobility Trajectory Generation with Spatiotemporal Constraints[J]. arXiv preprint arXiv:2408.13918, 2024.

[27] Ma F, Jin X, Wang H, et al. Vista-llama: Reliable video narrator via equal distance to visual tokens[J]. arXiv preprint arXiv:2312.08870, 2023.

[28] Sarah A, Sridhar S N, Szankin M, et al. LLaMA-NAS: efficient neural architecture search for large language models[J]. arXiv preprint arXiv:2405.18377, 2024.

[29] Zhu T, Qu X, Dong D, et al. Llama-moe: Building mixture-of-experts from llama with continual pre-training[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 15913-15923.

[30] Ye X, Gan Y, Huang X, et al. Voco-llama: Towards vision compression with large language models[J]. arXiv preprint arXiv:2406.12275, 2024.

[31] Wang J, Paliotta D, May A, et al. The mamba in the llama: Distilling and accelerating hybrid models[J]. Advances in Neural Information Processing Systems, 2025, 37: 62432-62457.

[32] Fang Q, Guo S, Zhou Y, et al. Llama-omni: Seamless speech interaction with large language models[J]. arXiv preprint arXiv:2409.06666, 2024.

[33] Raj D, Keren G, Jia J, et al. Faster Speech-LLaMA Inference with Multi-token Prediction[J]. arXiv preprint arXiv:2409.08148, 2024.

[34] Lu J, Yu L, Li X, et al. Llama-reviewer: Advancing code review automation with large language models through parameter-efficient fine-tuning[C]//2023 IEEE 34th International Symposium on Software Reliability Engineering (ISSRE). IEEE, 2023: 647-658.

[35] Wang J, Shao W, Chen M, et al. Adapting llama decoder to vision transformer[J]. arXiv preprint arXiv:2404.06773, 2024.

[36] Su J, Ahmed M, Lu Y, et al. Roformer: Enhanced transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.

[37] Shazeer N. Glu variants improve transformer[J]. arXiv preprint arXiv:2002.05202, 2020.

[38] Wang H, Ma S, Dong L, et al. Deepnet: Scaling transformers to 1,000 layers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.

[39] Zeng A, Liu X, Du Z, et al. Glm-130b: An open bilingual pre-trained model[J]. arXiv preprint arXiv:2210.02414, 2022.

[40] Sanh V, Webson A, Raffel C, et al. Multitask prompted training enables zero-shot task

- generalization[J]. arXiv preprint arXiv:2110.08207, 2021.
- [41] Chung H W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models[J]. Journal of Machine Learning Research, 2024, 25(70): 1-53.
- [42] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [43] Ye J, Chen X, Xu N, et al. A comprehensive capability analysis of gpt-3 and gpt-3.5 series models[J]. arXiv preprint arXiv:2303.10420, 2023.
- [44] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.
- [45] Bahrini A, Khamoshifar M, Abbasimehr H, et al. ChatGPT: Applications, opportunities, and threats[C]//2023 Systems and Information Engineering Design Symposium (SIEDS). IEEE, 2023: 274-279.
- [46] Christiano P F, Leike J, Brown T, et al. Deep reinforcement learning from human preferences[J]. Advances in neural information processing systems, 2017, 30.
- [47] Ziegler D M, Stiennon N, Wu J, et al. Fine-tuning language models from human preferences[J]. arXiv preprint arXiv:1909.08593, 2019.
- [48] Stiennon N, Ouyang L, Wu J, et al. Learning to summarize with human feedback[J]. Advances in neural information processing systems, 2020, 33: 3008-3021.
- [49] Nakano R, Hilton J, Balaji S, et al. Webgpt: Browser-assisted question-answering with human feedback[J]. arXiv preprint arXiv:2112.09332, 2021.
- [50] Gao L, Schulman J, Hilton J. Scaling laws for reward model overoptimization[C]//International Conference on Machine Learning. PMLR, 2023: 10835-10866.
- [51] Cohen D, Ryu M, Chow Y, et al. Dynamic planning in open-ended dialogue using reinforcement learning[J]. arXiv preprint arXiv:2208.02294, 2022.
- [52] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [53] Koubaa A. GPT-4 vs. GPT-3.5: A concise showdown[J]. Preprints. org, 2023, 2023030422.
- [54] Koubaa A. Gpt-4 vs. gpt-3[J]. Authorea Preprints, 2023.
- [55] Yang Z, Li L, Lin K, et al. The dawn of lmms: Preliminary explorations with gpt-4v (ision)[J]. arXiv preprint arXiv:2309.17421, 2023, 9(1): 1.
- [56] Wu Y, Wang S, Yang H, et al. An early evaluation of gpt-4v (ision)[J]. arXiv preprint arXiv:2310.16534, 2023.
- [57] Lin K, Ahmed F, Li L, et al. Mm-vid: Advancing video understanding with gpt-4v (ision)[J]. arXiv preprint arXiv:2310.19773, 2023.
- [58] Wang P, Bai S, Tan S, et al. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution[J]. arXiv preprint arXiv:2409.12191, 2024.
- [59] Bai S, Chen K, Liu X, et al. Qwen2. 5-VL Technical Report[J]. arXiv preprint arXiv:2502.13923, 2025.
- [60] Anthropic A. The claude 3 model family: Opus, sonnet, haiku; 2024[J]. URL https://www-cdn.anthropic.com/de8ba9b01c9ab7cbabf5c33b80b7bbc618857627/Model_Card_Claude_3.pdf, 2024.
- [61] Hurst A, Lerer A, Goucher A P, et al. Gpt-4o system card[J]. arXiv preprint arXiv:2410.21276, 2024.
- [62] Xie Z, Wu C. Mini-omni2: Towards open-source gpt-4o with vision, speech and duplex capabilities[J]. arXiv preprint arXiv:2410.11190, 2024.
- [63] Yue X, Ni Y, Zhang K, et al. Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 9556-9567.
- [64] Yue X, Zheng T, Ni Y, et al. Mmmu-pro: A more robust multi-discipline multimodal understanding benchmark[J]. arXiv preprint arXiv:2409.02813, 2024.
- [65] Mathew M, Karatzas D, Jawahar C V. Docvqa: A dataset for vqa on document images[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 2200-2209.
- [66] Mathew M, Bagal V, Tito R, et al. Infographicvqa[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 1697-1706.
- [67] Yang Z, Tang J, Li Z, et al. CC-OCR: A

- Comprehensive and Challenging OCR Benchmark for Evaluating Large Multimodal Models in Literacy[J]. arXiv preprint arXiv:2412.02210, 2024.
- [68] Liu Y, Li Z, Huang M, et al. OCRBench: on the hidden mystery of OCR in large multimodal models[J]. Science China Information Sciences, 2024, 67(12): 220102.
- [69] Chen J, Liang T, Siu S, et al. MEGA-Bench: Scaling multimodal evaluation to over 500 real-world tasks[J]. arXiv preprint arXiv:2410.10563, 2024.
- [70] Chen L, Li J, Dong X, et al. Are we on the right way for evaluating large vision-language models?[J]. arXiv preprint arXiv:2403.20330, 2024.
- [71] Fang X, Mao K, Duan H, et al. Mmbench-video: A long-form multi-shot benchmark for holistic video understanding[J]. Advances in Neural Information Processing Systems, 2025, 37: 89098-89124.
- [72] Lu P, Bansal H, Xia T, et al. Mathvista: Evaluating mathematical reasoning of foundation models in visual contexts[J]. arXiv preprint arXiv:2310.02255, 2023.
- [73] Wang K, Pan J, Shi W, et al. Measuring multimodal mathematical reasoning with math-vision dataset[J]. Advances in Neural Information Processing Systems, 2025, 37: 95095-95169.
- [74] Fu C, Dai Y, Luo Y, et al. Video-mme: The first-ever comprehensive evaluation benchmark of multi-modal llms in video analysis[J]. arXiv preprint arXiv:2405.21075, 2024.
- [75] Han M, Yang L, Chang X, et al. Shot2story20k: A new benchmark for comprehensive understanding of multi-shot videos[J]. arXiv preprint arXiv:2312.10300, 2023, 2.
- [76] Wang W, He Z, Hong W, et al. Lvbench: An extreme long video understanding benchmark[J]. arXiv preprint arXiv:2406.08035, 2024.
- [77] Gao J, Sun C, Yang Z, et al. Tall: Temporal activity localization via language query[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5267-5275.
- [78] Zhang J, Wu J, Teng Y, et al. Android in the zoo: Chain-of-action-thought for gui agents[J]. arXiv preprint arXiv:2403.02713, 2024.
- [79] Rawles C, Li A, Rodriguez D, et al. Androidinthewild: A large-scale dataset for android device control[J]. Advances in Neural Information Processing Systems, 2023, 36: 59708-59728.
- [80] Cheng K, Sun Q, Chu Y, et al. SeeClick: Harnessing gui grounding for advanced visual gui agents[J]. arXiv preprint arXiv:2401.10935, 2024.
- [81] Kaixin Li, Ziyang Meng, et al. ScreenSpot-Pro: GUI Grounding for Professional High-Resolution Computer Use.
- [82] Rawles C, Clinckemaulle S, Chang Y, et al. Androidworld: A dynamic benchmarking environment for autonomous agents[J]. arXiv preprint arXiv:2405.14573, 2024.
- [83] Xie T, Zhang D, Chen J, et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments[J]. Advances in Neural Information Processing Systems, 2025, 37: 52040-52094.
- [84] Jaech A, Kalai A, Lerer A, et al. Openai o1 system card[J]. arXiv preprint arXiv:2412.16720, 2024.
- [85] Temsah M H, Jamal A, Alhasan K, et al. OpenAI o1-preview vs. ChatGPT in healthcare: a new frontier in medical AI reasoning[J]. Cureus, 2024, 16(10).
- [86] <https://huggingface.co/Qwen/QVQ-72B-Preview>
- [87] Chen M, Tworek J, Jun H, et al. Evaluating large language models trained on code[J]. arXiv preprint arXiv:2107.03374, 2021.
- [88] <https://mp.weixin.qq.com/s/XnS1VRKeEc-LNd4CJizPng>
- [89] <https://mp.weixin.qq.com/s/GUxebYPjEaC7hyI5JpJrNQ>
- [90] <https://mp.weixin.qq.com/s/v4TVgqffLEygE24RClrz7A>
- [91] Liu A, Feng B, Xue B, et al. Deepseek-v3 technical report[J]. arXiv preprint arXiv:2412.19437, 2024.
- [92] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [93] Shao Z, Wang P, Zhu Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models[J]. arXiv preprint arXiv:2402.03300, 2024.
- [94] Peng B, Quesnelle J, Fan H, et al. Yarn: Efficient context window extension of large language models[J]. arXiv preprint arXiv:2309.00071, 2023.
- [95] Schulman et al.[EB/OL].(2020-03-07)
- [2025-02-19] <http://joschu.net/blog/kl-approx.html>

[96] Liu A, Feng B, Wang B, et al. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model[J]. arXiv preprint arXiv:2405.04434, 2024.

[97] Lepikhin D, Lee H J, Xu Y, et al. Gshard: Scaling giant models with conditional computation and automatic sharding[J]. arXiv preprint arXiv:2006.16668, 2020.

作者简介:

赵凯博, 男, (1996-), 工学学士, 博士生。研究

方向为计算机视觉、计算机图形学。在本文中负责

文章整体框架设计与主要内容撰写;

李宇楠, 男, (1992-), 工学博士, 西安电子科技

大学华山菁英副教授。研究方向为计算机视觉、手

势手语识别。在本文中负责内容审校与结构优化建

议;

彭成, 男, (1987-), 学士, 高级工程师。河北钢

铁集团滦县司家营铁矿有限公司, 矿物加工工程。

在本文中参与资料收集与部分章节撰写;

李珺玮, 男, (1987-), 学士, 高级工程师。河北

钢铁集团滦县司家营铁矿有限公司, 矿物加工工程。

在本文中参与资料收集与部分章节撰写;

鲍亮 (通讯作者), 男, (1981-), 工学博士, 西

安电子科技大学华山学者特聘教授。研究方向为云

计算技术、大数据分析和机器学习技术。E-mail:

baoliang@mail.xidian.edu.cn。在本文中负责内容审

校与结构优化建议;