

大模型文档分块方法对病历质量控制效果的影响研究

黄建桓 李小华 张海波 温必荣 赵霞

【摘要】 目的：探究检索增强生成（RAG）技术中不同分块方法对电子病历（EMR）质控效果的影响规律，探索电子病历质控场景的最优分块策略，为大语言模型（LLM）在病历质控领域的落地提供技术参考与实践依据。方法：选取固定大小、结构、递归、语义 4 种 RAG 分块策略，依托国家电子病历书写规范、临床诊疗指南等质控相关文件构建四级知识库，基于 DeepSeek-R1-32B 等模型搭建实验平台，对某三甲医院 1 500 份住院病历开展质控实验，以医学专家质控结果作为金标准，从精确率、召回率、F1 值及平均质控耗时等指标评估性能。结果：4 种分块方法均能精准识别乙级病历；语义分块策略在缺陷病历扣分项识别中表现最优，F1 值达到 89.1%，虽然单份病历质控耗时 62 s，长于其他方法，但能显著降低模型幻觉风险，且综合 F1 值与质控耗时的加权得分最高，达 0.802。结论：分块语义完整性是影响质控效果的核心因素，语义分块策略在病历质控的精准性与效率之间实现了较优平衡，可嵌入病历管理全流程，为提升电子病历质控效率与质量提供有效技术路径。

【关键词】 大语言模型；RAG；电子病历质控；文档分块方法

Doi: 10.3969/j.issn.1673-7571.2026.03.003

【中图分类号】 R197.323；TP391.1

Impact of document chunking methods of large language models on electronic medical record quality control

HUANG Jianhuan, LI Xiaohua, ZHANG Haibo, WEN Birong, ZHAO Xia. Information Center of the Southern Theater Command General Hospital of the People's Liberation Army of China, Guangzhou 510010, Guangdong Province, China

Corresponding author: ZHAO Xia, Email: myjob2010@126.com

【Abstract】 Objective To explore the influence rules of different chunking methods in Retrieval-Augmented Generation (RAG) on the quality control effect of electronic medical records (EMR), probe into the optimal chunking strategy for EMR quality control scenarios, and provide technical references and practical foundations for the application of Large Language Models (LLMs) in the field of EMR quality control. **Methods** Four RAG chunking strategies (fixed-size, structural, recursive and semantic chunking) were selected in this study. A four-level knowledge base was constructed based on quality control-related documents including national EMR writing specifications and clinical diagnosis and treatment guidelines. An experimental platform was built on the basis of the DeepSeek-R1-32B model and other relevant models, and quality control experiments were conducted on 1 500 inpatient medical records from a tertiary hospital. Taking the quality control results of medical experts as the gold standard, the performance of the four strategies was evaluated from the indicators of precision, recall, F1-score and average quality control time consumption per medical record. **Results** All the four chunking methods could accurately identify Grade B medical records. Semantic chunking achieved the optimal performance in the identification of deduction items of defective medical records with an F1-score of 89.1%. Although this method took 62 seconds for single medical record quality

基金项目：南部战区总医院院内科技计划项目（2024NZB003）

作者单位：510010 广州，中国人民解放军南部战区总医院信息中心

通信作者：赵霞，Email: myjob2010@126.com

control, which was longer than the other three methods, it significantly reduced the risk of model hallucination, and obtained the highest weighted score of 0.802 by comprehensively considering the F1-score and quality control time consumption. **Conclusion** The semantic integrity of chunking is the core factor affecting the EMR quality control effect. The semantic chunking strategy achieves a favorable balance between accuracy and efficiency in EMR quality control, and can be reliably embedded into the whole process of medical record management. It thus provides an effective technical path for improving the efficiency and quality of EMR quality control.

[Keywords] Large language model; RAG; EMR quality control; Document chunking methods

电子病历 (Electronic Medical Records, EMR) 是患者医疗过程中最完整的信息载体, 是医院信息化、数智化的核心; 高质量的病历是患者诊疗过程规范化的体现, 是患者安全的保障, 是出现医疗纠纷时的重要裁定凭证, 也是医院教学、科研的素材来源^[1], 未来更有成为医疗保险支付依据的趋势。国家卫生健康委和国家中医药管理局联合发布的《全面提升医疗质量行动计划 (2023—2025 年)》中要求^[2], 加强病历质量管理, 并以提升病历内涵质量和完整性、及时性为核心任务^[3], 凸显了病历质控在当前医疗体系中的重要性。

1 研究现状

1.1 电子病历质控技术发展趋势

电子病历质量控制 (以下简称质控) 技术的演进围绕“效率提升”与“质量深化”展开。传统人工抽查电子病历的质控手段效率偏低, 难以实现病历的全面质控, 容易出现遗漏。而基于自然语言处理 (Neuro-Linguistic Programming, NLP) 的半自动化质控系统, 多通过关键词匹配实现部分逻辑校验, 仅能实现形式层面的质控任务^[4], 因电子病历数据具有非结构化、专

业性强及语义复杂等特征, 导致该类系统在语义理解、上下文一致性判断中表现乏力^[5], 尤其在主诉内容与主要诊断一致性校验、治疗方案的合理性评估等病历内涵质控环节中表现欠佳, 难以满足持续增长的质控需求。近年来, 大语言模型 (Large Language Models, LLMs) 凭借强大的自然语言理解与生成能力, 为电子病历质控提供了新的技术途径。

1.2 RAG 技术在医疗领域应用

增强生成 (Retrieval-Augmented Generation, RAG) 技术和大语言模型相结合, 能够有效提高大模型在医学专业领域的知识准确性与回答可靠性^[6], 已成为医院 LLM 应用主流方法, 在病历结构化提取、临床决策支持等场景初步落地。RAG 技术核心优势在于知识库可灵活更新, 仅需调整局部文档块, 无需重训模型即可完成质控规则更新, 能够较好应对病历质控规则的不断迭代。当前研究多聚焦整体框架搭建, 对关键预处理步骤——文档分块技术的针对性研究不足, 缺乏结合电子病历质控知识文本特性的分块策略对比分析, 尚未明确分块方法与质控性能的量化关联^[7]。

1.3 文档分块技术研究

文档分块 (Chunking) 技术是 RAG 技术体系中的关键预处理步骤, 当前主流的 RAG 分块方法包括固定大小分块、结构分块、递归分块和语义分块等, 不同分块方法的技术原理与实际应用效果存在显著差异。选用适配的分块方法可提升信息检索精准度, 有效降低模型幻觉的风险^[8-9]; 而不合理的分块策略可能会造成信息碎片化, 影响输出结果的准确性。现有相关研究多聚焦于通用文本场景的分块策略探索, 针对电子病历的专业文本特性开展的分块技术专项适配分析仍较为欠缺^[10]。

2 研究内容与方法

本研究旨在系统评估不同 RAG 分块方法在电子病历质控任务中的性能差异, 确定相对最优分块策略。研究通过“数据集构建—对照标准确立—实验平台搭建—知识库构建—质控流程执行—多维度指标评估”的完整技术路径, 构建“对照组—实验组”双向验证体系。对照组以医学专家质控结果为金标准, 通过多维度指标完成性能评估; 实验组基于 4 种分块方法搭建 RAG 质控平台, 在本地构建标

准化病历质控知识库，开展批量病历质控实验并记录分析结果。

2.1 数据集构建

本研究数据来源于某三甲医院2025年第一季度住院病历，采用系统抽样方法，抽取入院记录、出院记录、病案首页、手术记录与病程记录每类各300份，并通过医院伦理委员会审查。对抽取的病历文件实施多阶段预处理：首先进行数据清洗，继而开展数据标准化（统一文件类型名称、日期、医学术语及计量单位），最终执行严格的数据脱敏，将涉及患者姓名、手机号、身份证号等敏感信息进行匿名化处理^[11]。处理完的病历将作为本实验的数据集。

2.2 对照标准确立

由医学专家组成专家组，建立标准化质控工作流程。评审依据严格遵循《病历书写基本规范》等国家规范，其中入院记录设23项评分指标，出院记录、病程记录各设22项评分指标，病案首页、手术记录各设16项评分指标。对数据集中1500份病历开展形式质控与内涵质控双维度审核，累计核查29700项扣分指标的全量核查，完整记录具体违规扣分项信息，并完成病历甲、乙、丙级的等级评定。质控过程采用独立评分与交叉核对相结合的方式，对存在分歧的质控

结果通过集体讨论达成共识，最终形成的质控结果既作为本研究的实验对照组结果，也作为评判模型质控效果的唯一金标准。

2.3 实验平台构建

本实验平台部署于Ubuntu 22.04 LTS Server 64位操作系统，搭载2张NVIDIA RTX A6000显卡，单卡显存容量达48GB，配合CUDA 12.9加速套件；处理器选用Intel Xeon Gold 6430；配置2块960G SATA SSD固态硬盘；核心开发环境选用Python 3.12，向量存储采用集成pgvector插件的PostgreSQL 15.4数据库。为防范患者信息外泄，实验相关模型均部署于本地环境。本研究选用主流模型搭建实验框架，各模型功能定位清晰、分工明确，具体见表1。

2.4 RAG知识库构建

2.4.1 知识库内容体系 以国家电子病历书写规范、医学术语和编码标准、临床诊疗指南、医院电子病历评分标准、优秀电子病历样例为核心，构建“国家规范—行业标准—

院内规则—实例参考”4级结构化知识库，确保质控依据的权威性与全面性，具体构成见表2。

2.4.2 4种分块策略的标准化实现

(1) 固定大小分块。核心原理：基于固定Token长度切分；关键参数。分块大小（Chunk Size）= 1024 Tokens，重叠率（Overlap）= 15%（153 Tokens）实现流程：首先取文档起始部分的1024个Tokens作为首个分块；后续分块在确保分块中包含1024个Tokens的同时，与前一个分块保持15%内容重叠，重复此操作直至完成目标文档分块。

(2) 结构分块方法。核心原理：利用目标文档内部固有的结构元素，比如文档中的标题、章节或段落，来定义分块边界。实现流程：遍历文档提取结构标签，以相邻两个结构标签之间的内容作为一个分块，通过文档的逻辑章节保持一致性，来维持结构完整性。

(3) 递归分块方法。核心原理：通过“拆分—检测—终止”

表1 实验选取模型与对应功能

模型类型	模型名称	核心功能
推理模型	DeepSeek-R1-32B	接收整合后的质控提示词，开展多维度质控分析并输出结果
嵌入模型	Qwen3-Embedding-4B	将分块文本转化为向量嵌入，支撑RAG检索环节的相似性匹配功能
重排模型	Qwen3-Rerank-4B	对检索召回的分块进行相关性评分，筛选高价值上下文

表2 RAG四级结构化知识库

知识层级	核心内容	数据来源	更新频率
国家规范层	《病历书写基本规范》《临床诊疗指南》	国家卫生健康委、中华医学会	每年更新
行业标准层	ICD-10疾病编码、CPT手术编码、医学术语标准	世界卫生组织、国家卫生健康委编码中心	每年更新
院内规则层	病案质量评分细则（2025版）（99项）	某三甲医院质控科	每年更新
实例参考层	优秀电子病历样例、典型违规案例库	医院质控专家筛选审核	季度更新

循环，动态平衡分块大小与语义连贯性。关键参数：最大 Token 阈值=1 024、最小 Token 阈值=50，分隔符优先级（段落、章节>句末点号>句内点号）。实现流程：①检测目标文档 Token 数量是否在设置阈值内，在阈值内可直接将其作为最终文本块；②如果超出 1 024 Tokens，按优先级寻找分隔符：优先选择最接近 512 Tokens（最大阈值一半）位置的分隔符；③对拆分后的子块重复步骤①—②，直至所有分块满足大小阈值。

(4) 语义分块方法。核心原理：基于文本语义相似度动态合并，确保分块内语义一致性。关键参数：余弦距离判定阈值=0.1，向量计算批次大小=64。实现流程：①初始分段。以句末点号作为基本单位，将文档拆分为独立分段。②向量编码。使用 Qwen3-Embedding-4B 向量化模型对每个初始分段进行 Embedding 计算，得到每个初始分段的 768 维嵌入向量^[12]。③相似度计算。采用余弦相似度式(1)计算相邻片段向量相似度，并依式(2)将其转换为余弦距离。④合并与切分。若相邻片段余弦距离<0.1，则将两个初始分段合并为新的分段，并计算出新分段的嵌入向量；若距离≥0.1，在该位置切分，形成独立语义分块^[13]。⑤循环执行。以每次合并后形成分块的后续未处理初始分段为起点，重复步骤③—④，直至完成目标文档所有内容分块。

$$\text{Cosine Similarity}(A, B) = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \cdot \sqrt{\sum_{i=1}^n b_i^2}} \quad (1)$$

$$\text{Cosine Distance}(A, B) = 1 - \text{Cosine Similarity}(A, B) \quad (2)$$

2.4.3 知识存储 将四种分块策略处理后的文本块，通过 Qwen3-Embedding-4B 模型转换为向量，分别存储于 PostgreSQL 数据库的 4 个独立向量表中，该知识库的核心构建流程对应图 1 中的橙色路径，为后续分块检索提供数据支撑。

2.5 质控流程

本研究基于搭建的 RAG 质控实验平台及四级结构化知识库，设计标准化的全流程自动化电子病历质控方案。该方案的执行流程对应图 1 中的绿色路径，整体围绕数据抽取、分块检索、分块重排、推理分析、结果记录 5 个核心环节开展，各环节的具体功能与实现方式见图 1。

2.5.1 数据抽取 从医院 HIS 数据库抽取与本次质控病历关联的住院信息，涵盖医嘱、诊断、手术操作、用药记录等。

2.5.2 分块检索 分别从 4 种不同分块方法构建的病历质控知识向量表中，设置向量相似度查询阈值为 0.6，召回 Top-K=20 个最相关分块。

2.5.3 分块重排 通过 Qwen3-Rerank-4B 模型对召回分块进行相关性评分（0~1 分），筛选并保留评分≥0.7

（高相关性）的分块，选取 Top-N=5 个得分最高的分块，作为有效上下文，纳入后续推理。

2.5.4 推理分析 将步骤 1 中获取的住院基本信息、步骤 3 重排后筛选的分块、完整病历文本及标准化病历质控指令，按照预设的结构化提示词（Prompt）模板^[14]（见图 2）进行整合，最后将整合后的提示词提交至 DeepSeek-R1-32B 推理模型进行多维度质控分析。

2.5.5 结果记录 根据模型返回的质控报告结果，记录每份病历在 4 种分块方法下的质控评分、扣分项及耗时等信息。

2.6 评价指标体系

2.6.1 等级判定一致性 通过对比甲、乙、丙级病历的判定结果与专家判断是否一致，评估方法在识别病历存在严重缺陷方面的能力。

2.6.2 细粒度质控效果统计分析 通过统计不同分块方法在病历质控扣分明细与专家金标准的一致性，并依据以下 4 类结果进行量化分析。真正例（TP）：模型正确识别的缺陷扣分项（与专家判断一致）数量；真反例（TN）：模

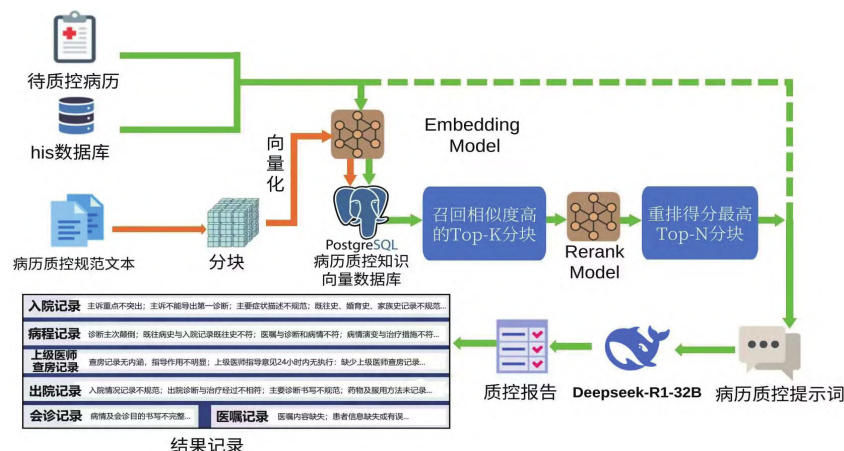


图 1 大语言模型 RAG 质控体系流程

型正确判断为无需扣分的项目数量；
假正例（FP）：模型误判为有缺陷
（专家未扣分且模型扣分）的项目数
量；假反例（FN）：模型漏判的缺陷
项（专家扣分而模型未扣分）数量。
在此基础上，使用式（3）～式（5）
计算各方法质控的精确率（Precision）、
召回率（Recall）和 F1 值（F1-Score）^[15]。

$$\text{Precision} = \frac{TP}{TP+FP} \quad (3)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (4)$$

$$\text{F1-score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5)$$

2.6.3 综合得分 为平衡质控效果
与效率的综合评估，结合质控效果
的核心指标 F1 值和质控效率指标
平均耗时，构建综合得分公式见式
（6）：

$$\text{综合得分} = \alpha \times \text{F1-score} + \beta \times \left(1 - \frac{t-t_{\min}}{t_{\max}-t_{\min}}\right) \quad (6)$$

其中， α 和 β 为权重系数，结
合病历质控场景情况设定 $\alpha=0.9$ 和
 $\beta=0.1$ 强化 F1 值（核心质控效果）
的主导作用； t 为当前分块方法的
质控平均耗时； $t_{\min}$ 和 $t_{\max}$ 分别
为 4 种分块方法中的质控平均耗时的
最小值与最大值。得分越高表示方
法的综合性能越优，既保证病历质
控的精准性与完整性，又兼顾实际
应用中的效率需求。

3 结果

3.1 病历等级判定一致性结果

对照组质控结果显示，1 500 份
病历中除了 8 份被划分为乙级病历，

其余 1 492 份均为甲级病历，未检
出丙级病历；实验组中，大模型结
合 4 种分块方法均能精准识别出 8
份乙级缺陷病历，与对照组的病历
等级判定结果完全一致，均满足等
级判定一致性要求。

3.2 缺陷扣分项识别的细粒度性能及综合得分

以专家金标准 117 项扣分项为
参照，4 种分块方法对 1 500 份病
历共 29 700 项扣分指标的识别结
果存在显著差异，见表 3。语义分
块的识别效果最优，其正确识别的
缺陷扣分项（TP = 106）最多、漏
判（FN = 11）和误判（FP = 15）
数量最少；递归分块与结构分块次
之；固定大小分块的识别效果最
差。对上述识别结果开展细粒度质
控效果统计分析与综合性能指标计
算，具体结果见表 4，使用固定大
小方法时，大模型平均单份病历质
控耗时最短（42 s），但质控结果
精确率、召回率、F1 值较低；结
构分块方法与递归分块方法的精确
率均高于固定大小分块，但质控消

耗的时间也相应增多；语义分块的
质控耗时最长（62 s），然而其精
确率、召回率和 F1 值最高，分别
为 87.6%、90.6% 和 89.1%。经 F1
值与质控耗时的加权计算，语义分
块综合得分最高，为 0.802。

3.3 分块方法质控指标与分块特性的关联结果

4 种分块方法在质控核心指标
及分块特性上呈现明显区别，见
表 5。质控耗时上，固定大小分块
最短，语义分块最长；质控准确性
上，语义分块表现最佳，固定大小
分块最差，递归分块与结构分块处
于中等水平。

分块特性方面，固定大小分块
的分块大小与数量均为固定，语义
完整性较低；结构分块的分块大小
差异较大，数量较少，在结构标准
的文档中语义完整性较高；递归分
块的分块大小在阈值区间内波动，
数量较多，在以文字为主的长文档
中语义完整性较好；语义分块的分
块大小差异最大，且分块语义完整
性为 4 种方法中最高。

病历质控提示词（Prompt）

【角色定义】
你是一名专业的病历质控专家...

【待质控病历】
[病历文本内容]

【系统指令】
请基于以下信息，对[文档类型/文档名称/所有]待质控病历进行质量评估，并进行评分：
【检索知识】（通过 RAG 在病历质控知识库中检索重排得到的分块）
1. [检索分块 1: XXX 书写规范]
2. [检索分块 2: XXX 评分标准]
...

【补充患者信息】
医嘱：[医嘱内容]
诊断：[初步/最终诊断]
...

【补充要求】（补充模型质控常遗漏判断的点）
对病历质控时，重点检查：
1. 主述与现病史是否一致...
2. 补充患者信息与病历内容是否有出入...
...

【输出格式】
以固定[xxx]格式输出质控结果...

图 2 病历质量提示词模板

4 讨论

4.1 质控效果的核心影响机制

质控实验中发现, DeepSeek-R1-32B 模型虽具备基础的自然语言推理能力, 但缺乏病历质控专业知识储备及对院内质控规范的适配能力, 因此对 RAG 技术召回的外部知识库分块具有强依赖性。召回分块若存在关键信息缺失或语义割裂, 将导致模型产生幻觉, 从而引发误判、漏判, 生成缺乏依据且不符合质控要求的结果。总而言之, 召回的分块语义越完整, 大模型质控的效果相应就更好。

固定大小分块方法即便设置了 15% 的重叠率, 仍存在大量分块因缺乏语义连贯性, 无法完整体现质控要求, 出现信息割裂和上下文丢

失的问题^[16], 质控准确性相对偏低。

结构分块方法依据文档的固有结构进行分块, 而递归分块方法则通过逐层递归的方式拆分文档, 但仍存在局限性: 结构分块的效果依赖病历格式的规范性, 面对结构复杂或不规范的病历质控规范文本时, 易出现分块边界不合理的问题; 递归分块在无显式分隔符的长段落中, 会在句内标点处切分, 造成部分语义断裂, 因此二者的质控精准度仍未达到最优。

相比其他分块方法, 语义分块方法确保了把一个完整的医学知识、内涵质控规则或病历评分步骤完整地保留在同一个分块中, 避免了核心概念被生硬拆分, 每个块都聚焦于一个相对独立的主题, 大幅

提升了 RAG 检索的精准性, 有效降低模型幻觉, 使模型能基于完整的上下文开展推理分析, 因此在精确率、召回率及 F1 值上均表现最优。

4.2 质控耗时的核心影响因素

在大语言模型结合 RAG 技术对病历质控的实验中, 模型质控耗时主要在 RAG 的分块向量检索重排阶段与大模型推理生成阶段, 占比约为 30% 和 70%, 在相同算力条件下, 检索重排阶段, 固定大小分块因分块规格统一、向量维度一致, 检索效率最高; 语义分块因分块大小无固定范围、规格差异大, 召回与重排耗时最长。推理生成阶段, 输入上下文的总 Token 数直接决定耗时, 固定大小分块召回分块的总 Token 数最少, 推理耗时最短;

表 3 4 种分块方法病历质控识别结果与金标准对照表

单位: 项

固定大小分块方法	金标准		合计	结构分块方法	金标准		合计
	阳性	阴性			阳性	阴性	
阳性	46	32	78	阳性	79	23	102
阴性	71	29 551	29 622	阴性	38	29 560	29 598
合计	117	29 583	29 700	合计	117	29 583	29 700

递归分块方法	金标准		合计	语义分块方法	金标准		合计
	阳性	阴性			阳性	阴性	
阳性	83	26	109	阳性	106	15	121
阴性	34	29 557	29 591	阴性	11	29 568	29 579
合计	117	29 583	29 700	合计	117	29 583	29 700

表 4 4 种分块方法大模型质控效果对比

分块方法	精确率 / %	召回率 / %	F1 值 / %	平均每份病历质控耗时 / s	综合得分 ($\alpha=0.9, \beta=0.1$)
固定大小分块	59.0	39.3	47.2	42	0.525
结构分块	77.5	67.5	72.1	51	0.710
递归分块	76.1	71.0	73.5	46	0.742
语义分块	87.6	90.6	89.1	62	0.802

表 5 四种分块方法质控核心指标与分块特性对比

类别	指标	固定大小分块	结构分块	递归分块	语义分块
核心质控指标	质控耗时	最短	中等	中等	最长
	质控准确性	较差	中等	中等	较好
分块特性	分块大小分布	大小固定	差异较大	差异较小	差异较大
	分块数量	数量固定	数量较少	数量较多	较少
	分块语义完整性	较低	较高（结构标准的文档）	较高（以文字为主的文档）	高

语义分块的有效上下文 Token 数最多，推理耗时相对较长。

4.3 质控精准性与效率的平衡关系分析

本研究发现，质控精准性与耗时呈一定的正相关关系，固定大小分块通过牺牲部分语义完整性实现了最高的质控效率，但其质控效果难以满足临床实际需求；语义分块虽耗时最长，但通过加权计算验证，其在质控精准性与效率之间实现了良好平衡，综合得分显著高于其他方法，且质控耗时处于可接受范围，能够适配医院批量病历质控的实际场景。

从耗时构成来看，检索重排和模型推理的耗时均与分块的大小、数量直接相关。这一规律为后续分块方法的优化提供了方向，可通过精细化调整语义分块的阈值参数，在保证语义完整性的前提下，合理控制分块大小与数量，进一步降低质控耗时。

4.4 研究局限性与后续优化方向

本研究已较好实现质控精准性与效率的平衡，但仍存在一定的局限性。一是使用大语言模型在内涵质控中存在结果随机性问题，

受限于知识库分块的语义覆盖度与推理逻辑关联度，难以确保每次均能全面识别病历中复杂类型的内涵错误^[17]。二是大语言模型受限于最大上下文长度（Context Window）约束^[18]，若输入模型的上下文 Token 总数量超出该约束阈值，超出部分将被系统截断或舍弃，导致质控关键信息流失、输入信息完整性受损，进而严重影响质控的覆盖范围与判断准确性。在后续的研究与实践中还联合使用微调和 API 等方法，增强大语言模型在电子病历质控领域的专业知识，规范其输出结果，进一步降低模型幻觉风险。三是本研究的数据集与质控评分规则仅来源于某一家三甲医院，病历的类型与格式具有一定的单一性，后续可扩大多中心、多类型病历的样本量，进一步验证语义分块策略的通用性。

5 小结

本研究以某三甲医院 1 500 份住院病历文件，搭建基于 DeepSeek-R1-32B 推理模型、Qwen3-Embedding-4B 嵌入模型、Qwen3-Rerank-4B 重排模型的 RAG 质控平台，并以国

家电子病历书写规范、临床诊疗指南等为核心搭建知识库，通过与医学专家质控结果的系统性对照分析，深入探究了 4 种主流 RAG 分块方法对病历质控效果的影响机制。实验结果表明，语义分块策略下大语言模型质控的结果精确率、召回率、F1 值均优于其他 3 种分块方法，其精确率达 87.6%、召回率达 90.6%、F1 值达 89.1%。尽管语义分块的平均单份病历质控耗时为 62 s，在 4 种方法中最长，但经 F1 值与质控耗时的加权计算进一步验证，语义分块以 0.802 的综合得分高于其他分块方法，其在质控精准性与效率之间实现了良好平衡，具备较强的临床适配性。可应用于病历书写实时提醒、提交事后筛查、归档批量初筛等环节，为提升电子病历质控的智能化水平与实际应用效能提供了切实可行的技术路径，助力推动电子病历质控工作向更精准、高效、全面的方向发展。

参考文献

[1] 郝安琪, 沈洁. 基于自然语言处理的智能病历质控系统的设计与应

- 用[J]. 中国医疗设备, 2024, 39(12): 71-77.
- [2] 关于开展全面提升医疗质量行动(2023—2025年)的通知[J]. 中华人民共和国国家卫生健康委员会公报, 2023(5): 8-14.
- [3] 梁志刚, 黄跃, 刘思凯, 等. 大模型技术在病历内涵质控中的应用研究[J]. 中国数字医学, 2025, 20(8): 20-28.
- [4] 温煜, 李雄, 曾菲菲, 等. 基于人工智能的病历质控系统的应用研究[J]. 四川大学学报(医学版), 2023, 54(6): 1263-1268.
- [5] ABACHA A B, YIM W W, FU Y J, et al. MEDEC: A benchmark for medical error detection and correction in clinical notes[J]. arXiv Preprints arXiv: 2412.19260, 2024.
- [6] 范霁月, 丁海龙, 荆芒, 等. 基于DeepSeek+RAG的病历内涵质控应用研究[J]. 江苏通信, 2025, 41(4): 81-86.
- [7] GOMEZ-CABELLO C A, PRABHAS, HAIDER S A, et al. Comparative evaluation of advanced chunking for retrieval-augmented generation in large language models for clinical decision support[J]. Bioengineering, 2025, 12(11): 1194.
- [8] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: a survey[J]. arXiv Preprint arXiv: 2312.10997, 2023.
- [9] ZHOU H, LIU F, GU B, et al. A survey of large language models in medicine: progress, application, and challenge[J]. arXiv Preprint arXiv: 2311.05112, 2023.
- [10] PARK S, KIM J, LEE H. Chunking strategies for electronic health records: Challenges and unmet needs[J]. Computers in Biology and Medicine, 2024, 168: 107654.
- [11] 李小华, 陈晓民, 刘家红. 新一代信息技术与健康医疗融合应用[M]. 北京: 人民卫生出版社, 2023.
- [12] WANG H W, ZHANG H M, YU D. On the dimensionality of sentence embeddings[C]//Findings of the Association for Computational Linguistics: EMNLP 2023, Singapore: Association for Computational Linguistics, 2023: 10344-10354.
- [13] 曹启航, 郑欣. 面向RAG的文本分块语义连贯性检测方法研究[J]. 自动化应用, 2025, 66(8): 124-128, 131.
- [14] 吴宏, 胡军, 陈尔真, 等. 基于大语言模型的医疗质量控制应用系统构建[J]. 医学信息学杂志, 2025, 46(2): 8-13.
- [15] 李慧, 刘宇, 张凯翔, 等. 基于统计和语义相似度的智能文档分块方法[J]. 江苏通信, 2025, 41(4): 92-95, 111.
- [16] ZHU Y, REN C, XIE S, et al. Realm: rag-driven enhancement of multimodal electronic health records analysis via large language models[J]. arXiv Preprint arXiv: 2402.07016, 2024.
- [17] 张晔, 熊莺, 张武军. 人工智能在病历质量管理中的应用进展与挑战[J]. 中国数字医学, 2025, 20(8): 1-8.
- [18] LIU N F, LIN K, HEWITT J, et al. Lost in the middle: how language models use long contexts[J]. arXiv Preprint arXiv: 2307.03172, 2023.
- 【收稿时间: 2025-11-18】
【修回时间: 2026-02-14】
(本文编辑: 辜琳)